236　べた書き文入力におけるキーワード抽出

荒木健治　鈴木康広　伊藤太亮　栃内香次　永田邦一
（北海道大学）

1．はじめに

現在、種々の日本語文書入力方式が開発されているが、日本語の持つ漢字かな混り文という性質のため、いまだに決定的な入力方式は開発されていない(1)。これらの入力方式のうち、人間側の負担が最も少ないのはべた書き文入力である(2)。我々は、特定分野の学術文献を対象に入力文の中から比較的少数個のキーワードを抽出して最初に漢字符号への変換を行い、それを手掛りに文全体の変換を行うべた書き文のかな漢字変換方式を検討中である。本稿では、実際の文書中における頻度分布を調査し、このようなキーワードになりうる語の推定を行った結果について報告する。

2．キーワード抽出実験

実際の文献について、上述のようなキーワードになりうる語がどの程度含まれているかの調査を行った。資料として、情報処理に関する論文（修士論文）1編を使用した。これを分析して、漢字・ひらがな・カタカナ・アルファベットについて頻度分布を求めた結果を図1～4に示す。

3．結果と考察

キーワードの条件は、頻度が高く、他の語と明らかに区別できる、の二つである。この二つの条件を満たすものを選び、図1～4に○印をつけて示す。

この結果からわかるように、ひらがな以外の字種では、いずれもキーワード占有率が高く、キーワードを最初にかな漢字変換する我々の方式は有効であると思われる。

表1は、キーワード占有率、すなわちのべ語数のうち上記のキーワードが占める割合を字種別に求めたものである。

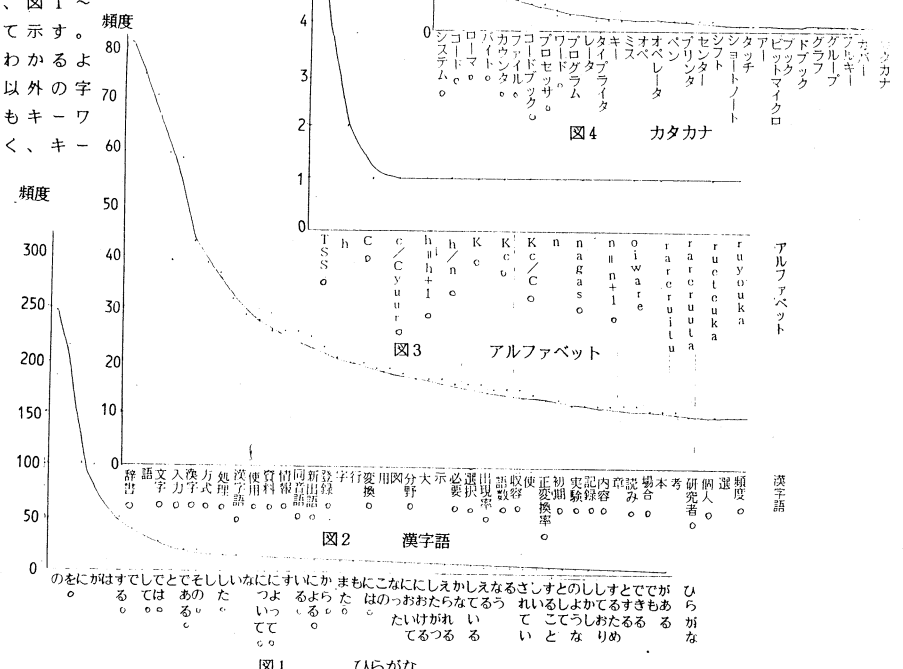


図1　ひらがな

図2　漢字語

図3　アルファベット

図4　カタカナ

4．おわりに

ここでは、特定個人、1文献のみの調査結果を述べたが、今後さらに、特定個人の多数の文献、さらに複数著者についてキーワードの調査を行い、べた書き文かな漢字変換のためのキーワード辞書を作成する予定である。

表1　キーワード占有率

語種	語数	キーワード語数	キーワード語種	占有率（%）
漢字語	2069	896	39	43.3
ひらがな	1732	458	14	26.4
カタカナ	151	104	9	67.9
アルファベット	28	19	15	68.9
計	3980	1477	77	37.1

＊　参考文献

（1）大岸　事務管理　Vol．19　No．8　pp．27－31
（2）牧野，木沢　情報処理学会論文誌　Vol．22　No．1　pp．59－67