231　前後の文字を利用する同音語の自動選択

伊藤太亮　荒木健治　鈴木康広　栃内香次　永田邦一
（北海道大学）

1．はじめに

かな漢字変換において、同音語選択をどのように行うかは、システムの性能を支配する重要な要素である。我々は、同音語とその前後に出現する文字の組を登録し、これら3つの組とのマッチングによって同音語を選択する方法を試みている。ここでは、このための実験システムの概要と、これまでに得られたいくつかの結果について報告する。

2．前後の文字による同音語選択

同音語　Wi，Wjが、各々

－－－Xi　Wi　Yi－－－

－－－Xj　Wj　Yj－－－

（Xi，Xj，Yi，Yjは空白を含む任意の1文字）

という形で使われているものとする。

もし、Wi≠Wjのとき

（Xi，Yi）≠（Xj，Yj）

が常に成立するならば、これを用いてWi，Wjを区別することができる。

3．同音語辞書の構造と自動選択方法

1語あたり320バイトをとり、図1のような構造とする。以下にその主な内容を記す。

Np：次の同音語番号のものの所在を示すポインタ

（Xi，Yi）：前後につく文字のローマ字表記

Ni：当該（Xi，Yi）組の出現頻度

Cp：（X，Y）組の探索用のポインタ

No：上記（X，Y）組以外の出現頻度の和

Nt：当該同音語の出現頻度合計

この辞書を用い、以下の方法で自動選択する。

① 同音語の前後の文字（X，Y）を抽出する。

② 当該同音語について同音語辞書を検索し、（X，Y）組の同一のものを見い出す。

③ 一つの語にのみ（Xi，Yi）＝（X，Y）となった場合には、　Nt≧Nの時、

そうでない場合には、　Ni／Nj≧M　でかつ、

Nt≧N　の時

Niの方の語を選択する。

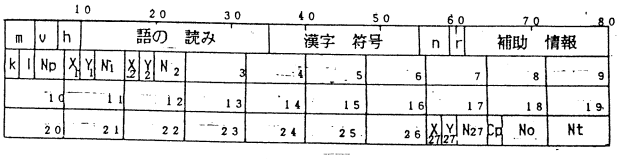


図1．　同音語辞書の構造

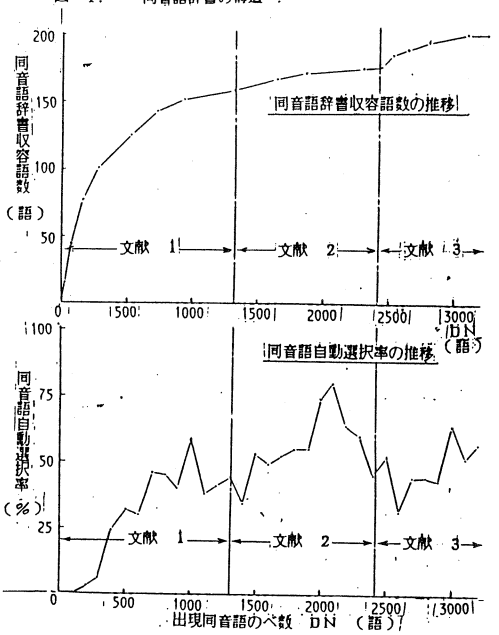


図2．　自動選択率と同音語収容語数の推移

4．実験結果と考察

入力文として、情報工学に関する3つの文献を用い、同音語自動選択実験を行った。

出現同音語数は、のべ約3200語で、自動選択率は平均50％、誤選択数は、のべ5回であった。また、自動選択率と同音語辞書の収容語数の推移を図2に示す。

今回の実験は、同音語辞書が空の状態から始めたことを考えると、使用が進んでも　50％　の自動選択率は十分に期待できると思われる。

自動選択された語を品詞別に比べてみると、動詞、形容詞など名詞以外の語が50％であったが、これは、送りがなによる区分がなされたためと考えることができる。名詞では、その文献に関係の深いものが多く選択されている。

5．おわりに

同音語自動選択方法と実験結果について述べたが、今後はさらに、誤変換することなしに自動選択率を向上させるよう、同音語辞書の構造の再検討や前後の文字の分類の細分化、その他の補助情報の活用方法などの検討を行っていくつもりである。