1727

キーワードによるべた書き文の分割

DIVISION OF NON-SEGMENTED KANA SENTENCES BY THE USE OF KEYWORDS

荒木健治　鈴木康広　伊藤太亮　栃内香次　永田邦一
Kenzi ARAKI　Yasuhiro SUZUKI　Taisuke ITOH　Koji TOCHINAI　Kuniichi NAGATA
北海道大学
HOKKAIDO UNIVERSITY

1．はじめに

我々は，特定分野の学術文献を対象とするべた書き文のかな漢字変換方式として，他の語と明らかに分離でき，かつ頻度の高い語を最初に抽出し，べた書き文を短い単位に分割してから処理する方法を検討している．本稿では，実際の文献からこのような語（以下，キーワードという）を抽出し，それによってべた書き文を分割する実験を行った結果について述べる．

2．キーワードによる変換単位への分割実験

資料として，情報処理に関する文献（修士論文2編，単行本2冊）を使用した．

2．1　キーワード抽出

資料中の語から，他の語とあいまいさなく分離できるという条件により，表1に示すように5186語種のキーワード候補が選出された．これは，総語数の52．5％にあたる．なお，総語数は漢字とひらがなの他にアルファベットとカタカナを加えたものである．これらのうち出現頻度の高いものをキーワードとした．本実験では，表2に示すように平均頻度の各々10倍，5倍，2倍で切って3種のキーワードをとり，比較を行った．

表1　キーワード語数

字種	語種	語数	キーワード語種	キーワード語数	占有率（％）	平均頻度
漢字	2152	21945	1631	15339	69．9	10．197
ひらがな	3762	22586	3555	12732	56．4	6．008
総合	6867	53813	5186	28271	52．5	8．810

表2　頻度によるキーワード語数の変化

	倍率	頻度 ひらがな	頻度 漢字	ひらがな キーワード語種	ひらがな キーワード語数	ひらがな 占有率（％）	漢字 キーワード語種	漢字 キーワード語数	漢字 占有率（％）	総合 キーワード語種	総合 キーワード語数	総合 占有率（％）
A	10	60．030	101．970	23	5029	22．3	21	4167	19．0	44	9196	17．1
B	5	30．015	50．985	52	6221	27．5	57	6775	30．9	109	12996	24．2
C	2	12．006	20．394	106	7204	31．9	171	10360	47．2	277	17564	32．6

2．2　キーワードによる分割実験

上記3種のキーワードを用い，べた書き文の分割実験を行った．使用した資料はキーワードを選出した文献と同一である．この結果を図1に示す．図1で［ ］はひらがなのキーワード，【 】は漢字のキーワードを示している．なお，キーワードが重なった時は，その部分は，キーワードとしない．

A．キーワード語種44語の時
おおくの【場合】あるとくていのぎょうむだけでりようされている．
B．キーワード語種109語の時
おおくの【場合】あるとくていのぎょうむだけで【利用】［されている］．
C．キーワード語種277語の時
おおくの【場合】ある【特定】の【業務】だけで【利用】［されている］．

図1　キーワードによる分割の例

3．結果と考察

キーワードをあまり多くすると，キーワード同士の重なりや，誤分割の可能性が増す．また，少なすぎると，キーワード間の文字数が多くなりすぎて分割の意味がなくなる．上記実験結果では，図1（表2）のBの場合キーワード間の平均文字数が2．5文字となり，この程度が妥当と思われる．

以上の実験から特定専門分野の学術文献において，上述の条件を満たすキーワードが存在し，それにより長いべた書き文を短い単位に分割してから処理する方法の可能性が示された．

4．おわりに

今後，ここで抽出したキーワードを，他の文献に適用する実験を行うとともに，キーワード辞書の構成法，変換処理方式の検討を進め，変換システムの試作を行う予定である．

※参考文献

（1）荒木，鈴木，伊藤，栃内，永田　「べた書き文入力におけるキーワード抽出」
昭和58年度電気四学会北海道支部大会講演集pp．270