1728

文字の接続情報を利用する同音語の自動選択

Automatic selection of homonyms using connective information of letters

鈴木康広　荒木健治　伊藤太亮　栃内香次　永田邦一
（北海道大学）
Yasuhiro Suzuki, Kenzi Araki, Taisuke Itoh, Koji Tochinai, Kuniichi Nagata
(Hokkaido University)

1．はじめに

我々は、同音語とその前後に出現する文字の組を辞書に登録し、これらの組とのマッチングによって同音語を自動的に選択する方法を試みている。(1)　ここでは、同音語の自動選択方法と、これまでに得られた結果について報告する。

2．自動選択方法

同音語W_1、W_1が各々

$--X_1W_1Y_1--$

$--X_1W_1Y_1--$　（X_1、X_1、Y_1、Y_1は空白を含む任意の1文字）

という形で使われているものとする。我々のシステムでは、同音語の前後の2文字の組（X，Y）を抽出し、当該同音語について同音語辞書を検索してこれと同一の前後2文字の組（X，Y）をもつものを見い出し、それがあらかじめ定められた頻度条件を満たした場合に、その同音語を自動的に選択するという方法を採用している。

3．実験結果と考察

入力文として情報工学に関する5編の文献（文献1～5）と機械工学に関する文献1編（文献6）を用いて、同音語自動選択実験を行った。その結果を表-1及び図-1に示す。また、上記の方法を変形させた同音語の後続の2文字の組を利用する同音語自動選択の実験も行ったので、その結果も同時に示す。

選択方式	文献	文字総数	漢字語数	同音語数	自動選択数	誤選択数	自動変換率	誤変換率
A	文献1	63325	7829	1273	395	1	31.0(%)	0.3(%)
	文献2	52186	8096	1150	647	0	36.3	0
	文献3	19632	4169	831	402	4	48.4	1.0
	文献4	11193	2362	510	312	9	61.2	2.9
	文献5	31234	4202	872	536	20	61.5	3.7
	文献6	24569	5011	843	508	26	60.3	5.1
	計	202139	31669	5479	2800	60	51.1	2.1
B	文献1	63325	7829	1273	436	2	34.2	0.5
	文献2	52186	8096	1150	783	3	68.1	0.4
	文献3	19632	4169	831	364	6	43.8	1.6
	計	135143	20094	3254	1583	11	48.6	0.7

表-1　同音語自動選択結果

図-1は、同音語の自動選択率の推移であるが、同音語の後続の2文字の組を利用した自動選択の方が、わずかではあるが、自動選択率が高いようである。また、同音語の前後の文字の組を利用した自動選択では、現在のところ約60％の自動選択率が得られている。

自動選択された語を品詞別に比べてみると、動詞、形容詞など名詞以外の語が約50％であったが、これは、送りがなによる区分がなされたためと考えることができる。名詞ではその文献に関係の深いものが多く選択されている。

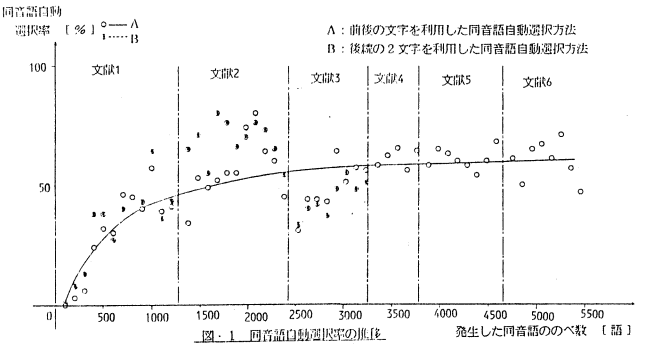


図-1　同音語自動選択率の推移

4．おわりに

以上、同音語自動選択方法とその実験結果について述べた。今後は、同音語の後続の2文字の組を利用した自動選択の実験を進めていくとともに、誤変換することなしに自動選択率を向上させるよう、同音語辞書の構造の再検討や前後の文字の分類の細分化、その他の補助情報の活用方法などの検討を行っていくつもりである。

参考文献

（1）　伊藤太亮　荒木健治　鈴木康広　栃内香次　永田邦一
昭和58年　電気四学会北海道支部連合大会　231