キーワード方式によるべた書き文のかな漢字変換
(1)変換辞書の構成

5J-4

鈴木康広　荒木健治　栃内香次　永田邦一
(北海道大学)

1. はじめに

我々は、特定分野の学術文書を対象とするべた書き文のかな漢字変換方式として、他の語から明らかに分離することができ、かつ、その出現頻度が高い語(これをキーワードと呼ぶ)を抽出し、べた書き文をキーワードによって短い単位に分割してから処理を行なう方式(キーワード方式)によるべた書き文かな漢字変換システムを検討中である。本稿では、このシステムにおける変換辞書の構成とその管理方式について述べる。

2. 変換辞書の構成

本システムは、数種の変換辞書を用いて、べた書き文を順次、漢字、かな及びカタカナに変換する。変換辞書には、キーワード辞書、カタカナ語辞書、単語辞書、一字漢字語辞書、接辞辞書の5種類がある。これらの変換辞書を用いて図1のように確実性の高いものから単語を当てはめていく。

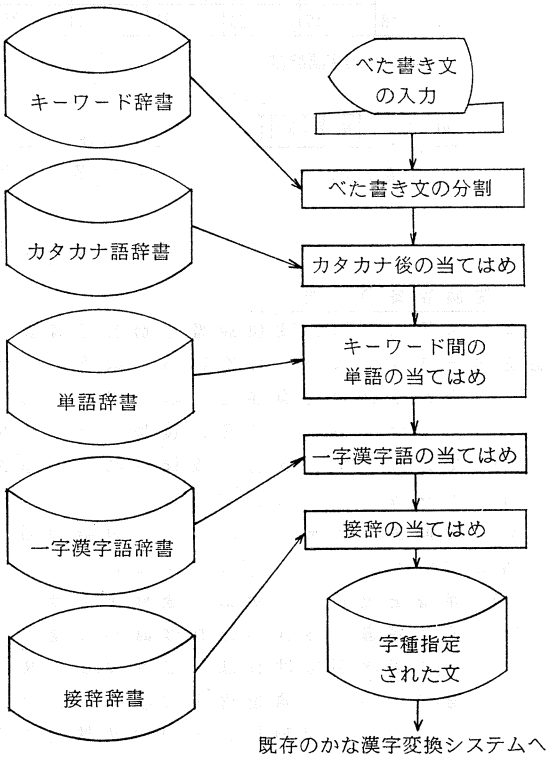


図1　単語の当てはめ

3. 変換辞書の構造

5種類の変換辞書は、それぞれ図2のような構造となっている。

1)キーワード辞書

キーワード辞書には、べた書き文字列から明らかに分離することができて、かつその出現頻度が高い語(キーワード)が約500語登録されている。なお、これらのキーワードは情報処理分野の文献等4編(総文字数146336字)から抽出したものである。(1)

2)カタカナ語辞書

カタカナ語辞書には「データベース」、「システム」、「ファイル」等の外来語を主として、カタカナ語が約200　語登録されている。

3)単語辞書

単語辞書には漢字語、ひらがな語、カタカナ語合わせて約　4000語が登録されている。

4)一字漢字語辞書

一字漢字語辞書には一字一音の漢字語(語，字)約200語が登録されている。

5)接辞辞書

接辞辞書には、接辞が約100語登録されている。

単語辞書と一字漢字語辞書の収録語は、情報処理、機械、化学の分野の論文等31編(総文字数330103字)から得られたものである。なお、語を収録する際、文中でその語の前後に連接している文字の組をともに抽出し、収録している。

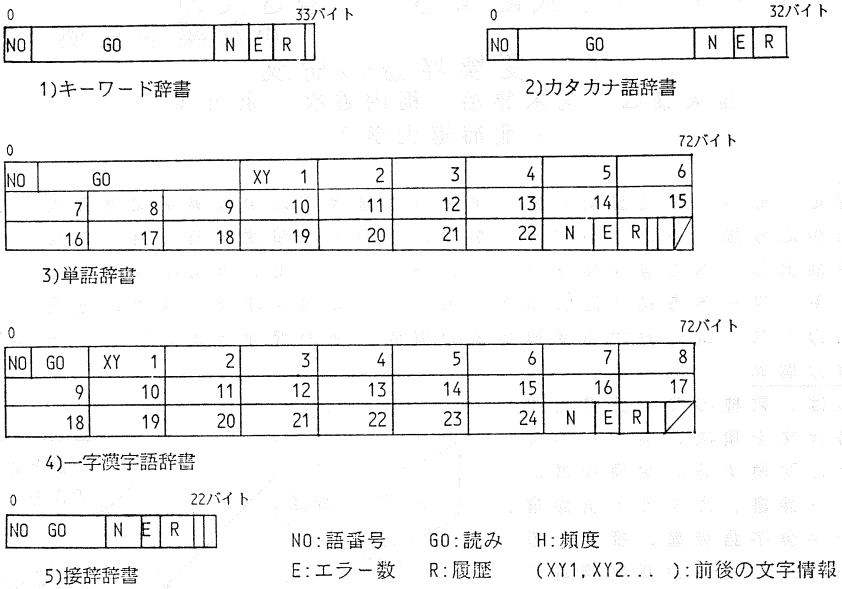


図2　変換辞書の構造

4．変換辞書の管理方式

本システムでは、変換辞書を動的に構成し、個々の使用者、分野に適応させて変換性能を向上させるようにしている。以下に、辞書管理方式の概要を述べる。

1）それぞれの変換辞書には、収録されている各語ごとに、図2のように頻度カウンタH、エラーカウンタE、履歴カウンタRを設けてある。

2）文の入力中、辞書に収録されているある語が参照されたとき、その語について、H＋1→H、0→Rとする。

3）変換後のチェックによって単語の当てはめが誤りであると確認された場合、その語について、E＋1→Eとする。

4）辞書を更新して新語を登録する際、その語について、1→H、0→Rとし、

イ）辞書に空きがあれば直ちに登録し、

ロ）空きがなければ、$C = \alpha E + R - H$（αは係数）を計算し、Cの値が最大の語の中から1語を選んで削除し、そのあとに登録する。

5）システムを起動し、一つの文献を入力した後、すべての収録語について、R＋1→Rとする。

5．おわりに

以上、キーワード方式によるべた書き文のかな漢字変換システムにおける変換辞書の構成やその管理方式について述べた。今後、実際にこのシステムを完成して稼動させ、変換辞書が個々の使用者、分野により良く適応し変換性能が向上するように、辞書の構造や管理方式について検討を加えていく予定である。

参考文献

（1）荒木健治　鈴木康広　伊藤太亮　栃内香次　永田邦一；
昭和58年電気四学会北海道支連合大会　230

（2）荒木健治　鈴木康広　伊藤太亮　栃内香次　永田邦一；
昭和59年電子通信学会総合全国大会　1727