5J-5

キーワード方式によるべた書き文のかな漢字変換 (2)変換アルゴリズム

荒木健治，鈴木康広，栃内香次，永田邦一
北海道大学

1．はじめに

我々は，数種の辞書を用いて，べた書き文を確実性の高い部分から順次変換する方式（これをキーワード方式とよぶ）べた書き文のかな漢字システムを開発している．本稿ではこのシステムにおける変換アルゴリズムについて述べる．

2．処理の流れ

図1は，キーワード方式によるべた書き文の処理過程を示す．なお，現在実験中のシステムでは，べた書き文を字種指定された形に直し，当研究室で稼動している既存のＫＫＨＩＩシステム[1]に渡す形をとっている．

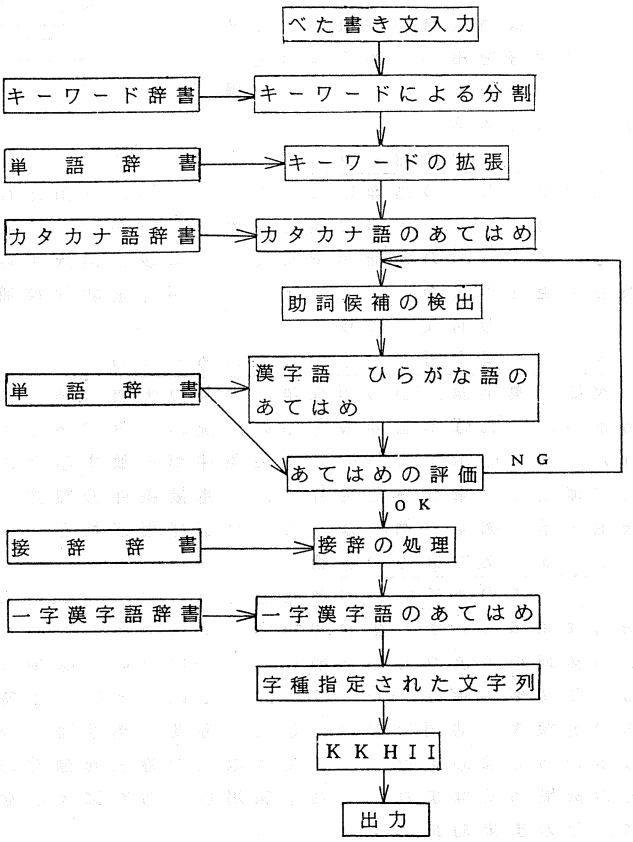


図1　処理の流れ

3．変換方式

べた書き入力文は，「．」，「，」，記号，空白，数字などによってある長さに区切られ，これを処理単位とする．

3．1　キーワードによる分割

最初にキーワードのあてはめを行う．キーワードとは，他の語と明らかに分離できる語で，あらかじめキーワード辞書に蓄えられており，べた書き文を分割する際もっとも確実にあてはめを行うことができる語である．[2],[3]図2にキーワードによる分割の例を示す．

3．2　キーワードの拡張

次に，キーワードを含んでいる語を単語辞書より探し図3に示すように，あてはめを拡張する．

（ａ）［れんぞく］［しょり］［を］おこ［なう］ように［なる］と，

（ｂ）［ぶろぐらむ］［しょり］がしゅであった［じだい］［には］，［しょり］［のうりょく］はおのず［から］

［　］：キーワード

図2　キーワードによる分割

図３において，（ａ）は，問題ないが，（ｂ）の場合は，Ａ，Ｃのうち文字長の長い方をとる．同じ長さの時は，前の方からあてはまるものを優先する．

３．３　カタカナ語のあてはめ

学術文献では，一般に，カタカナの外来語が頻出する．このようなカタカナ語は，つづりに特徴があるため，キーワードの次に確からしいと考えられる．そこで，次に，このような語を蓄積したカタカナ語辞書を用いてあてはめを行う．その方法は，キーワードの場合と同様である．

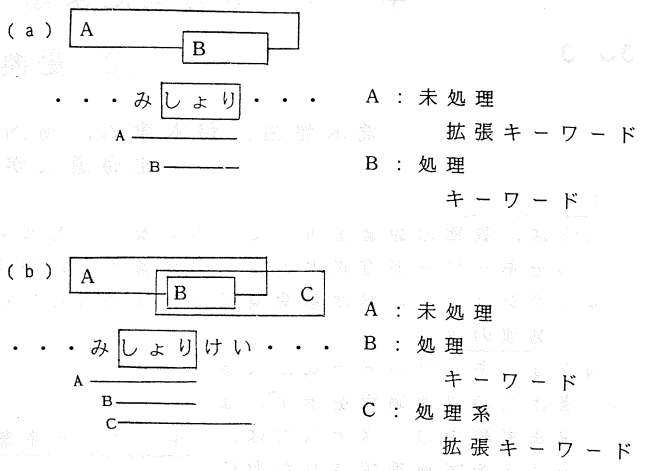


図３　　キーワードの拡張

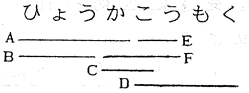
３．４　助詞候補の検出

次いで，以上の処理によっていくつかに分割されたべた書き文に，一般の漢字語，ひらがな語，カタカナ語のあてはめを行うが，その前に，文節端にくる助詞を検出しておくと，あてはめの候補が少なくなり以後の選択が容易になる．そこで，文節端の助詞である可能性が大きい「の，は，に，が」を助詞候補とする．ただし，文頭，「，」の後ろ，「．」の前などは除く．

３．５　漢字語，ひらがな語のあてはめ

次に，漢字語，ひらがな語，カタカナ語のあてはめであるが，これは単語辞書を用い，読みのみであてはめを行い，図４に示すように，連接条件が一致するところをまず確定し，重なった場合には，連接条件の頻度により決定する．図４の例では，Ａ，Ｄが採用される．

，ひょうかこうもく（が）



（　）：助詞候補

	連接条件	頻度
A 評　価	P　K	6
B　表	P　K	0
C 過　去	K　う	0
D 項　目	K　が	2
E　項	K　も	0
F 加　工	K　も	0

Ｋ：漢字　　Ｐ：句読点

図４　漢字語，ひらがな語のあてはめ

３．６　あてはめの評価

次に，このあてはめの評価を行う．語の間に挟まれた助詞は問題ないが，語の間が２文字以上あいていて，しかも助詞が含まれている場合には，いろいろな場合がある．２文字の時は，「のは」，「には」といった特殊なものを除き，助詞でないとして，再度，漢字語，ひらがな語のあてはめを行う．２文字以上の時も同様である．その結果あてはまればそれを採用し，あてはまらなければ，そのまま助詞とする．

３．７　接辞の処理

あてはまったもののうち漢字のみについて行う．接頭，接尾に分けて処理する．

３．８　一字漢字語のあてはめ

連接条件が一致するもののみをあてはめ，それ以外はあてはめを行わない．

４　おわりに

今後の課題として，現在開発しているシステムを完成し実験を行い，改良を進めるつもりである．なお，編集機能，辞書の更新アルゴリズムについては，今後報告したい．

※参考文献

(1)　栃内，伊藤，荒木，鈴木，永田　昭和５９年度北海道大学工学部研究会報告　第119号
(2)　荒木，鈴木，伊藤，栃内，永田　昭和５８年度電気四学会北海道支部大会講演集 230
(3)　荒木，鈴木，伊藤，栃内，永田　昭和５９年度電子通信学会総合全国大会 1727