べた書き文かな漢字変換の一方式

荒木健治，鈴木康広，中山恭與，栃内香次，永田邦一
北海道大学

1．はじめに

我々は，数種の辞書を用いて，べた書き文を確実性の高い部分から順次変換する方式（これをキーワード方式とよぶ）によるべた書き文のかな漢字システムを開発している．本稿ではこのシステムにおける変換アルゴリズムについて述べる．

2．変換方式

記号，数字などによって区切られた区間内のべた書き（かな）文字列を処理単位とする．

2．1　キーワードによる分割

最初にキーワードのあてはめを行う．キーワードとは，他の語と明らかに分離でき，かつ出現頻度の大きな語で，あらかじめキーワード辞書に蓄えられており，べた書き文を分割する際もっとも確実にあてはめを行うことができる語である[1][2]．図1にキーワードによる分割の例を示す．なお，キーワードとその前後の文字列とがキーワードを含む別な単語になっている場合は，これを拡張されたキーワードとみなし，ここであてはめる．

(a)　［きぞん］のひょうか［しゅほう］［を］わけると，［つぎ］の2つにわける［ことが］［できる］．

(b)　ぶんせき［する］ことによって［せいのう］ひょうか［を］おこなおうと［する］もの［である］．

［　］：キーワード

図1　　キーワードによる分割

2．2　カタカナ語のあてはめ

学術文献では，一般に，カタカナの外来語が頻出する．このようなカタカナ語は，つづりに特徴があるため，キーワードの次に確からしいと考えられる．そこで，次にカタカナ語をあてはめる．

2．3　助詞候補の検出

次いで，以上の処理によっていくつかに分割されたべた書き文に，一般の漢字語，ひらがな語，カタカナ語のあてはめを行うが，その前に，文節端にくる助詞を検出しておくと，あてはめの候補が少なくなり以後の選択が容易になる．そこで，文節端の助詞である可能性が大きい「の，は，に，が」を助詞候補とする．ただし，文頭，「，」の後ろ，「．」の前などは除く．

2．4　単語のあてはめ

次に，単語辞書を用いて漢字語，ひらがな語，カタカナ語のあてはめを行う．この場合は語の読みであてはめを行ってから，図2に示すように，連接条件が一致するところをまず確定し，重なった場合には，連接条件の頻度により決定する．図2の例では，A，Dが採用される．なお，接辞を含め漢字1字の語のあてはめは，ここでは行わない．

2．5　助詞の確定

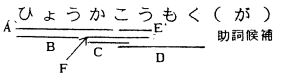
上述のように単語のあてはめを行った結果，語の間に上記助詞候補が1字だけ存在している場合はそのまま助詞とする．助詞候補を含んで，かつ2文字以上あいている場合は，それらが「のは」，「には」など特定の文字列である場合を除き，助詞でないとして，再度，単語のあてはめを行う．その結果あてはまればそれを採用し，あてはまらなければ，そのまま助詞とする．

2．6　接辞および一字漢字語のあてはめ

残った文字列について接辞辞書および一字漢字語辞書を検索し，該当するものをあてはめる．

3　おわりに

今後の課題として，現在開発しているシステムを完成し実験を行い，改良を進めるつもりである．



	連接条件	頻度
A 評価	P K	6
B 表	P K	0
C 過去	K う	0
D 項目	K が	2
E 項	K も	0
F 加工	K も	0

K：漢字　　P：句読点

図2　単語のあてはめ

参考文献

(1)　荒木，鈴木，伊藤，栃内，永田　昭和58年度電気四学会北海道支部大会講演集 230

(2)　荒木，鈴木，伊藤，栃内，永田　昭和59年度電子通信学会総合全国大会 1727