1456　キーワード方式べた書き文かな漢字変換システム 2．辞書の構成と管理方式

"Key-word" Method Kana-Kanji Translation System:
2. Construction and Management of Dictionaries.

鈴木康広　荒木健治　中山恭與　栃内香次　永田邦一
Yasuhiro SUZUKI, Kenji ARAKI, Yasutomo NAKAYAMA, Koji TOCHINAI, Kuniichi NAGATA
（北海道大学）
(Hokkaido University)

1．はじめに

かな漢字変換システムにおいて、変換辞書の構成と管理方式がその性能に大きく影響すると考えられる。本報告では、我々が開発中のキーワード方式べた書き文かな漢字変換システムの変換辞書の構成と管理方式について述べる。

2．変換辞書の構成

本システムではキーワード辞書、カタカナ語辞書、単語辞書、接辞辞書、一字漢字語辞書の5種の変換辞書を用い、入力べた書き文にこれら各辞書を順次適用して漢字、かな及びカタカナに変換する。(1)

3．変換辞書の管理方式

本システムでは変換辞書を動的に構成し、個々の使用者、分野に適応させて変換性能を向上させるようにしている。以下に、変換辞書の管理方式の概要を述べる。

1）それぞれの変換辞書には、収録されている各語ごとに頻度カウンタH、エラーカウンタE、履歴カウンタRを設けてある。

2）文の入力中、辞書に収録されているある語が参照されたとき、その語についてH＋1→H、0→Rとする。

3）変換後のチェックによって単語の当てはめが誤りであると確認された場合、その語についてE＋1→Eとする。

4）辞書を更新して新語を登録する際、その語について1→H、0→Rとし、

イ）辞書に空きがあれば直ちに登録し、

ロ）空きがなければ、$C = \alpha E + R - H$（αは係数）を計算し、Cの値が最大の語の中から1語を選んで削除し、その後に登録する。

5）一つの文献を入力した後、すべての収録語について、R＋1→Rとする。

4．文献入力実験の結果

実際に、情報処理分野の論文13編（総文字数111083字）をシステムに入力し、それぞれの変換辞書がどのように変化していくか実験を行った。結果の一部を図1、2に示す。図1は、単語辞書（容量6000語）における新出語出現率の推移であり、論文8編（総文字数約68000字）程度を入力すると、新出語の出現率が約5％とほぼ一定になった。図2は、キーワード辞書（容量500語）の収録語の変動を示したもので、これも同様に論文8編程度を入力すると、キーワードの入れ換わり率が10％とほぼ一定となった。

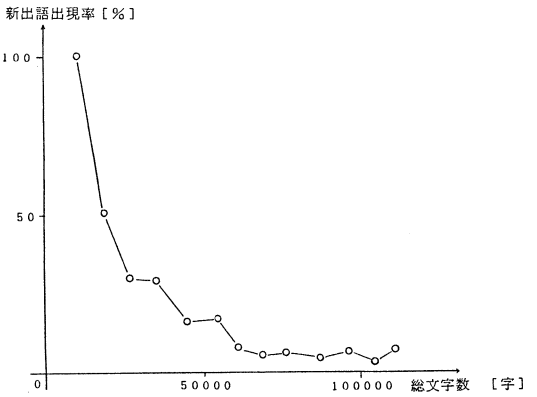


図1　単語辞書における新出語出現率の推移

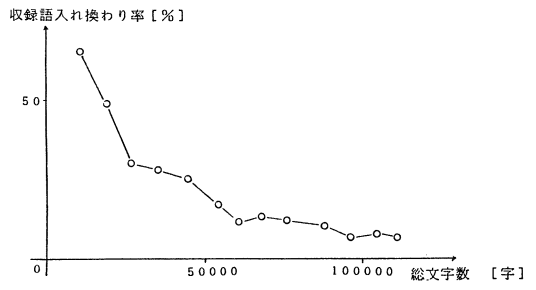


図2　キーワード辞書における収録語の入れ換わりの推移

5．おわりに

以上、キーワード方式によるべた書き文のかな漢字変換システムにおける変換辞書の構成やその管理方式、更に、文献入力実験の結果について述べた。今後、変換辞書が個々の使用者により良く適応し変換性能が向上するように、変換辞書の構造や管理方式について検討を加えていく予定である。

参考文献

(1)　鈴木康広　荒木健治　栃内香次　永田邦一　情報処理学会第29回（昭和59年後期）全国大会　5J－4