# 279　語および文書整形ツールの開発

山田洋志、荒木健治、内田幸司、栃内香次、永田邦一
（北海道大学）

## 1．まえがき

日本語の表記には、送りがなのつけ方、漢字の使い方などに個人差があり、計算機による日本語処理をする上での問題となっている。当研究室で研究中のべた書き文かな漢字変換システムでも変換精度測定をする際の障害となっている[1,2]。そこで、ローマ字表記字種指定文を対象とし、送りがなと漢字語の分割方法の統一を中心とした文書整形システムを開発した。以下にその概要と若干の実験結果について述べる。

## 2．方針

文書を整形する際の方針を下記のように定めた。

1）送りがなのつけ方は当用漢字音訓表に従う。

例　行なう → 行う

2）2文字の漢字からなる漢字語を1文字ずつに分けている場合は、1語にまとめる。

例　最/大 → 最大

3）3文字以上からなる漢字語が接辞を含んでいる場合は接辞を分離する。2文字の場合は分離しない。

例　一般的 → 一般/的

## 3．機能

1）テーブルを用いた置き換え

送りがなの統一、間違えやすい綴りの修正に用いる。あらかじめ元の文字列と、置き換える文字列とをテーブルに用意しておく。また、隣接する語の字種を指定して特定の字種の語の前後にある場合のみ置き換えることもできる。現在テーブルには送りがな統一のための文字列を中心に28個のパターンを用意している。

例　現わす → 現す
　　基ずく → 基づく

2）1文字漢字語の結合

漢字1文字からなる語が2つ続けて出現した場合、その2語を1つにつないでできる語が単語辞書にあるかどうかを調べ、ある場合は1語にまとめる。単語辞書は当研究室のかな漢字変換システムで使用しているものを転用した。

例　正/誤、大/小、総/数

3）接辞の分離

接辞はあらかじめ辞書に用意しておく。文中に接辞を含む語がみつかった場合は、接辞を取り去った残りの語が単語辞書に存在するかを調べ、存在しない場合は分離しない。また残りの部分が漢字1文字の場合も分離しない。2通り以上の分割方法が考えられる場合は使用者が選択する。

接辞の例　本、各、最　（接頭語）
　　的、性、化　（接尾語）

## 4．実験

当研究室のべた書き文かな漢字システムで出力された字種指定文に対して整形システムを使用してみた。文献はすべて情報処理に関する論文である。各論文ごとに前節の機能1～3が何個所適用されたかを下表に示す。

| | 機能1 | 機能2 | 機能3 |
|---|---|---|---|
| 文献1 | 5 | 37 | 22 |
| 文献2 | 6 | 33 | 19 |
| 文献3 | 1 | 3 | 22 |
| 文献4 | 2 | 17 | 16 |
| 計 | 14 | 90 | 79 |

機能1の14例のうちの11例は“表わす”を“表す”に置き換えるものであった。また誤りが1例あったが、これはかな漢字変換システムの誤りが原因であった。

機能2，3については不適当なものはなかった。

## 5．あとがき

送りがなと漢字分割の統一を中心とした整形システムを作り良好な結果を得た。今後の課題としては、より複雑な分割誤りの訂正、助詞の誤りの判別、辞書の更新機能の追加などが考えられる。

参考文献

1）鈴木他：キーワード方式によるべた書き文のかな漢字変換
（1）変換辞書の構成
情報処理学会第29回全国大会（昭和59年後期）5J－4

2）荒木他：キーワード方式によるべた書き文のかな漢字変換
（2）変換アルゴリズム
情報処理学会第29回全国大会（昭和59年後期）5J－5