# 280　キーワード方式べた書き文かな漢字変換におけるキーワードの階層化

荒木健治，内田幸司，山田洋志，栃内香次，永田邦一
北海道大学

## 1．はじめに

我々は，数種の辞書を用いて，べた書き文を確実性の高い部分から順次変換する方式（キーワード方式）によるべた書き文のかな漢字変換システムを開発している．本稿では，このシステムのもっとも重要な要素であるキーワードの階層化について検討した結果について述べる．

## 2．キーワードの階層化

本システムは，入力されたべた書き文を，数種の段階を経て字種指定文に変換する．この中で，キーワードは最初の段階で使用され，無条件に分割を行い，しかも固定してしまうので正確にあてはめる必要がある[1][2]．現在のシステムは，キーワードのあてはめに7～8%程度のエラーがあり，これを減少させる必要がある．そこでキーワードを2段階に分けてあてはめを行うことを検討した．

### 2．1　キーワード階層化の方法

キーワードを一種と二種に分離した．新しく抽出されたキーワードは，まず二種へ編入される．この二種のうち次の二つの条件を満たすものを一種とする．

条件1：登録されてから10回使用されない．（U=10）

条件2：F=頻度-10*エラー≧100

### 2．2　キーワードのあてはめ方法

最初に一種キーワードを用いてあてはめを行う．キーワードが互いに重複してあてはまる場合を除いてすべてあてはめる．次に二種キーワードを用いてあてはめを行う．二種については，一種のあてはめ条件に，さらに同時期に抽出されたキーワードが一処理単位中に二つ以上あてはまる時のみあてはめを行う．

### 2．3　性能評価実験

情報処理に関する論文14編（総文字数120741字）を用いて性能評価実験を行った．ここで，キーワード辞書，カタカナ語辞書はすべて空とし，他の辞書は頻度，エラー，履歴の情報を0にして出発した．論文一編を変換するごとに，辞書を更新し，次の論文を変換する操作を14回繰り返した．

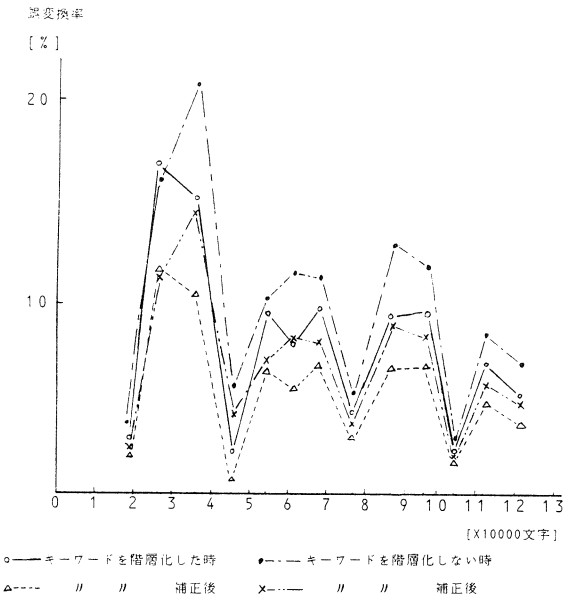



図1　キーワードのエラー率

表1　階層化の効果

| キーワードの形式 | 階層化せず | 階層化せず補正後 | 階層化する | 階層化する補正後 |
|---|---|---|---|---|
| 誤変換率[%] | 8．8% | 6．1% | 6．8% | 4．7% |

## 3．結果と考察

結果を図1に示す．ここで，誤変換は，同一文献を人間が字種分割して作ったファイルと比較して検出しているために，最終結果には影響しない，漢字語分割の相違までエラーとしてしまっている．図1の補正後とあるのはこれらを除いたものである．表1は，5編以後についてのキーワードの誤変換率の平均値である．図1と表1からキーワードを階層化し，そのあてはめに条件を加えることにより，キーワードのあてはめが正確に行えることがわかる．

## 4．おわりに

今後は，さらに，F，U，キーワード辞書の語数などのパラメータを検討しキーワードのあてはめを正確にしたい．その上で，システム全体としての精度が向上するように，あてはめ段階の整理を行いたい．

## ※参考文献

(1)荒木，金木，栃内，永田　情報処理学会第29回（昭和59年後期）全国大会講演論文集　5L-5
(2)荒木，金木，中山，栃内，永田　昭和59年度電気関係学会北海道支部大会講演論文集　197