597 キーワード方式べた書き文かな漢字変換システムの変換性能の向上

Performance Improvement
in the "Key-word" Method Kana-Kanji Translation System

荒木健治，内田幸司，山田洋志，栃内香次，永田邦一
Kenzi ARAKI Koji UCHIDA Hirosi YAMADA Koji TOCHINAI Kuniichi NAGATA
北海道大学
HOKKAIDO UNIVERSITY

1．はじめに

我々は，数種の辞書を用いて，べた書き文を確実性の高い部分から順次変換する方式（キーワード方式）によるべた書き文のかな漢字変換システムを開発している．本稿では，このシステムの変換性能の向上について検討した結果について述べる．

2．キーワードの階層化

本システムは，入力されたべた書き文を，数種の段階を経て字種指定文に変換する．このうち，最初の段階がキーワードによるあてはめである．この段階では無条件に分割を行って固定してしまうので正確にあてはめる必要があるが[1],[2]，現在のシステムは，この際7～8%程度のエラーを生じる．これを減少させるため，キーワードを2段階に分けてあてはめを行うことを検討した．

2．1 キーワード階層化の方法

キーワードを一種と二種に分離した．新しく抽出されたキーワードは，まず二種へ編入される．この二種のうち一種へ編入されるものの条件として次の二つの場合を考え実験を行った．

i）実験1
　a）登録されてから10回使用された．
　b）F＝頻度－10＊エラー≧100
ii）実験2
　a）登録されてから30回使用された．
　b）F＝エラー／頻度≦0.05

なお，二種のキーワード語数は，実験1では1000語，実験2では500語とした．

表1　階層化の効果

キーワードの形式	あてはめ数	エラー数	エラー率[%]	エラー率[%] 補正後
階層化しない	16666	1464	8.8	6.1
実験1	13422	918	6.8	4.7
実験2	11830	549	4.6	3.2

2．2 キーワードのあてはめ方法

最初に一種キーワードを用いてあてはめを行う．キーワードが互いに重複してあてはまる場合を除いてすべてあてはめる．次に二種キーワードを用いてあてはめを行う．二種については，一種のあてはめ条件に，さらに同時期に抽出されたキーワードが一処理単位中に二つ以上あてはまる時のみあてはめを行う．

2．3 性能評価実験

情報処理に関する論文14編（総文字数120741字）を用いて性能評価実験を行った．ここで，キーワード辞書，カタカナ語辞書はすべて空とし，他の辞書は頻度，エラー，履歴の情報を0にして出発した．論文一編を変換するごとに，辞書を更新し，次の論文を変換する操作を14回繰り返した．一種に入る条件としては，上記二つの場合を考えそれぞれ実験1，実験2を行った．

2．4．結果と考察

結果を表1に示す．ここで，誤変換は，同一文献を人間が字種分割して作ったファイルと比較して検出しているために，最終結果に影響しない漢字語分割の相違までエラーとしてしまっている．表1の補正後とあるのはこれらを除いたものである．表1は，5編以降についてのキーワードの誤変換率の平均値である．この結果から，キーワードを階層化し，そのあてはめに条件を加えることにより，キーワードのあてはめが正確に行えることがわかる．無条件にあてはめ，しかも固定してしまうというキーワードの性質から考え，正確にあてはめるということが第一であるので階層化することは性能向上に効果があると考えられる．また，同じ階層化でも，実験1より実験2の条件の方がより効果的であることがわかる．

3．辞書更新法の改良

現在のシステムでは辞書を更新するのに，同じデータに対して変換を繰り返し行うという無駄がある．そこで，誤変換数のカウントを変換結果の修正と同時に行うという方法を考え，システムを開発中である．

4．語および文書の整形

日本語表記には，多くの揺れがあり，このことが本システムでべた書き文を変換する際の問題になっている．そこで，一度変換されたべた書き文を，漢字語の分割，送りがなのつけ方，接辞の分離等について統一する必要がある．これについても現在システムを開発中である．

5．おわりに

今後は，パラメータを検討してキーワードのあてはめを正確にし，さらに，辞書の更新法，語および文書の整形についても実際にシステムを開発し実験を進めて，本システムの変換性能の向上を計りたい．

※参考文献

(1)荒木，鈴木，栃内，永田　情報処理学会第29回（昭和59年後期）全国大会講演論文集 5J-5
(2)荒木，鈴木，中山，栃内，永田　昭和59年度電気関係学会北海道支部大会講演論文集 197