4T-1

キーワード方式べた書き文かな漢字変換システムの性能評価

荒木健治、内田幸司、山田洋志、栃内香次、永田邦一
北海道大学

1．はじめに

我々は、数種の辞書を用いて、べた書き文を確実性の高い部分から順次変換する方式(キーワード方式)によるべた書き文のかな漢字変換システムを開発している。本稿では、このシステムの変換性能について、いくつかの検討を行った結果について報告する。

2．処理の流れ[1]

本システムは、入力されたべた書き文を数段階を経て字種指定文に変換する。最初の段階では、他の語と明らかに分離できる語であるキーワードを用いて、べた書き文を無条件に分割する。次にカタカナ語をあてはめる。ついで文節端の助詞候補を検出し、さらに一般の単語のあてはめを語の前後に連接する文字の条件(連接条件)を用いて行う。この時点で、文節端の助詞候補を、前後の未変換部分により評価し、単語のあてはめをやりなおし、助詞の確定を行う。

3．変換性能の向上

本方式の実験システムは、すでに稼働し一応の成果を得ている[2]。しかし、いくつかの改良点が残されている。以下改良を行った結果について述べる。

3．1キーワードの階層化[3]

本システムの最初の段階であるキーワードによるあてはめは、無条件に分割を行って固定してしまうので正確にあてはめる必要がある。そこで、キーワードを階層化し、一種と二種に分離した。ここで、一種キーワードは、二種キーワードとして登録されてから30回以上使用され誤変換率が5%以下のものである。キーワードのあてはめにおいては、初めに一種キーワードを無条件にあてはめる。また二種キーワードは抽出時期ごとにグループ分けしておき、同じグループに属するキーワードが二語以上あてはまる場合のみそのグループのキーワードをあてはめる。

以上のような方法をとることにより、従来7～8%程度あったエラーが、3～4%程度に改善された。

3．2ひらがな語の処理の改良

3．2．1ひらがな語の辞書への登録

辞書にどのようなひらがな語を登録するかということは本システムにおいては重要な意味を持つ。従来、本システムでは、ひらがな列を辞書を用いて分割し、残った未変換部分を新しいひらがな語として辞書に登録するようにしていた。このために、奇妙な形のひらがな語が登録され、辞書の登録語数も増加してしまう傾向があった。そこで、この部分は、初めに十分吟味したひらがな語を登録し、システムにより自動的に登録することはしないこととした。

3．2．2ひらがな列の処理方式

本システムにおいては、キーワードや連接条件を抽出する際に語を認識する必要がある。字種指定されたローマ字列より取り出すので、漢字やカタカナについては問題ないが、ひらがな列の中から、どのようにしてひらがな語を取り出すかという問題があった。従来は読みが存在すれば取り出していたので、図1の場合のように一つのひらがな列から重複してひらがな語を取り出すことが多く、このことがひらがな語に優位を持たせ変換性能に悪影響を及ぼしていたと考えられる。

(i)　一方が他方に含まれる場合

例　あるいは

「ある」　「あるいは」

(ii)　中途で重なる場合

例　ほとんどの

「ほとんど」　「どの」

図1　ひらがな語の重複

No	Go	FG

No：語番号(4バイト)
Go：読み(20バイト)
FG：重複フラグ(1バイト)

図2　ひらがな語重複辞書の構造

そこで、ひらがな列をひらがな語で一意に分割することが必要となってくる。ひらがな語が一意に決定できない場合は、図１に示す２通りに分けられる。ここで、(i)の場合は長い方に決定すればよいが、問題となるのは(ii)の場合である。そこで、まず情報処理に関する文献(総文字数236517字)より、十分吟味してひらがな語1190語を取り出し、図１(ii)の場合のように重なるすべての場合についてその対処法をあらかじめ決定しておき、ひらがな列の分割の際に中途で重なった時どうすべきかをこの情報を基に決定することにした。その情報を蓄えた辞書を図２に示す。ここで、重複フラグが１の場合は前方に決定し、０の場合は後方に決定する。図１(ii)の例でいえば、「ほとんど」という語の重複フラグが１であるので「ほとんど」が採用され、「どの」は採用されない。

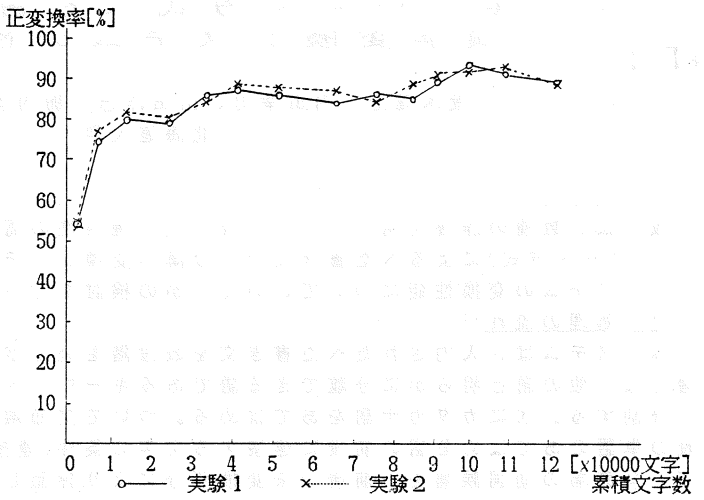


図３　ひらがな語を自動登録しないことのシステムに与える影響

３．２．３　実　　験

上記のようにしてひらがな語を自動的に登録しないことが、システムにどのような影響を与えるかについて比較対照実験を行った。資料は、情報処理に関する文献(総文字数115776字)を用いた。辞書は一種、二種キーワード辞書、カタカナ語辞書は、見出し語を含めてすべて空、その他の辞書は見出し語のみ残し他はすべて０から出発している。資料をその内容ごとに5000～8000字の14章に分割し、各章ごとにべた書き文で入力し、その変換結果を校正した後辞書を更新し、次の章へ進むという操作を繰り返した。

３．２．４　結果と考察

図３に実験結果を示す。ここで、実験１は、ひらがな語をシステムにより自動的に登録した場合であり、実験２は、ひらがな語の新語登録をしなかった場合である。この図を見とわかるように、二つはほぼ同じであるが、実験２の方が若干高い値になっているのがわかる。以上の結果と、辞書の容量の削減、ひらがな語の正確な認識の観点からひらがな語を限定し、重複情報を用いてひらがな列を分割していくことの有効性が確認された。

３．３キーワード関連語による単語のあてはめ

従来、キーワードにより決定できない部分は、連接条件を用いて単語のあてはめ段階で最も多くあてはめていた。しかし、この部分は本来一意に決定しにくい部分でありエラーが15%程度あった。そこで、キーワードと何らかの関係のある語をキーワード関連語と定義しこの情報を用いて単語をあてはめることを検討している。

４．おわりに

キーワードの階層化、ひらがな語の処理とシステムの性能向上を進めてきた。今後は、キーワードの次にあてはめ数の多い単語のあてはめを、キーワード関連語情報を用いてより正確にすることを目指したい。

なお、本研究は文部省科学研究費(一般Ｂ、60580015)の補助を受けて行われた。

※参考文献

(1)荒木、鈴木、栃内、永田　　情報処理学会第29回(昭和59年後期)全国大会 5J-5
(2)荒木、鈴木、中山、栃内、永田 昭和60年度電子通信学会総合全国大会 1455
(3)荒木、内田、山田、栃内、永田 昭和60年度電子通信学会情報・ｼｽﾃﾑ部門全国大会 597