電子情報通信学会創立70周年記念総合全国大会(昭和62年)

1448

誤りの多い文字列からの原文の復元

RECOVERY OF SENTENCES FROM ERRONEOUS CHARACTER STRINGS

荒木健治　　栃内香次　　永田邦一
Kenzi ARAKI　　Koji TOCHINAI　　Kuniichi NAGATA

北海道大学
Hokkaido UNIVERSITY

1．はじめに

日本語文を計算機に入力する手段として、現在はキーボードからローマ字あるいはカナで入力し、その後かな漢字変換によって漢字かな混じり文に変換する方式が主流であるが、キーボード操作練習の必要なしに入力できる方式として、音声入力の実用化が望まれている。しかし、音声入力においては個人差、時期変動などにより、キーボード入力に比べて相当多量の誤りを含むことが避けられない。本報告では、比較的大量の誤りを含んだ文字列から原文を自動的に復元する方法について考察する。これには、誤りの傾向を学習して復元する方法と、文脈の意味を理解し復元する方法の二つが考えられる。実用的には、この二方式を平行して処理を進める必要があると考えられるが、本稿では、まず前者について検討する。すなわち、市販の単音節認識装置を用い、入力された文章中の誤りの傾向を調査し、方式の有効性について考察した。

2．復元アルゴリズム

我々は、べた書き文を確実性の高い部分から順次変換する方式（キーワード方式）によるべた書き文のかな漢字変換システムを開発している[1)]。誤りを含む文字列を復元するために、このシステムに以下の機能を追加した。

(1) 予め誤りの傾向を単音節ごとに調査し、誤り情報辞書に誤りのパターンを蓄えておく。
(2) 認識結果より予測される文字を誤り情報辞書よりすべて取り出す。
(3) (2) のようにして予測された結果をもとに、考えられるすべての単語候補をあげる。
(4) 単語候補の中からキーワード方式べた書き文かな漢字変換システムで一意に単語を決定する。

これを、図１を例にして説明する。今、①のような文字列が単音節で音声入力されたとき、②のような認識結果が得られたとする。この認識結果より誤り情報辞書を参照して、可能性のある文字を予測し③のような単語候補が得られる。これをキーワード方式べた書き文かな漢字変換システムで処理して単語を一意に決定し、正しい文字列、すなわち原文が復元される。

①入力文字列　きんねん、はんどうたいぎじゆつのしんぽにはいちじるしいものがある。

②認識文字列　きんれん、はんぼもたいぎじゆつのしんとにはいじじるちいおのだある。

注）下線部は誤認識を示す。

③誤りを考慮した単語候補

認識結果	きんれん、はんぼもたいぎじゆつのしんとにはいじじるちいおのだある。
予測される文字	きんれん　はんぼもたいぎじゆつのしんとにはいじじるちいおのだある 　うねう　かうこうか　いちえすうちうぼいか　ちちうし　ううあおう 　ゆでゆ　　ゆとの　　き　や　と　ゆだみ　　　　らじ　ことたがら 　る　る　　るれ　　　　よ　む　るど　　　　　れ　　もむが　れ 　く　く　　くど　　　　　　ろ　くぼ　　　　　で　　　ろ　　で
単語候補	近年　　　半導体　回　技術　数値　信徒　には　著しい　地位　斧　　ある 　売れ　　買う　効果　　位置　　土地　進歩　　　父　　　　事　上がる 着る　　　巻頭　　　　　意地　　後　　題　　位置　　弟子　元　歌 　採れる　　黒　　　　　基地　　牛　　管

図１　　誤りを考慮した単語分割の例

表１　誤りパターン別頻度分布

頻度	種類	延数	累積占有率％
41〜	2	86	8.2
31〜40	2	64	14.3
21〜30	4	94	23.3
11〜20	9	139	36.6
６〜10	37	278	63.1
２〜５	100	281	90.0
1	105	105	100.0
計	259	1047	

3．実　験

本手法は、誤りの傾向がある程度一定であることを前提としている。そこで、市販の単音節音声認識装置[2)]を用い、認識誤りの傾向を調査した。

3．1　実験方法

まず、単音節を発声し、学習させて登録する。なお、実験に用いた音声認識装置では、拗音、促音は例えば「キャ」なら「キ」と「ヤ」のように分けて、「ッ」は「ツ」のように発声する必要があり、学習し登録する単音節は68音である。登録終了後、情報処理に関する論文の一部（2939音節）を単音節に分けて発声、入力し、認識誤りの傾向を調査した。

3．2　実験結果

誤りのパターン別の頻度分布を表１に示す。表１をみると判るように頻度２以上が90％を占め、頻度１のものは10％程度である。つまり、同じ誤りが何回も出現することがわかる。

4．考　察

同一の誤りが出現する場合、２回目以降は本手法により復元の可能性があると考えられる。上記の実験結果から、このような誤りは全誤りの９割に及ぶことが確かめられた。また、この傾向は、実験データを増加することにより、さらに強まるものと考えられる。したがって、この結果は本手法が有効である可能性を十分示していると思われる。

5．今後の課題

今後は、未認識の文字の処理方法や単語を決定する際に認識結果より予測して得られた単語候補にどのような重み付けをするかを検討し、実際にシステムを作成し原文を復元する実験を行う予定である。

謝　辞

音声認識ボードを貸与していただいた(株)ビー・ユー・ジーに感謝します。

※参考文献

(1) 荒木、鈴木、中山、栃内、永田　昭和60年度電子通信学会総合全国大会 1455
(2) 伊福部　達　音声タイプライタの設計（ＣＱ出版社）