D-88

表層からの単語共起関係の推定

The Presumption of Word Co-occurrence Relationship from Character Level

潤渇 謙一† 荒木 健治‡ 宮永 喜一† 栃内 香次†
K.Magata K.Araki Y.Miyanaga K.Tochinai

†北海道大学工学部 Hokkaido Univ.
‡北海学園大学工学部 Hokkaigakuen Univ.

1．はじめに

音声入力によるテキストプロセッシングでは、音声認識段階における曖昧さのために多数の候補文字が出現し、これらの組合わせからなる単語候補の個数は極めて多くなる。先に我々は、音声入力において発生する誤りを正しい文字列に復元するために、統計的手法を用いて段階的に自動訂正する多段階分割復元法を提案した[1]。しかしながら、この手法においても多数の単語候補の中から1つを決定するには相当な処理時間を要する。この復元システムは段階的に処理するため、精度や処理時間は、上位でいかに多数の正しい復元が出来るかにかかっているといえる。この問題に対して我々はすでに、単語間の共起関係により、候補に重みを付加することで効果を上げる手法を提案している[2]。そこで本稿では、この手法の有効性を確認するために行なった実験とその結果について報告する。

2．実験手順

人間は、文脈などを考慮してその文における核となる単語を認識して、検索空間を絞ることにより次にくる単語の範囲をある程度予測しているものと考えられる。そのように文章においての核となる単語を、キーワードと呼ぶことにする。

実験資料として、主に自立語、付属語という分割を中心に形態素解析を行なった文献を用意する。今回は文献として、情報処理に関する学術論文10編を対象とし、その資料をもとに、キーワードと共起単語の関係を調べた。

2．1 キーワードの決定

前述のように、キーワードはその文章において中心的な単語の一つである。ここでは、各々の実験資料において出現頻度が高く、その論文特有の語であるとみなすことができる単語一語をキーワードとして選んだ。

2．2 キーワード共起単語と意味的共起単語の抽出

キーワード共起出現単語とは、キーワードと同一文中に出現する単語のことである。抽出する単語は自立語のみとした。また、これと同時にキーワードと意味的に関係をもつ自立語の抽出を行なった。意味的に関係がある語として、ここではキーワードと直接係り受けの関係にあるものだけを抽出した。その一例を次に示す。

「/我々/は/計算機/に//よる/自動//学習/に//より/語/を/認識/する/手法/を/提案/する/。」
//：自立語 //：付属語

キーワード「認識」と同一文中に出現している自立語 7語のうち、ここで意味的に関係のあるのは直接係り受け関係にある「語」と「手法」ということになる。

2．3 キーワード共起単語と意味的共起単語との関係

このようにして、キーワードを含む同一文中に出現する自立語と、その中でキーワードと意味的に関係があるとみなせるものを頻度により順位を付け、その一致度を上位10位、20位、30位と比較した。ここで記号等は自立語に含めない。文献10編での平均は次の通りであった。

上位	10位	20位	30位
一致度	60%	67%	65%

これから、同一文中でキーワードと意味的に共起している単語と、文中に高頻度で出現する単語とには、ある程度の一致があるといえる。

2．4 意味的共起単語の抽出方法

意味的な共起単語を計算機で正確に自動抽出することは困難である。意味的共起単語としている直接の係り受け関係にあるものはキーワードの前後数語の範囲内にあることが多い。句読点を抽出範囲とし、実際に人間が抽出した意味的共起単語との一致度を調べた。以下に頻度上位より並べたその一例を示す。（）内は出現頻度である。

※キーワードを含む範囲内に出現する自立語		※意味的に関係のある自立語	
「語」	(64)	「語」	(38)
「結果」	(23)	「結果」	(21)
「文字」	(18)	「位置」	(15)
「正し」	(15)	「正し」	(11)
「学習」	(15)	「行な」	(11)
「位置」	(15)	「済み」	(9)
⋮		⋮	

この資料の場合、上位20位においてその一致度は85％であった。他の資料についてもほぼ同じで、これにより計算機で抽出した表層上より得られる共起単語を意味的共起単語とみなすことが可能であると考えられる。

3．おわりに

以上本稿では、ある文章において中心的な単語（キーワード）の含まれている文に高頻度で出現する語と当該キーワードとの意味的関係について報告した。次いで意味的共起単語を表層よりある範囲で推定し自動抽出した単語と、人間が考えているものとの関係について述べた。今後は多数の資料について共起する単語のデータを収集し、その上で実際に復元システム上にこの処理段階を組み込んで実験を行なう予定である。

参考文献

1）荒木健治、宮永喜一、栃内香次 「多段階分割復元法による誤りの多い文字列からの原文の復元」情報処理学会論文誌 Vol.30 No.2 pp.169-178 (1989)
2）潤渇謙一、荒木健治、宮永喜一、栃内香次 「キーワード共起単語による曖昧さの解消」電気関係学会北海道支部連合大会講演論文集 pp.329 (1989)