6S-2 多段階分割法による原文復元システムの性能評価

荒木健治、宮永喜一、栃内香次
北海道大学

1．はじめに

日本語文を計算機に入力する手段として、現在はキーボードからローマ字あるいはカナで入力し、その後かな漢字変換によって漢字かな混じり文に変換する方式が主流である。しかし、この方式はキーボードの操作に習熟する必要がある。そこで、これに代わる方式として、音声入力の実用化が望まれている。しかし、音声入力においては個人差、時期変動などにより、キーボード入力に比べて相当多量の誤りを含むことが避けられない。そこで、我々は、入力された文章中の誤りの傾向を学習し、認識結果より正しい文字を予測しながら、確実性の高いものから順に復元する方式を提案し、既に実験によりその有効性が推測されている[1]。本報告では、本方式の復元能力を評価し、その有効性を確認するために、認識率を変化させて行った復元実験結果について述べる。

2．復元アルゴリズム

2．1　多段階分割法

人間が、比較的誤りの多い文から原文を復元して行くときには、まず比較的少数の手がかりとなる部分を見いだして最初に復元し、前後のつながりに矛盾がなければ同様な操作を順次続けることによって復元を進めていると考えることが出来る。そこで、我々は、認識結果より予測された文字列を考慮しながら他の語と重なり合うことなく一意に復元できる部分から、順次、段階的に復元を行う手法（多段階分割法）を開発した。

図1に本アルゴリズムの処理の流れを示す。図1を見るとわかるように、まず、他の語と明らかに分離できる語であるキーワードによる分割及び復元を行う。このキーワードは、べた書き文の分割において、誤変換の比較的少ないものと多いものの2種に分けられている[2]。次に、このキーワードによって復元された部分の拡張、カタカナ語による分割及び復元、前後一文字の連接情報を用いた一般単語による分割及び復元、接辞の処理及び復元、助詞の決定及び復元、連接情報を用いた一字漢字語の処理及び復元と順次確実性の高いものより復元を行う。なお、多段階分割法は、既に、べた書き文のかな漢字変換に応用され[3]その有効性が確認されているが、これは、この方式を誤りの復元に応用したものである。

2．2　認識結果からの正しい文字の予測

本システムでは、認識結果より正しい文字を予測しながら復元を行う。そのために、一定量の資料より予め認識の傾向を学習しておく必要がある。そこで、入力された音節とその音節の認識結果を対応づけて認識情報辞書に記録しておく。このことにより、システムは認識結果が与えられたとき、各文字ごとに認識情報辞書より予測される文字を取り出すことができる。したがって、各段階では認識情報辞書より正しい文字を予測し、その結果得られうる単語の中から一意に単語を決定している。

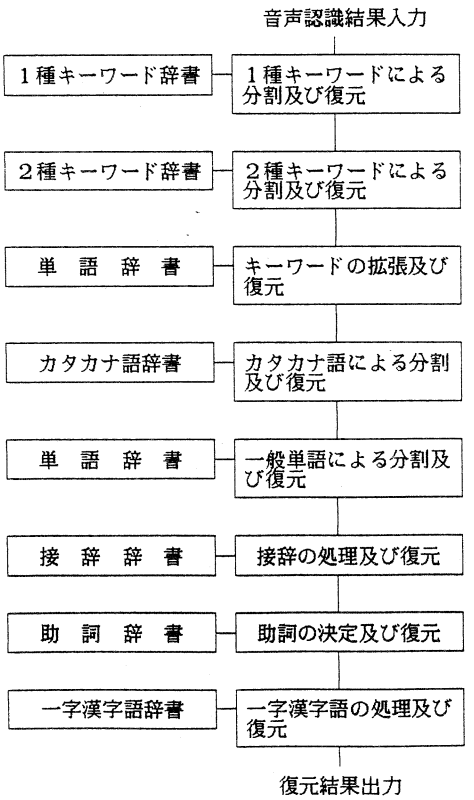


図1　処理の流れ

Performance Evaluation of System using Multi Stage Recovery Method for Sentences from Errouneous Character Strings
Kenzi Araki,Koji Tochinai,Yoshikazu Miyanaga
HOKKAIDOU University

３．性能評価実験

３．１　実験方法

音声認識装置として、市販の単音節認識装置を用いた。この装置は、単音節６８音を認識でき、予め単音節を発声して学習させる必要がある。音声認識装置に入力した資料は、情報処理に関する論文の一部（２９５３音節）を用いた。この資料を単音節に分けて発声、入力し、音声認識結果を得た。このデータは、正認識率が６３．７％であったので、エラーをランダムに訂正することにより、認識率を６７％、７０％、７５％、８０％、８５％、９０％の６種類に変化させたデータを作成し、それらについて復元実験を行った。また、辞書作成に用いた資料は、情報処理に関する論文１４編（１２０７４１文字）を用いた。辞書は、空の状態から、多段階分割法によるべた書き文かな漢字変換システム[3]を用いて論文一編ごとに更新を行って作成した。

表１　認識率の推移

	正認識	誤認識	未認識
復元前	67.0	23.4	9.6
復元後	85.9	14.1	0.2
復元前	70.0	21.0	9.0
復元後	87.2	12.6	0.3
復元前	75.0	17.5	7.5
復元後	88.4	11.6	0.2
復元前	80.0	13.8	6.2
復元後	90.3	9.7	0.1
復元前	85.0	10.2	4.8
復元後	93.5	6.6	0.1
復元前	89.9	7.0	3.1
復元後	96.2	3.9	0.0

注）単位は％

正認識率＝正しく認識された音節数／全音節数
誤認識率＝誤って認識された音節数／全音節数
未認識率＝認識できなかった音節数／全音節数

表２　復元の精度

正認識率	67%	70%	75%	80%	85%	90%
①正→正	61.9	65.2	69.8	75.3	81.8	87.8
②誤→正	24.8	22.8	19.0	15.2	11.9	8.5
③誤→誤	8.6	7.6	6.4	5.2	3.5	1.8
④正→誤	4.8	4.4	4.7	4.3	2.9	1.9

注）単位は％

①復元前に正しかった文字を復元後も正しい文字として認識した。
②復元前に誤っていた文字を復元によって正した。
③復元前に誤っていた文字が復元によっても正されなかった。
④復元前に正しかった文字が復元によって誤りとなった。
精度=①または②または③または④の音節細数／全復元数

３．２　実験結果

表１に音声認識の認識率を変化させた場合の復元後の認識率の推移を示す。これをみると、復元後の正認識率は、復元前の正認識率と共に上昇し、誤認識、未認識は減少していることがわかる。

表２に、復元の精度の推移を示す。この表からわかるように、正認識率を上昇させると、全復元のうち正しいものを誤りに変えてしまう復元が占める割合は、４．８％から１．９％に減少する。また、全復元のうち本システムにとって有効な正しいものを正しいままとした復元と誤りを正した復元が占める割合は８６．７％から９６．３％に上昇し、復元の精度も復元前の認識率の上昇と共に上昇している。

４．考察

表１を見ると、復元後の正認識率は復元前の正認識率を上昇させるにしたがって、次第に上昇し、８２～８３％あれば９０％以上まで正認識率を向上できることがわかった。また、表２からわかるように、復元前の正認識率が８５％のとき、全復元のうちで有効な復元が占める割合は９３．７％におよび、正確な復元をしていることがわかった。

以上より、誤りを２割程度含む正認識率８０％程度の文の正認識率を、本システムにより９０％以上まで高めることが出来ることがわかりその有効性が確認された。

５．おわりに

現在は、各文字や単語の持つ確からしさを考慮せず予測される全ての文字を同じ確からしさと見なして復元を行っている。このために、非常に低い確率で正しい文字と予測される文字を使って誤った単語をあてはめてしまう復元誤りが多い。そこで、今後は、各文字や個々の単語の持つ確からしさを総合的に評価する関数を定義し、その関数の値により予め確からしくない単語を除いた中から一意に単語を決定することにより復元能力の向上を図りたい。

＊参考文献

１）荒木、栃内、永田　「誤りの多い文字列からの原文の復元」昭和６２年電子情報通信学会創立７０周年記念総合全国大会講演論文集 pp6-126

２）荒木、内田、山田、栃内、永田　「キーワード方式べた書き文かな漢字変換システムの変換性能の向上」昭和６０年電子通信学会情報・システム部門全国大会講演論文集 pp3-169

３）荒木、栃内、永田　「多段階分割法によるべた書き日本語文のかな漢字変換」情報処理学会論文誌 Vol.28 No.4 pp412-421