281 誤りの多い文字列からの原文復元における多段階分割法の応用

荒木健治、宮永喜一、栃内香次
北海道大学

1．はじめに

現在、日本語文を計算機に入力する手段として主流となっているかな漢字変換に代わる手法として、音声入力の実用化が望まれている。しかし、音声入力においては個人差、時期変動などにより、キーボード入力に比べて相当多量の誤りを含むことが避けられない。そこで、我々は、多段階分割法[1)]を利用してこの誤りを復元することを試みた。以下、この手法を多段階分割復元法と呼ぶ。

2．復元アルゴリズム

2．1　多段階分割復元法の概要

多段階分割復元法は、認識結果より予測された文字列を考慮しながら、確実性の高いものから順次段階的に復元を行う手法である。その概要を以下に述べる。

まず、他の語と明らかに分離でき、確実性の最も高い語であるキーワードによる分割及び復元を行う。キーワードは、べた書き文の単語への分割において用いられるもので、誤変換の多少により２種に分けられている[2)]。次に、キーワードによって復元された部分の拡張、カタカナ語による分割及び復元、前後一文字の連接情報を用いた一般単語による分割及び復元、接辞の処理及び復元、助詞の決定及び復元、連接情報を用いた一字漢字語の処理及び復元と順次確実性の高いものより復元を行う。なお、多段階分割法は、既に、べた書き文のかな漢字変換に応用され[1)]、その有効性が確認されている。本方式はこれを誤りの復元に応用したものである。

2．2　正しい文字の予測の方法[3)]

本システムでは、音声認識結果から正しい文字を予測しながら復元を行う。そのために、認識の傾向を学習しておく必要がある。そこで、予めある程度大量の資料を入力し、入力音節とその音節の認識結果を対応づけて認識情報辞書に記録しておく。このことにより、システムは認識結果が与えられたとき、各文字ごとに認識情報辞書より予測される文字を取り出すことができ、それらの文字を組み合わせて得られうる単語群の中から一意に単語を決定している。

3．復元実験

3．1　実験方法

音声認識装置として、市販の単音節認識装置を用いた。この装置は、単音節６８音を認識でき、予め単音節を発声して学習させる必要がある。音声認識装置に入力した資料は、情報処理に関する論文の一部（２９５３音節）を用いた。この資料を単音節に分けて発声、入力し、音声認識結果を得た。このデータは、正認識率が６３．７％であったので、エラーをランダムに訂正することにより、認識率を６７％、７０％、７５％、８０％、８５％、９０％の６種類に変化させたデータを作成し、それらについて復元実験を行った。また、辞書作成に用いた資料は、情報処理に関する論文１４編（１２０７４１文字）を用いた。辞書の初期状態は、空から始め、多段階分割法によるべた書き文かな漢字変換システム[1)]を用いて論文一編ごとに更新を行いながら作成した。

表１　認識率の推移

	正認識	誤認識	未認識
復元前	67.0	23.4	9.6
復元後	85.9	14.1	0.2
復元前	70.0	21.0	9.0
復元後	87.2	12.6	0.3
復元前	75.0	17.5	7.5
復元後	88.4	11.6	0.2
復元前	80.0	13.8	6.2
復元後	90.3	9.7	0.1
復元前	85.0	10.2	4.8
復元後	93.5	6.6	0.1
復元前	89.9	7.0	3.1
復元後	96.2	3.9	0.0

注）単位は％
正認識率＝正しく認識された音節数／全音節数
誤認識率＝誤って認識された音節数／全音節数
未認識率＝認識できなかった音節数／全音節数

3．2　結果と考察

表１を見ると、復元後の正認識率は復元前の正認識率を上昇させるにしたがって、次第に上昇し、８２～８３％あれば９０％以上まで正認識率を向上できることがわかった。以上により、誤りの多い文字列からの原文の復元に本方式が有効であることが確認された。

5．おわりに

今後は、各文字や個々の単語の持つ確からしさを総合的に評価する関数を定義し、その関数の値により予め確からしくない単語を除いた中から本方式により一意に単語を決定することにより復元能力の向上を図りたい。

＊参考文献

１）荒木、栃内、永田　「多段階分割法によるべた書き日本語文のかな漢字変換」情報処理学会論文誌 Vol.28 No.4 pp412-421

２）荒木、内田、山田、栃内、永田　「キーワード方式べた書き文かな漢字変換システムの変換性能の向上」昭和６０年電子通信学会情報・システム部門全国大会講演論文集 pp3-169

３）荒木、栃内、永田　「誤りの多い文字列からの原文の復元」昭和６２年電子情報通信学会創立７０周年記念総合全国大会講演論文集 pp6-126