自然言語処理 68－6
（1988. 9. 16）

付属語パターンを用いたルールによる表層レベルでの係り受け関係の解析

荒木健治
（北海学園大学）

栃内香次
（北海道大学）

係り受け関係を解析することは、日本語文書処理における基本的な技術である。しかし、従来の係り受け関係の解析手法は、対象分野を制限していたり、複雑な処理を用いるため処理速度が遅いなどの問題点があり、決定的な手法は存在しない。本稿では、この問題に対して、表層レベルに付属語によって明示的に示される係り受け関係を付属語のパターンを用いて解析する手法を提案し、本手法による係り受け関係解析実験を行った結果、90.4%の精度で対象とする係り受け関係をすべて解析できることが確認された。さらに、本手法をべた書き文かな漢字変換システムに適用した結果、本手法による単語分割は97.1%の精度であることがわかり本手法の有効性を示すことができた。

Character Level Dependency Relations Analysis by Auxiliary Words Pattern Rules

Kenji ARAKI,

Hokkai Gakuen University

S 26, W 11, CHUO-KU, SAPPORO,
064 JAPAN

Koji Tochinai

Hokkaido University

N 13, W 8, KITA-KU, SAPPORO,
060 JAPAN

Analysis of the dependency relations is a fundamental technique in Japanese text processing. But there are no complete method for the analysis of the dependency relations. In the proposed method, the dependency relations are analysed by the auxiliary words patterns. The proposed method, first, extracts the analysis rules, and then determines the dependency relations from other sentences by them. We confirmed that the proposed method can analyse the dependency relations of sentences with the correctness rate 90.4% by the analysis experiment for dependency relations. In the word division experiment by the connected words, it is shown that the correctness rate of the word division by the proposed method is 97.1%.

１．はじめに

係り受け関係の解析は日本語文書処理における基本的技術[1]であるが、従来の係り受け関係解析手法は対象分野を限定したり、複雑な処理を用いるため処理速度が遅い[2),3)]などの問題点があり、文書の検索、抄録、要約、機械翻訳といった問題に適用する際には十分ではない。したがって、日本語文書をこのような問題に適用できる形に処理するには、膨大な労力を要するのが現状である。

この問題に対して、本稿では、まず、表層レベルに付属語によって明示的に示される係り受け関係を付属語のパターンによって解析する手法を提案し、次に、本手法による係り受け関係解析実験を行い、本手法により係り受け関係が正確に解析できることを示し、最後にべた書き文のかな漢字変換における単語分割に本手法を適用した結果について述べる。

２．概　要

本手法は、付属語のパターンを用いた解析ルールにより文中の係り受け関係を解析し、単語を意味的に関係のある事項ごとに分類するものである[4)]。解析の方法は、まず予め一定量の文章中より解析ルールを抽出しておき、この解析ルールの付属語パターンと一致する文字列を解析ルールを抽出した文章とは異なる文章中より検出し、その文字列と隣接する自立語を関連語として取り出すものである。ここで、解析ルールとは付属語パターンとその係り受け関係の種類を定義する規則である。また、ここでいう付属語には「する、ある」といった付属語的に使われる動詞の一部を含んでいる。また、ある語Ａと係り受け関係にある語Ｂを語Ａの関連語と呼ぶ。

３．解析アルゴリズム

３．１　係り受け関係の解析手順

係り受け関係の解析手順を以下に示す。１文ごとに以下の手順を繰り返す。

（１）解析ルールを用いて単語単位に分割された文字列を解析し、係り受け関係を決定する。
- (1-1) 解析ルール中に存在する付属語パターンを文字列中より検索する。
- (1-2) 各解析ルールに一致するように付属語パターンの直後または直前に自立語が存在する場合に、この語の組を係り受け関係候補とする。
- (1-3) 相互の関連を考慮して係り受け関係候補の修正を行い、係り受け関係を決定する。

（２）解析された係り受け関係に基づき、関連語の組を抽出する。
　この際には、各組ごとに、その係り受け関係の種類を示すフラグを付加する。

なお、解析ルールは、次節で述べるように予め一定量の文章から人手により抽出し、解析ルール辞書に蓄えておく。

３．２　解析ルールの抽出

解析ルールは人手によって文章中より抽出する。解析ルールの抽出では、初めに、文中で係り受け関係にある語に着目し、次いで係り受け関係を明示しているその語に隣接する付属語を文章中より取り出し、付属語パターンとその係り受け関係の種類を結び付ける解析ルールを決定している。この際には、付属語によって明示的に示される係り受け関係をすべて解析ルールとして抽出する。また、解析ルールを抽出する基準は、係り受け関係にある自立語に従属する付属語が１つ以上あることである。

図１に解析ルール抽出の例を示す。図１(a) のような単語単位に分割された文が与えられたとき、例えば図１(b) ①の「データベース」と「言葉」が主語と述語であるという係り受け関係に着目し、図１(c) ①の「ＡとはＢである→ＡはＢの主語」という解析ルールが得られる。

データベース¦という¦言葉¦は¦いろいろ¦異¦なった¦意味¦を¦持って¦いる¦が¦、¦ここでは¦次¦のように¦定義¦する。

（ａ）　単語単位に分割された文

①「データベース」は「言葉」と同格
②「言葉」は「持って」の主語
③「意味」は「持って」の目的語
④「次」は「定義」の例示

（ｂ）　着目した係り受け関係

①ＡというＢ　→　ＡはＢと同格
②ＡはＢいる　→　ＡはＢの主語
③ＡをＢいる　→　ＡはＢの目的語
④ＡのようにＢする　→　ＡはＢの例示
注）Ａ、Ｂは自立語である。

（ｃ）　抽出された解析ルール

図１　解析ルール抽出の例

３．３　解析ルールによる係り受け関係の決定

３．３．１　概　要

前述のようにして抽出した解析ルールを用い、以下のようにして係り受け関係の解析を行う。まず、解析ルール中の付属語パターンを文中で検索する。次に、検索された付属語の直前または直後に解析ルールのパターンと一致するような自立語が存在するか否かを検査する。存在すれば、その自立語の組を係り受け関係候補とする。このようにして得られた係り受け関係の候補を相互の関連を考慮して修正を行い、係り受け関係を決定する。以下、図２の例を用いてこの過程を説明する。

図２(a) に示す３つの解析ルール①～③が解析ルールとして予め抽出されているものとする。ここで、解析ルール①は、「Ａは－Ｂする」という語の組が文章中に存在すれば、ＡとＢは主語と述語の関係にあることを表している。以下、具体的な解析の例を示す。

（１）付属語「は」および「する」が文中に存在するかどうかを検索する。

（２）存在する場合、これらの付属語の直前に自立語

が存在するかどうかを検索する。

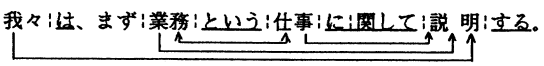
（３）この例では、「我々」と「説明」が存在するので、この両者が係り受け関係候補として抽出される。

（４）ここで、他の係り受け関係を解析し、すべての係り受け関係候補取り出し、相互の関係を考慮して３．３．２で述べる係り受け関係の修正を行い、係り受け関係を決定する。

以上のようにして解析ルール①により「我々」と「説明」が係り受け関係にあることが決定されるので、解析ルール①で定義された自立語Ａ、Ｂの関係である主語と述語より、「我々」と「説明」が主語と述語の関係にあることがわかる。

①Aは－Bする　→　AはBの主語
②AというB　→　AはBと同格
③Aに関してBする　→　AはBの対象
注）－：文字（空も可）
A、B：自立語

（ａ）　解析ルール



注）｜：単語の区切り
＿：用いられた付属語パターン

（ｂ）　係り受け関係解析結果

(i)　①より「我々」は「説明」の主語
(ii)　②より「業務」は「仕事」と同格
(iii)　③より「仕事」は「説明」の対象
(vi)　②③より「業務」は「説明」の対象

（ｃ）　得られた関連語の組

図２　解析ルールによる関連語抽出の例

３．３．２　係り受け関係候補の相互関係の評価

本手法では、付属語パターンにより係り受け関係を解析していくが、この際には局所的な係り受け関係が決定される。そこで、文全体の係り受け関係を相互の関連を考慮して総合的に評価する必要がある。このような観点から、本手法では、まず付属語パターンを用いて局所的な解析により係り受け関係の候補を抽出し、次に文全体より候補相互の状態を考慮して修正を行い、最終的な係り受け関係を決定する。なお、この修正を行う際の情報は、解析ルール個々に与えられている。

この係り受け関係候補の修正を行うことによって得られた関連語の組が、図２(c) (vi)である。(vi)の場合には、解析ルール②より「業務」は「仕事」と同格、解析ルール③より「仕事」が「説明」の対象という係り受け関係候補が抽出される。この２つの係り受け関係候補より、「業務」が「説明」の対象という係り受け関係が追加される。

３．３．３　関連語の組の抽出

解析された係り受け関係に基づき、係り受け関係を構成する自立語の組を関連語の組として抽出する。この際には、その関連語の組の係り受け関係の種類として抽出に用いた解析ルール中の係り受け関係の種類が、付加される。

４．辞書の構造

４．１　解析ルール辞書

解析ルールを蓄える解析ルール辞書について説明する。解析ルール辞書の構造とその例を図３に示す。図に示すように、各解析ルールは固有の番号によって管理されている。ここで、Z1、Z2、ZKは付属語および係り受け関係の種類を示し、Ａ、Ｂを自立語とするとき「Ａ　Z1　Ｂ　Z2」という文字列において、「ＡはＢのZKである」ことを表している。また、係り受け関係候補を修正する際の情報として各ルールにKZ1, X1, KZ2, X2が各々最大５個まで蓄えられる。解析ルール辞書の例を図３(ii)に示す。

次に、係り受け関係修正用のフラグの用い方について説明する。図３で自立語ＡとＢが係り受け関係候補であるとき、KZ1, X1は係り受け関係候補の前方の自立語Ａを、KZ2, X2は係り受け関係候補の後方の自立語Ｂを修正する情報である。つまり、前方の語Ａにさらに解析ルールKZ1で示される係り受け関係候補が係っている場合にX1のように対処するということを表す。これは、KZ2, X2についても同様である。

図４に、X1, X2 の使用法とその例を示す。図４では、図３(ii)の解析ルールが与えられているものとする。以下に、図４(a) と(b) の場合の係り受け関係候補修正フラグの使用法の手順を示す。

（１）図４(a) の場合

(1-1) 文字列「ＡのＢやＣのＤ」から、係り受け関係候補として図３(ii)の解析ルール３、４より係り受け関係候補「Ａ修飾Ｂ、Ｃ修飾Ｄ、Ｂ並列Ｃ」が抽出される。

(1-2) 図３(ii)の解析ルール３「ＡやＢ」の係り受け関係候補の後方の自立語を修正する解析ルール番号を参照し、解析ルール４「ＡのＢ」を得る。

(1-3) 解析ルール３における解析ルール４の対処法フラグが'０'となっているので、「Ｂ並列Ｃ」は「Ｂ並列Ｄ」と修正される。

（２）図４(b) の場合

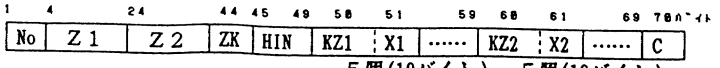
(2-1) 文字列「ＡとはＢやＣである」からは、係り受け関係候補として図３(ii)の解析ルール３、ｂより「Ａ主格Ｃ、Ｂ並列Ｃ」が抽出される。

(2-2) 図３(ii)の解析ルールｂ「Ａとは－Ｂである」の係り受け関係候補の後方の自立語を修正する解析ルール番号を参照し、解析ルール３「ＡやＢ」を得る。

(2-3) 解析ルールｂにおける解析ルール３の対処法フラグが'１'なので抽出される係り受け関係に「Ａ主格Ｂ」が追加される。

また、図３の交換性フラグＣについては、次節で説明する。

(i) 構造



Ｎｏ（解析ルール番号）　：３バイト（１…９ａ…ｚＡ…Ｚ）
Ｚ１（前方付属語）　：２０バイト
Ｚ２（後方付属語）　：２０バイト
ＺＫ（係り受け関係の種類）　：１バイト
ＺＨＩＮ（使用頻度）　：５バイト
ＫＺ１（係り受け関係候補の前方の自立語を修正する解析ルール番号）：１バイト
Ｘ１　（係り受け関係候補の前方の自立語の修正結果対処法フラグ）　：１バイト
ＫＺ２（係り受け関係候補の後方の自立語を修正する解析ルール番号）：１バイト
Ｘ２　（係り受け関係候補の後方の自立語の修正結果対処法フラグ）　：１バイト
対処法フラグ
　'１' … 修正前と修正後の係り受け関係候補の両方を採用
　'０' … 修正された係り受け関係候補を採用
Ｃ（交換性フラグ）　：１バイト（'０'は交換性なし、'１'は交換性あり）

(ii) 例

1ha	tearu	1	031c1	31c1	0
2na		2	0		0
3ya		3	0	2040	1
4no		2	0		0
5nituite	tearu	4	031c1		0
6toiu		5	0		0
7ha	iru	1	031c1	31c1	0
8niyoqte	iru	6	031c1		0
9wo	iru	4	031c1		0
anoyouni	suru	7	031c1	31c1	0
btoha	dearu	1	031c1	31c1	0
cmataha		3	0	4121	1

図３　　解析ルール辞書の構造と例

(a) 対処法フラグ'０'の時 ― 修正前と修正後の両方の係り受け関係候補を採用する。

ＡのＢやＣのＤ

修正前（Ａ 修飾 Ｂ、Ｃ 修飾 Ｄ、Ｂ 並列 Ｃ）
↓
修正後（Ａ 修飾 Ｂ、Ｃ 修飾 Ｄ、Ｂ 並列 Ｄ）

(b) 対処法フラグ'１'の時 ― 修正された係り受け関係候補を採用する。

ＡとはＢやＣである

修正前（Ａ 主格 Ｃ、Ｂ 並列 Ｃ）
↓
修正後（Ａ 主格 Ｃ、Ａ 主格 Ｂ、Ｂ 並列 Ｃ）

注）Ａ、Ｂ、Ｃ、Ｄは自立語である。

図４　係り受け関係候補修正対処法フラグ

４．２　関連語辞書

係り受け関係の解析によって取り出された情報を蓄える関連語辞書の構造とその例を図５に示す。図５の(i)に示すように、関連語辞書は見出し語情報として、固有番号、字種、読み、頻度、関連語数を持つ。また、関連語情報として、固有番号によって指示される関連語番号と、その見出し語と関連語との係り受け関係の種類とその出現頻度が付加されている。ここで、KGKAN は係り受け関係の種類を示し、「見出し語（YOMI）は関連語（KG NUM ）の KGKANである」ことを表す。図５の (ii)には関連語辞書の例を示す。①は辞書に入っている状態をそのまま書き出したもので、②は、この内容を見やすく表示したものである。

また、関連語辞書に書き込まれる情報は、情報量の圧縮という観点から、以下のように登録する。

（１）係り受け関係にある語の位置を交換するとその係り受け関係の種類が変化する解析ルール。
↓
交換性フラグＣに'０'を与える。

（２）係り受け関係にある語の位置を交換してもその係り受け関係の種類が変化しない解析ルール。
↓
交換性フラグＣに'１'を与える。

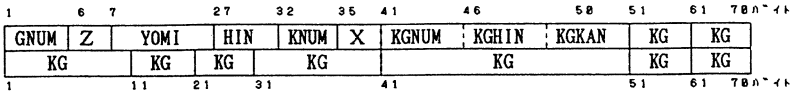
例えば、文字列「ＡのＢ」の場合、「Ａ修飾Ｂ」と「Ｂ被修飾Ａ」の両方を辞書に登録するのではなく、「Ａ修飾Ｂ」のみを登録する。

したがって、関連語情報を用いる際の関連語辞書の検索は、Ａ、Ｂを自立語、Z1、Z2を付属語としたとき、文字列「Ａ　Z1　Ｂ　Z2」とすると、以下のようになる。

（１）係り受け関係の解析に使用された解析ルールの交換性フラグが'０'の時、Ａは見出し語、Ｂは関連語の項を検索する。

（２）係り受け関係の解析に使用された解析ルールの交換性フラグが'１'の時、Ａ、Ｂともに、見出し語情報、関連語情報の両方の項目を検索する。

(i) 構造



○見出し語情報
- ＧＮＵＭ（固有番号）　：５バイト
- Ｚ（字種）　：１バイト（Ｋ：漢字、Ｃ：カタカナ、Ｈ：ひらがな、Ｚ：複合語、Ｌ：アルファベット、Ｇ：記号）
- ＹＯＭＩ（読み）　：２０バイト
- ＨＩＮ（頻度）　：５バイト
- ＫＮＵＭ（関連語数）　：３バイト（１語当り最大頻度上位より50語）
- Ｘ（空き）　：６バイト

○ＫＧ（関連語情報）
- ＫＧＮＵＭ（関連語番号）　：５バイト
- ＫＧＨＩＮ（関連語頻度）　：４バイト
- ＫＧＫＡＮ（係り受け関係の種類）：１バイト

(ii) 例

①辞書中の状態

```
 3C  dehtabehsu              264 24        304  182   35  164   84  144
  2    122    9  122   37  102   15   94  104   92  325   64  308   52
 22     42  281   42  335   44  824   42   46   42   23   34  344   32
101     32  644   32   37   24   87   24   77   22   65   22  392   22
```

②①の意味

語番号：3　字種：カタカナ(C)　読み：データベース　頻度：264　関連語数：50

関連語	関連語頻度	係り受け関係種類	関連語	関連語頻度	係り受け関係種類
導入	18	修飾語	対	16	目的語
アクセス	14	目的語	内容	12	修飾語
定義	12	修飾語	変更	10	修飾語
利用	9	目的語	更新	9	修飾語
投入	6	目的語	運用	5	修飾語
こと	4	修飾語	論理	4	修飾語
格納	4	目的語	独立性	4	修飾語
データ	4	修飾語	関	3	目的語
大	3	修飾語	すべて	3	修飾語
物理的	3	修飾語	変更	2	目的語
容易	2	目的語	中	2	修飾語
目的	2	修飾語	設計	2	修飾語

図５　関連語辞書の構造と例

５．係り受け関係解析実験

本手法による係り受け関係解析実験を行った[4]。

５．１　実験方法

実験に用いた資料は、「データベース要論」（穂鷹良介著）の第１章（総文字数 2,458文字）である。実験手順を以下に示す。

(1) 表１に示す解析ルールを資料の初めの８文（ 455文字）から人手により抽出する。

(2) １文ごとに以下の手順を繰り返す。

(2-1) これらの解析ルールを用いて資料中の係り受け関係を解析し、関連語の組を抽出する。

(2-2) 係り受け関係を正確に解析し、関連語の組が正しく抽出されているかを人手により調査する。

５．２　実験結果と考察

係り受け関係解析実験の結果を表２に示す。表２に示すように、正解析率は90.4%、誤解析率は 9.6%、未解析率が 0.0%であった。したがって、本解析ルールを用いた場合に解析されるべき係り受け関係はすべて正確に解析されている。しかし、係り受け関係にないものが 9.6%余分に抽出されている。この原因としては、解析ルールが存在しないために係り受け関係が未解析となり、

表１　係り受け関係解析実験に用いた解析ルール

No	形　式	内　容	ZK	KZ1	X1	KZ1	X1	KZ2	X2	KZ2	X2	C
1	Aは……Bてある	AはBの主語	1	3	1	c	1	3	1	c	1	0
2	AなB	AはBの修飾語	2									0
3	AやB	AとBは並列	3					2	0	4	0	1
4	AのB	AはBの修飾語	2									0
5	Aについて…Bてある	AはBの目的語	4	3	1	c	1					0
6	AというB	AとBは同格	5									0
7	Aは…Bいる	AはBの主語	1	3	1	c	1	3	1	c	1	0
8	Aによって…Bいる	AはBの手段	6	3	1	c	1					0
9	Aを…Bいる	AはBの目的語	4	3	1	c	1					0
a	Aのように…Bする	AはBの例	7	3	1	c	1	3	1	c	1	0
b	Aとは…Bである	AはBの主語	1	3	1	c	1	3	1	c	1	0
c	AまたはB	AとBは並列	3					4	1	2	1	1
d	Aに…Bできる	AはBの目的語	4	3	1	c	1	3	1	c	1	0
e	Aに…Bされた	AはBの目的語	4	3	1	c	1	3	1	c	1	0
f	Aに…Bする	AはBの目的語	4	3	1	c	1	3	1	c	1	0
g	Aを…Bする	AはBの目的語	4	3	1	c	1	3	1	c	1	0
h	Aに…Bして	AはBの目的語	4	3	1	c	1	3	1	c	1	0
i	Aは…Bされている	AはBの目的語	4	3	1	c	1	3	1	c	1	0
j	Aで…Bされている	AはBの目的語	4	3	1	c	1	3	1	c	1	0
k	Aは…Bできない	AはBの主語	1	3	1	c	1	3	1	c	1	0
l	Aが…Bとなって	AはBの主語	1	3	1	c	1	3	1	c	1	0
m	Aが…Bした	AはBの主語	1	3	1	c	1	3	1	c	1	0
n	Aを…Bした	AはBの目的語	4	3	1	c	1	3	1	c	1	0
o	Aにしか…Bできない	AはBの限定目的語	8	3	1	c	1	3	1	c	1	0

ー　：文字（空も可）
ＺＫ　：係り受け関係の種類を表すフラグ
ＫＺ１：前方の自立語の係り受け関係候補を修正する解析ルール番号
Ｘ１　：前方の自立語の係り受け関係候補の修正結果対処法フラグ
ＫＺ２：後方の自立語の係り受け関係候補を修正する解析ルール番号
Ｘ２　：後方の自立語の係り受け関係候補の修正結果対処法フラグ
Ｃ　：交換性フラグ

表２　係り受け関係解析実験結果

項　目	度数
正しく解析された係り受け関係　（Ａ）	141
誤って解析された係り受け関係　（Ｂ）	15
係り受け関係の解析総数　（Ａ＋Ｂ）	156
係り受け関係の未解析数　（Ｃ）	0
解析されるべき係り受け関係（Ａ＋Ｃ）	141
解析率＝Ａ／（Ａ＋Ｃ）	100.0%
未解析率＝Ｃ／（Ａ＋Ｃ）	0.0%
正解析率＝Ａ／（Ａ＋Ｂ）	90.4%
誤解析率＝Ｂ／（Ａ＋Ｂ）	9.6%

他の係り受け関係が未修正となることが挙げられる。これは、必要かつ十分な解析ルールを与えると解決されると考えられる。

ところで、今回の実験では対象とする係り受け関係は約90%の精度ですべて解析できることが確認されたので、抽出された関連語の情報を日本語文書処理に適用することは有効であると推測される。そこで、次にこの関連語情報の有効性を確認するためにべた書き文のかな漢字変換における単語分割の問題を取り上げ、関連語情報を適用する実験を行った。

６．べた書き文かな漢字変換単語分割への適用

６．１　適用方法

単語単位に分割された一定量の文章より抽出された関連語情報を用いて、べた書き文を単語に分割する実験を行った。

ここで、実験に使用したシステムは、多段階分割法によるべた書き文かな漢字変換システム[5]である。このシステムでは、べた書き文を最初に少数の手掛り語（キーワード）によって一意に分割し、以後の分割候補を少なくしてから確実性の高いものより順次段階的に分割を進める。そこで、このシステムの１処理段階として「関連語情報による分割」段階を設け、本手法によるべた書き文の単語分割を行った。図６に「関連語情報による分割」段階の実験システムにおける適用位置を示す。

本手法のべた書き文かな漢字変換における単語分割へ

の適用手順を以下に示す。

（１）各解析ルールの付属語の読みをべた書き文中で検索する。

（２）付属語の読みが存在した解析ルールＮの付属語に隣接する文字列と読みの一致する関連語の組（Ａ、Ｂ）を関連語辞書中よりすべて取り出す。

（３）以下の２つの条件を満たす時、Ａ、Ｂをあてはめる。

①関連語辞書中にＡの関連語としてＢが存在する。

②関連語辞書中のＡとＢの係り受け関係の種類が、Ａ、Ｂを取り出すのに使用された解析ルールＮが示す係り受け関係の種類と一致する。

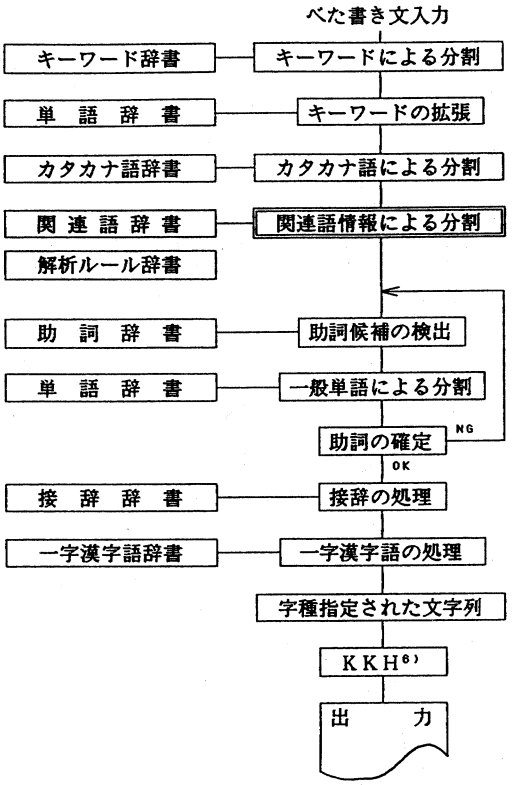


図６　多段階分割法によるべた書き文かな漢字変換システムにおける関連語情報の適用位置

これを、図７を用いて説明する。ここで、解析ルール辞書には図７(a) の解析ルールが、関連語辞書には図２(c)と同じ図７(b)の関連語情報が蓄えられているものとする。図７(c) のべた書き文を図６に示すシステムで処理すると、「カタカナ語による分割」段階が終了した時点では図７(d) のように単語があてはめられている。ここで、例えば、図７(a) の解析ルール①の付属語「が、する」に着目し、解析ルール①のＡ、Ｂとして「我々」と「説明」を抽出する。図７(b)(i)より、「我々」は「説明」の主語の関係を持つ関連語として関連語辞書に登録されている。これは、解析ルール①の係り受け関係の種類である「ＡはＢの主語」と一致するので、「我々」を「説明」の関連語としてあてはめる。なお、「我々」は、すでにキーワードとしてあてはめられているので、関連語情報により新たにあてはまる語は「説明」のみである。同様にして、「仕事」が「説明」の関連語としてあてはめられる。

①Ａが一Ｂする　→　ＡはＢの主語
②ＡについてＢする　→　ＡはＢの対象

（ａ）　解析ルール

(i)　「我々」は「説明」の主語
(ii)　「業務」は「仕事」と同格
(iii)　「仕事」は「説明」の対象
(vi)　「業務」は「説明」の対象

（ｂ）　関連語情報

われわれがしごとについてせつめいする。

（ｃ）　入力されたべた書き文

［我々］がしごと［について］せつめいする。

（ｄ）「カタカナ語による分割」段階までの結果

［我々］が〒仕事〒［について］〒説 明〒する。

［　］：キーワード　　〒　〒：関連語
＿＿：用いられた付属語パターン

（ｅ）「関連語情報による分割」処理の結果

図７　関連語情報による分割の例

６．２　関連語情報による単語分割実験

６．２．１　実験方法

資料は、初期辞書作成用に、前記、「データベース要論」（穂鷹良介著、総文字数63,265文字）を用い、単語分割実験を行う資料として表３に示す文献を用いた。また、解析ルール辞書には「データベース要論」の初めの８文から抽出された表１の24の解析ルールが蓄えられている。

表３　関連語情報による単語分割実験に用いた資料

No	文字数	No	文字数
1	9,274	4	8,630
2	9,011	5	7,970
3	6,438	6	11,188

総文字数52,511文字
出典「情報検索」（中原啓一著）

図８に実験の手順を示す。表３の No.１～６までの各文章ごとに図８の処理を行う。なお、関連語辞書及び解析ルール辞書を除く辞書の自動更新については、校正前の字種指定ローマ字列と校正済みの字種指定ローマ字列を用いる文献５）に示す方法を用いた。また、関連語辞

書の更新については、３．１節で述べた解析アルゴリズムにより関連語を抽出することにより行い、解析ルール辞書については新たな解析ルールの追加は行わない。

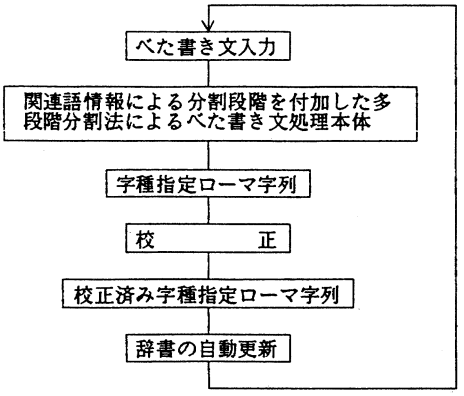


図８　関連語情報による単語分割実験手順

６．２．２　実験結果と考察

表４に関連語情報による単語分割実験の結果を示す。

表４　関連語情報による単語分割実験結果

資料No	新たな分割数			分割率[%]	
	総分割数	正分割数	誤分割数	正分割率	誤分割率
1	16	15	1	93.8	6.3
2	23	22	1	95.7	4.3
3	19	19	0	100.0	0.0
4	30	30	0	100.0	0.0
5	21	21	0	100.0	0.0
6	28	26	2	92.9	7.1
計	137	133	4	97.1	2.9

表４より関連語情報によるべた書き文の単語分割の精度は、97.1%である。これは、べた書き文の単語分割において関連語情報が有効であることを十分示している。

問題点としては、総分割数が 137箇所と少ないことが挙げられる。この原因としては、以下の３点が挙げられる。

（１）本手法で解析できる係り受け関係を構成する単語がキーワードであることが比較的多く、すでにキーワードとしてあてはめられている。

（２）用いた解析ルールの数が少数（24個）である。

（３）関連語辞書の初期辞書を作成したデータが少なく、見出し語が 1,100語程度である。

これらの問題点は、「関連語情報による分割」段階をさらに上位の階層にすることや使用するルールの数及び関連語辞書を作成する資料を増加することによって改善されるものと考えられる。

７．おわりに

文書検索、抄録、要約、機械翻訳を行うには基本的技術として係り受け関係の解析手法が必要となるが、現在のところ決定的な手法は存在しない。この問題に対して、本稿では、すべての係り受け関係を複雑な処理により深く解析するのではなく、表層レベルに付属語によって明示的に示される係り受け関係を付属語パターンによって解析する手法を提案し、実験システムを作成して性能評価実験を行った。その結果、与えられた解析ルールを用いて解析することのできる係り受け関係をすべて解析できることが実験により確認できた。そこで、係り受け関係を解析することにより抽出された関連語情報をべた書き文のかな漢字変換における単語分割に適用し、関連語情報による単語分割が97.1%の精度で行われることが確認された。これは、本方式の有効性を十分示していると考えられる。

今後さらに、本手法の自然言語による文書検索、抄録、要約、機械翻訳といった分野への適用について検討を進める予定である。

謝　辞

本研究に際し、種々御討論いただき、適切な御示唆をいただいた北海学園大学工学部電子情報工学科各位及び北海道大学工学部電子工学科電子機器工学講座各位に感謝します。なお、本研究の一部は文部省科学研究費補助金（一般研究（Ｃ）第63580017号）の補助により行われた。

参考文献

１）吉田将：二文節間の係り受け関係を基礎とした日本語文の構文分析、電子情報通信学会論文誌、Vol.55-D, No.4, pp.238-244 (1972).

２）吉田将、松山晶子：日本語の規格化－係り受け関係の規格化とそれへの変換ルール－、情報処理学会自然言語処理研究会資料、51-4, pp.1-6 (1985).

３）鶴丸弘明、兵頭竜二、松崎功、日高達、吉田将：語義を考慮した単語間の階層構造の抽出について、情報処理学会自然言語処理研究会資料、64-2, pp.9-16 (1987).

４）荒木健治、内田幸司、山田洋志、栃内香次、永田邦一：キーワード方式べた書き文かな漢字変換システムにおける付属語情報を用いた単語のあてはめ、第33回情報処理学会全国大会講演論文集、pp.1793-1794 (1986).

５）荒木健治、栃内香次、永田邦一：多段階分割法によるべた書き日本語文のかな漢字変換、情報処理学会論文誌、Vol.28, No.4, pp.412-421 (1987).

６）栃内香次、伊藤太亮、荒木健治、鈴木康広、永田邦一：ローマ字漢字変換システムＫＫＨのユーザインタフェースと使用効率、情報処理学会ソフトウェア工学研究会資料、34-20, pp.115-120 (1984).