267　表層上の文字列パターンを利用した係り受け関係の解析

荒木健治　（北海学園大学）
栃内香次　（北海道大学）

1．はじめに

高度情報化社会の進展に伴い、日本語文書を解析し、計算機が有効に利用できる形に処理する必要性が高まっている。しかし、この問題に対する決定的な方法は、未だ見い出されていない。これに対して、我々は、文を解析する上でまず必要となる係り受け関係の解析[1]において、すべての係り受け関係を深く解析するのではなく、表層レベルに付属語によって明示的に示される係り受け関係を付属語のパターンによって解析する手法を提案する。本報告では、初めに、付属語のパターンを用いた係り受け関係の解析手法を提案し、次に係り受け関係解析実験を行い、本手法により係り受け関係が正確に解析できることを示し、最後にべた書き文のかな漢字変換における単語分割に本手法を適用した結果について述べる。

2．係り受け関係の解析

本手法は、付属語のパターンを用いた解析ルールにより文中の係り受け関係を解析し、単語を意味的に関係のあるものごとに分類するものである[2]。ここで、解析ルールとは付属語パターンとその係り受け関係の種類を定義する規則である。また、ここで用いられる付属語とは「する、ある」といった付属語的に使われる動詞の一部を含むが、ここではこれらを総称して付属語と呼ぶ。また、ある語Aと係り受け関係にある語Bを語Aの関連語と呼ぶ。

2．1　解析アルゴリズム

2．2．1　解析ルールの抽出

解析ルールは予め一定量の文章中より人手によって決定される。次いで、システムは、この解析ルールを用いて他の文章の係り受け関係を解析する。図1に解析ルール抽出の例を示す。図1(a)のような単語単位に分割された文が与えられたとき、例えば図3(b)①の「データベース」と「ファイル」が主語と述語であるという係り受け関係に着目し、図1(c)①の「AとはBである→AはBの主語」という解析ルールが得られる。

データベース｜とは｜種々｜の｜業務｜または｜ユーザ｜に｜利用｜できる｜ように｜統合化｜された｜共用｜ファイル｜である。

（a）　単語単位に分割された文

①「データベース」は「ファイル」の主語
②「種々」は「業務」の修飾語
③「業務」と「ユーザ」は並列
④「業務」は「利用」の目的語
⑤「業務」は「統合化」の目的語
⑥「ユーザ」は「統合化」の目的語

（b）　着目した係り受け関係

①AとはBである　→　AはBの主語
②AのB　→　AはBの修飾語
③AまたはB　→　AとBは並列
④AにBできる　→　AはBの目的語
⑤AにBされた　→　AはBの目的語
注）A、Bは自立語である。

（c）　抽出された解析ルール

図1　解析ルール抽出の例

2．2．2　解析ルールによる係り受け関係の解析

前述のようにして得られた解析ルールを用いて解析ルールを抽出した文とは異なる文を対象に係り受け関係の解析を行う。この解析ルールを用いた係り受け関係の解析の処理手順を図2の例を用いて述べる。今、図2(a)のような5つの解析ルールが存在するとする。ここで、図2(a)の①の解析ルールは「Aが―Bする」という語の組が文章中に存在すれば、AとBは主語と述語の関係にあることを表す。解析ルール①を用いる場合には、初めに、付属語「が」及び「する」が文中に存在するかどうかを検索し、存在すれば次にこれらの付属語の直前に自立語が存在するかどうかを検索する。この場合には「私」と「解説」が存在するので、この両者の係り受け関係が決定される。以上のようにして解析ルール①により「私」と「解説」が係り受け関係にあることが決定されるので、解析ルール①で定義された自立語A、Bの関係である主語と述語より、「私」と「解説」が主語と述語の関係にあることがわかる。

①Aが―Bする　→　AはBの主語
②AなB　→　AはBの修飾語
③AやB　→　AとBは並列
④AのB　→　AはBの修飾語
⑤Aについて―Bする　→　AはBの対象
注）―：文字（空も可）
A、B：自立語

（a）　解析ルール

私｜が、｜アセンブラ｜言語｜の｜起源｜や｜基本的｜な｜性格｜について｜解説｜する。

注）｜：単語の区切り
＿：用いられた付属語パターン

（b）　係り受け関係解析結果

(i)　①より「私」は「解説」の主語
(ii)　②より「基本的」は「性格」の修飾語
(iii)　②③より「起源」と「性格」は並列
(iv)　④より「言語」は「起源」の修飾語
(v)　⑤より「性格」は「解説」の対象
(vi)　②③⑤より「起源」は「解説」の対象

（c）　得られた関連語の組

図2　解析ルールによる関連語抽出の例

本手法では、付属語パターンにより係り受け関係を解析していくが、この際には局所的に係り受け関係を決定していくので、係り受け関係相互の関連を考慮する必要がある。図2の(c)(iii)は係り受け関係候補の修正を行うことによって得られた関連語の組である。この場合には、解析ルール②より「基本的」が「性格」の修飾語、解析ルール③より「起源」と「基本的」が並列という係り受け関係候補が抽出される。しかし、「基本的」は「性格」の修飾語であるので「起源」と「性格」の並列関係に係り受け関係が修正される。

2．2．3　関連語の組の抽出

解析された係り受け関係に基づき、係り受け関係を構成する自立語の組を関連語の組として抽出し、関連語辞

書に蓄える．この際には、その関連語の組の係り受け関係の種類が付加される．

3．係り受け関係解析実験

本手法による係り受け関係解析の性能を評価する実験を行った[2]．

3．1　実験方法

資料として、「データベース要論」（穂鷹良介著）の第1章（総文字数 2,458文字）を用いた．実験手順を以下に示す．

(1) 資料の初めの８文（ 455文字）より予め24の解析ルールを人手により抽出しておく．
(2) １文ごとに以下の手順を繰り返す．
　(2-1) これらの解析ルールを用いて資料中の係り受け関係を解析し、関連語の組を抽出する．
　(2-2) 係り受け関係を正確に解析し、関連語の組が正しく抽出されているかを人手により調査する．

3．2　結果と考察

係り受け関係解析実験の結果を表１に示す．

表１　係り受け関係解析実験結果

項　目	度数
正しく解析された係り受け関係　（Ａ）	141
誤って解析された係り受け関係　（Ｂ）	15
係り受け関係の解析総数　（Ａ＋Ｂ）	156
係り受け関係の未解析数　（Ｃ）	0
解析されるべき係り受け関係（Ａ＋Ｃ）	141
解析率＝Ａ／（Ａ＋Ｃ）	100.0%
未解析率＝Ｃ／（Ａ＋Ｃ）	0.0%
正解析率＝Ａ／（Ａ＋Ｂ）	90.4%
誤解析率＝Ｂ／（Ａ＋Ｂ）	9.6%

本実験において誤解析率が 9.6%である原因としては、解析ルールが存在しないために係り受け関係が未解析となり、他の係り受け関係が未修正となることが挙げられる．これは、必要かつ十分な解析ルールを与えると解決されると考えられる．しかし、分野及び各人によって表層レベルでの文章の表現方法が違うので解析ルールは変動する．したがって、システムが解析ルールを自動的に抽出し分野及び個人に動的に適応させるということが必要となるが、これは、今後の課題である．

次に、この関連語情報の有効性を確認するためにべた書き文のかな漢字変換における単語分割に関連語情報を適用する実験を行った．

4．べた書き文かな漢字変換の単語分割への適用

4．1　適用方法

前述のように単語単位に分割された一定量の文章より抽出された関連語情報を用いて、関連語情報を抽出した文章とは異なる文章のべた書き文を単語に分割する実験を行った．ここで、実験に使用したシステムは、多段階分割法によるべた書き文かな漢字変換システム[3]である．このシステムでは、べた書き文を最初に少数の手掛り語（キーワード）によって一意に分割し、以後の分割候補を少なくしてから確実性の高いものより順次段階的に分割を進める．そこで、このシステムの１処理段階として「関連語情報による分割」段階を設け、本手法によるべた書き文の単語分割を行った．「関連語情報による分割」は、「カタカナ語による分割」の後、「助詞候補の検出」の前に行われる．本手法のべた書き文かな漢字変換における単語分割への適用手順を以下に示す．

(1) 各解析ルールの付属語を検索する．
(2) 存在した解析ルールＮの付属語に隣接する文字列と読みの一致する関連語の組（Ａ、Ｂ）を関連語辞書中よりすべて取り出す．
(3) 関連語辞書中でＡの関連語としてＢが存在し、ＡとＢの係り受け関係の種類が、Ａ、Ｂを取り出すのに使用された解析ルールＮが示す係り受け関係の種類と一致する場合のみＡ、Ｂをあてはめる．

4．2　関連語情報による単語分割実験

4．2．1　実験方法

資料は、解析ルール辞書を除く初期辞書作成用に「データベース要論」（穂鷹良介著、総文字数63,265文字）を用い、単語分割を行う資料として「情報検索」（中原啓一著、総文字数52,511文字）を用いた．また、解析ルール辞書は係り受け関係解析実験と同じ24の解析ルールを用いた．実験の手順は、まず、べた書き文の状態で文章を入力し、次に、これを関連語情報による分割段階を付加した多段階分割法によるべた書き文処理本体を用いて字種指定ローマ字列に変換し、次いで、これを人手により校正し、この校正されたローマ字列を用いて辞書を自動更新[2]し、次の文章を入力する．

4．2．2　結果と考察

表２に関連語情報による単語分割実験の結果を示す．

表４　関連語情報による単語分割実験結果

資料No	新たな分割数			分割率［%］	
	総分割数	正分割数	誤分割数	正分割率	誤分割率
1	16	15	1	93.8	6.3
2	23	22	1	95.7	4.3
3	19	19	0	100.0	0.0
4	30	30	0	100.0	0.0
5	21	21	0	100.0	0.0
6	28	26	2	92.9	7.1
計	137	133	4	97.1	2.9

関連語情報によるべた書き文の単語分割の精度が、97.1%であることは、べた書き文の単語分割において関連語情報が有効であることを十分示している．しかし、総分割数は 137箇所と少ない値であった．この原因としては、本手法で解析できる係り受け関係を構成する単語がキーワードであることが比較的多く、すでにキーワードとしてあてはめられていたことが挙げられる．また、その他に用いた解析ルールの数が24と少なかったことや、関連語辞書の初期辞書を作成したデータが少なく、見出し語が 1,100語程度であったことが挙げられる．これらは、「関連語情報による分割」段階をさらに上位の階層にすることや使用するルールの数及び関連語辞書を作成する資料を増加することによって改善されるものと考えられる．

5．おわりに

今後さらに、本手法における解析ルールの自動抽出及び本手法の自然言語による文書検索への適用について検討を進める予定である．

＊参考文献

１）吉田　「二文節間の係り受け関係を基礎とした日本語文の構文分析」電子通信学会論文誌 Vol.55-D, No.4, pp.238-244
２）荒木、内田、山田、栃内、永田　「キーワード方式べた書き文かな漢字変換システムにおける付属語情報を用いた単語のあてはめ」情報処理学会第33回全国大会講演論文集　pp.1793-1794
３）荒木、栃内、永田　「多段階分割法によるべた書き日本語文のかな漢字変換」情報処理学会論文誌 Vol.28 No.4 pp.412-421