D-498

3－ｗａｙカテゴリカルデータ解析法によるＤＮＡ配列の解析 －3－ｗａｙ数量化分析Ⅲ類の応用－

Analysis of DNA Sequences by 3-way Categorical Data Analysis - An Application of 3-way Quantification Method Ⅲ -

山ノ井高洋* 荒木健治* 飯田陽一**

Takahiro YAMANOI* Kenji ARAKI* Yôichi IIDA**

*北海学園大学工学部電子情報工学科 **北海道大学理学部化学第二学科

*Department of Electronics and Information Engineering, Faculty of Engineering, Hokkai Gakuen University
**Department of Chemistry, Faculty of Science, Hokkaido University

1．はじめに

遺伝子の塩基配列データ（遺伝情報）は、生物の機能に関する情報を蓄えている生物学的に非常に興味ある信号である。最近、ＤＮＡ一次構造における塩基配列を決定する方法が開発され、いろいろな生物種の遺伝子について塩基配列データが急速に集積されつつある。[1]しかし、遺伝情報の意味や遺伝情報の細胞中での認識の方法については解明されていない。ここでは、鋳型となるべき情報を持つＲＮＡを、ＤＮＡのどの場所からどの程度の量で発現させるのかという制御や位置を決める情報であるスプライス信号配列を解析する。

この塩基配列データはカテゴリカルデータである。これまで、このような観点から、種々の研究が行なわれてきた。これらには、塩基配列をアイテムカテゴリに変換し、数量化Ⅱ類を用いて分析する方法[2]等がある。これに対して本報告では、数量化分析Ⅲ類の拡張である３－ｗａｙカテゴリカルデータ解析法[3]を用いた遺伝子の塩基配列データのスプライス信号配列の解析について述べる。

2．３－ｗａｙカテゴリカルデータ解析法

数量化分析とは質的なデータを数量に表して分析しようとするものである。数量化分析にはⅠ類からⅣ類まである[4]が、ここで用いた数量化分析Ⅲ類は、外的基準を持たない。この分析の対象となるデータは、いくつかの範疇に対して、各個体がどの範疇に反応したかを１または０で示したものである。しかし、数量化分析Ⅲ類では、個体と一つの属性のアイテム・カテゴリーからなる、いわゆる２－ｗａｙデータの解析を目的としている。これに対して一般に得られるカテゴリカル・データは、２つの観点に関したものばかりとは限らない。そこで、数量化Ⅲ類を３つの観点に関したデータも扱えるように拡張した３－ｗａｙカテゴリカルデータ解析法が提案された。ここでは、スプライス信号配列を塩基の配列順序、塩基のカテゴリ、標本を３つの観点とした３－ｗａｙデータとみなし、この手法を適用する。

3．スプライス信号配列解析への応用

３－ｗａｙカテゴリカルデータの３方向の要因をそれぞれ、$X=\{x_1, x_2, \cdots, x_l\}$、$Y=\{y_1, y_2, \cdots, y_m\}$、$Z=\{z_1, z_2, \cdots, z_n\}$と表わす。このとき、三方向の要因に対して、ある規準のもとで数値を与えることを考える。つまり、Ｘについて言えば、x_iとx_jが一定の時に（ｙ，ｚ）面のパターンが互いに類似しているものには近い数値を与える。Ｙ，Ｚについても同様である。

このような、条件のもとで、各セルの出現確率が（セル確率）をp_{ijk}を既知とする。ここで、規準とする３次相関係数は、

$$\rho_{xyz}=(1/3)\sum_i\sum_j\sum_k p_{ijk}(u_i v_j+v_j w_k+w_k u_i) \cdots (1)$$

となる。ここで、

$$u_i=(x_i-\sum_l p_{i..}x_i)/\{\sum_l p_{i..}x_i^2-(\sum_l p_{i..}x_i)^2\}^{1/2},$$

$$v_i=(y_j-\sum_j p_{.j.}y_j)/\{\sum_j p_{.j.}y_j^2-(\sum_j p_{.j.}y_j)^2\}^{1/2},$$

$$w_k=(z_k-\sum_k p_{..k}z_k)/\{\sum_k p_{..k}z_k^2-(\sum_k p_{..k}z_k)^2\}^{1/2},$$

である。式（１）でρ_{xyz}を最大にするu_i，v_j，w_kを求めるには、正規化を行なうと、

$$\sum_{i=1}^{l} p_{i..}u_i^2=1, \quad \sum_{j=1}^{m} p_{.j.}v_j^2=1, \quad \sum_{k=1}^{n} p_{..k}w_k^2=1$$

なので、この問題は、以下の固有方程式を解くことに帰着する。

$$\begin{bmatrix} p_{i..} & p_{ij.} & p_{i.k} \\ p'_{ij.} & p_{.j.} & p_{.jk} \\ p'_{i.k} & p'_{.jk} & p_{..k} \end{bmatrix} \begin{bmatrix} u_i \\ v_j \\ w_k \end{bmatrix} =$$

$$\begin{bmatrix} (1-\lambda_1)p_{i..} & 0 & 0 \\ 0 & (1-\lambda_2)p_{.j.} & 0 \\ 0 & 0 & (1-\lambda_3)p_{..k} \end{bmatrix} \begin{bmatrix} u_i \\ v_j \\ w_k \end{bmatrix}$$

ここで、$p'_{ij.}$、$p'_{i.k}$、$p'_{.jk}$は、$p_{ij.}$、$p_{i.k}$、$p_{.jk}$の転置行列である。また、λ_1、λ_2、λ_3はLagrangeの未定乗数である。

4．スプライス信号配列のデータ

得られたスプライス信号配列の一部を表１に示す。

表１　スプライス信号配列

Ｎｏ	ｸﾞﾙｰﾌﾟ	スプライス信号配列	遺伝子
1	1	ＧＡＧＧＴＧＡＧＧ	人間α－グロビン
2	1	ＡＡＧＧＴＧＡＧＣ	
3	1	ＣＡＧＧＴＴＧＧＴ	人間β－グロビン
4	1	ＡＧＧＧＴＧＡＧＴ	
・	・	・	
・	・	・	
155	1	ＡＧＧＧＴＧＡＧＣ	犬　インシュリン
156	2	ＡＣＡＴＴＴＧＣＴ	人間β－グロビン
157	2	ＣＡＴＴＴＧＣＴＴ	
・	・	・	
・	・	・	
1751	2	ＴＴＴＣＡＴＴＧＣ	

表１でグループ１は、イントロの５’末端を指定する信号である５’－スプライス信号配列を含み、グループ２は、含まない９塩基配列のデータの一部である。表１のデータをカテゴリカルデータにし、３次相関係数を規準として数量化し、カテゴリウェイトを求めることにより２つのグループに分類する。データは２つのグループに分かれることがわかっているので各標本のカテゴリウェイトに対して検定を行ない、分類の妥当性を調べる。

5．おわりに

３つの観点からカテゴリカル・データの解析が行える数量化Ⅲ類の拡張である３－ｗａｙカテゴリカルデータ解析法によりスプライス信号配列を解析する方法について述べた。数量化Ⅱ類の拡張である山ノ井と潘の数量化法[5]を試みることが今後の課題である。

※参考文献

1）GenBank: Genetic Sequence Data Bank, Release 48.0, BBN Laboratories, U.S.A 1987.
2）Y. Iida: DNA sequences and multivariate statistical analysis. Categorical discrimination approach to 5' splice site signals of mRNA precursors in higher eukaryotes' genes, CABIOS, 3, No.2, p93-98, 1987.
3）T. Yamanoi, M. Shimbo, Y. Sato and M. Kawaguti: On the definition of three-way correlation coefficient, TENSOR N. S., 33, No.3, p.343, 1979.
4）岩坪：数量化法の基礎、朝倉書店、pp.67-160、1987.
5）山ノ井、潘：３－ｗａｙデータ数量化の１手法について、北海道大学工学部研究報告、第132号、pp.155、1986.