帰納的学習による文字列中の語の認識

Recognition of Words in Character Strings by Inductive Learning

荒木　健治
Kenji Araki

栃内　香次
Koji Tochinai

北海学園大学
Hokkai-Gakuen University

北海道大学
Hokkaido University

日本語文書を計算機で処理する機会が増大しているが、日本語には分かち書きの習慣がないので、計算機で日本語文書を処理する場合、まず分かち書きを行なわなければならない。この問題に対して、我々は、人間が未知文字列より語を学習する過程を基にした形態素解析手法を提案する。本手法は、未知文字列中に出現する共通パターンより語を帰納的に学習する過程、確実性の高いものより語の尤度を評価して最適な語を選択し語を認識する過程および認識結果と校正済みの認識結果より未登録語や誤りの状況をフィードバック学習する過程よりなる。本手法を用いた性能評価実験により９０％程度の正認識率が得られることがわかり、本手法の有効性が確認された。

1．はじめに

近年、日本語文書を計算機で処理する機会が急激に増大しているが、この際にまず問題となるのが、日本語文をどの様な単位で処理したら良いのかということである。すなわち、日本語には分かち書きの習慣がないので、計算機で日本語文書を処理する場合には、まず分かち書きを行なわなければならない。この分かち書きを、計算機によって行なうための手法として、これまで種々の手法が提案されている[1,2,3]。いわゆる、形態素解析と呼ばれる処理である[4]。これまで提案された形態素解析手法には、辞書を用い、各語の文字長を考慮する方法、字種の情報を利用する方法、文法規則を用いる方法など種々のものがあるが、辞書を用いる方法では辞書の作成に労力が必要であり、さらに、未登録語（辞書に存在しない語）が出現するという問題がある。字種の情報を利用する方法では、その精度に依然として問題が残されている。文法規則を用いる方法では文法を予め情報として与える必要があり、その上、日本語文法には種々のものがあるという問題がある。さらに、文法を用いる方法では会話文に頻繁に現われる文法を逸脱した文に対処できない。

この問題に対して、我々は計算機による自動学習により語を認識する手法を提案する。本手法は、従来の立場である「どのようにしたら形態素解析がうまく行えるか」とは異なり、「人間が未知文字列に遭遇した場合どのように文字列中より語を学習するのか」という観点から開発された。すなわち、人間が未知文字列から語を学習する過程を基にして形態素解析を行なう手法である。したがって、本手法ではまず文字列中に出現する共通パターンに着目することにより、語を推測し、次にその結果の正否より推測した語を修正し、正しい語を文字列中より学習する。この考えに基づいて、本手法は文字列中の共通パターンより語を帰納的に学習する過程、形態素解析過程、人間が誤りを校正することにより正しく分割された文書と、本手法の認識過程により語を認識した文書との比較に基づく正認識および誤認識情報を収集する過程および未登録語をフィードバック学習する過程よりなる。なお、ここで用いている帰納的学習とは、人間が未知の文字列に対して行なうと考えられる、共通パターンより認識単位である語を推測する過程を意味している。このように、本手法は学習により語を自動的に推測し、獲得するので、辞書や文法を予め用意する必要がなく、未登録語を文字列より推測するので、未登録語に対処することができる。また、学習により辞書を自動的に構築していくので、対象分野に適応することができ、辞書の容量を少なくすることができる。また、本手法に基づいて作成された形態素解析システムでは、使用者は学習のために何等特別な作業を行なう必要がない。

本論文では、学習に基づいた未知文字列中の語の認識手法を提案し、本手法に基づいて作成された実験システムにより行なった性能評価実験について述べる。

2．概　要

本手法は２つの学習過程により文字列中より語を認識するものである。一つは、未知文字列中に出現する共通パターンより語を推測する帰納的学習の過程であり、もう一つは、本手法により語単位に分割された文字列中の誤りを人間が校正した正しく語を認識した文字列と本手法により語単位に分割された文字列より正認識や誤認識の状況および未登録語を学習するフィードバック学習の過程である。また、認識の過程では、フィードバック学習された情報と共通パターンより語を推測し、認識を進めていく。

2．1　未知文字列からの語の帰納的学習[5]

次に、未知文字列中に共通に出現するパターンにより語を帰納的に学習する方法の基本概念について述べる。人間は、文書中では語を基本単位として用いてい

るので、共通に出現するパターンは、語である可能性が高いと考えられる。そこで、文字列中に共通に出現するパターンを語と推測することができる。

これを、図１の例で説明すると、「連続音声認識とは」の時点では語を認識することはできないが、後に「連続、音声、認識」が単独で使用されているので「連続音声認識」は「連続、音声、認識」という語に分割できることが推測される。しかし、実際には複合語や語ではないものも抽出されるので、この段階で取り出される語は、語の可能性がある文字列（語切片）である。以後、このような語切片を Word Segments と呼び、ＷＳと表記する。

連続音声認識とは連続した音声を認識することである。

図１　共通パターンによる語の帰納的学習の例

２．２　語の推測と認識

語を帰納的に認識した結果を基にして漢字かな混じり文を語単位に分割する。この際には、抽出された語を確実性の高いものより順に４つの段階に分けて認識を行なう。これは、２．３で述べる正しい認識結果から得られた語を最も確実性の高い語として、帰納的学習で得られた語より前に認識を行なう。また、２．１で述べた帰納的学習によって抽出されたＷＳはその抽出段階によって３つのクラスに分類されているので、これらのクラスの確実性の高い順に認識を行なう。

２．３　正しい認識結果からのフィードバック学習

２．２で述べたようにして得られた認識結果とそれを人間が校正した結果を用いて、フィードバック学習を行なう。これは、認識誤りや未登録語を学習することにより次からの認識を正確に行なうものである。具体的には、未登録語は辞書に登録し、正認識を行なった語の尤度を上昇させ、誤認識を行なった語の尤度を下げるものである。この段階で、抽出された語は、正しい語であることがわかっているので Correct Words と呼び、ＣＷと表記する。

３．処理過程

３．１　帰納的学習

まず、入力文字列中より共通に出現するパターンを取り出し、語の可能性がある文字列を取り出す。

３．１．１　文字列中からの共通パターンの抽出

まず、初めに文書中から共通部分を取り出す。これは、文書を任意の長さに切り出して、文書中に複数回出現する部分を取り出すものである。このようにして取り出された文字列を Segments １と呼び、Ｓ１と表記する。この際には、２文字以上のもののみをＳ１として抽出している。なお、一字の語については、４．１．４で述べる。また、この際には、文字列中に共通パターンとして出現した回数を出現頻度として記録しておく。この例を、図２（２）に示す。ここで、上述のような基準でＳ１を取り出すと、図２（２）には、「連続音、声認識」等のように「連続音声、音声認識」を中途で分割した形の語がＳ１として抽出されてしまう。これは、Ｓ１が第１段階の共通パターンの抽出であり、一つのＳ１の中に複数の語が含まれる可能性があるので、ある共通パターンがすべての出現位置で別の共通パターンに含まれてしまう場合には、その共通パターンはＳ１として抽出しないという規則を設けるができ、このような誤りを防ぐことができる。したがって、「連続音声、音声認識」がＳ１として抽出され、「連続音、声認識」は抽出されない。すなわち、共通パターンが重複した場合には、最も文字数の多いＳ１が抽出されることになる。

（１）例文
　連続音声認識では連続音声を認識している。しかし、単音節音声認識では単音節ごとに認識する。

（２）Ｓ１の抽出結果
　連続音声(2)、認識(4)、音声認識(2)
　では(2)、単音節(2)

（３）Ｓ２、Ｓ３の抽出過程
(音声認識(2)、認識(4))→音声：Ｓ３(2)<自立語>
　　認識：Ｓ２(4)<自立語>
(連続音声(2)、音声(2))→連続：Ｓ３(2)<自立語>
　　音声：Ｓ２(4)<自立語>
では　　Ｓ１(2)<付属語>

（４）ＷＳの抽出結果
　Ｓ１：　では(2)<付属語>、単音節(2)<自立語>
　Ｓ２：　音声(4)<自立語>、認識(4)<自立語>
　Ｓ３：　連続(2)<自立語>

注）（）内の数字は出現頻度を表わす。
　　<　>内は品詞を表わす。

図２　ＷＳの抽出の例

３．１．２　文字列中の共通パターンからの高次共通パターンの抽出

次に、Ｓ１同士の共通パターンによりＳ１を分解する。これは、Ｓ１が複数の語を含む可能性があるので、Ｓ１同士の共通部分が語である可能性が高いためである。この場合にも、２文字以上の共通パターンのみを取り出している。一字語の処理については３．１．４で述べる。また、この際には共通の部分を Segment 2 と呼んで、Ｓ２と表記し、残りの部分を Segment 3 と呼び、Ｓ３と表記する。また、分解されたＳ１は削除される。したがって、ＷＳはＳ１、Ｓ２、Ｓ３の３つのクラスに分類される。なお、ＷＳの抽出の段階で、前回の学習によりすでにＳ１、Ｓ２、Ｓ３が存在する場合には、新たに入力されたＳ１と既存のＷＳの間で共通パターンを検出することにより、新たなＳ１、Ｓ２、Ｓ３を抽出する。また、新たなＷＳの中にＣＷと同一のものがあれば、これをＷＳより削除する。なお、この際には、Ｓ２、Ｓ３を抽出する基になったＳ１中の出現頻度をＳ２、Ｓ３の出現頻度として記録してお

く。図２（３）、（４）にこの例を示す。

３．１．３　品詞の推測

ＷＳを抽出する段階で、同時に品詞の推測を行なう。この段階で得られた品詞は推測であるので、誤りを含んでいるが、これらは、３．３で述べるフィードバック学習の段階で、誤認識度数が上昇し、最後には尤度評価関数の値が低くなり、ＷＳ中より削除されてしまう。このような仕組みにより、品詞を正確に決定することができるようになる。したがって、ここで行なう品詞の推測は精密なものでなく、大まかな予測で十分である。これは、人間は知識が不十分な状態では大まかな予測を行い、その誤りを修正されることにより、正確な品詞の決定ができるようになることに対応している。ここでは、品詞分類を自立語、付属語、接頭語、接尾語、活用語尾の５種類に限定して品詞の推測を行なう。より詳細な品詞分類を行なうことも可能であるが、これについては、別の機会に述べたい。以下に品詞推測の方法を示す。

（１）接辞…ＷＳ同士の共通パターンの抽出の際に、共通パターン以外の部分が一字の漢字語の時
　①接頭語…共通パターン以外の部分が前に存在する場合
　②接尾語…共通パターン以外の部分が後ろに存在する場合
（２）付属語…すべてひらがな書きの語
（３）活用語尾…ＷＳ同士の共通パターンの抽出の際に、共通パターン以外の部分が一字のひらがな語で「を、の、は、に、が、と、や、で、も、へ、て、ば、か」以外の語
（４）自立語…（１）（２）（３）以外の語

このような方法で、品詞の推測を行なうと、すべてひらがな書きの自立語、２文字以上の活用語尾などは、誤って品詞を推測してしまう。しかし、この段階では、このような誤りを防ぐためには、情報が不十分なので、前述のような推測を行なわざるを得ない。しかし、このような誤りは３．２で述べるフィードバック学習により、次第に訂正される。品詞の推測の例を図２（３）、（４）に示す。

３．１．４　一字語の処理

３．１．１、３．１．２で述べたように共通パターンの抽出の際には２文字以上共通である場合に限り共通パターンとして抽出している。しかし、一字の語も両側がその一字の語と異なる字種で囲まれている場合に限り共通パターンとして抽出している。これは、一字の語が出現する場合には、「一字の語が」の「語」のように、両側が異なる字種で囲まれて用いられる場合が多いためである。原則として日本語では漢字一字でも意味を持つので、すべての漢字は一字語になってしまう。しかし、実際にすべての漢字を一字語として用いるわけではない。そこで、一字の語として単独で用いられたことを確認するための基準としてこのような規則を設けている。

４．１．５　重複した場合の処理

共通パターンを抽出する際に共通パターンが重複して出現することが頻繁に起こる。この際には、重複している共通パターンの中から適当と思われるものを選ばなければならない。この選択の方法を以下に示す。

（１）尤度評価値（ＬＥＶ：Likelihood Evaluation Value）の大きいもの。
　尤度評価値（ＬＥＶ）は以下の尤度評価関数（ＬＥＦ：Likelihood Evaluation Function）により算出される。
　$LEF = \alpha CF + AF - \beta EF$
　ＣＦ：Correct Frequency（正認識度数）
　ＡＦ：Appearance Frequency（出現頻度）
　ＥＦ：Erroneous Frequency（誤認識度数）
　α、β：係数
（２）誤認識度数（ＥＦ）の少ないもの。
（３）正認識度数（ＣＦ）の大きいもの。
（４）出現頻度（ＡＦ）の大きいもの。
（５）文字数の多いもの。
（６）分割が前のもの。
（７）任意

ここで、ＡＦは３．１．１、３．１．２で述べたＷＳの抽出過程および校正済みの認識結果中に出現した頻度で、ＣＦ、ＥＦは３．２で述べるフィードバック学習でカウントされるものである。詳細については、３．３で述べる。

３．２　語の認識

入力文字列中の共通パターンにより学習されたＷＳと校正済みの認識結果より得られたＣＷを用いて、漢字かな混じり文中の語を認識する。

３．２．１　認識方法

確実性の高いものより順に認識を行なう。以下に、その手順を示す。

（１）ＣＷによる認識
（２）ＷＳによる認識
　①Ｓ２による認識
　②Ｓ１による認識
　③Ｓ３による認識

各段階では、文字列の表記が一致したものを認識したものとして固定する。次の段階では、残りの未認識の部分を対象として認識を行なう。なお、表記の一致は原則として、２文字以上の文字が一致した場合に認識したものとして固定する。一字語の処理については、３．２．２で述べる。図３に認識の例を示す。また、図４に辞書の構造を示す。図３の（３）は使用者が用いる形態素解析結果で、どの段階で認識されたかの情報は付加されていない。（４）はシステムが内部表現として記憶しているもので、どの段階で認識されたか

を示す記号が付加されている。使用者は、（３）の結果に誤りがあれば、修正する。この際に、同時に内部表現である（４）をシステムが自動的に修正することにより３．３で述べるフィードバック学習が可能となる。

（１）入力文字列

解析ルールは人手によって文書中より取り出す。

（２）辞書の内容

①ＣＷ				
解析	205	21	0	自立
ルール	4	0	0	自立
抽出	84	18	0	自立
に	367	224	3	付属
中	11	2	0	接尾
は	262	107	0	付属
②Ｓ２				
人手	2	1	0	自立
よって	4	3	0	付属
③Ｓ１				
取り出す	15	9	5	付属
④Ｓ３				
より	95	35	2	付属

（３）認識結果

/解析//ルール/¦は¦/人手/¦に¦¦よって¦文章
<中>¦より¦/取り出す/。

/ /: 自立語　¦ ¦: 付属語　< >: 接尾語

（４）認識結果の内部表現

¥解析¥¥ルール¥+は+/人手/+に+$よって$文章
`中`@より@[取り出す]。

¥ ¥: ＣＷの自立語　　+ +: ＣＷの付属語
` `: ＣＷの接尾語　　/ /: Ｓ２の自立語
$ $: Ｓ２の付属語　　[ ]: Ｓ１の自立語
@ @: Ｓ３の付属語

図３　語の認識の例

1	30	35	40	45	55 58byte
表記	ＡＦ	ＣＦ	ＥＦ	空	ＰＳ

・ＡＦ:　Appearance Frequency（出現頻度）
・ＣＦ:　Correct Frequency（正認識度数）
・ＥＦ:　Erroneous Frequency（誤認識度数）
・ＰＳ:　A part of speech（品詞）
　自立語　：自立　　付属語　：付属
　接頭語　：接頭　　接尾語　：接尾
　活用語尾：語尾

図４　辞書の構造

３．２．２　一字語の処理

各段階では、２文字以上の文字が一致した場合に認識したものとしているが、一字の語も両側がその一字の語と異なる字種で囲まれている場合、あるいは認識済みの語で囲まれている場合に限り、一字の語でもその語を認識したものとして固定する。異なる字種で両側が囲まれているかどうかの検査は各段階ごとに行なうが、認識済みの語で囲まれているかどうかの検査は、ＣＷからＳ３まで認識した後にＣＷ、Ｓ２、Ｓ１、Ｓ３の順に行なう。

３．２．３　尤度の評価と品詞の決定

この認識の過程で語が同一文字列に重複して認識された場合の最適なものを選択する手法は、３．１．５と同様である。また、認識する際には辞書中に付加されている品詞情報を参照して品詞を決定する。

３．３　フィードバック学習

次に、システムにより認識された結果とそれを人間が校正した正しい認識結果とを用いて、認識誤りや未登録語を学習するフィードバック学習を行なう。認識誤りの状況を把握するために、内部表現としてどの段階で認識されたかを付加した文字列を記憶しておく。一方、使用者は語単位の認識状況（品詞の識別を含む）が付加された文書を修正する。この際に、同時に内部表現をシステムが自動的に修正することにより、辞書を更新することができる。

３．３．１　形態素解析の方針

今回行なった形態素解析の方針を以下に列挙する。

（１）品詞分類は自立語、付属語、接頭語、接尾語、活用語尾の５種類に限定する。
（２）分割の単位は短単位である。
（３）接辞はできるだけ分離する。
（４）活用語尾は自立語活用語尾のみとする。
（５）用言は原則として変化しない部分を基準として分割する。したがって、語幹は不変化部分とする。
（６）記号のうちで、まとまって意味を持つもの、あるいは慣用的に良く使用されるものについては一つの自立語とする。
（７）「いる、ある、ない、した、する」等は補助用言であるが、付属語的にしようされるので付属語とする[6]。
（８）「的に、的な、同様に」などの形容動詞は「名詞（的、同様）＋付属語（に、な）」とする。
（９）接続詞は一つの自立語とする。

このような基準により認識結果を修正する。

３．３．２　正認識の場合の処理

認識結果が正認識であった場合の処理について述べる。ここで、正認識とは認識結果と校正済みの認識結果が認識の位置と品詞が一致している場合である。この場合には、以下のような処理を行なう。

（１）認識した語の所属をＣＷとする。
（２）認識した語のＣＦ（正認識度数）とＡＦ（出現頻度）を１増加する。

図５（１）（２）に図３の例を修正した結果をしめす。図３の例ではＳ２に所属していた「人手、よって」、Ｓ３に所属していた「より」は正認識であったのでＣＷの所属となる。また、図５の（３）に示すように辞書も図３の（２）に比べて、正認識であった「解析、ルール、抽出、に、中、は、人手、よって、より」は出現頻度と正認識度数が１増加している。

3．3．3　誤認識の場合の処理

認識結果が誤認識である場合の処理について述べる。ここで、誤認識とは認識結果と校正済みの認識結果が認識の位置あるいは品詞が異なる場合である。この場合には、以下の処理を行なう。

（１）正しい語の処理

①正しい語が辞書に存在しないときはＣＷにＡＦを１にして登録する。

②正しい語が辞書に存在するときはＡＦを１増加させる。また、その語の所属がＣＷ以外の時はＣＷに変更する。

（２）誤った語についてはＥＦを１増加させる。

図３（３）の例では、「/取り出す/」が誤っていたので、図５（１）に示すように修正される。これにともない、図３（３）の内部表現は図５（２）の「[*取り出**す*]」のように誤認識の記号が付加される。したがって、図５（３）のように「取り出、す」がＣＷに登録され、「取り出す」のＥＦが１増加される。

（１）校正後の認識結果

/解析//ルール/¦は¦/人手/¦に¦¦よって¦/文章/<中>¦より¦/取り出/$す$。

/ /: 自立語　　¦ ¦: 付属語

< >: 接尾語　　$ $: 活用語尾

（２）校正後の誤りの情報を含む認識結果内部表現

¥解析¥¥ルール¥+は+/人手/+に+$よって$?文章?`中`@より@[*取り出**す*]。

¥ ¥: ＣＷの自立語　　+ +: ＣＷの付属語

` `: ＣＷの接尾語　　/ /: Ｓ２の自立語

$ $: Ｓ２の付属語　　[ ]: Ｓ１の自立語

@ @: Ｓ３の付属語

＊＊: 誤認識　　？？: 未認識

（３）フィードバック学習後の辞書

①ＣＷ				
解析	206	22	0	自立
ルール	5	1	0	自立
抽出	85	19	0	自立
に	368	225	3	付属
中	12	3	0	接尾
は	263	108	0	付属
人手	3	2	0	自立
よって	5	4	0	付属
より	96	36	2	付属
＊文書	1	0	0	自立
＊取り出	1	0	0	自立
＊す	1	0	0	語尾
③Ｓ１				
取り出す	15	9	6	付属

＊: 新たに登録された語

図５　フィードバック学習の例

3．3．4　未認識の場合の処理

未認識の場合には、以下の処理を行なう。

（１）正しい語が辞書に存在しないときはＣＷにＡＦを１にして登録する。

（２）正しい語が辞書に存在するときはＡＦを１増加させる。また、その語の所属がＣＷ以外の時はＣＷに変更する。

図５（２）に示すように「文書」が未認識であり、図３（２）に示すように辞書中にも存在しなかったので、ＣＷに「文書」をＡＦを１にして登録する。

3．3．5　尤度評価関数による所属クラスの制限

以上のような処理が終了した後に、ＷＳを対象として尤度評価関数による所属クラスの制限を行なう。これは、共通パターンとして抽出されたＷＳの認識能力を評価して適正なものをＷＳに残すためである。以下の基準で尤度評価関数による所属クラスの制限を行なう。

①　０＜ＬＥＶ　　の時はＳ２に所属する。

②－５＜ＬＥＶ≦０　の時はＳ１に所属する。

③－10＜ＬＥＶ≦－５の時はＳ３に所属する。

④　　ＬＥＶ≦－10の時はＷＳより削除する。

3．3．6　品詞情報の処理

以上の処理で未登録語を辞書に登録する場合、辞書中に存在しない語とは、表記あるいは品詞が異なる場合である。したがって、表記が同じで品詞が異なる語が辞書中に存在する。日本語には多品詞語が存在するので、同一表現で品詞の異なる語は確かに存在する。しかし、ＷＳの抽出過程で品詞の推測を行なっているので、誤った品詞属性を付加された語もＷＳには存在する。これらの語は、未登録語を辞書に登録する段階では判断できない。そこで、誤った品詞属性を付加された語を削除する方法としては、実際に認識を行なった段階で３．３．５で述べた尤度評価関数による評価により誤りを頻繁に起こす語として辞書から削除する形を取る。

4．性能評価実験

本手法による実験システムを作成し、性能評価実験を行なった。

4．1　実験方法

4．1．1　実験に用いた資料

実験に用いた資料は表１に示す情報処理に関する論文４編（総文字数３５，８６７文字）である。これらの文献を各章ごとに２０に分割して、実験を行なった。なお、この分割された資料の文字数は５７７文字から５０３０文字の間である。

4．1．2　実験手順

以下の手順により、性能評価実験を行なった。なお、初期辞書は全く空の状態から行なった。

（１）帰納的学習によるＷＳの抽出

①入力文字列よりＳ１を抽出する。

②Ｓ１よりＷＳを抽出する。なお、既存のＷＳがすでに存在する場合は、既存のＷＳと新たなＳ１よ

りＷＳを抽出する。
③ＣＷ中に存在するＷＳをＷＳより削除する。
（２）語の認識
・文字列中の語を認識する。
（３）認識結果の校正
・人手により認識結果の誤りを校正する。
（４）フィードバック学習
・校正済みの認識結果と認識結果より誤りの状態を学習する。
①正認識の語の処理
②誤認識の語の処理
③未認識の語の処理
④ＷＳの尤度評価関数による所属クラスの検定
（１）から（４）の手順を２０回繰り返した。

表１　実験に用いた資料

1．題名：音声認識における誤りの段階的復元手法
著者：荒木健治、栃内香次
出典：北海学園大学工学部研究報告第16号
総文字数：９，２０１文字
2．題名：日本語文の表層レベルでの浅い解析
著者：荒木健治、栃内香次
出典：北海学園大学工学部研究報告第16号
総文字数：７，３３３文字
3．題名：付属語パターンを用いたルールによる表層レベルでの係り受け関係の解析
著者：荒木健治、栃内香次
出典：情報処理学会自然言語処理研究会68-6
総文字数：８，０１２文字
4．題名：多段階分割復元法による誤りの多い文字列からの原文の復元
著者：荒木健治、宮永喜一、栃内香次
出典：情報処理学会論文誌、第３０巻、第２号
総文字数：１１，３２１文字

合計　　３５，８６７文字

４．２　評価方法

４．２．１　評価内容

評価は以下の３点について行なった。
（１）認識位置の精度
認識された語が正しい位置で認識されているかを評価する。この際には、品詞が正しく認識されているかは無視する。
（２）品詞と認識位置の精度
認識された語が正しい位置で認識され、しかも品詞が正しく認識されているかを評価する。
（３）品詞推定の精度
認識位置が正しい語のうちどの程度の割合で品詞を正しく推定できたかを評価する。

４．２．２　評価式

評価式は以下の３式を用いる。網羅率とは文字列中に存在する語のうちのどの程度の語を認識の対象とすることができたかを表わす。また、正認識率は認識した語のうちのどの程度の語を正しく認識したかを表わし、誤認識率は認識した語のうちのどの程度の語を誤って認識したかを表わす。

$$\text{網羅率} = \frac{\text{正認識語数} + \text{誤認識語数}}{\text{総語数}}$$

$$\text{正認識率} = \frac{\text{正認識語数}}{\text{正認識語数} + \text{誤認識語数}}$$

$$\text{誤認識率} = \frac{\text{誤認識語数}}{\text{正認識語数} + \text{誤認識語数}}$$

４．３　実験結果

４．２で述べた評価方法により実験システムの性能を評価した。表２に性能評価実験の結果を示す。評価は、４．２．１で述べたように、認識位置の精度、認識位置と品詞の精度、認識位置の正しい語のうちでどの程度の品詞を正しく推定できたかを表わす品詞推定の精度について評価した。評価の単位としては、ＣＷ、ＷＳおよび総合で、ＷＳについては、さらに、Ｓ２、Ｓ１、Ｓ３に分けて評価した。また、各項目は品詞別に評価している。

４．４　考　察

４．４．１　網羅率について

まず、表２より網羅率について見てみると、９３．５％を網羅していることがわかる。特に、自立語、付属語、活用語尾はどれも９０％以上を示しているが、接頭語、接尾語といった接辞では８０％以下になっている。これは、接辞は一字語であるので、一字語の処理に問題があるものと思われる。これについては、４．４．５で述べる。また、ＣＷが約８５％、ＷＳが約８％であるので大部分はＣＷによって認識されていることがわかる。これは、表３に示すように、最終的な辞書の登録語数がＣＷが大部分を占めているためである。これは、ＣＷに存在するＷＳを削除したためである。しかし、ＷＳが未登録語に対処するために抽出されたことを考えると、ＣＷによる未認識である１４．８％のうちの５６．１％を網羅していることになり、良好な結果といえる。

表３　最終的な辞書の登録語数

ＣＷ：１３８２語　　Ｓ２：１５３語
Ｓ１：　５４語　　Ｓ３：　７４語

４．４．２　認識位置の精度について

次に、認識位置の精度についてみると、総合では正認識率は９１．５％で良好な値である。しかし、ＷＳの正認識率は６１．３％でＣＷが９４．４％であるのに比べると悪い値になっている。これは、ＣＷで認識した部分は比較的認識しやすい部分であるのに対して、ＷＳは一字の語である接頭語、接尾語、表記に揺れがある活用語尾などが多かったためであると考えられる。

表２　認識結果の評価

			網羅率	認識位置の精度		認識位置と品詞の精度		品詞推定の精度	
				正認識率	誤認識率	正認識率	誤認識率	正認識率	誤認識率
ＣＷ		自立語	８３．４	９２．３	７．７	９２．０	８．０	９９．６	０．４
		付属語	９０．２	９７．９	２．１	９６．８	３．２	９８．９	１．１
		接頭語	６２．４	１００．０	０．０	８２．９	１７．１	８２．９	１７．１
		接尾語	６３．４	１００．０	０．０	８３．７	１６．３	８３．７	１６．３
		活用語尾	７５．０	８５．６	１４．４	６５．６	３４．４	７６．７	２３．３
		計	８５．２	９４．４	５．６	９２．９	７．１	９８．４	１．６
ＷＳ	Ｓ２	自立語	５．６	７５．２	２４．８	５８．５	４１．５	７７．９	２２．１
		付属語	４．５	４２．４	５７．６	４２．１	５７．９	９９．３	０．７
		接頭語	１１．１	１００．０	０．０	１１．５	８８．５	１１．５	８８．５
		接尾語	７．５	１８．８	８１．３	０．０	１００．０	０．０	１００．０
		活用語尾	１２．１	１７．９	８２．１	２．４	９７．６	１３．３	８６．７
		計	５．５	６０．６	３９．４	４７．２	５２．８	７８．０	２２．０
	Ｓ１	自立語	２．３	７１．９	２８．１	６７．２	３２．８	９３．４	６．６
		付属語	１．０	３１．１	６８．９	２９．７	７０．３	９５．７	４．３
		接頭語	２．６	６６．７	３３．３	０．０	１００．０	０．０	１００．０
		接尾語	１．４	０．０	１００．０	０．０	１００．０		
		活用語尾	２．６	１６．７	８３．３	０．０	１００．０	０．０	１００．０
		計	１．８	５９．９	４０．１	５４．２	４５．８	９０．６	９．４
	Ｓ３	自立語	１．２	８３．２	１６．８	７３．０	２７．０	８７．７	１２．３
		付属語	０．４	１５．４	８４．６	１５．４	８４．６	１００．０	０．０
		接頭語	４．３	１００．０	０．０	４０．０	６０．０	４０．０	６０．０
		接尾語	４．７	２０．０	８０．０	２０．０	８０．０	１００．０	０．０
		活用語尾	１．４	２０．０	８０．０	２０．０	８０．０	１００．０	０．０
		計	１．０	６８．４	３１．６	５８．０	４２．０	８４．８	１５．２
	総合	自立語	９．１	７５．４	２４．６	６２．６	３７．４	８３．０	１７．０
		付属語	５．９	３８．８	６１．２	３８．４	６１．６	９８．８	１．２
		接頭語	１７．９	９５．２	４．８	１６．７	８３．３	１７．５	８２．５
		接尾語	１３．６	１７．２	８２．８	６．９	９３．１	４０．０	６０．０
		活用語尾	１６．１	１７．９	８２．１	３．６	９６．４	２０．０	８０．０
		計	８．３	６１．３	３８．７	５０．０	５０．０	８１．６	１８．４
総合		自立語	９２．５	９０．７	９．３	８９．１	１０．９	９８．２	１．８
		付属語	９６．０	９４．３	５．７	９３．２	６．８	９８．９	１．１
		接頭語	８０．３	９８．９	１．１	６８．１	３１．９	６８．８	３１．２
		接尾語	７７．０	８５．４	１４．６	７０．１	２９．９	８２．１	１７．９
		活用語尾	９１．１	７３．６	２６．４	５４．７	４５．３	７４．２	２５．８
		計	９３．５	９１．５	８．５	８９．１	１０．９	９７．４	２．６

注）単位は％

また、ＣＷは人間が校正した文字列より取り出されているので正しい語であることは確実であるが、ＷＳは未登録語を文字列中の共通パターンより予測しているので、語とは言えないものの含まれている。したがって、このような結果になったものと考えられる。しかし、ＷＳはＣＷによって未登録であった１４．８％のうちの５６．１％を網羅し、そのうちの６１．３％を正しく認識しているので、ＣＷによる未認識の語のうちの３４．４％の未認識の語を正しく認識したことになる。

４．４．３　認識位置と品詞の精度について

次に、認識位置と品詞の精度についてみると、総合では正認識率は８９．１％でさほど認識の一致だけを見た場合と変わってはいない。また、ＣＷも９２．９％でさほど低下していないが、ＷＳは５０．０％と１１．３％も低下している。特に、Ｓ１の接頭語、接尾語、活用語尾は１００％誤ってしまっている。これは、Ｓ１はＷＳの抽出の際に分解されるので、ＷＳの抽出で行なう品詞推測の際に、接辞や活用語尾になる条件の一つである「共通パターンを除いた残りの部分」を満たすことはない。そのため、Ｓ１に存在する接辞および活用語尾は尤度評価関数の検定によりＳ２から落ちてきた語である。したがって、接辞および活用語尾については、誤りを起こすことが多い語がＳ１に存在することになる。これは、尤度評価関数の検定によってＬＥＶが低い場合に、その語の所属するクラスを下位にするのではなく、ＷＳより削除するという方法を取ることにより解決されると考えられる。

４．４．４　品詞推定の精度について

次に、品詞推定の精度であるが、全体としては正認識率は９７．４％で、良好な値を示している。これは、大部分の認識を行なっているＣＷが、多品詞語を除い

て複数の品詞の可能性がないので、９８．４％という高い正認識率を示したためである。一方、ＷＳも品詞推定においては、ＷＳを抽出する際の少ない手掛りから推定したことを考慮すれば、８１．６％と良好な値を示しているといえる。

４．４．５　誤りの傾向と原因について

図６に誤りの例を示す。また、表４に図６で用いられている記号の意味を示す。まず、問題となるのは、図６（１）に示すように、数字や記号である。これは、例えば「１９８９と１９８８」が未登録語であり、この資料中よりＷＳを抽出すると「１９８」が取り出されてしまう。これは、共通パターンを抽出する際に、字種によらず２字以上の語を抽出しているためであると考えられる。すなわち、漢字は表意文字であり、一字でも意味を持つが漢字以外の語は持たないので、漢字と漢字以外の文字（ひらがな、カタカナ、記号、数字）では、１文字が持つ意味が異なるということである。そこで、漢字以外の語は２字あるいは３字の時に現在行なわれている一字語の処理を行なうことが考えられる。

また、図６（２）は、初めて出現し、しかもＷＳを抽出する資料中に一度しか出現しない人名などの語である。これは、共通パターンによりＷＳを抽出しても未登録語になってしまう。この問題に対しては、このような未認識が連続して起きることは考えにくいので、認識済みの語で囲まれた部分の漢字語を自立語とするといったＣＷやＷＳとは異なった観点からの認識状態からの推測による認識を行なう方法が考えられる。

次に、図６（３）は「多」の問題であるが、これは、「多い」という形容詞の語幹であり、「多段階」といった場合の接頭語でもあるといった多品詞語である。現在の処理ではこのように重複した場合は３．２で述べた方法でどちらかに決定しているが、「多い」と「多段階」では、明らかに後続する文字が異なっている。今後は、このような情報の利用も必要であろう。

次に、図６（４）は、付属語の認識位置の誤りである。日本語においては、特に付属語が連続して出現する場合の分割は前後の状態によって異なり、単独の語では決定しにくい。やはり、この場合も前後の文字列を考慮する必要があると考えられる。

図６（５）は、漢字とひらがな混じりの語の認識誤りである。この例で、「取り出す」という語は「取る、出す」の語幹としての「取、出」があるので、重複した場合の処理により「取り出」が選択されず、「取、出」が選択されてしまっている。これは、尤度評価関数を用いた場合、語数の少ない語は出現頻度が高いので、有利になってしまうということが原因と考えられる。このような語は、誤認識度数が増加するので、次第に、尤度が低くなり「取り出」が優先されるようになるので、使用につれて解決されるが、「取、出」の尤度が低くなると「取る、出す」といった語が出現した場合に誤る可能性が高くなってしまう。したがって、重複した場合に文字数の長いものを優先する段階をもう少し上位の段階で行なう必要があると考えられる。

５．おわりに

人間が未知文字列から語を学習する過程を基にした形態素解析手法を提案し、その性能評価実験を行なった結果について述べた。実験の結果９０％程度の精度で語を認識することができることが確認された。これは、本手法の有効性を示しているものと考えられる。

今後の課題としては、認識する際に現在は用いていない前後の文字列の状態の利用や本方式の本質的な問題といえる処理時間の増大を減少させる方法を検討することが挙げられる。

（１）数字、記号の誤り
¥pp.¥¥*17¥93¥－¥¥17¥94*¥*（¥198¥6）*

（２）初めて出現し、しかも資料中に一度しか出現しない人名などの語
¥¥荒木¥¥健治¥、¥内田¥?幸司?、¥山田¥?洋志?、¥栃内¥¥香次¥、¥永田¥¥邦一¥

（３）一字語の品詞の誤り
¥{多}¥¥段階¥¥分割¥?法??に?+よる+¥べた書き¥¥文¥¥かな¥¥漢字¥¥変換¥¥システム¥¥5）¥+で++ある+。

（４）付属語の認識位置の誤り
¥関連¥¥語¥¥情報¥+を+¥*用¥$い**て*$、¥べた書き¥¥文¥+を+¥単語¥+に+¥分割¥+する+¥実験¥+を+¥行¥$*っ**た*$。

（５）漢字とひらがな混じりの語の認識誤り
¥すべて¥¥*取¥+り+/出*/-す-。
¥*係¥+り+¥受け*

図６　誤りの例

表４　記号の意味

	自立語	付属語	接頭語	接尾語	活用語尾
CW	¥ ¥	+ +	: :	` `	- -
S2	/ /	$ $	# #	& &	( )
S1	[ ]	< >	% %	^ ^	_ _
S3	¦ ¦	@ @	! !	~ ~	; ;

＊＊: 誤認識　？？: 未認識　｛｝: 品詞の誤り

参考文献

１）建石、小野、山田: DictionとStyleの日本語化について、第31回情報処理全国大会講演論文集、pp.1381-1382(1985).

２）藤崎、亀田: 新聞記事データを対象とする自動単位切り処理とそれに基づく語彙調査、情報処理学会自然言語処理研究会報告、NL51-2(1985).

３）吉村、武内、津田、首藤: 未登録語を含む日本語文の形態素解析、情報処理学会論文誌、Vol.30, No.3, pp.294-301(1989).

４）中野、野村: 日本語の形態素分析、情報処理学会誌、Vol.20, No.10, pp.857-864(1979).

５）荒木、栃内: 文字列中の共通パターンを用いた語の認識、平成元年度電気関係学会北海道支部連合大会講演論文集、pp.327-328(1989).

６）長尾　真: 日本語情報処理、電子情報処理学会編、pp.107-108(1984).