多段階分割復元法を用いた連続音声認識の誤りの復元

Recovery of Errors in Continuous Speech Recognition Using Multi-Stage Segmentation and Recovery Method

堤　正勝[T]　荒木健治[TT]　宮永喜一[T]　栃内香次[T]

Masakatsu Tsutsumi[T]　Kenji Araki[TT]　Yoshikazu Miyanaga[T]　Koji Tochinai[T]

[T] 北海道大学　[TT] 北海学園大学

[T] Hokkaido University　[TT] Hokkai-Gakuen University

我々は、先に誤りを含む単音節認識の結果から、文章中の単語出現状況により正しい文を復元する手法を提案し、この手法を用いた実験システムを作成して、その有効性を確認した。一方、より実用的な連続音声認識を目的とし、音声を音素単位に分割して認識する手法の研究も行っている。本報告では、上記の手法を音素分割による連続音声認識に適用し、単音節認識では現れない、音素単位の付加・脱落などの誤りに対処できる、文書中の単語出現状況を利用した復元手法を提案する。

1．はじめに

文章を計算機に入力する手段として現在ではキーボード入力が主流である。しかしながら、キーボード操作にはある程度の熟練を要し、誰でも気軽に文章を入力するわけにはいかない。パーソナルコンピュータの普及により多くの人が計算機に触れるようになった今日、より簡単な方法としての音声認識による入力が望まれている。しかし、現時点では膨大な語彙を含む一般文章に対して連続音声認識を行うことは困難である。

そこで我々は、連続音声を音素単位に分割[1]し、音素単位でおおまかな認識を行い、言語処理の段階で統計的な手法により曖昧さを除去する手法を提案する。

なお、我々はこれまで単音節単位での認識誤りを修正するために、多段階分割復元法[2]と呼ばれる手法を提案し、システムを構築し、その有効性を報告している。この多段階分割復元法をもとにして、連続音声の分割結果の音素列を対象としたときに生じる問題（付加、脱落）に対処できる新たな手法を提案する。

2．多段階分割復元法

2．1　概要

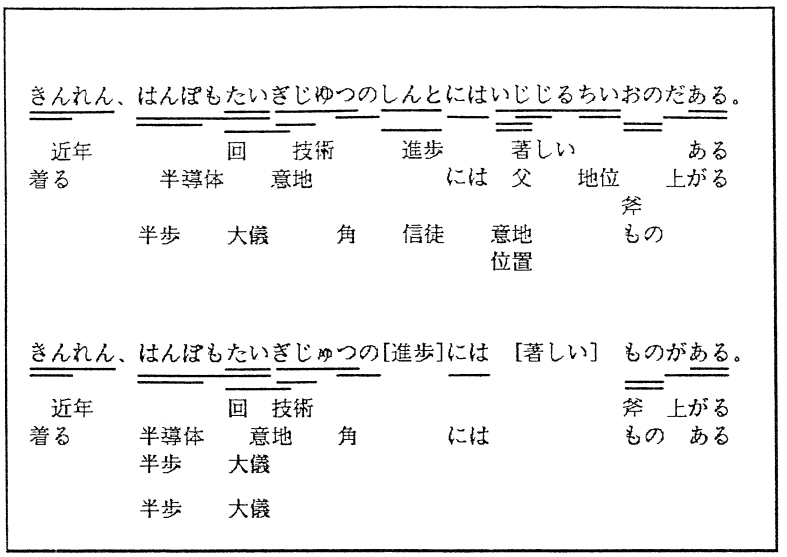


図2．1　語のあてはめによる単語候補の減少

誤りを含む文字列の分割、復元をするにあたって問題となる点は、文字レベルの曖昧さのために候補文字が多数となり、更にこれらの組合せからなる単語候補はきわめて多数となり、無意味な検索を膨大に行う必要がでてくることである。そして、そこから正しい単語を一意に決定する手続きもきわめて複雑になる。

そこで、本方式では、キーワードと称する少数の確実性の高い語から順に、段階的に、島駆動的に確定して行くことにより、組合せの爆発を回避している。なお、このようなアルゴリズムを用いているため、各段階に対応する複数の辞書を用いている。段階的な単語あてはめの一例を図2．1に示す。

2．2　処理手順

2．2．1　文字候補と組合せの問題

多段階分割復元法では、まず、音声認識によって得られる誤りを含む文字列を入力し、文字単位で修正の候補を頻度の順に複数個取り出す。

この候補文字を単純に組み合わせると文字列の長さnに対し指数的に組合せが増え（平均候補数のn乗）、膨大な回数の検索をおこなう必要が生ずる。

そこで、検索をせずに逆に辞書中の単語を認識候補文字列に当てはめることを考える。しかし、はじめから辞書中の単語全てについて平等に当てはめを行おうとすると、組み合わせた後にも多数の文章候補が生ずることになり、一意に決定できない。そこで以下に示すように正しい文章になる確実性の高い語から順に当てはめを行う。

2．2．2　あてはめ手順

多段階分割復元法の各段階の処理の流れを図2．2に示す。各段階について、以下(1)～(7)で説明する。

(1)　キーワードのあてはめ

まず最初に、最も確実性の高い候補として、次に定義するキーワードという語群にから当てはめを行う。

定義１：　キーワード

文字列中にその語と同じ文字並びが存在した場合に、一意にその文字並びをその語であると決定しても誤りとならない語であり、他の語と重なり合うことはない。

なお、このキーワードはこの定義の成立する範囲により２種類に分類され、１種、２種の順に当てはめる。

定義２：　１種キーワード

キーワードで最も確実性の高い語であり、対象とする分野によらずキーワードになり得る語。

定義３：　２種キーワード

キーワードとしては比較的不安定なものであり、対象とする文献の属する分野によりキーワードとして成立するかどうかが決定されるものである。対象とする分野ごとに２種キーワードの辞書が必要となる。

キーワードは予め一定量の文献より抽出して辞書とする。

(2)　キーワードの拡張

キーワードの前後に文字列を付加したものが更に単語として辞書中に存在する場合はこれをあてはめる。なお、この様な単語はキーワード辞書ではなく、拡張キーワード辞書中に登録しておく。

(3)　カタカナ語のあてはめ

外来語などを表すのに使われるカタカナ語は一般に綴りに特徴があるものが多いので一般語に先立ち、決定する。

(4)　一般単語のあてはめ

一般語はさらに確実度が低くなり、入力文字列に一致する語が多くなるので、連接情報[2)]を用いてあてはめる単語を絞り込んでから、決定する。

(5)　接辞のあてはめ

すでに決定された語の前後の未決定文字列が接辞と一致する場合に接辞を決定する。

(6)　一字助詞のあてはめ

決定された語の間に１文字だけ残っている場合それが助詞に一致すればこれを決定する。

(7)　一字漢字語のあてはめ

最後に残った部分で漢字１字で表される文字列があればこれを決定する。

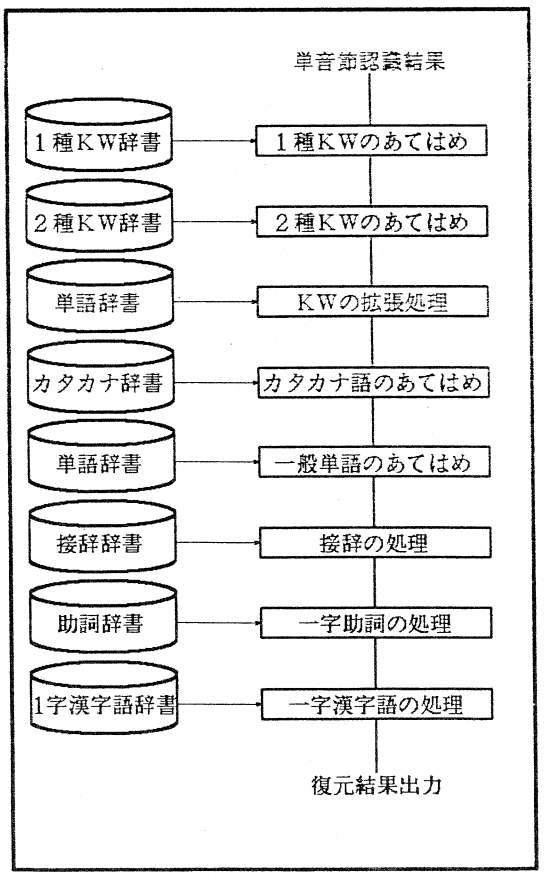


図２．２　単語復元処理の流れ

3．連続音声の問題点と対処方法

多段階分割復元法は、単音節単位で認識された、誤りを含む文字列を自動訂正する手法として開発されたものである。

3．1　連続音声をどのように扱うか

連続音声を扱う場合、２通りの方法が考えられる。ひとつは単語ごとに音声を登録し、それぞれマッチングする方法と、もうひとつは、入力した音声をパワーやスペクトルの変化に着目して音素単位に分割し、その後でマッチングをとる方法である。前者は、例えば数字音声認識などのように分野を限った比較的少数のパターンマッチングには有効であるが、テキストプロセッシングで対象とする大量の語を扱う場合には、膨大な数のパターンマッチングを行う必要があるため、現実的ではない。そこで我々は後者の方法を用いる。こちらの方法では、最も単純に考えた場合、音素の数だけパターンを用意しておけばよい。

なお、音素分割を行うための分析アルゴリズムに、精度よりも高速性を重視してＬＰＣ[3)]法を用い、分割後のパターンマッチングにはＤＰマッチングを用いている。

3．2　単音節単位から音素単位へ

これまでの手法では単音節単位で認識された入力文字列を用い、未認識を含む６８単音節を対象として復元を行ってきたが、音素を対象とする場合は、記号的にみればこれを２０種類の英字記号を扱うことに置き換えることで達成される。しかし、ここで問題となるのは、単音節で発声されたものは、厳密に１文字は１発声に対応していたのに対して、連続音声の場合は、音声から音素単位に切り出した結果として、付加、脱落が生じることである。つまり、単なる文字の誤りだけでなく文字列中の文字の有無さえも問題になり、入力と出力で文字列の長さが異なる。また、誤りを含む音素表記の文字列を入力するため、単音節単位で直接かな文字に対応していたのに対し、入力音素の組合せが必ずしもかな文字として成立しない場合が生ずる。

3．3　付加、脱落

上述した文字列中の文字の有無について以下で述べる。

入力された音声は音素単位に分割されたものが得られるとしているが、必ずしも 100% 正しいものではないので、分割の誤りを考える必要がある。分割の境界が１個検出されなければそこで１音素脱落したことになる。また１個余計に分割されたならば、一音素が付加されたことになる。また、「しすてむ」と発声したとき、「す」に対応する音 su の母音 u が認識されなかったり、また実際に発声されないこともある。このような場合も脱落として扱わなければならない。さらにここでは誤って発声してしまった場合についても同様の手法で訂正できるようにする。

これらを整理すると以下のようになる。

・定義

脱落：

- 話者の意図に反して発声しなかった音素および
- 発声したが正しく検出されなかった音素

付加：

- 話者が誤って発声してしまった音素および
- 一つの音素が複数に分割された場合

それぞれ、２つづつの要因をまとめた形になっているが、同じ処理を行うことで対応できると考えている。

3．4　挿入、削除の文字処理

付加、脱落に対応する処理を以下のように定義する。

・定義

挿入：
・脱落した文字を予測し、文字候補をたる。

削除：
・付加された文字を予測し、文字が存在しないものとして処理する。

処理方法を単純に考えれば、辞書の単語の当てはめの際に不都合のあるところを変更すればよいように思われる。

(例)

```
認識音素：      maikrookonkuta
    ・
    ・          maik roo konk uta
    ・              ^  /l   x^   ^
    ・          maikuro  konpiutaa
    ・
復元結果：      マイクロ  コンピュータ
```

^：文字挿入　/：文字削除
l：単語分割　x：文字置換

しかし、ここで脱落に対して任意の文字を挿入できるとは仮定できない。付加に対して任意の文字を削除するすることも同様である。なぜならこれらの操作により、幾らでも文字の挿入削除が行われ、入力された文章とは全く異なる文字列を作成することも可能であるからである。

(上例に対し異なる例)

```
maikuroo kon   ku  ta
  x    x/l   x^^^ l ^^
maekara  koukouku sita

前から     広告     した
```

そこで、これらの挿入、削除に対して次のような制限を設けることにする。

(1) 付加および脱落の傾向の学習により、挿入、削除の対象を頻度の高い文字に限定する。

(2) 誤る文字の前後の文字1文字づつと組合せ、3つ組文字とすることにより、誤る場合のバターンを細分化する。

(3) 一箇所につき挿入は1文字までとする。

削除については、一つの音素を長く発声した場合に誤って分割されてしまう可能性を想定すると、1個の削除では足りない。そこで連続削除は候補として考えてよいとする。

3．5　認識傾向辞書

認識情報辞書[2)]は音声認識によって得られた文字単位の誤りの訂正のための候補を取り出すために、予め認識文字列と正しい文字列を比較する方法によって作成しておく。この辞書により、あらたな認識文字列の訂正のための候補をたてる。なお、連続音声対応としたことにより内容的に大きく変化したため、以後はこれを認識傾向辞書ということにする。

認識傾向辞書には前後1文字を含む認識3文字組とこれに対応する複数の訂正候補およびその頻度を収める。訂正候補の文字は認識3文字の中央の1文字に対応する1文字で表現する。また、文字列の先頭や末尾の文字の項目には3文字組のひとつに". "を使用し、区別する。また、挿入、削除の文字候補に対し("_")を使用する。

(例)

```
文頭：   .KA -> K P T
文末：   TU. -> U O A
挿入：   S_S -> I U O
削除：   SEE -> E _ I A
```

認識傾向辞書の例を図３．１に示す。

```
認識文字３つ組／　入力候補文字

._A   /   .MA .NA .SA XXX ...
.KE   /   .KE .TE .PE XXX ...
.TI   /   .TI .KI .PI XXX ...
.ZA   /   .DA .ZA .GA .NA ...
AIG   /   AIG XXX XXX XXX ...
ANZ   /   ANZ A_Z XXX XXX ...
E_A   /   EHA XXX XXX XXX ...
ENE   /   ENE EME XXX XXX ...
EAN   /   EAN XXX XXX XXX ...
IGZ   /   IGZ XXX XXX XXX ...
INZ   /   INZ XXX XXX XXX ...
IPZ   /   IPZ XXX XXX XXX ...
I_P   /   IUP XXX XXX XXX ...
GEN   /   GEN XXX XXX XXX ...
GOP   /   GOP XXX XXX XXX ...
GZI   /   GZI XXX XXX XXX ...
G_Z   /   GIZ XXX XXX XXX ...
NEA   /   NEA N_A XXX XXX ...
NZG   /   NZG N_G XXX XXX ...
OPA   /   OPA OTA OKA XXX ...
O_P   /   OUP XXX XXX XXX ...
PAI   /   PAI XXX XXX XXX ...
PS.   /   P_U XXX XXX XXX ...
S_.   /   S_. SU. XXX XXX ...
S_T   /   SET SAT SOT SUT ...
TIN   /   TIN XXX XXX XXX ...
ZGE   /   ZGE ZNE XXX XXX ...
ZIP   /   ZIP XXX XXX XXX ...
ZGO   /   ZGO ZDO XXX XXX ...
```

図３．１　認識傾向辞書

３．６　文字候補の作成

認識された長さｎの音素の列（以下音素列）に対し、最小

（桁）×（行）＝（２ｎ＋１）×ｍ

の２次元の文字配列を用意する（ｍは候補の最大数）。挿入を考慮し、ｉ番目の認識音素には２ｉ番目の桁を割り当てる。この配列に認識傾向辞書から認識文字列に対応する文字候補をすべてとりだし、行方向に埋めて行く。候補のないところには”＊”を埋める。なお、配列中の奇数桁目の第一候補はもともと認識文字がないので”＿”を入れておかねばならない。

３．７　単語のあてはめ

単語のあてはめは多段階分割復元法に基づき、キーワードから順にあてはめてゆく。なお、あてはめに際して、削除候補”＿”はとばされる。

付録の図に文字候補から単語をあてはめるまでを例を示した。

４．性能評価実験

現段階では結果を得ていないので、実験方法のみ紹介するにとどめる。

本手法の有効性を確認するためには大量の音声データが必要となる。しかし現時点では、連続音声を分割して得られたデータは少量にすぎない。そこで、本実験では正しい文書を乱数を用いて確率的に誤らせたデータを用いる。

評価は正しい文字列と修正された文字列を比較することで行う。

５．おわりに

５．１　まとめ

本報告では、多段階分割復元法を改良し、連続音声の認識の結果を扱えるように挿入、削除の機能をあらたに付け加えた。

5．2　システム構成

現在、我々は図5．1に示すような構成のシステムを構築中である。

5．3　今後の課題

今後の予定としては認識傾向辞書を用いて音声認識部の更新学習を行うフィードバック学習システム[4]を考えている。当面、これに伴うさまざまな問題点を解決していきたいと考えている。

【参考文献】

[1] 広重、宮永、栃内：スペクトル選択機能を備えた有声音声向き適応信号処理システム、電子情報通信学会論文誌、
Vol.72-D-Ⅱ、No.4、pp.476-486(1989).

[2] 荒木、宮永、栃内：多段階分割復元法による誤りの多い文字列からの原文の復元、情報処理学会論文誌、
Vol.30、No.2、pp.169-178(1989).

[3] 古井：デジタル音声処理、
東海大学出版会(1985).

[4] 堤、荒木、宮永、栃内：多段階分割法における復元情報の音声認識部へのフィードバック学習、情報処理学会第37回全国大会講演論文集、pp1035-1036(1988).

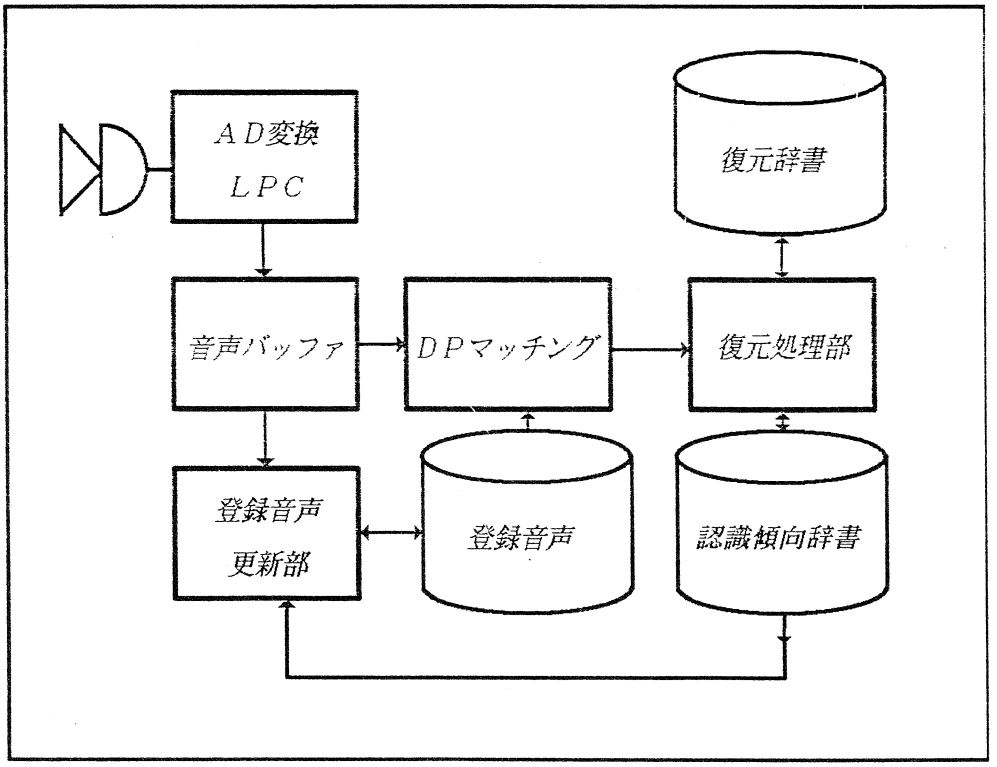


図5．1　システム構成

認識層	. _ t _ i _ n _ z _ g _ e _ n _ e a _ n _ z _ g _ o _ p _ a _ i _ g _ z _ i _ p _ s _ .
認識傾向	. .TI TIN INZ NZG ZGE GEN ENE NEA EAN ANZ NZG ZGO GOP OPA PAI AIG IGZ GZI ZIP IPZ
辞書	.KI ZNE EME ZDO OTA ITS P_U
	OKA
Insert	EHA OUP GIZ IUP SU.
Delete	N_G N_A A_Z N_G
文字候補層	. _ T _ I _ N _ Z _ G _ E _ N _ E _ A _ N _ Z _ G _ O _ P _ A _ I _ G _ Z _ I _ P _ S _ .
	* K * * * * * _ * N * * * M * _ H * * * * _ * D * * U T * * * * * * I * * * U T * U U *
	* K * * * * * * * * * * * * * * _ * .
ローマ字層	T I N G E N E H A N D O U T A I G I Z I _ P U U
	Ü T S _
	K _ N M _ G _ P -
	K
単語候補層	kinnen e handoutai tai giziutu
	kingen han doutai pai igi
	tingen goutai ai gizi
	kin gen ha dou itu
	tin nen outai
	ki in ge ne uta zitu utu
	ti me kaigi
	kai
文書層	絵 半導体 胴体 対 技術
	近年 言 根 導体 π 意義
	謹言 原 目 半 剛体 愛 議事
	珍言 下 半 銅 何時
	金 応対
	貴 街 歌 実 打つ
	木 会議
	地 院 員