274 文字列中の共通パターンを用いた語の認識

荒木 健治
（北海学園大学工学部）

栃内 香次
（北海道大学工学部）

1. はじめに

近年、日本語文書を計算機で処理する必要性が急激に増大している。しかし、日本語には分かち書きの習慣がないので機械処理を行なう場合には、まず分かち書きを行なわなければならない。これは、いわゆる形態素解析と呼ばれる処理であるが、種々の方法[1~3]が提案されている。しかし、そもそも日本語における語の単位には様々なものがあり[4]、その上辞書を用いる方式では辞書中にない語（未登録語）が出現するという問題がある。

そこで、我々は言語が時代とともに変化することを考慮し、適応機能を持った方式として文書中に共通に出現するパターンを学習することにより語を認識する手法を提案する。これは、従来用いられていた辞書、文法規則および経験則を用いず、文書中の共通パターンより語を学習するので言語の変化に柔軟に対応できる手法といえる。また、共通に使用される部分を語としているので、人間が直感的に感じる語の単位との整合性が高いと考えられる。本報告では、本手法の概要と小規模な実験結果について述べる。

2. 基本概念

語の単位は人間の使用法に基づくものでなければならない。このような観点から人間が語を使用した結果である文書中より語の単位を帰納的に学習する方法が望ましいと考えられる。これは、人間が文書中で語を単位として用いているので、共通に出現する部分は語の単位であると推測することができるからである。

形態素解析とは形態素に文を分割することである。

図１ 語の認識の例

これを、図１の例で説明すると、「形態素解析」の時点では語を認識することはできないが、後に「形態素」が単独で使用されているので「形態素」を語と認識することができる。

3. 処理の概要

3. 1 文書中からの共通部分の抽出

まず、初めに文書中から共通部分を取り出す。これは、文書を任意の長さに切り出し、文書中に複数回出現する部分を取り出すものである。このようにして取り出された文字列をSegment1と呼びＳ１と表記する。このとき、取り出された文字列が２文字以上のもののみをＳ１とする。ただし、一字の漢字語は両側が異なる字種で挟まれている状態で複数回出現した場合にはＳ１としている。なお、この際には出現頻度を記録し、すべての出現位置がすでに出現した共通パターンに含まれている場合には記録しない。図２の（２）にこの例を示す。

3. 2 Ｓ１の分解

次に、Ｓ１同士の共通パターンによりＳ１を分解する。これは、Ｓ１には複数の語が含まれている可能性があるので、Ｓ１の中の１語で構成されているもので、これらを分解するものである。この場合の取り出す基準は3. 1とほぼ同じであるが、特に一方が他方に完全に含まれる形で重複するものを取り出す。このとき、共通の部分をＳ２、残りの部分をＳ３とし、分解されたＳ１は削除する。さらに、Ｓ１が追加された場合には、Ｓ１、Ｓ２、Ｓ３（これらを総称してWord Segmentと呼び、ＷＳと表記する）を基にして同様の操作を繰り返す。図２の（３）（４）にこの例を示す。

3. 3 ＷＳによる語の認識

まず、２段階の共通部分の抽出によって取り出されるので最も確実性が高いと考えられるＳ２を用いて表記の一致する部分を分割する。次いで、Ｓ２で分割されなかった部分にＳ２の次ぎに確実性の高いＳ１を用いて表記の一致する部分の分割を行なう。最後に、Ｓ３を用いてＳ２、Ｓ１で分割されなかった部分に表記の一致する部分の分割を行なう。この例を図２の（５）に示す。

（１）例文
連続音声認識では連続音声を認識している。しかし、単音節音声認識では単音節ごとに音声を認識する。

（２）Ｓ１の抽出結果
連続音声(2)、認識(4)、音声認識(2)
では(2)、単音節(2)

（３）Ｓ２、Ｓ３の抽出過程
（音声認識(2)、認識(4)）→音声：Ｓ３(2)
認識：Ｓ２(4)
（連続音声(2)、音声(2)）→連続：Ｓ３(2)
音声：Ｓ２(4)

（４）ＷＳの抽出結果
Ｓ１：では(2)、単音節(2) → ＜＞
Ｓ２：音声(4)、認識(4) → ［］
Ｓ３：連続(2) → （）

（５）ＷＳによる語の認識
単語[音声][認識]<では>単語ごとに[音声]を[認識]する。

注）（）内の数字は出現頻度を表わす。

図２ ＷＳの抽出と語の認識の例

3．4　重複した場合の処理

ＷＳを抽出する際およびＷＳによる分割で表記の一致する部分が重複した場合には以下のヒューリスティクスを順に用いて一方に決定する。

（１）文字数の多いもの。
（２）出現頻度の大きいもの。
（３）分割が前のもの。

4．認識実験

4．1　実験方法

ＷＳを抽出し、それを用いて文書を分割する実験を行なった。用いた資料は情報処理に関する論文の一部（２７７５語）である。まず、この資料より３．１と３．２で述べた方法によりＷＳを抽出する。なお、全資料を元にしてＳ１を抽出すると組合せの爆発が起こるので、資料を章、節ごとに１０個に分け、以下の手順によりＷＳを抽出した。

（１）それぞれよりＳ１を抽出する。
（２）最初の資料より抽出されたＳ１よりＷＳを抽出する。
（３）次の資料のＳ１とそれまでに抽出されたＷＳより新たなＷＳを抽出する。
（４）（３）の操作を１０回繰り返す。

次に、３．３で述べた方法によりＷＳを用いてこの文書を語単位に分割した。次いで、手作業により資料に自立語、付属語、接頭語、接尾語、自立語活用語尾の区別を付加し短単位に分割した。これと、ＷＳによる分割結果を比較し、評価した。

4．2　実験結果

実験結果を表１に示す。表１で網羅率とは総語数のうちどの程度の語を認識しようとしたかを表わす。また、正認識率は認識しようとした語の内どの程度の語を正しく認識したかを表わし、誤認識率は認識しようとした語の内どの程度の語を誤って認識したかを表わす。定義式を以下に示す。

網羅率　＝（正認識数＋誤認識数）／総語数
正認識率＝正認識数／（正認識数＋誤認識数）
誤認識率＝誤認識数／（正認識数＋誤認識数）

4．3　考　察

表１を見るとＳ２が網羅率５１．６％で７３．３％の正認識率を示している。これは、Ｓ２が文書中より共通部分として抽出されたＳ１同士の共通部分なので確実性が高くなっていると考えられる。品詞別にみると、Ｓ２の自立語は正認識率が８２．６％であるが、付属語は６０．２％である。これは、自立語はある程度一定の単位として使用されるが、付属語は種々変化して使用されると考えられるためである。また、全体では網羅率は６２．２％、正認識率は６８．９％なので、さほど高くはなっていない。これは、ＷＳを抽出した文献の量が不十分であったことや組合せの爆発を避けるために資料を７７語から４４６語に１０分割してＳ１を抽出したために共通部分が減少したこと、および評価方法として手作業で分割された文書と厳密に比較したために正しいが分割法の違いにより誤りとなったものが存在したことが挙げられる。また、この結果よりＳ２は自立語をある程度正しく分割できることがわかったので、Ｓ２を利用して複合語を分割することができると考えられる。

表１　認識実験結果

		網羅率	正認識率	誤認識率
S1	自立語	９．８	５８．４	４１．６
	付属語	４．４	５．７	９４．３
	接頭語	０．０	――	――
	接尾語	２４．１	０．０	１００．０
	活用語尾	６．０	０．０	１００．０
	計	７．４	４０．７	５９．３
S2	自立語	６５．４	８２．６	１７．４
	付属語	４０．７	６０．２	３９．８
	接頭語	０．０	――	――
	接尾語	０．０	――	――
	活用語尾	２６．７	６．５	９３．５
	計	５１．６	７３．３	２６．７
S3	自立語	３．７	６２．５	３７．５
	付属語	１．１	７．７	９２．３
	接頭語	５０．０	１００．０	０．０
	接尾語	３４．５	８０．０	２０．０
	活用語尾	０．９	０．０	１００．０
	計	３．２	６２．９	３７．１
総合	自立語	７８．７	７８．７	２１．３
	付属語	４６．２	５３．８	４６．２
	接頭語	５０．０	１００．０	０．０
	接尾語	５８．６	４７．１	５２．９
	活用語尾	３３．６	７．７	９４．９
	計	６２．２	６８．９	３１．１

注）単位は％、'－'は一つも分割しなかったことを示す。

5．おわりに

今後は、さらに大量の文書を用いて実験を行ない、本手法によりどの程度の語をどの程度正確に認識できるのかの検討を行なうことおよび未知の文書に対する適応能力についての検討を行ない、本手法の改良を図る予定である。

※参考文献

１）建石、小野、山田：DictionとStyleの日本語化について、第31回情報処理全国大会講演論文集、pp.1381-1382(1985).
２）藤崎、亀田：新聞記事データを対象とする自動単位切り処理とそれに基づく語彙調査、情報処理学会自然言語処理研究会報告、NL51-2(1985).
３）吉村、武内、津田、首藤：未登録語を含む日本語文の形態素解析、情報処理学会論文誌、Vol.30,No.3, pp.294-301(1989).
４）中野、野村：日本語の形態素分析、情報処理学会誌、Vol.20, No.10, pp.857-864(1979).