275 キーワード共起出現単語による曖昧さの解消

潤潟 謙一† 荒木 健治†† 宮永 喜一† 栃内 香次†
† 北海道大学 †† 北海学園大学

1．はじめに

音声入力によるテキストプロセッシングでは、音声認識段階における曖昧さのために多数の候補文字が出現し、これらの組合わせからなる単語候補の個数は極めて多くなる。先に我々は、音声入力において発生する誤りを正しい文字列に復元するために、統計的手法を用いて段階的に自動訂正する多段階分割復元法を提案した[1]。しかしながら、この手法においても多数の単語候補の中から1つを決定するには相当な処理時間を要する。この問題に対して本稿では、音声認識によって得られた文字列から単語候補を決定する際に、表層上の単語出現傾向と意味的な出現傾向の相関を予測することで単語候補を絞り、これによって処理時間を短縮させる手法を提案する。

2．基本概念

人間が文章を読む場合、文脈などを考慮してその文における核となる単語を認識して検索空間を絞ることにより、次にくる単語の範囲をある程度予測しながら読み進んでいるものと考えられる。本研究における復元処理においても、文章中の核となる単語が当てはめられた後、同一文に出現している他の単語は核となる単語に意味的に関わっていて出現しているのではないかと予測して、共起しやすい単語群を当てはめ候補とすることが有効であると考えられる。本稿では、この手法の有効性を確認するために行なった実験とその結果について報告する。

3．実験手順

特定専門分野の学術論文を対象とし、主に自立語、付属語という分割を中心に形態素解析を行なう。次いでその資料をもとに、キーワードと共起単語の関係を調べる。なお、実験に使用した資料は次の論文である。

荒木他「付属パターンを用いたルールによる表層レベルでの係り受け関係の解析」情報処理学会自然言語処理研究会資料 68-6 (1988)

3・1 キーワードの決定

核となる単語をキーワードと呼ぶことにする。前述のように、キーワードはその文章において中心的な単語の一つである。ここでは、実験資料において出現頻度が高く、その論文特有の語である「係り受け」という単語を選んだ。

3．2 キーワード共起単語と意味的共起単語の抽出

キーワード共起出現単語とは、キーワード「係り受け」を含む文中に出現する単語のことである。抽出する単語は自立語のみとした。また、これと同時に「係り受け」という語と意味的に関係をもつ自立語の抽出を行なった。意味的に関係がある語として、ここではキーワードと直接係り受けの関係にあるものだけを抽出した。その一例を次に示す。

「ここで解析ルールとは付属語パターンとその係り受け関係の種類を評価する規則である。」

キーワードと同一文中に出現している自立語（下線部）のうち、意味的に関係のあるのは、複合名詞をつくっている「関係」と、直接かかっている「その」と「種類」ということになる。

3．3 キーワード共起単語と意味的共起単語との関係

このようにしてキーワードを含む同一文中に出現する自立語と、そのなかでキーワードと意味的に関係があるとみなせるものとの、それぞれの頻度を上位より比較する。ここでは記号等は含めない。（）内は出現頻度を示す。

※同一文中に出現する自立語	※意味的に関係のある自立語
「関係」(97)	「関係」(93)
「解析」(72)	「解析」(35)
「語」(62)	「候補」(22)
「ルール」(40)	「種類」(13)
「候補」(23)	「語」(8)
「関連」(22)	「修正」(7)
「抽出」(18)	「決定」(7)
「付属」(15)	・
「種類」(13)	・
・	・
・	・

これから同一文中でキーワードと意味的に共起している単語と、文中に高頻度で出現する単語とはかなり一致しているといえる。従って前述のように、本手法により多段階分割復元法の処理時間を短縮することが可能であると考えられる。

4．おわりに

以上本稿では、ある文章において中心的な単語（キーワード）の含まれている文に高頻度で出現する語と当該キーワードとの意味的関係について述べた。今後は多数の資料について共起する単語のデータを収集すること、および共起関係の評価方法の再検討を試み、その上で実際に復元システム上にこの処理段階を組み込んで実験を行なう予定である。

参考文献

1）荒木健治、宮永喜一、栃内香次 「多段階分割復元法による誤りの多い文字列からの原文の復元」情報処理学会論文誌 Vol.30 No.2 pp.169-178 (1989)