D-78

学習に基づく形態素解析手法

Morphological Analysis Method Based on Machine Learning

荒木 健治
Kenji Araki
北海学園大学
Hokkai-Gakuen University

栃内 香次
Koji Tochinai
北海道大学
Hokkaido University

1．はじめに

高度情報化社会の進展にともない、日本語文書を計算機で処理する機会が急激に増大している。しかし、日本語には欧米語のように分かち書きの習慣がないので、計算機によって日本語文書を処理する場合には、まず初めに分かち書きを行わなければならないことが多い。このことが、日本語による高度な情報処理を妨げる一因となっている。この問題に対しては、これまで種々の手法が提案されてきたが[1]、未登録語処理や種々の分野に対する辞書作成の手間等の問題点があり、決定的な手法は未だ確立されていない。我々は、この問題に対してすでに計算機による自動学習により文字列中より語を認識する手法を提案し、実験によりその有効性を確認している[2]。本稿では、本手法の学習能力について考察する。

2．処理過程

2．1 帰納的学習による語の推測

未登録語に対処するため、文書中の共通パターンを利用して文書中に出現する語の推測を行う。以下の2つの過程により語が推測される。

（1）文字列中より共通パターンを抽出する。
（2）抽出された共通パターンより高次共通パターンを抽出する。

（1）の過程で抽出される共通パターンをS1（Segments 1）と表記する。また、（2）の過程で抽出される共通パターンをS2（Segments 2）、残りの部分をS3（Segments 3）と表記する。これらを総称してWS（Word Segments）と表記する。また、高次共通パターンの抽出段階で品詞の推測を行う。これは、共通パターンの出現状況と字種情報より品詞を推測するものである[2]。重複した場合には以下に示す尤度評価関数によって最適なものを選択する。

尤度評価関数＝αCF＋AF－βEF

CF:正認識度数、AF:出現頻度、EF:誤認識度数、α、β：係数

2．2 語の認識

確実性の高いものより順に認識を行う。まず、未知文字列中でCW（Correct Words）と表記が一致する部分を最も確実性の高い部分として語と認識する。CWは2．4で述べるフィードバック学習により校正済みの文字列中より学習されたもので正しい語であることがわかっている。次に、CWによって認識されなかった部分についてWSの認識を行う。WSの認識は、WSの中で最も確実性が高いと考えられるS2より認識を行う。以下、S1、S3の順に認識を行う。

2．3 校正処理

得られた認識結果を人手により校正し、正しい認識結果を得る。

2．4 フィードバック学習

認識結果と校正済みの認識結果の比較により認識誤りの状況と未登録語の学習を行う。処理手順を以下に示す。

（1）正認識の場合（文字列上で語が認識された位置と品詞が一致）
①認識した語の所属をCWとする。
②認識した語のCFとAFを1増加する。
（2）誤認識の場合（認識位置あるいは品詞が一致しない）
①正しい語について
a．正しい語が辞書中に存在しない場合…CWにAFを1にして登録
b．正しい語が辞書中に存在する場合…所属をCWにしAFを1増加
②誤った語について…誤った語のEFを1増加させる。
（3）未認識の場合…誤認識の場合の正しい語の処理と同様

3．学習能力評価実験

本手法による実験システムを作成し、学習能力を評価する実験を行った。

3．1 実験方法

実験に用いた資料は情報処理に関する論文4編（総文字数35、867文字）で、これらの文献を1つの論文を各章ごとに5個に分割し計20個に分割して実験を行った。辞書を空の状態にしてから以下の手順を20回繰り返した。なお、尤度評価関数の係数はαを2、βを4とした。

（1）帰納的学習によるWSの抽出
（2）語の認識
（3）認識結果の校正
（4）フィードバック学習

3．2 実験結果

表1に正認識率、誤認識率、未認識率の推移を示す。なお、評価式を以下に示す。

$$\text{正認識率} = \frac{\text{正認識語数}}{\text{全語数}}$$

$$\text{誤認識率} = \frac{\text{誤認識語数}}{\text{全語数}}$$

$$\text{未認識率} = \frac{\text{未認識語数}}{\text{全語数}}$$

表1 認識率の推移

資料No	正認識率			誤認識率			未認識率
	CW	WS	総合	CW	WS	総合	
1	——	53.5	53.5	——	19.5	19.5	27.0
2	50.0	12.8	62.8	3.3	7.1	10.4	26.8
3	64.6	11.8	76.4	5.8	7.0	12.8	10.8
4	72.5	8.9	81.4	5.2	4.5	9.6	8.9
5	75.0	6.2	81.1	4.8	4.4	9.2	9.7
6	64.5	11.2	75.8	4.8	7.3	12.1	12.1
7	73.5	2.3	75.8	3.9	8.8	12.8	11.4
8	82.2	1.7	83.9	7.2	4.4	11.6	4.4
9	85.9	0.7	86.6	6.0	5.1	11.1	2.3
10	78.2	0.5	78.8	5.7	4.4	10.1	11.1
11	85.7	0.8	86.4	7.2	1.0	8.2	5.4
12	87.6	0.8	88.4	7.6	2.1	9.7	1.9
13	88.4	1.0	89.4	7.8	1.4	9.3	1.3
14	84.5	0.3	84.8	8.4	3.8	12.2	3.0
15	86.1	0.4	86.5	6.5	2.1	8.6	4.9
16	86.3	0.9	87.3	4.9	2.3	7.2	5.6
17	88.5	0.5	89.0	3.9	2.9	6.8	4.2
18	86.3	1.2	87.5	6.8	2.4	9.2	3.3
19	82.8	1.1	83.9	7.0	4.6	11.6	4.6
20	86.5	0.3	86.9	7.0	2.5	9.5	3.7
計	79.1	4.2	83.3	6.0	4.2	10.2	6.5

注）単位は%、破線は各論文の区切りを示す。

3．3 考 察

表1より正認識率は次第に上昇し、11回目以降は約85%程度を示している。CWについても同様の傾向である。また、WSについてはCWの未登録語を認識するという観点からは、CWが低い値の時には高い値を示し、CWの未認識を救っているのがわかる。未認識率は11回目以降では6%以下となっている。

4．おわりに

2つの学習過程による形態素解析手法を用いた実験システムを作成し、その学習状態を考察した。実験の結果、直ちに良好な値を示すことがわかり学習の効果が急速であることが確認された。今後は、異なる対象分野に対する学習能力について考察する予定である。

参考文献

1）吉村、武内、津田、首藤：未登録語を含む日本語文の形態素解析、情処論文誌, Vol. 30, No. 3, pp. 294-301 (1989).
2）荒木、栃内:帰納的学習による文字列中の語の認識、信学会音声研究会資料、SP89-91, pp. 39-46 (1989).