関連語情報を用いたべた書き文のかな漢字変換

荒木健治[*1]・栃内香次[*2]

Kana-Kanji Translation of Non-Segmented Sentences Using Connected Word Information

Kenji ARAKI[*1] · Koji TOCHINAI[*2]

実用的な日本語文を計算機が有効に利用できる形に処理することは膨大な労力を要するのが現状である。この問題に対して，先に我々は，人間が行っている浅い解析に着目し，表層レベルで付属語によって明示的に示される係り受け関係を付属語のパターンを用いて解析する手法を提案し，実験によりこれを確認している。そこで，本論文では，この手法によって得られる関連語情報をべた書き文のかな漢字変換に適用し，その有効性を確認した結果について述べる。本手法では，最初に一定量の文章より予め付属語パターンとその係り受け関係の種類を定義する解析ルールを人手により抽出し，次いでその解析ルールを用いて文章中の係り受け関係を解析し，係り受け関係にある語（関連語）の組を抽出することにより得られた関連語情報をべた書き文かな漢字変換の単語分割に適用する。その方法としては，べた書き文中に存在する付属語パターンと予め抽出された関連語情報より導き出される係り受け関係が一致したものをあてはめるというものである。本手法をべた書き文かな漢字変換に適用した結果，本手法による単語分割は97.1%の精度であることがわかり本手法の有効性を示すことができた。

1．はじめに

近年，高度情報化社会の進展にともない，日本語文書を計算機で処理し，有効に活用したいという要求が急速に高まっている。しかし，日本語文書を計算機が有効に活用できる形に処理するには，膨大な労力を要するのが実状である。この問題に対しては，種々の側面からのアプローチ[1),2),3)]が試みられているが，対象を制限し，複雑な解析を用いている点に依然として問題が残されている。

＊1 北海学園大学工学部電子情報工学科
＊2 北海道大学工学部電子工学科
＊1 Department of Electronics and Information Engineering, Hokkai-Gakuen University
＊2 Department of Electronic Engineering, Hokkaido University

一方，人間が文章を読み，その内容を理解し，作業を行う場合には，常に厳密に文を解析し，完全に文の意味を把握しているわけではなく，目的に応じて完全な意味の把握が必要なときには厳密に文を解析し，内容の大局的な把握で十分なときには，表層レベルの文字列より大局的に意味を把握していると考えられる。また，仮に完全な深い理解が必要な場合でも，人間は，まず一度通読することにより大局的に意味を把握し，再度文を読み返すときにその情報を基に厳密な解析を行い深い理解を行っていると考えられる[4]。以上より計算機が文を解析する際にも表層レベルの浅い解析を利用することが有効であると考えられる。

我々は，このような観点から文を解析する上でまず必要となる係り受け関係の解析[5]を，日本語が膠着語であることに着目し，すべての係り受け関係を深く解析するのではなく，表層レベルに付属語によって明示的に示される係り受け関係を付属語のパターンによって解析する手法を提案し，その有効性をすでに実験により確認している[6]。そこで，本論文では，付属語のパターンを用いた係り受け関係の解析手法によって得られた関連語情報をべた書き文の単語分割に適用する方法の概要を述べ，その性能評価実験結果について述べる。

2．関連語情報の抽出[6]

本手法は，付属語のパターンを用いた解析ルールにより文中の係り受け関係を解析し，単語を意味的に関係のあるものの組に分類するものである[7]。ここで，解析ルールとは付属語パターンとその係り受け関係の種類を定義する規則である。また，ここで用いられる付属語とは「する，ある」といった付属語的に使われる動詞の一部を含むが，ここではこれらを総称して付属語と呼ぶ。また，ある語Aと係り受け関係にある語Bを語Aの関連語と呼ぶ。

ここで，解析される文としてはすでに単語単位に分割されたものを用いる。本研究では，これは多段階分割法によるべた書き文かな漢字変換システム[8]にべた書き文を入力して単語単位に分割し，さらに人手により校正した文字列である。この文字列はローマ字表記され，漢字，ひらがな，カタカナ等の字種が指定され[9]，さらに単語単位に分割されている。入力文字列の例を以下に示す。

例　[Bunkatu] (wo) [Susu]meru | mono | | dearu |

分割　を　進　める　もの　である

この例で，先頭が大文字の語は漢字語である。また，記号は，多段階分割法によるべた書き文のかな漢字変換システムのどの段階で分割されたかを示すもので，[ ]はキーワード，( )は助詞，| |は一般単語を示す[7]。

関連語情報の抽出手順を以下に示す。

(1) 予め一定量の文章より解析ルールを抽出しておく。

(2)　1文ごとに以下の手順を繰り返す。

（2－1）　解析ルールを用いて単語単位に分割された文字列を解析し，係り受け関係を決定する。

(a)　解析ルール中に存在する付属語パターンを検索する。

(b)　各解析ルールに一致するように付属語パターンの直後または直前に自立語が存在する場合に係り受け関係候補とする。

(c)　係り受け関係候補を相互の関連を考慮して修正を行い，係り受け関係を決定する。

（2－2）　解析された係り受け関係に基づき，関連語の組を抽出する。

この際には，各組ごとに，その係り受け関係の種類を示すフラグを付加する。

解析ルールは予め一定量の文章中より人手によって決定される。次いで，システムは，この解析ルールを用いて他の文章の係り受け関係を解析する。解析ルールの抽出では，初めに，文中で係り受け関係にある語に着目し，次いで係り受け関係を明示している付属語と，その係り受け関係の種類を決定する。

このようにして得られた解析ルールを用いて解析ルールを抽出した文とは異なる文を対象に係り受け関係の解析を行う。なお，対象とする文章は単語単位に分割されている。初めに，解析ルールの付属語パターンを文中で検索する。次に，検索された付属語の直前または直後の自立語を文中で検索する。このようにして得られた係り受け関係の候補の修正を相互の関連を考慮して行い，係り受け関係を決定する。

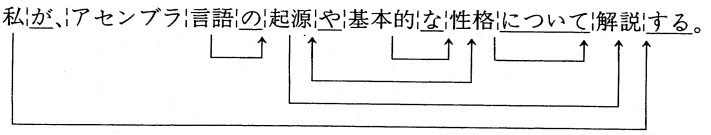
解析ルールを用いた係り受け関係の解析の処理手順を図1の例を用いて述べる。今，図1(a)のような5つの解析ルールが解析ルール辞書に存在するとする。ここで，図1(a)の①の解析ルールは「Aが…Bする」という語の組が文章中に存在すれば，AとBは主語と述語の関係にあることを表す。解析ルール①を用いる場合には，初めに，付属語「が」及び「する」が文中に存在するかどうかを検索し，存在すれば次にこれらの付属語の直前に自立語が存在するかどうかを検索する。この場合には「私」と「解説」が存在するので，この両者の係り受け関係が決定される。以上のようにして解析ルール①により「私」と「解説」が係り受け関係にあることが決定されるので，解析ルール①で定義された自立語A，Bの関係である主語と述語より，「私」と「解説」が主語と述語の関係にあることがわかる。

解析された係り受け関係に基づき，係り受け関係を構成する自立語の組を関連語の組として抽出し，関連語辞書に蓄える。この際には，その関連語の組の係り受け関係の種類が付加される。

①Aが…Bする　→　AはBの主語
②AなB　→　AはBの修飾語
③AやB　→　AとBは並列
④AのB　→　AはBの修飾語
⑤Aについて…Bする　→　AはBの対象

注）…：文字（空も可）
A,B：自立語

（a）解析ルール



注）|：単語の区切り
＿：用いられた付属語パターン

（b）係り受け関係解析結果

（i）①より「私」は「解説」の主語
（ii）②より「基本的」は「性格」の修飾語
（iii）②③より「起源」と「性格」は並列
（iv）④より「言語」は「起源」の修飾語
（v）⑤より「性格」は「解説」の対象
（vi）②③⑤より「起源」は「解説」の対象

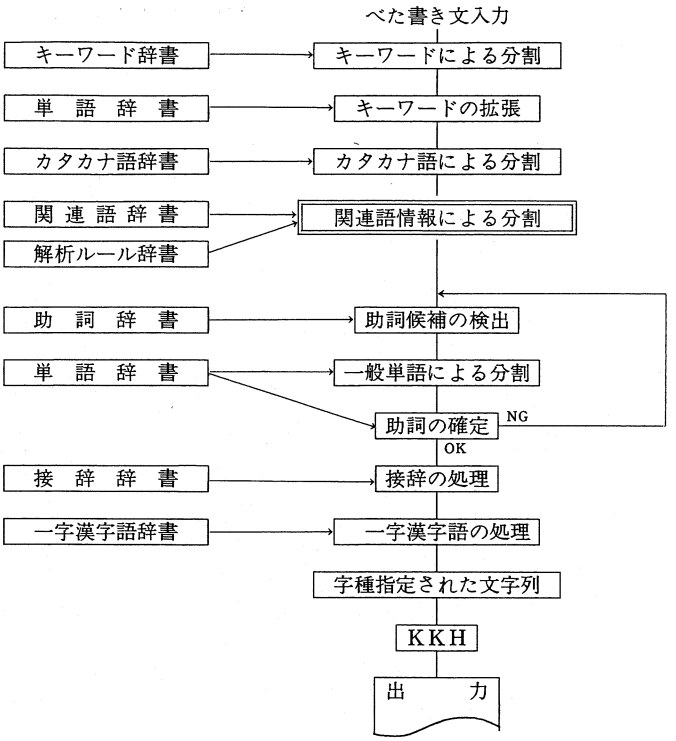
（c）得られた関連語の組

図－1　解析ルールによる関連語抽出の例

3．べた書き文かな漢字変換への適用方法

前述のように単語単位に分割された一定量の文章より抽出された関連語情報を用いて，べた書き文を単語に分割する実験を行った。ここで，実験に使用したシステムは，多段階分割法によるべた書き文かな漢字変換システム[7]である。このシステムでは，図2に示すようにべた書き文を最初に少数の手掛り語（キーワード）によって一意に分割し，以後の分割候補を少なくしてから確実性の高いものより順次段階的に分割を進める。

そこで，このシステムの1処理段階として「関連語情報による分割」段階を設け，本手法によるべた書き文の単語分割を行った。図2に「関連語情報による分割」段階の実験システムにおける適用位置を示す。図2に示すように，「カタカナ語による分割」の後，「助詞候補の検出」の前にこの新段階が置かれている。したがって，べた書き文中で，関連語情報によりあてはめられる単語の組の一方または両方が，すでにあてはめられた単語，すなわちキーワードまたは



図－2　多段階分割法によるべた書き文かな漢字変換システムにおける関連語情報の適用位置

カタカナ語である場合がある。この場合は，未分割の部分のみ関連語情報を用いた分割により新たな単語をあてはめる。

次に，「関連語情報による分割」段階を「カタカナ語による分割」段階の後に行った理由を述べる。これは，多段階分割法によるべた書き文かな漢字変換システムにおいては，キーワードが最も確実性の高い語で，キーワードに準ずる語がカタカナ語であるので，「カタカナ語による分割」段階の終了した時点では誤分割が少なく，しかも処理がさほど進んでいないので未分割が比較的多く，他の語との関連性を利用するという本手法の性質から考えて最適と考えられるためである。

本手法のべた書き文かな漢字変換における単語分割への適用手順を以下に示す。

(1)　各解析ルールの付属語を検索する。

(2)　存在した解析ルールNの付属語に隣接する文字列と読みの一致する関連語の組(A，B)を関連語辞書中よりすべて取り出す。

(3)　関連語辞書中でAの関連語としてBが存在し，しかも，AとBの係り受け関係の種類が，A，Bを取り出すのに使用された解析ルールNが示す係り受け関係の種類と一致する場合

⑥　AとB　→　AとBは並列
(a)　図1(a)に追加する解析ルール

きげんとせいかくについてかいせつする。
(b)　入力されたべた書き文

［起源］とせいかく［について］かいせつする。
(c)　「カタカナ語による分割」段階までの結果

［起源］と¥性格¥［について］¥解説¥する。
［ ］：キーワード　　¥　¥：関連語　　＿＿：用いられた付属語パターン
(d)　「関連語情報による分割」処理の結果

図－3　関連語情報による分割の例

のみA，Bをあてはめる。

これを，図3を用いて説明する。ここで，解析ルール辞書には図1(a)と図3(a)の解析ルールが，関連語辞書には図1(c)の関連語情報が蓄えられているものとする。図3(b)のべた書き文を図2に示すシステムで処理すると，「カタカナ語による分割」段階が終了した時点では図3(c)のように単語があてはめられている。ここで，例えば，図3(a)の解析ルール⑥の付属語「と」に着目し，解析ルール⑥のA，Bとして「起源」と「性格」を抽出する。図1(c)より，「起源」と「性格」は並列関係にある関連語として関連語辞書に登録されている。これは，解析ルール⑥の係り受け関係の種類である「AとBは並列」と一致するので，「性格」を「起源」の関連語としてあてはめる。同様にして，「解説」が「性格」の関連語としてあてはめられる。

4．関連語情報による単語分割実験

4．1　実験方法

資料は，解析ルール辞書を除く初期辞書作成用に，「データベース要論」(穂鷹良介著，総文字数63,265文字)を用い，単語分割を行う資料として表1に示す文献を用いた。また，解析ルール抽出に用いた資料は「データベース要論」の初めの8文より抽出された24種の解析ルールを用いた。

図4に実験の手順を示す。この手順は，表1のNo.1～6までの各文章ごとに行われる。まず，べた書き文の状態で文章を入力し，次に，これを図2に示す関連語情報による分割段階を付加した多段階分割法によるべた書き文処理本体を用いて字種指定ローマ字列に変換し，次いで，これを人手により校正し，この校正されたローマ字列を用いて辞書を自動更新[7]し，次の文章を

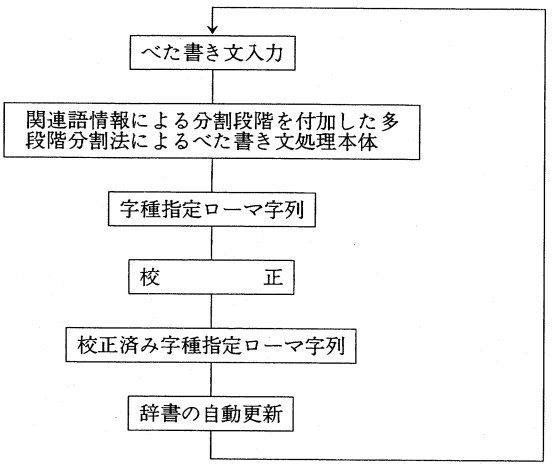
入力するという処理を6回繰り返した。なお，関連語辞書の更新については，2．2節で述べた解析アルゴリズムにより関連語を抽出することにより行われる。また，解析ルール辞書については新たな解析ルールの追加は行わない。

表1　関連語情報による単語分割実験に用いた資料

No.	文字数	No.	文字数
1	9,274	4	8,630
2	9,011	5	7,970
3	6,438	6	11,188

総文字数52,511文字

出典「情報検索」（中原啓一著）



図－4　関連語情報による単語分割実験手順

4．2　実験結果

表2に関連語情報による単語分割実験の結果を示す。表2に示すように，関連語情報により新たに分割された137箇所のうち正しく分割されたものは133箇所で誤って分割したものが4箇所であった。したがって，正分割率が97.1%，誤分割率が2.9%であった。

表2　関連語情報による単語分割実験結果

資料No.	関連語情報による新たな分割数			分割率［%］	
	総分割数	正分割数	誤分割数	正分割率	誤分割率
1	16	15	1	93.8	6.3
2	23	22	1	95.7	4.3
3	19	19	0	100.0	0.0
4	30	30	0	100.0	0.0
5	21	21	0	100.0	0.0
6	28	26	2	92.9	7.1
計	137	133	4	97.1	2.9

4.3 考察

関連語情報によるべた書き文の単語分割の精度は，97.1%であった。これは，べた書き文の単語分割において関連語情報が有効であることを十分示している。しかし，対象とした総数は137箇所であり，比較的少ない値であった。この原因としては，本手法で解析できる係り受け関係を構成する単語がキーワードであることが比較的多く，すでにキーワードとしてあてはめられていたことが挙げられる。また，その他に用いた解析ルールの数が少なかったことや，関連語辞書の初期辞書を作成したデータが少なく，見出し語が1,100語程度であったことが挙げられる。これらは，「関連語情報による分割」段階をさらに上位の階層にすることや使用するルールの数及び関連語辞書を作成する資料を増加することによって改善されるものと考えられる。

5. おわりに

日本語文の係り受け関係を解析し，その利用を図ることは大きな問題である。本論文では，すべての係り受け関係を複雑な処理により深く解析するのではなく，表層レベルに付属語によって明示的に示される係り受け関係を文章より付属語パターンによって解析する手法により関連語の組を抽出し，その情報によるべた書き文を単語単位に分割する手法を提案した。性能評価実験の結果，本情報による単語分割が97.1%の精度で行われることが確認された。これは，本方式の有効性を十分示していると考えられる。

参考文献

1）吉田将，松山晶子：日本語の規格化ー係り受け関係の規格化とそれへの変換ルールー，情報処理学会自然言語処理研究会資料，51－4，pp. 1－6（1985）.
2）本間茂，山階正樹，小橋史彦：連語解析を用いたべた書きかな漢字変換，情報処理学会論文誌，Vol. 27，No. 11，pp. 1062－1068（1986）.
3）鶴丸弘明，兵頭竜二，松崎功，日高達，吉田将：語義を考慮した単語間の階層構造の抽出について，情報処理学会自然言語処理研究会資料，64－2，pp. 9－16（1987）.
4）岡夏樹：読み返しによる学習，第33回情報処理学会全国大会講演論文集，pp. 1247－1248（1986）.
5）吉田将：二文節間の係り受け関係を基礎とした日本語文の構文分析，電子通信学会論文誌，Vol. 55－D，No. 4，pp. 238－244（1972）.
6）荒木健治，栃内香次：日本語文の表層レベルでの浅い解析，北海学園大学工学部研究報告，第16号，pp. 123－136（1989）
7）荒木健治，栃内香次：付属語パターンを用いたルールによる表層レベルでの係り受け関係の解析，情報処理学会自然言語処理研究会資料，NL 68－6，pp. 1－8（1988）.
8）荒木健治，栃内香次，永田邦一：多段階分割法によるべた書き日本語文のかな漢字変換，情報処理学会論文誌，Vol. 28，No. 4，pp. 412－421（1987）.
9）栃内香次，斉藤康：適応型変換辞書を用いるかな漢字変換，情報処理学会論文誌，Vol. 24，No. 2，pp. 209－213（1983）.