帰納的学習による形態素解析手法における適応能力の評価

Evaluation of Adaptation Capability for Morphological Analysis Method by Inductive Learning

荒木　健治
Kenji Araki

栃内　香次
Koji Tochinai

北海学園大学
Hokkai-Gakuen University

北海道大学
Hokkaido University

日本語文書を計算機で処理する場合、まず、行わなければならないのが形態素解析の処理である。本論文では文書中に出現する未知語を帰納的学習により推測することを基本とする形態素解析手法の概要と処理方法の改良法について述べ、さらに、適応能力を評価するために行った実験により対象とする分野が変化しても正認識率は、さほど変化しないことより本手法の適応能力が有効であることが確認された。

1．はじめに

高度情報化社会の進展により日本語文書を計算機により利用したいという要求は年々急速に高まっている。日本語文書を計算機で高度に利用する場合、まず、問題となるのが文書中の単語認識の問題である。すなわち、日本語には分かち書きの習慣がないので、計算機で日本語文書を処理する場合には、まず分かち書きを行って文を単語単位に分割しなければならず、いわゆる形態素解析[1]が必要となる。

計算機による自動分かち書きの処理に対しては、これまで種々の方法が提案されてきた[2,3,4,5]。これらはすべて既知語（登録語）に対する処理のみに限定しているか、既知語に対する処理の枠組みの中に未知語（未登録語）の処理を付け加えている。しかし、自然言語が本来持つ非常に語彙が多く、しかも、時代につれて変化するという性質上、実用システムで未知語が出現しないということは考えられない。また、文節や語の概念も人によって異なっている[6]。したがって、未知語の処理は自然言語を扱う上で本質的に重要なことである。

この様な立場に立ち、我々は未知語の処理を基本とする形態素解析手法を提案してきた[7]。本手法では、文字列中に共通に出現するパターンを語と推測することにより帰納的に語を学習することによって未知語に対処している。また形態素解析された結果を人手で校正することによって得られる正しく分割された文書と認識結果を比較することにより正認識および誤認識の情報を学習する。したがって、本手法は語を学習により獲得するので辞書や文法の構築の必要がなく、対象分野あるいは個人に動的に適応することが可能である。

しかし、本手法については、共通部分を抽出するための処理時間の増大、尤度を決めるための評価関数の係数の最適値、大量の資料を用いた異なる分野に対する適応能力の評価について十分な考察が行われてはいなかった。そこで、本論文では、本手法の概要、処理時間の短縮および精度の向上のために行った本手法の改良について述べ、さらに改良された実験システムを用いて行った異なる分野の資料を用いた適応能力評価実験結果について述べる。

2．概　要

本手法は2つの学習過程、2つの認識過程および1つの校正過程よりなる。処理過程を図1に示す。

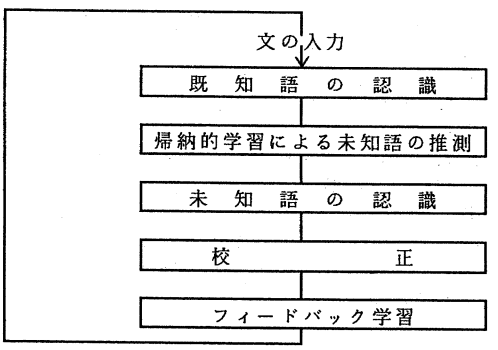


図1　処理過程

本手法では、まず、文が入力されると既知語による認識が行われる。これは、すでに獲得され、蓄積された語によって入力された文字列中の語を認識する過程である。次に帰納的学習による未知語の推測を行う。これは、既知語によって認識されなかった部分より共通パターンを2段階で抽出することにより未知語を推測する過程である。これは、文書を構成する単位は語であるので、文字列中に繰り返し現われる同一文字列は語である可能性が高いという仮定に基づいている。次に推測された未知語を用いて未知語の認識を行う。この段階では、確実性の高いものより認識を行ってい

る。このようにして得られた認識結果の誤りを人手により校正する。次に、認識結果と校正により得られた正しい認識結果を比較して正認識、誤認識の傾向を学習させる。さらに未登録語を辞書に登録する。これにより、次回の認識の精度を向上させている。この過程をフィードバック学習という。

3．処理過程

3．1　既知語の認識

この段階ではこれまでに獲得された既知の語を用いて入力文字列中の語を認識する。ここで用いられる語はフィードバック学習で人手によって校正された文書より得られる語である。したがって、語であることが確認されているので最も確実性が高い語である。本論文では、このような語をCorrect Wordと呼びＣＷと表記する。既知語の認識は以下のように行われる。

（１）入力文字列と各ＣＷとを比較する。
（２）語と認識する基準
　①２文字以上一致する部分があれば既知語であると認識する。
　②１文字のみ一致する場合は以下の条件のいずれかを満足する場合のみ既知語であると認識する。
　　ａ．両側が異なる字種で囲まれている場合
　　ｂ．両側が認識済みの語で囲まれている場合
（３）認識した単語候補が重複した場合の処理は以下のようにする。
　以下の尤度評価関数によって算出された尤度評価値の最大のものを選択する。

$$\text{尤度評価関数} = \alpha * CF + AF - \beta EF$$

　ＣＦ：正認識度数、ＡＦ：出現頻度、
　ＥＦ：誤認識度数、α、β：係数

　尤度評価値が最大のものが複数ある場合には、誤認識度数最小、正認識度数最大、出現頻度最大、文字数最大、分割の位置の最前の順に評価して最適な単語を決定する。なお、正認識度数、誤認識度数、出現頻度はそれぞれフィードバック学習で更新される。

既知語の認識の方法を図２に示す。図２でＡに場合には２文字以上一致しているのでＣＷと認識する。また、Ｂの場合には１文字しか一致していないが、両側が異なる字種で囲まれているのでＣＷと認識する。Ｃの場合には単語候補が重複して出現する場合でこの場合には尤度評価関数によって最適なＣＷを決定する。

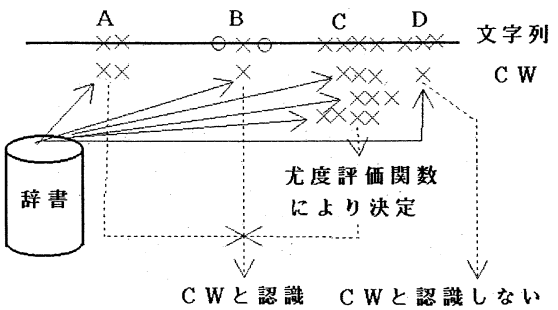


図２　既知語の認識の方法

しかし、Ｄの場合には１文字しか一致していない上に両側が同一の字種であるのでこの場合にはＣＷと認識しない。

既知語の認識の例を図３に示す。

連続音声認識では連続音声｜を｜認識して
　　ＣＷ
いる。／しかし／、／単音節／音声認識では
　　ＣＷ　　ＣＷ
／単音節／ごとに認識｜する｜。
　ＣＷ　　ＣＷ

自立語：／　／　　付属語：｜　｜

図３　既知語の認識の例

3．2　帰納的学習による未知語の推測

入力文字列中で既知語によって認識されなかった未認識文字列より未知語を帰納的学習により推測する。本論文で用いている帰納的学習とは未知文字列中より共通部分を２段階に抽出することにより語を推測する過程をいう。

帰納的学習による未知語の推測では、まず、ＣＷによって認識されなかった未認識文字列より共通パターンを抽出する。これをType Ⅰ Segmentと呼び、Ｓ１と表記する。この共通パターンを抽出する条件を以下に示す。

（１）２文字以上一致した場合
（２）１字のみ一致した場合
　　以下の条件のいずれかを満たす場合
　①両側が異なる字種で囲まれている場合
　②両側が認識済みの語で囲まれている場合
（３）少なくとも１つは他の共通パターンに含まれない出現位置が存在する。

さらに抽出された共通パターン中（Ｓ１）より共通部分を抽出する。これは、複数の語から構成されるＳ１を１つの語から構成されるＳ１で分解するものである。この過程を高次共通パターンの抽出と呼ぶ。ここでの共通パターンの条件を以下に示す。

（１）２文字以上一致した場合
（２）１字のみ一致した場合
　　以下の条件のいずれかを満たす場合
　①両側が異なる字種で囲まれている場合
　②両側が認識済みの語で囲まれている場合
（３）一方が他方に完全に含まれる形で重複している。

この様にして抽出された共通部分をType Ⅱ segmentと呼び、Ｓ２と表記する。また、共通部分以外の残りの部分をType Ⅲ segmentと呼び、Ｓ３と表記する。また、分解されたＳ１は削除され、共通部分であったＳ１はＳ２となる。

以上、Ｓ１、Ｓ２、Ｓ３を総称して、Word segmentと呼び、ＷＳと表記する。図４に帰納的学習による語の推測の例を示す。

また、この高次共通パターンの抽出段階では、品詞の推測を行う。品詞の推測はヒューリスティックスを用いて行われる。この段階では誤りを含む可能性があるが、これらの誤りはフィードバック学習で修正される。すなわち、誤った品詞を持った語は次第に尤度が下がり辞書から削除される。品詞推測のヒューリスティックスを図５に、品詞推測の例を図６に示す。

（１）ＣＷによって認識された文書
連続音声認識では連続音声｜を｜認識して
ＣＷ
いる。／しかし／、／単音節／音声認識では
ＣＷ　ＣＷ
／単音節／ごとに認識｜する｜。
ＣＷ　ＣＷ
自立語：／　／　付属語：｜　｜
（２）Ｓ１の抽出結果
連続音声、認識、音声認識、では
（３）Ｓ２、Ｓ３の抽出過程
（音声認識、認識）→音声：Ｓ３＜自立語＞
認識：Ｓ２＜自立語＞
（連続音声、音声）→連続：Ｓ３＜自立語＞
音声：Ｓ２＜自立語＞
では　Ｓ１＜付属語＞
（４）ＷＳの抽出結果
Ｓ１：では＜付属語＞、
Ｓ２：音声＜自立語＞、認識＜自立語＞
Ｓ３：連続＜自立語＞

図４　帰納的学習による未知語の推測の例

（１）接辞
共通パターン以外の部分が一字の漢字語の時
①接頭語
共通パターン以外の部分が前に存在
②接尾語
共通パターン以外の部分が後ろに存在
（２）付属語…すべてひらがな書きの語
（３）活用語尾
①共通パターン以外の部分が一字ひらがな語
②一字助詞以外の語
（４）自立語…（１）（２）（３）以外の語

図５　品詞推測のヒューリスティックス

（本論文、論文）→　本　：Ｓ３＜接頭語＞
論文：Ｓ２＜自立語＞
（簡単化、簡単）→　簡単：Ｓ２＜自立語＞
化　：Ｓ３＜接尾語＞
では　→　Ｓ１＜付属語＞
（行う、行）　→　行　：Ｓ２＜自立語＞
う　：Ｓ３＜活用語尾＞

図６　品詞の推測の例

なお、以上の処理で単語候補が重複した場合の処理は既知語の認識の場合と同様である。

３．３　未知語の認識

ＣＷによって認識されなかった未認識文字列について、帰納的学習によって推測された語を用いて未知語の認識を行う。認識は、確実性の高いものより行われる。したがって、その手順は以下のようになる。
（１）Ｓ２による認識
（２）Ｓ１による認識
（３）Ｓ３による認識
認識の基準を以下に示す。
（１）２文字以上一致した場合
（２）１字のみ一致した場合
以下の条件のいずれかを満たす場合
①両側が異なる字種で囲まれている場合
②両側が認識済みの語で囲まれている場合
また、認識された語が重複した場合の処理も既知語の認識と同様である。図７に未知語の認識の例を示す。

／連続／／音声／／認識／｜では｜／連続／／音声／
Ｓ３　Ｓ２　Ｓ２　ＣＷ　Ｓ３　Ｓ２
｜を｜／認識／している。／しかし／、／単音節／
ＣＷ　Ｓ２　ＣＷ　ＣＷ
／音声／／認識／｜では｜／単音節／ごとに／認識／
Ｓ２　Ｓ２　Ｓ１　ＣＷ　Ｓ２
｜する｜。
ＣＷ
自立語：／　／　付属語：｜　｜

図７　未知語の認識の例

３．３　校正

次に、人手によりシステムが認識した結果を人手により校正する。図７の認識結果を校正したものを図８に示す。図８で＝の部分が未認識を修正したものであり、～の部分が誤認識を修正したものである。

／連続／／音声／／認識／｜では｜／連続／／音声／
Ｓ３　Ｓ２　Ｓ２　ＣＷ　Ｓ３　Ｓ２
｜を｜／認識／｜して｜｜いる｜。／しかし／、
ＣＷ　Ｓ２　ＣＷ
［単］／音節／／音声／／認識／｜では｜
ＣＷ　Ｓ２　Ｓ２　Ｓ１
［単］／音節／｜ごと｜｜に｜／認識／｜する｜。
ＣＷ　Ｓ２　ＣＷ
自立語：／　／　付属語：｜　｜　接頭語：［　］

図８　校正結果

３．４　フィードバック学習

次回の認識の精度を向上させるために、認識の状況を学習する。これをフィードバック学習と呼ぶ。フィードバック学習は認識結果と校正結果を比較することにより行われる。一つは、未登録語の辞書への登録を行う。また、正認識を行った語の尤度を上げ、誤認識を行った語の尤度を下げる。具体的手順を以下に示す。
（１）正認識の場合
①認識した語の所属をＣＷとする。
②認識した語のＣＦ（正認識度数）とＡＦ（出現頻度）を１増加する。
（２）誤認識の処理
①正しい語の処理
ａ．正しい語が辞書に存在しないときはＣＷにＡＦを１にして登録する。
ｂ．正しい語が辞書に存在するときはＡＦを１増加させる。また、その語の所属がＣＷ以外の時はＣＷに変更する。
②誤った語についてはＥＦを１増加させる。
（３）未認識の処理
①正しい語が辞書に存在しないときはＣＷにＡＦを１にして登録する。
②正しい語が辞書に存在するときはＡＦを１増加させる。また、その語の所属がＣＷ以外の時はＣＷに変更する。
この他フィードバック学習では尤度の評価による所属クラスの制限[7]が行われる。

４．処理方法の改良[8]

４．１　処理時間の削減

本手法では、従来、既知語の有無に関わらず全文字列を対象として帰納的学習による未知語の推測を行っていた。このために、処理時間の増大が問題となっていた。そこで、入力された文字列をまず、既知語によって認識し、既知語によっても認識されなかった部分を対象として未知語の推測を行うことにした。この効果を確認するために実験を行った。資料は、情報処理に関する文献1編（総文字数9、223文字）を章ごとに5つに分割し、図1の処理を5回繰り返した。辞書の初期状態は空とした。実験結果を表1に示す。

表1　処理時間の減少の効果

		正認識	誤認識	未認識	処理時間
改良前	1	53.7	18.6	27.6	7:39.10
	2	62.3	11.8	25.8	6:06.84
	3	75.8	12.8	11.4	15:49.02
	4	80.5	9.5	10.0	2:02:05.07
	5	80.4	9.5	10.1	1:40:13.51
	計	75.8	11.0	13.2	4:12:53.54
改良後	1	54.4	20.6	25.1	12:30.46
	2	68.5	11.6	19.9	47.77
	3	78.3	11.1	10.6	1:11.18
	4	83.4	10.6	6.0	3:57.82
	5	84.0	9.7	6.3	5:10.34
	計	78.9	11.3	9.8	23:37.57

注）単位は認識率は［%］、処理時間は［s］

表1より明らかなように処理時間は1／10に減少している。また、精度も3～4%の向上が確認された。以上より、初めにCWによって認識を行い、CWによって認識されなかった部分を対象として未知語を推測する改良は本手法にとって有効であることが確認された。

4．2　尤度評価関数における最適な係数の決定

表2　尤度評価関数係数決定実験の結果
（正認識率について）

β	α				
	種別	1	2	3	10
2	No.5	84.0	84.1	84.0	84.0
	総合	78.6	78.6	78.4	78.5
4	No.5	84.4	84.0	84.2	84.1
	総合	78.8	75.9	78.7	78.6
6	No.5	84.3	83.7	84.0	84.0
	総合	78.8	77.8	78.6	78.6
8	No.5	75.1	84.3	84.0	84.0
	総合	75.8	78.8	78.5	78.6
10	No.5	**84.7**	84.4	84.3	84.1
	総合	**79.1**	79.0	78.7	78.6
50	No.5	82.3	83.8	83.8	84.7
	総合	77.8	78.3	78.6	78.6

単位は%

認識された単語が重複した場合に最適な語を決定する尤度評価関数の係数は、従来誤認識を起こした語の尤度を大きく下げるという観点からαを2、βを4としていたが、最適値については確認されていなかった。そこで、実験により最適なαとβを決定するための実験を行った。資料および初期状態は処理時間の削減の場合の実験と同様である。総合と5番目のデータの正認識率を表2に示す。表2より5番目のデータと総合で最も高い正認識率を示している$\alpha=1$、$\beta=10$に決定した。

5．適応能力評価実験

改良された実験システムを用いて本手法の適用能力を評価するための実験を行った。

5．1　実験方法

実験に用いた資料は表3に示す情報処理に関する論文14編（総文字数120、417文字）と機械工学に関する論文10編（総文字数58、009文字）の24編（総文字数178、426文字）である。これらの資料を各論文ごとに章を単位として5分割して用いた。

実験手順は図1に示す処理を各章ごと120回行った。なお、初期状態の辞書は空の状態から行った。

5．2　実験結果

認識の位置と品詞が一致したものを正認識とし、認識位置あるいは品詞が一致しないものを誤認識、認識されなかったものを未認識と呼ぶ。正認識率、誤認識率、未認識率はそれぞれ正認識語数、誤認識語数、未認識語数の総語数に占める割合である。定義式を以下に示す。

$$\text{正認識率}=\frac{\text{正認識語数}}{\text{総語数}}\qquad \text{誤認識率}=\frac{\text{誤認識語数}}{\text{総語数}}$$

$$\text{未認識率}=\frac{\text{未認識語数}}{\text{総語数}}$$

実験結果を表4に、総合の正認識率、誤認識率、未認識率の推移を図8に示す。また、表4でWSの未知語推測能力とは、帰納的学習による未知語の推測能力を評価したもので、それぞれ、CWの未認識語数に占めるWSの正認識語数、誤認識語数、未認識語数の割合である。WSの未知語推測能力の評価の定義式を以下に示す。

$$\text{正認識率}=\frac{\text{WSの正認識語数}}{\text{CWの未認識語数}}$$

$$\text{誤認識率}=\frac{\text{WSの誤認識語数}}{\text{CWの未認識語数}}$$

$$\text{未認識率}=\frac{\text{WSの未認識語数}}{\text{CWの未認識語数}}$$

表３　　実験に用いた資料

（１）分野：情報工学　出典：情報処理学会論文誌

No	論　文　名	著者名	巻　名	文字数
1	高集積マイクロコンピュータに適したマイクロプログラム制御方式	前島他	Vol.23 No.1	10,920
2	ＣＯＢＯＬマシンとその設計思想 ― ハードウェア構成について ―	山本他	Vol.23 No.1	8,504
3	フーリエ変換を用いたテクスチュアの構造解析	松山他	Vol.23 No.2	7,752
4	日本語文入力用カタカナ語検出規則とオンライン国語辞典の一分析	木村	Vol.23 No.2	8,655
5	インテリジェント・コンソール ― ＯＳの機能拡張の一方法 ―	有田	Vol.23 No.3	9,394
6	ポータブル画像処理ソフトウェア・パッケージ ＳＰＩＤＥＲの開発	田村他	Vol.23 No.3	9,611
7	グラフィック・ディスプレイ・ターミナルのための端末作画システム	高藤他	Vol.23 No.4	6,582
8	オペレーティング・システムのファームウェア化対象選定法	長岡他	Vol.23 No.4	7,636
9	プログラム階層構造の生成、処理、文書化能力を有するテキスト・エディタ	酒井他	Vol.23 No.4	8,034
10	パステストに本質的な分岐に着目した網ら率尺度の提案	中所他	Vol.23 No.5	10,010
11	計算機システムにおける性能管理の一方式とそれを用いた実験	吉住他	Vol.23 No.6	8,991
12	高速パケット伝送路用前置処理装置の一構成法	寺田他	Vol.23 No.6	8,404
13	ソフトウェア生産過程の評価実験に関する考察	有澤他	Vol.23 No.3	6,550
14	文節数最小法を用いたべた書き日本語文の形態素解析	吉村他	Vol.24 No.1	9,374
情報工学分野の文字数の合計				120,417

（２）分野：機械工学　出典：北海道大学工学部研究報告

No	論　文　名	著者名	巻　名	文字数
1	格子乱流中における垂直平板の流力特性	有江他	第106号	4,905
2	疲れ強さにおよぼす加工効果および残留応力の影響 ― 低温燃焼の場合 ―	秦　他	第 97号	8,810
3	暖房用ストーブの燃焼性能に関する研究（第１報）－ポット式灯油ストーブの燃焼実験及び流動解析－	園田他	第106号	7,212
4	暖房用ストーブの燃焼性能に関する研究（第２報） ― 温風、ＦＦおよびポータブル形各種ストーブの燃焼実験 ―	園田他	第106号	5,353
5	任意に調節可能な座標線密度をもつ流れ場内格子点網の創成法	飯田他	第107号	6,387
6	円弧切欠きと荷重端の干渉について（第３報　平面弾塑性応力問題）	岸田他	第108号	2,141
7	境界層剝離の近似的な推定法	知名他	第 98号	4,508
8	換気回数の低い室内における都市ガスの燃焼と一酸化炭素の発生	伊藤他	第105号	7,495
9	チェーンソーの振動におよぼす切削条件の影響	金内他	第104号	7,120
10	任意形状を有する四辺形膜の自由振動	入江他	第 96号	4,078
機械工学分野の文字数の合計				58,009

図８で破線は論文の切れ目を表わしている。

５．３　考察

表４と図８を見るとわかるように、総合の正認識率は、次第に上昇しているが、情報工学の論文４で極端に下がっている。これは、論文４が日本語処理について書かれた論文であり、”「けしきばむ」が「けしきばむ」となっていた”といった日本語入力の誤りの例や話言葉などがあり、形態素解析を行うことが困難なためである。しかし、論文４でも学習により正認識率は次第に向上している。

また、全体を通していえることは、認識率が最高で９０％程度でさほど高くないということである。これは、第一には共通部分を抽出する際のＣＷによる未認識文字列が少なかったために、共通部分がさほど出現せず、ＷＳによる未知語の推測が行われなかったことが原因である。これは、表４のＷＳの未知語推測能力の

表４　　適応能力評価実験結果

（１）情報工学

分野	論文No	番号	文字数		総合			WSの未知語推測能力		
			各ﾃﾞｰﾀ	累積	正認識	誤認識	未認識	正認識	誤認識	未認識
情報工学	1	1	2725	2725	54.8	30.1	15.1	54.8	30.1	15.1
		2	1836	4561	78.1	12.5	9.4	39.7	23.1	37.2
		3	1785	6346	84.2	7.8	8.0	47.6	20.7	31.7
		4	1389	7735	81.6	9.5	8.9	39.9	14.0	46.2
		5	3185	10920	85.1	7.0	7.8	23.5	17.6	58.8
	2	1	1418	12338	83.3	9.5	7.2	39.1	26.7	34.2
		2	2807	15145	84.2	9.9	5.9	42.9	23.0	34.1
		3	1096	16241	86.6	7.2	6.2	22.2	19.0	58.7
		4	1603	17844	86.8	6.7	6.5	19.2	25.3	55.6
		5	1580	19424	85.7	5.9	8.4	10.4	22.9	66.7
	3	1	1193	20617	80.7	9.4	9.9	40.8	21.2	38.0
		2	810	21427	78.8	12.1	9.1	29.9	23.7	46.4
		3	2146	23573	84.3	8.8	6.9	47.0	14.9	38.2
		4	3001	26574	84.7	8.2	7.1	38.0	22.0	40.1
		5	602	27176	86.0	9.2	4.8	0.0	19.0	81.0
	4	1	1867	29043	61.1	19.2	19.7	16.3	30.9	52.9
		2	1173	30216	76.2	12.0	11.7	26.8	14.5	58.7
		3	1651	31867	73.7	15.9	10.3	10.3	41.7	48.0
		4	3013	34880	71.2	17.5	11.2	16.3	24.9	58.7
		5	951	35831	67.5	18.7	13.8	4.7	16.0	79.2
	5	1	1103	36934	81.8	12.0	6.2	41.3	15.2	43.5
		2	1580	38514	82.5	10.2	7.2	23.1	25.9	50.9
		3	2032	40546	79.1	16.4	4.5	23.8	37.7	38.5
		4	4003	44549	81.7	14.3	4.1	36.6	33.6	29.9
		5	676	45225	79.4	10.7	10.0	6.3	8.5	85.1
	6	1	1359	46584	80.7	11.4	7.8	22.5	31.7	45.8
		2	1619	48203	80.9	7.6	11.6	9.1	10.7	80.2
		3	1362	49565	80.6	10.2	9.2	2.2	18.7	79.1
		4	2268	51833	75.9	15.6	8.5	16.0	36.4	47.6
		5	3003	54836	82.1	9.9	8.0	3.7	13.0	83.2
	7	1	1085	55921	82.7	13.5	3.8	44.6	20.0	35.4
		2	1440	57361	81.2	12.4	6.3	8.6	28.4	63.0
		3	1473	58834	86.3	9.4	4.3	26.9	19.4	53.7
		4	1448	60282	86.8	6.9	6.4	24.2	0.0	75.8
		5	1136	61418	87.7	7.2	5.1	20.4	12.2	67.3
	8	1	514	61932	91.0	5.3	3.8	16.7	0.0	83.3
		2	1696	63628	83.2	12.0	4.9	34.6	22.4	43.0
		3	641	64269	86.7	5.2	8.2	15.2	3.0	81.8
		4	3334	67603	84.7	11.2	4.1	33.8	25.8	40.4
		5	1451	69054	84.3	9.1	6.6	24.1	7.6	68.4
	9	1	879	69933	83.2	11.3	5.5	13.7	27.5	58.8
		2	1028	70961	82.1	10.8	7.1	22.7	12.1	65.2
		3	2158	73119	88.6	8.2	3.2	29.1	17.7	53.2
		4	2548	75667	82.5	12.7	4.8	7.2	33.9	58.9
		5	1421	77088	84.6	10.4	5.0	18.0	13.1	68.9
	10	1	695	77783	84.2	5.1	10.7	4.3	4.3	91.3
		2	1118	78901	84.8	9.4	5.8	29.4	13.2	57.4
		3	2856	81757	84.3	8.7	7.0	60.9	9.3	29.8
		4	3759	85516	83.9	10.4	5.8	9.0	26.6	64.3
		5	1582	87098	87.3	7.2	5.5	17.3	12.0	70.7
	11	1	722	87820	81.7	10.3	8.0	11.9	4.8	83.3
		2	2767	90587	84.3	11.7	4.0	33.9	29.9	36.2
		3	1044	91631	85.8	9.4	4.8	12.5	15.0	72.5
		4	2502	94133	86.9	8.4	4.7	13.3	13.3	73.5
		5	1956	96089	85.8	8.5	5.7	13.6	11.1	75.3
	12	1	942	97031	90.2	7.1	2.8	42.6	29.6	27.8
		2	1403	98434	86.2	7.2	6.6	10.8	24.1	65.1
		3	3524	101958	87.8	9.3	3.0	22.4	28.4	49.1
		4	2095	104053	89.1	8.1	2.8	30.4	27.8	41.8
		5	440	104493	88.6	7.9	3.5	0.0	59.1	40.9
	13	1	1914	106407	81.8	10.7	7.5	12.3	23.0	64.6
		2	890	107297	84.0	11.6	4.5	31.7	14.6	53.7
		3	1170	108467	79.3	13.6	7.2	16.5	22.4	61.2
		4	1820	110287	83.6	11.3	5.1	11.2	32.7	56.1
		5	756	111043	80.8	11.5	7.7	0.0	12.5	87.5
	14	1	1068	112111	83.2	12.2	4.5	15.8	31.6	52.6
		2	1748	113859	76.3	18.2	5.5	23.6	53.9	22.7
		3	3753	117612	86.7	10.6	2.7	16.0	56.4	27.6
		4	2343	119955	89.7	6.5	3.9	17.0	18.2	64.8
		5	462	120417	88.1	9.6	2.3	0.0	36.4	63.6

（２）機械工学

分野	論文No	番号	文字数		総合			WSの未知語推測能力		
			各ﾃﾞｰﾀ	累積	正認識	誤認識	未認識	正認識	誤認識	未認識
機械工学	1	1	806	121223	80.9	10.8	8.3	37.1	22.9	40.0
		2	668	121891	80.2	8.3	11.5	32.9	5.3	61.8
		3	996	122887	85.3	10.6	4.1	34.8	10.9	54.3
		4	1379	124266	84.1	10.8	5.1	22.7	13.6	63.6
		5	1056	125322	86.4	7.6	6.0	19.4	16.1	64.5
	2	1	942	126264	79.3	12.8	7.9	55.0	7.5	37.5
		2	486	126750	83.9	10.3	5.8	43.6	10.3	46.2
		3	3614	130364	80.4	14.6	4.9	26.0	43.4	30.6
		4	3139	133503	85.3	10.8	3.9	7.9	50.8	41.4
		5	629	134132	87.1	6.6	6.3	0.0	13.8	86.2
	3	1	1901	136033	73.6	15.8	10.6	42.0	11.3	46.7
		2	1077	137110	81.6	12.2	6.2	19.4	16.1	64.5
		3	957	138067	77.7	12.5	9.8	10.1	27.0	62.9
		4	1474	139541	83.5	9.2	7.2	10.0	6.3	83.8
		5	1803	141344	83.4	9.9	6.6	12.1	12.1	75.8
	4	1	959	142303	83.3	10.3	6.4	21.6	7.8	70.6
		2	798	143101	87.6	8.3	4.1	9.1	0.0	90.1
		3	1272	144373	87.8	7.4	4.8	11.6	0.0	88.4
		4	1412	145785	85.4	10.7	3.8	0.0	10.8	89.2
		5	912	146697	86.6	6.9	6.5	0.0	10.0	90.0
	5	1	735	147432	76.3	15.9	7.8	10.1	36.2	53.6
		2	1639	149071	80.9	15.1	4.0	18.6	52.6	28.8
		3	2168	151239	79.8	14.4	5.8	14.7	37.9	47.5
		4	781	152020	76.8	14.8	8.4	14.3	25.7	60.0
		5	1064	153084	80.3	14.8	5.0	5.4	57.0	37.6
	6	1	699	153783	79.6	14.0	6.4	14.6	27.1	58.3
		2	294	154077	76.4	8.0	15.5	0.0	3.6	96.4
		3	408	154485	79.7	19.3	1.0	13.1	78.9	78.9
		4	517	155002	82.5	14.5	3.0	0.0	40.0	60.0
		5	223	155225	83.9	7.7	8.4	0.0	25.0	75.0
	7	1	880	156105	81.0	10.5	8.5	6.5	21.0	72.6
		2	1153	157258	88.9	9.1	2.0	15.6	48.9	35.6
		3	1020	158278	87.6	8.8	3.6	17.1	24.4	58.5
		4	632	158910	81.2	14.4	4.4	21.9	18.8	59.4
		5	823	159733	83.9	13.1	3.0	0.0	46.4	53.6
	8	1	694	160427	83.5	8.2	8.2	23.4	0.0	76.6
		2	1265	161692	84.3	9.9	5.9	7.0	10.5	82.5
		3	2394	164086	86.5	9.4	4.2	21.9	25.8	52.3
		4	2463	166549	87.0	10.8	2.2	12.6	51.5	35.9
		5	679	167228	87.8	5.6	6.5	0.0	0.0	100.0
	9	1	950	167778	80.9	9.7	9.4	34.0	4.0	62.0
		2	1021	168799	79.3	14.3	6.4	23.6	32.6	43.8
		3	653	169432	81.9	10.3	7.8	9.8	24.4	65.9
		4	3805	173257	85.7	10.1	4.2	11.0	15.4	73.5
		5	1091	174348	89.7	4.9	5.4	0.0	0.0	100.0
	10	1	779	175107	73.0	19.5	7.4	22.0	31.7	46.3
		2	736	175843	81.9	10.3	7.8	14.0	19.3	66.7
		3	1480	177323	83.4	12.4	4.3	14.9	28.4	56.8
		4	708	178031	84.3	10.7	5.0	31.9	21.3	46.8
		5	395	178426	86.9	9.5	3.6	0.0	30.8	69.2

正認識率が０～６０％であったことから明かである。これは、ＣＷによる認識が非常に多いために、ＣＷによる未認識が少なかったためである。したがって、入力する文書の量を増やす必要があると考えられる。また、どの程度の文字数であれば帰納的学習により未知語を推測することが可能であるのかといった実験も必要である。第２には、今回は人手による校正処理を２人で行ったために、形態素解析の基準が細かいところで異なっていたために学習が正しく行われなかったと考えられる。校正の方法を統一する必要がある。

分野の変化による適応能力の評価については、図８よりわかるように情報工学から機械工学に分野が変わってもさほど正認識率は下がっていない。このことは本手法の適応能力の高さを表わしているものと考えられる。

また、特に誤認識となった部分では数字・記号、アルファベット、カタカナ、ひらがなが多い。この原因としては、これらの文字が表意文字ではなく漢字とは１字の持つ情報量が異なるためであると考えられる。したがって、字種ごとにその処理を変えるという方法が考えられる。しかし、本手法は学習を基礎としているので字種の違いをシステムが自動的に学習により獲得する方法を考察する必要がある。

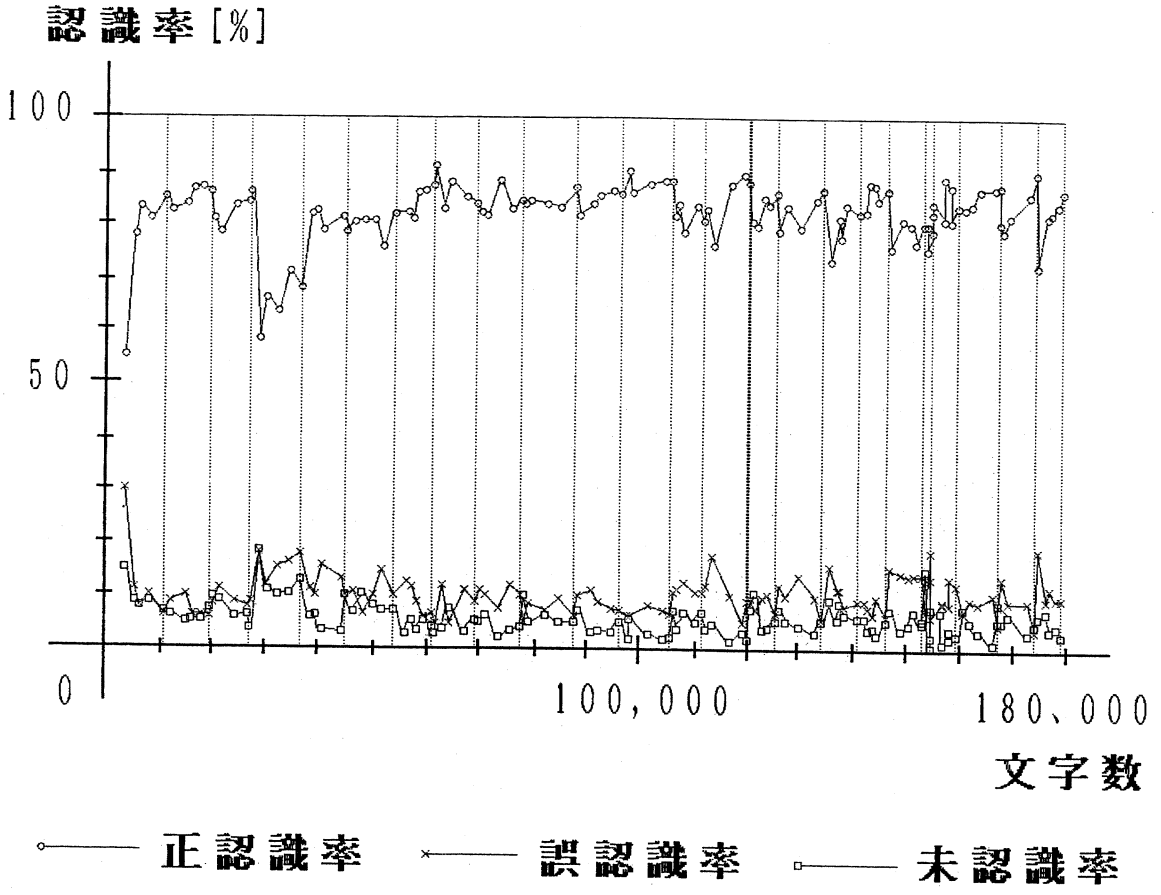


図9　認識率の推移

6．おわりに

未知語の推測を帰納的学習により行うことを基本とする形態素解析手法の概要とその処理方法の改良について述べ、次いで本手法の適応能力を実験により評価した結果について述べた。実験の結果より、分野が異なっても正認識率はさほど変化がないことがわかり本手法の適応能力の有効性が確認された。

今後の課題としては、1度に学習する文書の量がどれくらいあれば未知語の推測が可能なのかを実験により確認すること、学習により自動的に字種の違いを獲得し、字種により処理方法を変化させる方法の検討、さらに文学といった全く異なった分野に対する本手法の適応能力についても考察を進める予定である。

なお、本研究の一部は文部省科学研究費補助金（奨励研究A第2855098号）の補助により行われた。

参考文献

1）中野洋、野村雅昭：日本語の形態素分析、情報処理学会誌、Vol.20, No.10, pp.857-864(1979).

2）建石由佳、小野芳彦、山田尚勇：DictionとStyleの日本語化について、第31回情報処理全国大会講演論文集、pp.1381-1382(1985).

3）藤崎博也、亀田弘之：新聞記事データを対象とする自動単位切り処理とそれに基づく語彙調査、情報処理学会自然言語処理研究会資料、NL51-2(1985).

4）吉村、武内、津田、首藤：未登録語を含む日本語文の形態素解析、情報処理学会論文誌、Vol.30, No.3, pp.294-301(1989).

5）大沢、藤崎：未知語を含む文の形態素解析システム、情報処理学会第41回全国大会講演論文集、Vol.3, pp.107-108(1990).

6）原田：日本語テキストにおける認知的単位、情報処理学会研究会報告、Vol.89, No.7(1989).

7）荒木、栃内：帰納的学習による文字列中の語の認識、電子情報通信学会技術研究報告、Vol.89, No.341, pp.39-46(1989).

8）荒木、栃内：帰納的学習による形態素解析手法における処理方法の改良、平成2年度電気関係学会北海道支部連合大会講演論文集、pp.345(1990).