293 帰納的学習による形態素解析手法における処理方法の改良

荒木 健治（北海学園大学工学部）
栃内 香次（北海道大学工学部）

1．はじめに

日本語文書を計算機で処理する機会が急激に増大しているが、計算機で日本語を扱う場合には、まず、分かち書きを行わなければならない。分かち書き（形態素解析）の計算機による処理に対しては、種々の方法が提案されているが[1]、未登録語の問題、辞書の作成および文法構築の労力、文法を逸脱した文に対する処理、精度など多くの問題点があり、決定的な方法は未だ見い出されてはいない。我々は、この問題に対して、帰納的学習により形態素解析を行う手法を提案し[2]、システムを作成して小規模な実験を行い、その有効性を確認している[3]。本稿では、本手法の処理時間の削減と精度向上のために行った改良について述べる。

2．概要[3]

本手法は、文書を構成する基本単位としては語であるので、文書中に出現する同一文字列は語である可能性が高いという前提に基づいている。このような立場に基づき、本手法は既知単語の認識、未登録語の推測、未登録語の認識、人手による校正、認識結果のフィードバック学習、の５段階より構成される。既知単語の認識とは、辞書に登録された既出の単語を表記上の一致により認識するものである。また、未登録語の推測では、前述の観点から未認識文字列中に共通に出現する部分を、２段階の処理によって、３つのカテゴリーに分類し、これらの共通部分を確実性の高いものより順に未認識の部分に適用し、認識を行う。この結果を人手により校正する。フィードバック学習では、各単語に認識の際の優先度を表わす尤度を付加する。具体的には、校正結果と認識結果により正認識、誤認識および未認識を検出し、正認識を行った語の尤度を上げ、誤認識を行った語の尤度を下げる。また、未登録語の登録を行う。なお、各処理段階で重複して語の候補が出現する場合には、３．２節で述べる尤度評価関数により最適なものを決定する。

したがって、本手法では、共通部分より語を推測するので未登録語の問題に対処できる、学習により語を獲得して行くので、辞書の作成の労力が不要である、予め文法を構築しておく必要がないので、文法を逸脱した文にも対処できる、文法を構築する労力が不要である等の利点がある。また、学習により語を獲得するために、使用につれてシステムが対象分野および個人に適応するので汎用性が高いという特徴を有する。

3．処理方法の改良

従来、本手法では入力された全文字列を対象として共通部分を抽出し、これを語として認識していた。しかし、学習を数回行った時点では、辞書にはすでに語がある程度登録されている。したがって、この既知語を積極的に利用することが考えられる。そこで、まず、入力された文字列より辞書に登録されている既知語の認識を行い、その後で未認識の文字列を対象として未登録語の推測を行うように、改良を行った。この結果、処理時間の削減および精度の向上が期待され、実験によりこのことを確認した。

また、単語候補が重複した場合に尤度評価関数によって最適な単語を決定しているが、この尤度評価関数の係数は実験により最適な値を求めた。そして、これによる精度の向上が確認された。なお、実験は、資料に情報処理に関する文献１編（総文字数９２２３文字）を章ごとに５つに分けて用い、辞書の初期状態は空とした。また、実験はＶＡＸ８５５０上で行った。

3．1 処理時間の削減と精度の向上

処理方法の改良による処理時間の減少と精度の向上を実験により測定した。実験結果を表１に示す。表１からわかるように、処理時間は１０％以下に減少している。また、精度も正認識率で３～４％の向上が確認された。以上より、既知語の認識を先に行い、残りの部分より未登録語の推測を行うことは有効であることが示された。

表１ 処理時間の減少と精度の向上

		正認識率	誤認識率	未認識率	処理時間
改良前	1	53.7	18.6	27.6	7:39.10
	2	62.3	11.8	25.8	6:06.84
	3	75.8	12.8	11.4	15:49.02
	4	80.5	9.5	10.0	2:02:05.07
	5	80.4	9.5	10.1	1:40:13.51
	計	75.8	11.0	13.2	4:12:53.54
改良後	1	54.4	20.6	25.1	12:30.46
	2	68.5	11.6	19.9	47.77
	3	78.3	11.1	10.6	1:11.18
	4	83.4	10.6	6.0	3:57.82
	5	84.0	9.7	6.3	5:10.34
	計	78.9	11.3	9.8	23:37.57

注）単位は認識率は［％］、処理時間は［ｓ］

3．2 尤度評価関数における最適な係数

認識されるべき単語候補が重複した場合には以下のような尤度評価関数によって最適な単語を決定している。

ＬＥＦ＝αＣＦ＋ＡＦ－βＥＦ

ＬＥＦ：尤度評価関数、ＣＦ：正認識度数、

ＡＦ：出現頻度、ＥＦ：誤認識度数、α，β：係数

従来、α、βについては、誤認識をした語の尤度を大きく下げるという観点から、αを２、βを４としていたが、これが最適であることは確認されていなかった。そこで、実験により最適なα、βを決定することにした。その実験結果を表２に示す。

表２ 尤度評価関数係数決定実験の結果（正認識率）

β	α 種別	1	2	3	10
2	No.5	84.0	84.1	84.0	84.0
	総合	78.6	78.6	78.4	78.5
4	No.5	84.4	84.0	84.2	84.1
	総合	78.8	75.9	78.7	78.6
6	No.5	84.3	83.7	84.0	84.0
	総合	78.8	77.8	78.6	78.6
8	No.5	75.1	84.3	84.0	84.0
	総合	75.8	78.8	78.5	78.6
10	No.5	84.7	84.4	84.3	84.1
	総合	79.1	79.0	78.7	78.6
50	No.5	82.3	83.8	83.8	84.7
	総合	77.8	78.3	78.6	78.6

注）単位は％

表２には、この実験で最も辞書が飽和している５番目のデータと総合の正認識率とを示す。表２より５番目のデータと総合で最も高い認識率を示したα=1、β=10に決定した。

4．おわりに

既知語を優先して認識し、残りの未認識文字列より未登録語を予測することにより、処理速度と精度が改善された。また、尤度評価関数の最適な係数を実験により決定することができた。今後は、大量の資料を用い、一度ある分野で飽和した辞書が学習により異なる分野に適応することを実験により確認する予定である。

＊参考文献

１）吉村、武内、津田、首藤：未登録語を含む日本語文の形態素解析、情処論文誌、Vol.30, No.3, pp.294-301 (1989).
２）荒木、栃内：文字列中の共通パターンを用いた語の認識、支部大会講演論文集、pp.327-328(1989).
３）荒木、栃内：帰納的学習による文字列中の語の認識、信学会言語理解とコミュニケーション研究会資料、NLC89-32, pp.39-46(1989).