帰納的学習による形態素解析手法における処理時間の削減と尤度評価関数について

荒　木　健　治*1・栃　内　香　次*2

Reduction of Process Time and Likelihood Evaluation Function in Morphological Analysis Method by Inductive Learning

Kenji ARAKI*1 Koji TOCHINAI*2

日本語文には分かち書きの習慣がないので日本語文を計算機で扱う場合には，まず，分かち書きを行わなければならない。この問題に対しては計算機による自動分かち書きの手法（形態素解析）が種々提案されている。しかし，これらの手法はすべて既知語（登録語）を中心に考えられたものであり，自然言語を扱う場合必ず出現する未知語（未登録語）の処理を中心としたものではない。そこで，我々は未知の文字列中より共通に出現する部分を2段階に抽出することにより未知語を帰納的に学習し，推測する手法を提案している。本論文では，特に本手法の処理時間の削減および尤度評価関数について検討を行った結果について述べる。

1．はじめに

日本語文には分かち書きの習慣がない。このことは，計算機で日本語文書を扱う上で大きな問題となる。この問題に対しては，種々の方法が提案されている[1),2),3)]が，これらは既知語（登録語）を既存の文法体系によって処理することを基本としているために，未知語（未登録語），会話文などの文法を逸脱した文，表記の揺れ，文節概念の揺れ[4)]等に対する処理に問題が存在する。さらに，未知語を極力少なくするために大規模な辞書を持たなければならない。

＊1 北海学園大学工学部電子情報工学科
＊2 北海道大学工学部電子工学科
＊1 Department of Electronics and Information Engineering, Hokkai-Gakuen University
＊2 Department of Electronic Engineering, Hokkaido Unversity

こられの問題に対して，我々は未知語の存在を前提とした手法として，帰納的学習による形態素解析手法を提案し，実験によりその有効性を確認している[5]。本手法は，まず既知語によって入力文字列中の語を認識し，次いで未認識文字列中より2段階に共通部分を抽出することにより語を推測し，認識する。さらに，得られた認識結果を人手により校正し，その結果と認識結果を比較することにより未登録語を辞書に登録し，認識の傾向を学習するというものである。

ところで，本手法においては共通部分を抽出する際にすべての組み合せで比較を行うために処理時間が非常に長い。そこで，処理時間を削減する必要がある。また，認識の候補が重複して出現する場合に最適な候補を決定する尤度評価関数における係数を最適なものに決定する必要がある。本論文では，本手法の概要，処理時間を削減するために行った処理過程の改良その実験結果および尤度評価関数の最適な係数を決定するために行った実験結果の詳細について述べる。

2．概　　要

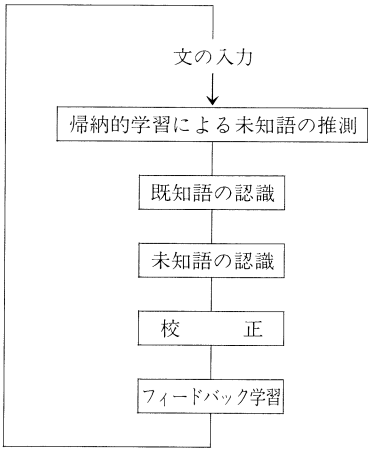
本手法は未知語の存在を前提とし，学習によって未知語を推測するものである。未知語の推測は，文書中に出現する同一文字列は語である可能性が高いという仮定に基づいている。これは，文書を構成する基本単位が語であるためである。このような立場に基づき文書中に出現する共通部分を2段階に抽出することにより未知語を推測している。また，人手によって校正された文書を用いて未登録語および認識の傾向を学習する。この様にして蓄えられた語を用いて確実性の高いものより順次段階的に認識を行う。

3．処理時間の削減について

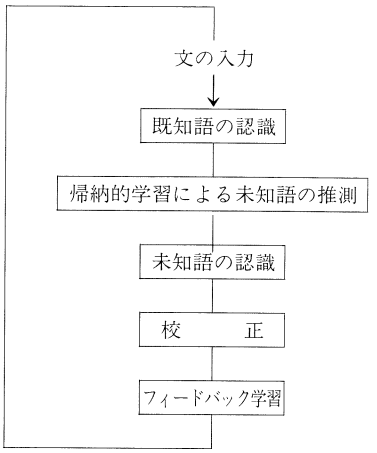
3．1　処理時間の削減方法

本手法では，文字列中より共通部分を2段階に見い出すことにより未知語を予測する。従来の本手法の処理過程を図1に示す。図1から明らかなように未知語を推測する際に全入力文字列を対象として共通部分を抽出し，未知語を推測していた。これは，未知語を推測する資料は共通部分を抽出するという観点からは多い方が良いということと，既知語と同一のものが推測されても認識の際には既知語が優先されるので問題とならないためであった。しかし，従来の方法では，既知語である部分も未知であるとして未知語を推測するので，共通部分を抽出する際の処理時間は入力される文字数が増えると急激に増大してしまうという問題点があった。そこで，図2に示すように処理過程を改良した。

図2に示すように本手法は文が入力されると，まず既知語，すなわちこれまでの学習によっ



図－1　従来の処理過程



図－2　改良後の処理過程

て辞書に登録された語によって文字列中の語を認識する。この場合，認識される単語候補が重複した場合には尤度評価関数を用いて最適な候補を決定する。次に，既知語によって認識されなかった未認識文字列のみを対象として未知語の推測を行う。これは，未認識文字列中より共通部分を2段階に抽出することにより行われる[5]。この際に，従来共通部分を抽出する対象が入力された全文字列であったのが，既知語による未認識部分のみとなるので処理時間が削減される。しかし，共通部分を抽出する際の資料が減少するので，共通部分が減少することも考えられる。この問題については，3．2で述べる実験結果により冗長な資料が削除されて，精度も若干向上することが確認されている。次に，推測された語を用いて未認識文字列中より未知語の認識を行う。このようにして認識された文字列を人手により校正する。最後にこの校正された文字列と認識結果を比較することにより未登録語の辞書への登録および認識状況の学習を行う。これは，正認識された語の尤度を上げ，誤認識された語の尤度を下げるものである。未知語推測の例を図3に示す。

図3（1）のような入力文字列が入力されると，既知語の認識が行われる。この結果が図3（2）である。ここで，CWと表記されているのが既知語によって認識された語である。既知語は，フィードバック学習で得られる語で，人手によって語であることが確認されている。したがって，既知語は最も確実性が高い語である。本システムではこれをCorrect Wordと呼び，CWと表記している。また，図3（2）では，品詞の別を自立語，付属語として記号で表現している。本手法における品詞の決定は，フィードバック学習で人手によって校正された文字列によって行われるものと，未知語の推測の過程で共通パターンの出現状況を考慮したヒューリスティクスを用いて行われる[5]ものがある。図3（2）は，フィードバック学習によって学習さ

(1) 入力文字列

連続音声認識では連続音声を認識している。しかし、単音節音声認識では、単音節ごとに認識する。

(2) 既知語の認識結果

連続音声認識では連続音声｜を｜認識している。／しかし／、／単音節／音声認識では／単音節／ごとに認識｜する｜。

CW CW CW CW CW

自立語：／ ／ 付属語：｜ ｜

(3) 未知語の推測を行う文字列

連続音声認識では連続音声＃認識している。＃、＃音声認識では＃ごとに認識＃。

＃：既知語の出現位置

(4) 未知語の推測結果

①S1の抽出結果…連続音声、認識、音声認識、では

②S2、S3の抽出過程

（音声認識、認識）→音声：S3〈自立語〉

認識：S2〈自立語〉

（連続音声、音声）→連続：S2〈自立語〉

では S1〈付属語〉

③WSの抽出結果

S1：では〈付属語〉、S2：音声〈自立語〉、認識〈自立語〉、S3：連続〈自立語〉

図－3 未知語の推測の例

れた既知語の品詞情報を用いて行った結果を表わしたものである。図3（3）に未知語の推測を行うための文字列を示す。この文字列は入力文字列より既知語として認識された箇所を＃で置き換えたものである。図3（1）（3）から明らかなように入力された文字列全体を対象として未知語の認識を行った場合に比較して，文字数が44文字から32文字に減少している。図3の（4）には未知語の推測結果を示す。ここで，①は図3（3）に示す未認識文字列中より図中で下線を引いて示している共通部分として抽出された文字列である。この段階で抽出された共通部分をS1と表記し，Type I Segmentと呼ぶ。なお，この段階では「続音声，声認識」等の部分も共通部分として抽出されるはずであるが，以下のような条件で抽出することにより，このような文字列はS1として抽出されない。

（1）2文字以上一致した場合。

（2）1文字のみ一致し，かつ以下の条件のいずれかを満たす場合。

①両側が異なる字種で囲まれている。

②両側が認識済みの語で囲まれている。

（3）少なくとも1つは他の共通パターンに含まれていない出現位置が存在する場合。

次に，S1同士の共通部分を抽出することによりS1を分解する。これを高次共通パターンの抽出という。これは，複数の語から構成されているS1を単独の語で構成されているS1で

分解するために行う。ここでは，上記の条件の（3）を特に「一方が他方に完全に含まれる形で重複している」という条件に置き換えて共通部分を抽出する。この段階で共通部分として抽出された語をＳ２，異なる部分をＳ３と表記し，それぞれ Type II Segment, Type III Segment と呼ぶ。この様子を図３（４）②に示す。図３（４）③は図３（３）の未認識文字列より推測された未知語を示す。なお，Ｓ１，Ｓ２，Ｓ３を総称して Word Segment と呼び，ＷＳと表記する。

３．２　処理時間削減の評価実験

辞書の初期状態は空である。用いた資料は荒木他著「音声認識における誤りの段階的復元手法」北海学園大学工学部研究報告，第16号，pp.137－151(1989)である。この資料の総文字数は9,223文字で，これを章ごとに５つに分割して用いた。実験は図１による処理を５回繰り返し，処理時間を測定し，次に図２による処理を５回繰り返して処理時間を測定した。表１に実験結果を，表２に改良前と改良後の処理時間の削減の程度についての相対値を示す。なお，本実験で用いた計算機は VAX8550 であり，使用した言語はＰＬ／Ｉである。

全体としてみると処理時間は改良前の9.3%，すなわち１/10以下に減少している。この原因

表－１　処理時間の削減評価実験結果

（１）改良前の手法（図１）

文　献	文字数	認識精度［%］			処理時間［時間：分：秒］				
		正認識	誤認識	未認識	未知語推測	既知語認識	未知語認識	フィードバック	合　計
1	922	53.7	18.6	27.6	7:16.68	2.64	6.51	13.27	7:39.10
2	715	62.3	11.8	25.8	5:43.96	4.06	7.52	11.39	6:06.84
3	1233	75.8	12.8	11.4	15:05.12	7.82	12.23	24.03	15:49.02
4	3129	80.5	9.5	10.0	1:59:27.74	23.97	26.57	1:46.79	2:02:05.07
5	3224	80.4	9.5	10.1	1:37:34.29	26.17	28.42	1:44.72	1:40:13.51
合　計	9223	75.8	11.0	13.2	4:05:07.79	1:04.66	1:21.25	4:20.20	4:12:53.54

（２）改良後の手法（図２）

文　献	文字数	認識精度［%］			処理時間［時間：分：秒］				
		正認識	誤認識	未認識	既知語認識	未知語推測	未知語認識	フィードバック	合　計
1	922	54.4	20.6	25.1	2.65	12:13.88	9.54	13.39	12:30.46
2	715	68.5	11.6	19.9	4.12	22.37	9.80	11.48	47.77
3	1233	78.3	11.1	10.6	8.57	21.68	15.48	25.45	1:11.18
4	3129	83.4	10.6	6.0	20.91	1:07.64	36.47	1:52.80	3:57.82
5	3224	84.0	9.7	6.3	25.42	1:31.93	36.76	2:00.69	5:10.34
合　計	9223	78.9	11.4	9.7	1:01.67	1515:37.50	1:48.05	4:43.81	23:37.57

表－2 処理時間の削減の効果

文献	認識精度の差［%］			処理時間削減率［%］				
	正認識	誤認識	未認識	既知語認識	未知語推測	未知語認識	フィードバック	合　計
1	+0.7	+2.0	−2.5	100.4	168.1	146.5	100.9	163.5
2	+6.2	−0.2	−5.9	101.5	6.5	130.3	100.8	13.0
3	+2.5	−1.7	−0.8	109.6	2.4	126.6	105.9	7.5
4	+2.9	+1.1	−4.0	87.2	0.9	137.3	105.6	3.2
5	+3.6	+0.2	−3.8	97.1	1.6	129.3	115.3	5.2
合計	+3.1	+0.4	−3.5	95.4	6.4	133.0	109.1	9.3

＊認識精度の差［%］＝改良後の値［%］－改良前の値［%］
＊処理時間削減率［%］＝改良後の処理時間×100／改良前の処理時間

としては，未知語の推測の過程が6.4%に減少していることが挙げられる。これは，従来すべての入力文字列を未知語の推測を行う場合の対象としていたのを，既知語によって認識されなかった部分のみを対象とするように改良したためである。また，既知語の認識，フィードバック学習では処理時間がほぼ同じか若干低下しているが，未知語の認識では処理時間が増大している。これは，入力文字列中より既知語によって認識されなかった未認識部分を抽出するための処理時間であると考えられる。また，精度についても正認識率が3.1%向上しているが，これは未知語を推測する部分を限定したために誤った文字列が未知語として推測されなかったためであると考えられる。

また，特に１番目の資料については辞書が空の状態で行われるので既知語が存在しない。このため，既知語の認識ができない。したがって，処理時間は減少しないはずである。実験結果を見ると，逆に処理時間が増大している。これは改良前では既知語の認識と未知語の認識は連続して行われるので辞書を１度読み込んで段階的に認識できるが，改良後では既知語の認識と未知語の認識の間に未知語の推測過程が入るために処理が分断されるためである。しかし，本質的には同程度の処理時間となる。傾向としては，学習が進むにつれて，資料の文字数が増大しているにも関わらず，処理時間が減少している。これは，既知語が学習によって次第に増大するために未知語の推測を行う既知語によって認識されなかった未認識文字列が減少するためで，学習が進むと処理時間はさらに減少するものと考えられる。

4．尤度評価関数における最適な係数

4．1　尤度評価関数[5)]

本手法では以下のような尤度評価関数を用いて単語候補の尤度を評価している。なお，以下の式でＣＦ，ＡＦ，ＥＦはフィードバック学習で更新されるものである。

尤度評価関数（LEF：Likelihood Evaluation Function）

$LEF=\alpha CF+AF-\beta EF$

CF：Correct Frequency（正認識度数）

AF：Appearance Frequency（出現頻度）

EF：Erroneous Frequency（誤認識度数）

α，β：係数

この尤度評価関数は既知語の認識，未知語の推測，未知語の認識においては単語候補が重複した場合の最適な候補の選択に用いられ，フィードバック学習では所属クラス（CW，S1，S2，S3）あるいは辞書からの削除の決定に用いている。従来，尤度評価関数における係数であるα，βは誤認識を引き起こした語の尤度を大きく下げるという観点から，αを2，βを4としていた。しかし，これが最適であるかどうかについては考察が行われていなかった。そこで，実験により最適なα，βを決定することにした。

4．2　尤度評価関数の係数決定実験

資料は，処理時間の削減実験で用いたものと同じである。手順は図2に示す処理を係数を変更する度ごとに5回繰り返している。各係数ごとの詳細な実験結果を表3－1，表3－2，表3－3，表3－4に，総合と辞書が最も飽和した状態である5番目のデータの正認識率を表4に示す。表4より総合と5番目の資料の正認識率が最も高いのは，$\alpha=1$，$\beta=10$の時であることがわかる。また，表3を見ても$\alpha=1$，$\beta=10$の時がCWのみ，WSのみでも一番高い正認識率を示している。特に，従来の値である$\alpha=2$，$\beta=4$と$\alpha=1$，$\beta=10$の時を比較すると総合で正認識率が3.2%向上していることがわかる。このことより尤度評価関数の係数を$\alpha=1$，$\beta=10$と決定した。

表3－1　尤度評価関数の係数決定実験結果（$\alpha=1$の時）

［$\alpha=1$の時］

β			2			4			6			8			10			50		
認識の別			正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識
CW		自立語	32.7	2.8		32.8	2.6		32.9	2.5		32.8	2.4		33.0	2.4		33.0	2.4	
		付属語	29.3	0.6		29.3	0.6		29.2	0.7		29.0	0.7		29.2	0.7		28.2	1.9	
		接頭語	0.2	0.0		0.2	0.0		0.2	0.0		0.2	0.0		0.2	0.0		0.2	0.0	
		接尾語	0.4	0.0		0.4	0.0		0.4	0.0		0.4	0.0		0.4	0.0		0.4	0.0	
		活用語尾	1.5	0.8		1.6	0.7		0.8	0.7		1.6	0.7		1.6	0.7		1.5	0.8	
		計	64.1	4.2		64.3	3.9		63.5	3.9		64.0	3.8		64.4	3.8		63.1	5.1	
WS	S2	自立語	4.2	2.0		4.1	2.0		4.0	0.2		3.5	1.5		4.0	1.2		4.1	1.9	
		付属語	2.5	0.8		2.5	0.7		2.5	0.6		2.5	0.6		2.5	0.6		2.5	0.5	
		接頭語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.5		0.0	0.3		0.0	0.1		0.0	0.2		0.0	0.2		0.0	0.1	
		計	6.7	3.3		6.6	3.0		6.5	0.9		6.0	2.3		6.5	2.0		6.6	2.5	
	S1	自立語	6.3	2.0		6.4	1.6		6.4	1.6		4.4	1.1		6.4	1.6		6.4	1.5	
		付属語	0.6	0.9		0.6	0.9		0.6	0.8		0.4	0.7		0.6	0.9		0.6	0.9	
		接頭語	0.0	0.3		0.0	0.0		0.0	0.2		0.0	0.1		0.0	0.2		0.0	0.3	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.5		0.0	0.4		0.0	0.2		0.0	0.4		0.0	0.4		0.0	0.6	
		計	6.9	3.7		7.0	2.9		7.0	2.8		4.8	2.3		7.0	3.1		7.0	3.3	
	S3	自立語	0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1	
		付属語	0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		接頭語	0.0	0.2		0.1	0.0		0.0	0.0		0.1	0.0		0.1	0.0		0.1	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.1	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.2		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		計	0.6	0.6		0.7	0.3		0.7	0.3		0.7	0.1		0.7	0.1		0.7	0.1	
	総合	自立語	11.2	3.7		11.2	3.7		11.2	3.7		8.5	2.7		11.2	3.7		11.2	6.1	
		付属語	3.1	1.8		3.1	1.8		3.1	1.7		3.0	1.4		3.1	1.6		3.1	3.5	
		接頭語	0.1	0.4		0.1	0.3		0.1	0.3		0.1	0.2		0.1	0.3		0.1	0.3	
		接尾語	0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.1	
		活用語尾	0.0	0.9		0.0	0.9		0.0	0.8		0.0	0.8		0.0	0.8		0.0	1.6	
		計	14.4	6.9		14.4	6.8		14.4	6.5		11.6	5.1		14.4	6.4		14.4	11.6	
総合		自立語	43.9	6.5	49.4	44.0	6.4	49.4	44.1	6.3	49.4	41.4	5.2	53.3	44.3	6.1	49.4	44.3	3.6	49.5
		付属語	32.4	2.5	64.9	32.5	2.4	64.9	32.3	2.4	65.1	32.0	2.1	65.7	32.4	2.4	65.1	31.2	1.6	65.1
		接頭語	0.3	0.5	99.2	0.3	0.4	99.2	0.4	0.3	99.2	0.4	0.2	99.3	0.4	0.3	99.2	0.4	0.3	99.2
		接尾語	0.4	0.1	99.4	0.4	0.1	99.3	0.4	0.1	99.3	0.4	0.1	99.4	0.4	0.1	99.3	0.4	0.0	99.3
		活用語尾	1.6	1.7	96.6	1.6	1.6	96.6	1.6	1.6	96.7	1.6	1.5	96.8	1.6	1.5	96.7	1.5	0.8	96.7
		計	78.6	11.3	10.1	78.8	10.9	10.3	78.8	10.7	10.5	75.8	9.1	15.1	79.1	10.4	10.5	77.8	6.3	15.9

注）単位は%

表３－２　尤度評価関数の係数決定実験結果（$\alpha=2$ の時）

［$\alpha=2$ の時］

β			2			4			6			8			10			50		
認識の別			正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識
CW		自立語	32.7	2.7		32.7	2.7		31.2	2.3		32.9	2.5		32.9	2.5		33.0	2.4	
		付属語	29.2	0.7		29.3	0.6		28.1	0.7		29.2	0.7		29.2	0.7		28.5	1.4	
		接頭語	0.2	0.1		0.2	0.1		0.2	0.0		0.2	0.0		0.2	0.3		0.2	0.0	
		接尾語	0.4	0.0		0.4	0.0		0.3	0.0		0.4	0.0		0.4	0.0		0.4	0.0	
		活用語尾	1.5	0.7		1.5	0.8		1.5	0.6		1.6	0.7		1.6	0.7		1.5	0.8	
		計	64.0	4.2		64.1	4.2		61.3	3.6		64.3	3.9		64.3	4.2		63.6	4.6	
WS	S2	自立語	4.2	2.0		3.8	0.2		4.3	2.3		4.0	0.2		4.0	2.0		4.1	1.9	
		付属語	2.5	0.8		2.5	0.7		2.8	0.8		2.5	0.6		2.5	0.6		2.5	0.5	
		接頭語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.3		0.0	0.2		0.0	0.3		0.0	0.2		0.0	0.2		0.0	0.1	
		計	6.7	3.1		6.3	1.1		7.1	3.4		6.5	1.0		6.5	2.8		6.6	2.5	
	S1	自立語	6.3	1.5		6.4	1.6		7.3	1.6		6.4	1.5		6.4	1.5		6.4	1.5	
		付属語	0.6	0.9		0.6	1.0		0.8	1.3		0.6	0.9		0.6	0.9		0.6	0.9	
		接頭語	0.0	0.3		0.0	0.2		0.1	0.3		0.0	0.2		0.0	0.2		0.0	0.3	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.5		0.0	0.5		0.0	0.5		0.0	0.4		0.0	0.4		0.0	0.6	
		計	6.9	3.2		7.0	3.3		8.2	3.7		7.0	3.0		7.0	3.0		7.0	3.3	
	S3	自立語	0.6	0.1		0.6	0.1		0.7	0.2		0.6	0.1		0.6	0.1		0.6	0.1	
		付属語	0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		接頭語	0.0	0.0		0.1	0.0		0.1	0.0		0.1	0.0		0.1	0.0		0.1	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.0		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		計	0.6	0.2		0.7	0.3		0.8	0.3		0.7	0.1		0.7	0.1		0.7	0.1	
	総合	自立語	11.2	3.7		11.2	3.7		12.4	4.2		11.2	3.7		11.2	3.7		11.2	3.6	
		付属語	3.1	1.8		3.1	1.8		3.6	2.2		3.1	1.6		3.1	1.6		3.1	1.6	
		接頭語	0.0	0.4		0.1	0.3		0.1	0.3		0.1	0.3		0.1	0.2		0.1	0.3	
		接尾語	0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.9		0.0	0.9		0.0	0.9		0.0	0.8		0.0	0.8		0.0	0.8	
		計	14.3	6.9		14.4	6.8		16.1	7.7		14.4	6.4		14.4	6.3		14.4	6.3	
総合		自立語	43.9	6.5	49.4	43.9	6.5	49.4	43.7	6.5	49.6	44.1	6.3	49.4	44.2	6.2	49.4	44.3	6.1	49.5
		付属語	32.4	2.5	64.9	29.7	2.5	64.9	31.8	3.0	65.1	32.3	2.4	65.1	32.4	2.4	65.1	31.7	3.0	65.1
		接頭語	0.3	0.5	99.2	0.3	0.4	99.2	0.3	0.4	99.2	0.4	0.3	99.2	0.4	0.3	99.2	0.4	0.3	99.2
		接尾語	0.4	0.1	99.3	0.4	0.1	99.3	0.4	0.1	99.4	0.4	0.1	99.3	0.4	0.1	99.3	0.4	0.1	99.3
		活用語尾	1.6	1.6	96.7	1.6	1.7	96.6	1.6	1.6	96.7	1.6	1.5	96.7	1.6	1.5	96.7	1.5	1.6	96.7
		計	78.6	11.2	10.2	75.9	11.2	12.9	77.8	11.6	10.6	78.8	10.5	10.6	79.0	10.5	10.5	78.3	11.1	10.6

単位は％

表3－3　尤度評価関数の係数決定実験結果（$\alpha=3$の時）

［$\alpha=3$の時］

β			2			4			6			8			10			50		
認識の別			正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識
CW		自立語	32.7	2.7		32.7	2.7		32.7	2.7		32.7	2.7		32.8	2.6		33.0	2.4	
		付属語	29.3	0.6		29.3	0.6		29.1	0.7		29.1	0.7		29.2	0.7		28.9	1.0	
		接頭語	0.2	0.1		0.2	0.1		0.2	0.1		0.2	0.1		0.2	0.0		0.2	0.0	
		接尾語	0.3	0.1		0.3	0.0		0.3	0.0		0.4	0.0		0.4	0.0		0.4	0.0	
		活用語尾	1.4	0.7		1.5	0.7		1.5	0.7		1.6	0.7		1.6	0.7		1.5	0.8	
		計	63.9	4.2		64.0	4.1		63.8	4.2		64.0	4.2		64.2	4.0		64.0	4.2	
WS	S2	自立語	4.2	2.0		4.1	2.0		4.0	2.0		4.0	2.0		4.0	2.0		4.1	1.9	
		付属語	2.5	0.8		2.5	0.7		2.5	0.7		2.5	0.7		2.5	0.7		2.5	0.5	
		接頭語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.3		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.3		0.0	0.1	
		計	6.7	3.1		6.6	2.9		6.5	2.9		6.5	2.9		6.5	3.0		6.6	2.5	
	S1	自立語	6.3	1.5		6.4	1.6		6.4	1.5		6.4	1.5		6.4	1.5		6.4	1.5	
		付属語	0.5	0.8		0.6	0.9		0.5	0.9		0.5	0.9		0.5	0.9		0.5	0.9	
		接頭語	0.0	0.3		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.2	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.5		0.0	0.5		0.0	0.5		0.0	0.5		0.0	0.4		0.0	0.6	
		計	6.8	3.1		7.0	3.2		6.9	3.1		6.9	3.1		6.9	3.0		6.9	3.2	
	S3	自立語	0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1	
		付属語	0.0	0.0		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		接頭語	0.0	0.0		0.1	0.0		0.1	0.0		0.1	0.0		0.1	0.0		0.1	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.0		0.0	0.0		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		計	0.6	0.1		0.7	0.2		0.7	0.3		0.7	0.1		0.7	0.1		0.7	0.1	
	総合	自立語	11.2	3.7		11.2	3.7		11.2	3.7		11.2	3.7		11.2	3.7		11.2	3.6	
		付属語	3.1	1.8		3.1	1.8		3.1	1.7		3.1	1.7		3.1	1.6		3.1	1.6	
		接頭語	0.0	0.3		0.1	0.3		0.1	0.3		0.1	0.3		0.1	0.3		0.1	0.3	
		接尾語	0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.8		0.0	0.8		0.0	0.8		0.0	0.8		0.0	0.8		0.0	0.8	
		計	14.3	6.7		14.4	6.7		14.4	6.6		14.4	6.5		14.4	6.4		14.4	6.3	
総合		自立語	43.9	6.5	49.4	44.0	6.4	49.4	44.0	6.4	49.4	43.9	6.5	49.4	44.1	6.3	49.4	44.3	6.1	49.5
		付属語	32.4	2.5	64.9	32.4	2.5	64.9	32.3	2.5	65.0	32.3	2.5	65.1	32.3	2.4	65.1	32.1	2.6	65.1
		接頭語	0.2	0.5	99.2	0.3	0.4	99.2	0.3	0.4	99.2	0.3	0.4	99.2	0.3	0.3	99.2	0.3	0.3	99.2
		接尾語	0.3	0.2	99.3	0.4	0.1	99.3	0.4	0.1	99.3	0.4	0.1	99.3	0.4	0.1	99.3	0.4	0.1	99.3
		活用語尾	1.6	1.6	96.7	1.6	1.6	96.6	1.6	1.6	96.7	1.6	1.6	96.7	1.6	1.6	96.7	1.5	1.6	96.7
		計	78.4	11.3	10.3	78.7	11.0	10.3	78.6	11.0	10.3	78.5	11.1	10.4	78.7	10.7	10.6	78.6	10.7	10.7

単位は%

表3－4　尤度評価関数の係数決定実験結果（$\alpha=4$ の時）

［$\alpha=4$ の時］

β			2			4			6			8			10			50		
認識の別			正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識	正認識	誤認識	未認識
CW		自立語	32.6	2.7		32.7	2.7		32.7	2.7		32.7	2.7		32.7	2.7		33.0	2.4	
		付属語	29.4	0.5		29.4	0.5		29.4	0.5		29.4	0.6		29.3	0.6		29.1	0.8	
		接頭語	0.2	0.1		0.2	0.1		0.2	0.1		0.2	0.1		0.2	0.1		0.2	0.0	
		接尾語	0.3	0.1		0.3	0.1		0.3	0.1		0.3	0.1		0.3	0.0		0.4	0.0	
		活用語尾	1.4	0.8		1.4	0.8		1.4	0.8		1.4	0.8		1.4	0.8		1.6	0.7	
		計	63.9	4.2		63.8	4.2		63.8	4.2		63.8	4.3		63.7	4.2		64.3	3.9	
WS	S2	自立語	4.2	2.0		4.1	2.0		4.0	2.0		4.0	2.0		4.0	1.8		4.1	1.9	
		付属語	2.5	0.8		2.5	0.6		2.5	0.6		2.5	0.6		2.5	0.6		2.5	0.5	
		接頭語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.3		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.1	
		計	6.7	3.1		6.6	2.8		6.5	2.8		6.5	2.8		6.5	2.6		6.6	2.5	
	S1	自立語	6.3	1.5		6.4	1.5		6.4	1.5		6.4	1.5		6.4	1.5		6.4	1.5	
		付属語	0.5	0.8		0.5	0.9		0.5	0.9		0.5	0.9		0.5	0.9		0.5	1.0	
		接頭語	0.0	0.3		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.2		0.0	0.2	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.4		0.0	0.4		0.0	0.4		0.0	0.4		0.0	0.4		0.0	0.6	
		計	6.8	3.0		6.9	3.0		6.9	3.0		6.9	3.0		6.9	3.0		6.9	3.3	
	S3	自立語	0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1		0.6	0.1	
		付属語	0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.0		0.1	0.0		0.0	0.0	
		接頭語	0.0	0.0		0.1	0.0		0.1	0.0		0.1	0.0		0.0	0.0		0.1	0.0	
		接尾語	0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.0		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0		0.0	0.0	
		計	0.6	0.2		0.7	0.3		0.7	0.3		0.7	0.1		0.7	0.1		0.7	0.1	
	総合	自立語	11.2	3.7		11.2	3.7		11.2	3.7		11.2	3.7		11.2	3.7		11.2	3.6	
		付属語	3.1	1.8		3.1	1.8		3.1	1.8		3.1	1.7		3.1	1.7		3.1	1.6	
		接頭語	0.0	0.3		0.1	0.3		0.1	0.3		0.1	0.2		0.1	0.2		0.1	0.2	
		接尾語	0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.1		0.0	0.0		0.0	0.0	
		活用語尾	0.0	0.8		0.0	0.8		0.0	0.8		0.0	0.8		0.0	0.8		0.0	0.8	
		計	14.3	6.7		14.4	6.7		14.4	6.7		14.4	6.5		14.4	6.4		14.4	6.2	
総合		自立語	43.9	6.5	49.4	43.9	6.5	49.4	43.9	6.5	49.4	43.9	6.4	49.4	43.9	6.4	49.4	43.9	6.1	49.4
		付属語	32.6	2.3	64.9	32.6	2.3	64.9	32.6	2.3	64.9	32.6	2.3	64.9	32.6	2.3	64.9	32.6	2.4	64.9
		接頭語	0.2	0.4	99.2	0.3	0.4	99.2	0.3	0.4	99.2	0.3	0.3	99.2	0.3	0.3	99.2	0.3	0.3	99.2
		接尾語	0.3	0.2	99.3	0.3	0.2	99.3	0.3	0.2	99.3	0.3	0.2	99.3	0.3	0.1	99.3	0.3	0.1	99.3
		活用語尾	1.5	1.7	96.7	1.5	1.7	96.7	1.5	1.7	96.7	1.5	1.7	96.7	1.5	1.7	96.7	1.5	1.5	96.7
		計	78.5	11.1	10.4	78.6	11.1	10.3	78.6	11.1	10.3	78.6	10.9	10.5	78.6	10.8	10.6	78.6	10.4	11.0

単位は%

表－4 尤度評価関数の係数決定実験結果（総合）

β	α				
	種　別	1	2	3	10
2	No.5	84.0	84.1	84.0	84.0
	総　合	78.6	78.6	78.4	78.5
4	No.5	84.4	84.0	84.2	84.1
	総　合	78.8	75.9	78.7	78.6
6	No.5	84.3	83.7	84.0	84.0
	総　合	78.8	77.8	78.6	78.6
8	No.5	75.1	84.3	84.0	84.0
	総　合	75.8	78.8	78.5	78.6
10	No.5	**84.7**	84.4	84.3	84.1
	総　合	**79.1**	79.0	78.7	78.6
50	No.5	82.3	83.8	83.8	84.7
	総　合	77.8	78.3	78.6	78.6

単位%で正認識率を示す。

5．おわりに

未知語の処理を基本とした従来の手法と異なる形態素解析手法についてその処理時間の削減方法と尤度評価関数の最適な係数の決定方法ならびに実験結果について述べた。実験の結果，既知語を優先して認識し，残りの未認識部分より未知語を推測する方法により処理時間が1/10に削減されることが確認された。このことは，この改良が本手法にとって有効であることを示している。また，尤度評価関数の係数を種々変化させて実験を行い，最適な係数を決定した。

今後は，未知語を推測する場合の最適な資料の量を実験によって考察すること，および一度工学の分野で飽和した辞書が文学などといった全く異なる分野の資料にどの程度の学習で適応することができるのかについて研究を進める予定である。なお，本研究の一部は文部省科学研究費補助金（奨励研究A第2855098号）の補助により行われた。

参考文献

1）建石由佳，小野芳彦，山田尚勇：DictionとStyleの日本語化について，第31回情報処理全国大会講演論文集，pp.1381－1382（1985）.

2）藤崎博也，亀田弘之：新聞記事データを対象とする自動単位切り処理とそれに基づく語彙調査，情報処理学会研究報告，Vol.85，No.31（1985）.

3）吉村賢治，武内美津乃，津田健蔵，首藤公昭：未登録語を含む日本語文の形態素解析，情報処理学会論文誌，Vol.30，No.3，pp.294－301（1989）.

4）原田悦子：日本語テキストにおける認知的単位，情報処理学会研究報告，Vol.89，No.7（1989）.

5）荒木健治，栃内香次：帰納的学習による文字列中の語の認識，電子情報通信学会技術研究報告，Vol.89，No.341，pp.39－46（1989）.