帰納的学習によるべた書き文のかな漢字変換

Kana-Kanji Translation of Non-Segmented Japanese Kana Sentences by Inductive Learning

荒木　健治
Kenji Araki

栃内　香次
Koji Tochinai

北海学園大学
Hokkai-Gakuen University

北海道大学
Hokkaido University

本稿では日本語文を計算機に入力する手段として最も広く用いられているべた書き文のかな漢字変換の一手法として入力べた書き文とその漢字かな混じり文より帰納的に学習を行うことによりべた書き文のかな漢字変換をおこなう手法を提案する．本手法を用いることにより未登録語，辞書作成の労力，精度の向上，異なる分野での精度の低下および辞書の容量の削減といった問題を解決することができる．次いで本手法に基づく実験システムを作成して行った学習実験，変換実験により本手法の学習機能の有効性を確認した結果について述べる．

1．はじめに

現在，日本語文を計算機に入力する手段としてはかな漢字変換が広く用いられている．中でも一切の区切りを入れる必要のないべた書き文入力方式が使用者に負担が少ないという点で有望である．しかし，これまで提案された種々のべた書き文のかな漢字変換手法は，未登録語，変換辞書作成の労力，変換精度等に依然として問題が残されており，未だ決定的な手法は見いだされていないのが現状である[1,2,3]．特に，専門分野の辞書が未整備なので専門分野においては未登録語を登録する労力が大きくなってしまう．この問題に対しては，専門用語の自動抽出システムが提案されているが，処理時間の大きさ，対象の限定等の問題が残されている[4]．また，専門用語を含めた大規模な辞書によるかな漢字変換では処理時間がかかり，しかも変換精度が低下するという問題がある．

この問題に対して我々は，従来よりシステムが動的に使用者あるいは対象分野に適応する手法を提案している[5]．しかし，本手法は使用者が単語単位に分割した校正結果を用いて学習するもので使用者に負担がかかっていた．我々はすでに人間が未知の文字列より語を認識する過程に基づく手法として未登録語を含む漢字かな混りの日本語文中から帰納的学習により語の表記を獲得する形態素解析手法を提案し，その有効性を確認している[6]．そこで，我々は上述の問題を解決する手法として，入力文字列と変換結果より帰納的に語の表記と読みを獲得し，この獲得された語を用いて確実性の高いものより変換する手法を提案する[7]．本手法は人間が未知の読みとその表記より語を獲得し，その獲得された語を用いてかな漢字変換を行う過程に基づいている．本手法を用いることにより辞書の自動作成が可能である．このため本手法によるシステムは使用者あるいは対象分野に動的に適応することが可能である．したがって，本手法を用いることにより予め辞書を作成する労力が入らない，使用者あるいは対象分野に動的に適応するので変換精度が向上し，どの様な分野にも高い精度で用いることができる，未登録語を自動的に学習できるおよび辞書の容量を小さくできるという利点がある．本稿では，本手法の概要，語の学習方法，変換方法，学習実験結果および変換実験結果について述べる．

2．概　要

処理過程を図１に示す。

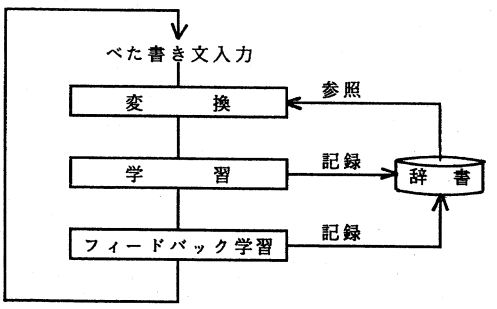


図１　　処理過程

図１に示すように，入力されたべた書き文は学習によって獲得された語によって確実性の高いものより変換される．確実性を決定する要素は，学習時における状況と変換に使用されたときの精度によって決定される．変換の結果得られた漢字かな混じり文に誤りがある場合には人手により修正される．学習処理では，入力されたべた書き文と変換された漢字かな混じり文の共通部分を手掛りに語候補を得る．この語候補よりさらに共通部分と差異部分を抽出することにより語を得る．最後にフィードバック学習処理では，変換結果と

校正された変換結果より正しく変換した語の尤度を上げ，誤って変換した語の尤度を下げる．したがって，辞書が最初，空であっても，学習，フィードバック学習によって次第に変換精度が向上する．

3．処理過程

3．1　変　換

3．1．1　手　順

変換は確実性の高いものより行われる．辞書中に存在する語はその語の抽出状況および変換に用いた場合の精度によって4階層に分類されている．語の抽出状況による語の分類については4章で，変換に用いた精度による分類については5章で述べる．この4分類とは，ＭＳ（Most certain Segment），ＣＰ（Common Pattern），Ｓ１（Segement One），ＲＳ（Remaining Segment）である．これらは，この順に確実性が高いので，この順に変換される．なお，この場合に読みが一致したとみなす条件は２文字以上一致した場合であり，一字のみ一致するものは２文字以上一致したものに対する処理終了後，再度読みが一字の語についてのみＭＳ，ＣＰ，Ｓ１，ＲＳの順に変換を行う．この場合には，両側が確定済みである場合のみあてはめを行う．また，解析は左から右の方向へ行う．

3．1．2　重複の処理

上述のような変換中に一致した語候補が重複した場合には尤度評価関数によって最適なものを選択する．尤度評価関数は以下の式によって与えられる．

$$EV = AF + \alpha * CF - \beta * EF$$

ＥＶ（Evaluation Value）　：尤度評価値
ＡＦ（Appearance Frequency）　：出現頻度
ＣＦ（Correctness Frequency）：正変換度数
ＥＦ（Error Frequency）　：誤変換度数
α，β　：係数

ここで，ＡＦは4章で述べる学習時に語候補が出現した回数と変換に使用された回数の和である．また，ＣＦ，ＥＦについては5章のフィードバック学習で述べる．このような尤度評価関数で計算されたＥＶの最大のものを最適な語候補として選択する．尤度評価値が同じ場合には，図２の順に評価して最適なものを決定する．また，図３に変換の例を示す．

（１）尤度評価値の最大のもの．
（２）誤認識度数の最小のもの．
（３）正認識度数の最大のもの．
（４）出現頻度の最大のもの．
（５）一致した文字数の最大のもの．
（６）一致した位置が一番左のもの．
（７）辞書に一番新しく登録されたもの．

図２　語候補が重複した場合の処理

```
%3複数%3%4存在%4%4す%4%3るもの%3%3がある%3
%2階層%2%5的%5テクスチャア%2%4とは%4

%2 %2：ＭＳ，%3 %3：ＣＰ，%4 %4:Ｓ１
%5 %5：ＲＳ
```

図３　変換の例

4．学　習

4．1．1　べた書き文とその漢字かな混じり文からの語候補の獲得

入力べた書き文と変換後の漢字かな混じり文の共通部分を手掛りに語候補を抽出する．この際に抽出される語をＳ１と表記し，Segment one と呼ぶ．図４にＳ１抽出の例を示す．

（１）入力べた書き文
　　われわれはしゅじゅのほうほうをおこなった
（２）変換結果
　　我々は種々の方法を行った
（３）語候補の抽出結果
　　（われわれ：我々）　（は：は）
　　（しゅじゅ：種々）　（の：の）
　　（ほうほう：方法）　（を：を）
　　（おこな：行）　（った：った）

図４　Ｓ１抽出の例

図３のように対応関係が一意に決定できる場合は問題ないが，例えば漢字の読みの中に助詞と同じ文字が含まれる場合には対応関係が多対多になり，誤った対応関係が抽出されてしまう．この例を図５に示す．

（１）入力べた書き文
　　そのすんぽうはびさいかされつつある
（２）変換結果
　　その寸法は微細化されつつある
（３）語候補の抽出結果
　　（その：その）　（すんぽう：寸法）
　　（は：は）　（び：微細化）
　　（いかされ：れ）（つつある：つつある）

図５　Ｓ１の対応関係が正しく決定できない例

図５は左から右の方向へ解析した場合の結果である．そこで，このような誤ったＳ１が抽出されることを防ぐために右から左の方向へも解析を行い，その結果が異なれば語候補を抽出しないことにした．図５の例の右から左の方向の解析結果を図６に示す．図６では解析は成功している．しかし，システムはどちらが正しいかを判断することができないので，両方の解析結果に存在するＳ１のみをＳ１とし，両方の解析結果に存在しないＳ１はＳ１としない．ここで，抽出されなかったＳ１は別の文で曖昧さの生じない用いられ方をすると抽出されるので，このことによる語の未登録はあまり存在しないと考えられる．

（１）入力べた書き文
　　そのすんぽうはびさいかされつつある
（２）変換結果
　　その寸法は微細化されつつある
（３）語候補の抽出結果
　　（その：その）　（すんぽう：寸法）
　　（は：は）　（びさいか：微細化）
　　（されつつある：されつつある）
（４）Ｓ１として抽出されるもの
　　（その：その）　（すんぽう：寸法）
　　（は：は）

図６　図５の例の右から左への解析結果

このような左から右，右から左へ両方向の解析によ

るＳ１の抽出を本稿では双方向解析と呼ぶ．双方向解析によるＳ１抽出の手順を図７に示す．

（１）左から右，右から左と双方向の解析を行う．
（２）両方向の解析によるＳ１の抽出個数が同じ時
　　右から左の解析結果の出現順序を逆にしたものと出現順が同じで読みおよび表記が一致するもののみ辞書に登録する．
（３）両方向の解析によるＳ１の抽出個数が異なる時
　　読みおよび表記が一致するものが存在する場合にのみ辞書に登録する．

図７　双方向解析によるＳ１の抽出手順

４．１．２　Ｓ１の共通部分と差異部分による語の獲得

この様にして抽出された語候補Ｓ１よりさらに共通部分と差異部分を抽出し，語を獲得する．これは，Ｓ１が複数の語から構成されている場合にこれを分解するためのものである．このとき抽出された共通部分をＣＰと表記し，Common Pattern と呼ぶ．また，差異部分をＲＳと表記し，Remaining Segment と呼ぶ．なお，Ｓ１がＣＰ，ＲＳに分解されたとき元のＳ１は辞書中より削除される．このＳ１の共通部分と差異部分の抽出による語の獲得の例を図８に示す．

（１）抽出されたＳ１
　　（れんぞくおんせい：連続音声）
　　（おんせい：音声）
（２）抽出されたＣＰ，ＲＳ
　　ＣＰ：（おんせい：音声）
　　ＲＳ：（れんぞく：連続）

図８　ＣＰ，ＲＳの抽出の例

このＣＰ，ＲＳの抽出の際に共通部分であることの条件は，表意文字とそれ以外の文字で情報量が異なる点を考慮し図９のように定める．図９で（２）の条件はこの処理が複数の語を含むＳ１を一つの語から構成されるＳ１で分割することを目的としていることに起因している．

（１）文字数による制限
　　Ｄ＝読みの文字数－表記の文字数
　　①Ｄ＝０の時：表意文字でない字種を近似
　　３文字以上表記が一致する．
　　②Ｄ≠０の時：表意文字を近似
　　２文字以上表記が一致する．
（２）共通部分の状況による制限
　　一方が他方を完全に含む形で重複する．

図９　ＣＰ，ＲＳ抽出の条件

５．フィードバック学習

５．１　概　　要

上述のようにして獲得された語には誤りも含まれる可能性があるので，正しく変換した語の尤度を上げ，誤って変換した語の尤度を下げる必要がある．このことによって次回の変換の精度が向上すると考えられる．このような操作を行うのがフィードバック学習である．フィードバック学習では正しい変換結果と変換結果を比較することにより行われる．正しい変換結果は変換結果に誤った部分がある場合に人手によって修正することにより得られる．

５．２　出現頻度（ＡＦ），正認識度数（ＣＦ），誤認識度数（ＥＦ）

次に，３．１．２項で述べた尤度評価関数の各パラメータの更新方法について述べる．まず，出現頻度は２つの過程で更新される．一つは，３章で述べた変換において語が変換にしようされたときにＡＦを１増加させる．もう一つは，４章で述べた学習で語がＳ１として抽出された時その出現の度にＡＦを１増加させる．Ｓ１がＣＰ，ＲＳに分解されたときはＣＰのＡＦはＣＰを生成するために用いられた２つのＳ１のＡＦの和とし，ＲＳのＡＦはＲＳを生成するために用いられた２つのＳ１の文字数の多い方のＳ１のＡＦとする．次に正認識度数についてはフィードバック学習で正しい変換結果と変換結果を比較して一致している場合に正変換とし，その変換に用いられた語の正変換度数を１増加させる．また，誤認識度数についてはフィードバック学習で正しい変換結果と変換結果を比較して一致しない場合に誤変換とし，その変換に用いられた語の誤認識度数を１増加させる．

５．３　正変換率による所属クラスの制限

５．１節で述べた正認識度数と誤認識度数を用いて辞書中の各語の所属クラスの制限を行う．この制限は正認識率を用いて行われる．正認識率（ＣＲ：Correctness Rate）の定義を以下に示す．

$$CR = \frac{CF}{CF + EF}$$

この所属クラスの制限はその語が１０回以上使用されてから行われる．すなわち，ＣＦとＥＦの和が１０以上の時図１０に示す評価が行われる．図１０に所属クラスの制限の方法を示す．

ＭＳ：ＣＰでＣＲが９５％以上のもの
ＣＰ：ＣＲが５０％以上９５％未満のもの
Ｓ１：ＣＲが５０％以上のもの
ＲＳ：ＣＲが５０％以上のもの
削除：ＣＰ，Ｓ１，ＲＳでＣＲが５０％未満のもの

図１０　所属クラスの制限の方法

６．学習実験

６．１　実験方法

本手法による実験システムを作成し，学習実験を行った．用いた資料は”前島他著，高集積マイクロコンピュータに適したマイクロプログラム制御方式，情報処理学会論文誌，Vol.23，No.1”である．文字数は，漢字かな混じり文で１０３０６文字である．初期辞書は空である．上記の資料を用いて４章で述べた学習を行い，その精度を考察した．

6．2　実験結果

表1に実験結果を示す．

表1　語の獲得実験結果

	文字数	率［%］
正しい語	10257	99.5
誤った語	0	0.0
未登録語	49	0.5
合　　計	10306	100.0

表1で正しい語とは読みと表記が一致している語で誤った語とは読みと表記が一致していない語である．また，未登録語とは辞書に登録できなかった語である．

6．3　考　察

表1に示すように精度は９９％以上を示し，良好な結果である．４．１．１項で述べた双方向解析によって削除された語のうち他の部分で明らかな形で出現したために回復した語の割合は，削除された語４８６文字のうち４３７文字が回復されたので，回復率は８９．９％であった．この結果より双方向解析によって登録できない語が存在しても９０％程度は回復できることが示され，双方向解析による誤ったＳ１の削除の有効性が示された．しかし，獲得された語の中には複数の語を含むものも存在するので，このような語を用いた変換では適用できない場合があり，変換の精度に関する実験が必要である．この実験については７章で述べる．また，図１１に示すような問題点も明らかになった．

（１）分割されない語
　　ＲＩ）
（２）過分割してしまう語
　　（マイクロ：マイク）→マイク，ロ
　　（したがって：したが）→したが，って

図１１　語の獲得における問題点

図１１（１）に示すような”ＲＩ）”がＳ１に存在すると”ＲＩ”と”）”にＣＰ，ＲＳの抽出で分割されなければならない．しかし，”ＲＩ）”は表意文字ではないので図９の（１）①の場合となり，３文字以上の表記が一致しなければならず分割されない．この場合には，資料中の他の場所に”ＲＩ”，”）”が独立して存在すれば抽出されるので長期的には解決されると考えられる．また，図１１の（２）の場合には，今度は逆にＳ１に”マイクロ”と”マイク”が存在した場合には図９（１）①の３文字以上の条件を満たし”マイク”と”ロ”に分割されてしまう．本実験では”マイク”が資料中に出現しなかったためにこのような誤りは起こらなかった．しかし，仮に”マイク”が辞書に存在したとしても，その結果変換が誤るのでとフィードバック学習によって次第にこのような誤った語は削除されるので長期的には解決されると考えられる．

7．変換実験

7．1　実験方法

次に変換の精度を評価する実験を行った．６章で述べた学習実験で作成された辞書を用いた．次に”山本他著，ＣＯＢＯＬマシンとその設計思想－ハードウェア構成について－，情報処理学会論文誌，Vol.23，No.1”，総文字数８０５７文字，”松山他著，フーリエ変換を用いたテクスチャの構造解析，情報処理学会論文誌，Vol.23，No.2”，総文字数７４６６文字を用いて変換実験を行った．これらの資料のべた書き文を１文ごとに入力し，図１に示す処理を行った．なお，ＡＦ，ＣＦ，ＥＦの更新は一文ごとに行っているが，５．３節で述べた正変換率による所属クラスの制限は各章ごとに行っている．表２に資料の各章ごとの文字数を示す．

表２　変換実験に用いた資料の章ごとの文字数

（１）ＣＯＢＯＬマシンとその設計思想
　　－ハードウェア構成について－

章	文字数	章	文字数
1	607	6	1036
2	746	7	476
3	812	8	1174
4	1838	9	338
5	1030	計	8057

（２）フーリエ変換を用いたテクスチャの構造解析

章	文字数	章	文字数
1	1155	5	401
2	784	6	175
3	2046		
4	2905	計	7466

7．2　実験結果

変換率の定義を以下に示す．

$$\text{正変換率} = \frac{\text{正変換文字数}}{\text{総文字数}}$$

$$\text{誤変換率} = \frac{\text{誤変換文字数}}{\text{総文字数}}$$

$$\text{未変換率} = \frac{\text{未変換文字数}}{\text{総文字数}}$$

なお，総合での変換率の定義では正変換文字数とは正しく変換された文字数と未変換で結果として正しかった文字数すなわち読みと表記がもともと一致している文字数を含んでいる．しかし，各段階ごとの正変換文字数とは正しく変換された文字数のみである．また，誤変換文字数とは誤って変換された文字数である．また，未変換文字数とは未変換で結果として誤った文字数すなわち読みと表記がもともと一致していない文字数である．また，文字数からは句読点，空白を除いて

いる．３．１．２項で述べた尤度評価関数の係数はα＝２，β＝４として実験を行った．表３に実験結果を示す．表３の資料No.は表２で資料に付加された番号を表わす．また，表４に資料３編を学習後の最終的な辞書の登録語数を示す．

７．３　考　察

７．３．１　総　合

表３－１に示す総合の正変換率は資料１では初めのうちは８０％程度であるが終わりには９０％程度に上昇している．資料の論文が変わると一時７５％に減少するが，その後次第に上昇して９０％程度になっている．また，誤変換率は資料１では１．５％～１０％まで分布しているが，やはり後半に行くにしたがって，誤変換率は低下している．特に，資料２に変化したところでは１１％となっているが，資料２の終わりでは２％となっている．総合の未変換率も資料の初めでは１０％以上であるが，学習が進むにつれて５％に減少している．特に資料２の初めでは１２％となっているが，終わりでは５％に減少している．これらの結果は学習の有効性を示している．

７．３．２　ＭＳ

表３－２より明らかなようにＭＳは資料に関わらずほぼ１００％の精度を示している．これは，ＭＳの条件がＣＰで１０回以上あてはめられしかも９５％以上の精度であるもの，あるいは新語登録された語であるためである．すなわち，ＭＳはＳ１の共通部分なので語である確率が高く，しかも精度が低い場合にはＣＰに落ちるので，このような結果になったと考えられる．注目したいのは，資料が変化しても精度が変化しないことで，このような語は資料に関わらず高い精度を示す語であると考えられる．しかも，表４より明らかなようにこのような語は次第に増加している．表５に資料２学習後のＭＳの例を示す．表５で「わけ，たに」は１０回使用されていないが，新語登録されたのでＭＳに所属している．しかし，１０回以上使用されていないので，次回の所属クラスの制限でＣＰに落ちる．

表３　　変換実験結果

（表３－１）総合

資料No	章	文字数	累積文字数	正変換		誤変換		未変換	
				文字数	率［%］	文字数	率［%］	文字数	率［%］
1	1	607	607	498	82.0	37	6.1	72	11.9
	2	746	1353	591	79.2	74	9.9	81	10.9
	3	812	2165	704	86.7	46	5.7	62	7.6
	4	1838	4003	1517	82.5	100	5.4	221	12.0
	5	1030	5033	857	83.2	79	7.7	94	9.1
	6	1036	6069	866	83.6	59	5.7	111	10.7
	7	476	6545	421	88.4	7	1.5	48	10.1
	8	1174	7719	1070	91.1	42	3.6	62	5.3
	9	338	8057	303	89.6	18	5.3	17	5.0
2	1	1155	9212	867	75.1	138	11.9	150	13.0
	2	784	9996	666	84.9	59	7.5	59	7.5
	3	2046	12042	1764	86.2	146	7.1	136	6.6
	4	2905	14947	2500	86.1	181	6.2	224	7.7
	5	401	15348	353	88.0	25	6.2	23	5.7
	6	175	15523	160	91.4	5	2.9	10	5.7

（表３－２）ＭＳ

資料No	章	文字数	累積文字数	正変換		誤変換	
				文字数	率［%］	文字数	率［%］
1	1	607	607	5	100.0	0	0.0
	2	746	1353	20	100.0	0	0.0
	3	812	2165	128	100.0	0	0.0
	4	1838	4003	289	99.0	3	1.0
	5	1030	5033	221	100.0	0	0.0
	6	1036	6069	239	100.0	0	0.0
	7	476	6545	161	100.0	0	0.0
	8	1174	7719	351	100.0	0	0.0
	9	338	8057	82	100.0	0	0.0
2	1	1155	9212	114	100.0	0	0.0
	2	784	9996	102	100.0	0	0.0
	3	2046	12042	380	100.0	0	0.0
	4	2905	14947	682	99.7	2	0.3
	5	401	15348	114	100.0	0	0.0
	6	175	15523	60	100.0	0	0.0

（表３－３）ＣＰ

資料No	章	文字数	累積文字数	正変換		誤変換	
				文字数	率［%］	文字数	率［%］
1	1	607	607	211	98.1	4	1.9
	2	746	1353	247	95.7	11	4.3
	3	812	2165	206	99.0	2	1.0
	4	1838	4003	414	100.0	0	0.0
	5	1030	5033	216	90.4	23	9.6
	6	1036	6069	210	93.8	14	6.2
	7	476	6545	95	100.0	0	0.0
	8	1174	7719	239	100.0	0	0.0
	9	338	8057	86	100.0	0	0.0
2	1	1155	9212	285	93.8	19	6.2
	2	784	9996	139	97.9	3	2.1
	3	2046	12042	369	96.1	15	3.9
	4	2905	14947	461	94.5	27	5.5
	5	401	15348	77	97.5	2	2.5
	6	175	15523	29	100.0	0	0.0

（表３－４）Ｓ１

資料No	章	文字数	累積文字数	正変換		誤変換	
				文字数	率［%］	文字数	率［%］
1	1	607	607	213	87.7	30	12.3
	2	746	1353	227	80.8	54	19.2
	3	812	2165	214	83.6	42	16.4
	4	1838	4003	592	88.1	80	11.9
	5	1030	5033	290	86.6	45	13.4
	6	1036	6069	296	88.6	38	11.4
	7	476	6545	124	94.7	7	5.3
	8	1174	7719	293	89.3	35	10.7
	9	338	8057	98	84.5	18	15.5
2	1	1155	9212	338	78.2	94	21.8
	2	784	9996	298	87.6	42	12.4
	3	2046	12042	711	87.0	106	13.0
	4	2905	14947	1011	88.0	138	12.0
	5	401	15348	129	86.0	21	14.0
	6	175	15523	58	92.1	5	7.9

（表３－５）ＲＳ

資料No	章	文字数	累積文字数	正変換		誤変換	
				文字数	率［%］	文字数	率［%］
1	1	607	607	11	78.6	3	21.4
	2	746	1353	30	76.9	9	23.1
	3	812	2165	20	90.9	2	9.1
	4	1838	4003	47	73.4	17	26.6
	5	1030	5033	22	66.7	11	33.3
	6	1036	6069	25	78.1	7	21.9
	7	476	6545	9	100.0	0	5.3
	8	1174	7719	59	89.4	7	10.6
	9	338	8057	11	100.0	0	0.0
2	1	1155	9212	28	52.8	25	47.2
	2	784	9996	41	74.5	14	25.5
	3	2046	12042	90	78.2	25	21.8
	4	2905	14947	56	80.0	14	20.0
	5	401	15348	5	71.4	2	28.6
	6	175	15523	7	100.0	0	0.0

（表３－６）未変換

資料No	章	文字数	累積文字数	未変換文字数	正		誤	
					文字数	率[%]	文字数	率[%]
1	1	607	607	130	58	44.6	72	55.4
	2	746	1353	148	67	45.3	81	54.7
	3	812	2165	198	136	68.7	62	31.3
	4	1838	4003	396	175	44.2	221	55.8
	5	1030	5033	202	108	53.5	94	46.5
	6	1036	6069	207	96	46.4	111	53.6
	7	476	6545	80	32	40.0	48	60.0
	8	1174	7719	190	128	67.4	62	32.6
	9	338	8057	43	26	60.5	17	39.5
2	1	1155	9212	252	102	40.5	150	59.5
	2	784	9996	145	86	59.3	59	40.7
	3	2046	12042	350	214	61.1	136	38.9
	4	2905	14947	514	290	56.4	224	43.6
	5	401	15348	51	28	54.9	23	45.1
	6	175	15523	16	6	37.5	10	62.5

表４　辞書登録語数

クラス	学習実験後	資料１学習後	資料２学習後
MS	0	30	91
CP	155	232	314
S1	795	1044	1338
RS	248	416	559
合計	1198	1722	2302

注）表中の数値は語数を表わす.

表５　資料２学習後のＭＳの例

読み	表記	ＡＦ	ＣＦ	ＥＦ
わけ	分け	4	3	0
たに	谷	3	2	0
しょりた	処理	75	64	0
でーた	データ	60	52	0
よってる	よってる	62	38	0
されるん	されるマシン	43	36	0
ましん		65	42	0

表６　資料２学習後のＣＰの例

読み	表記	ＡＦ	ＣＦ	ＥＦ
びさい	微細	3	0	0
きかん	期間	2	0	0
じかん	時間	2	0	0
がありこうほ	があり候補	5	3	0
ｐ２がない	ｐ２がない	7	4	0
		3	1	0
		2	0	0

次に誤変換率であるが，当然のことながらほぼ０％である．このことはＭＳが確実性の高いものより決定するという本手法で最初に変換される語としてふさわしい語であることを示していると考えれる．

７．３．３　ＣＰ

表３－３でＣＰの正変換率を見るとＭＳには劣るもののすべて９０％以上で１００％も多い．しかし，ＣＰは資料が変化すると９３％に低下している．これは，Ｓ１の共通部分ではあるが，資料に依存して精度の高い語が含まれていることを示している．表６に資料２学習後のＣＰの例を示す．

７．３．４　Ｓ１

表３－４に示すＳ１の正変換率を見ると資料１では８７％～９４％で，やはり学習が進んだ資料の終わりの方で高くなっている．資料が変化すると７８％となるが，資料２の終わりでは９２％まで回復している．Ｓ１は入力べた書き文とその漢字かな混じり文より共通部分を手掛りに分割したものなので，複数の語が含まれている可能性がある．このためにＭＳ，ＣＰに比べて低い正変換率になったものと考えられる．また，ＣＰ，ＲＳの抽出で分解されたＳ１はＳ１より削除されるので複数の語を含むＳ１が多く残る．このために，このような結果になったものと考えられる．表７に資料２学習後のＳ１の例を示す．表７に示すように１字語が多く含まれている．これは，これ以上分解されることがないためで分解され得る語はＣＰ，ＲＳへ組み込まれＳ１から削除される．

表７　資料２学習後のＳ１の例

読み	表記	ＡＦ	ＣＦ	ＥＦ
に	に	４２２	１５０	0
と	取	２３	0	0
した	した	６４	３０	0
ふか	付加	3	0	1
３）	３）	5	2	0
ミリかく	ミリ角	1	0	0
はいぶん	配分	1	0	0

７．３．５　ＲＳ

表３－５に示すＲＳの正変換率を見ると資料の初めで低く，終わりで高くなっている．しかし，資料の初めでは７８％，５２％とかなり低い値となっている．これは，ＲＳがＳ１同士の差異部分であるために一字語や語の一部が比較的多く含まれていることが考えれる．特にＲＳは最後にあてはめるために上位段階で誤った影響を受けてしまうことや変換が難しい部分のみを変換の対象としていることが上げらる．しかし，資料の終わりでは１００％となるので，上位の段階の変換の精度がある一定値以上になると急激に精度が向上するものと考えられる．表８に資料２学習後のＲＳの例を示す．

表８　資料２学習後のＲＳの例

読み	表記	ＡＦ	ＣＦ	ＥＦ
や	や	4	0	0
）	）	5	0	0
たすう	多数	1	0	0
しい」	しい」	1	0	0
ほうしき	方式	7	0	0
ゆにっと	ユニットり	5	2	0
りの５０％	の５０％			

７．３．６　未変換

未変換の中には未変換のままで正しい表記となるものがある．すなわち，ひらがな，記号，数字などである．これらは，システムは語として認識していないがかな漢字変換としては結果として正しいものである．このような語の割合を示しているのが表３－６である．これらは平均して５０％程度である．このような部分は形態素解析としては未認識となるので，何らかの対策が必要である．

７．３．７　問題点と対策

この変換実験では学習実験で生成された辞書を用いたために，初期状態で尤度評価関数で用いられるＡＦのみが突出し，そのために，ＣＦ，ＥＦの影響が小さくなり学習結果が即座に反映されないという問題点があった．しかし，本来ＡＦは学習段階と変換段階で更新されるのでＣＦ，ＥＦの変化による尤度評価関数の急激な変化を防ぐ役割を果たしている．したがって，即座にＡＦの値を小さくすることは危険であるが，この点についての実験が必要である．

また，一字語の連続による未変換の問題がある．これは，例えば「かきこみ：書き込み」という組からは「か：書，き：き，こ：込，み：み」のようにＳ１が抽出される．一方，一字語は両側が確定済みの場合のみあてはめを行うので，このような語は永久に正しく変換されない．そこで，Ｓ１の抽出で一字語が連続しているような場合にはそれらを一語としてまとめる処理が必要である．

また，個人の表記の相違による誤変換が考えられる．これは，例えば「事」を「こと」として使うなど個人の好みによる表記の揺れが存在する．この問題は，辞書が個人に適応することで誤った方が次第に優先度が落ちて解決される．しかし，個人でも文脈によって「事，こと」の両方を使うことが考えられるので，文脈情報の導入が必要である．

最後にこの変換実験では辞書中の語の正変換率による所属クラスの制限を各章の終了後に行い，一方ＡＦ，ＣＦ，ＥＦの更新は一文ごとに行っていたために条件からはそのクラスに所属できない語が次回の所属クラスの制限までそのクラスに残り結果として変換に悪影響を及ぼしていた．これは，正変換率による所属クラスの制限を一文ごとに行うことで解決できると考えられる．

８．おわりに

本稿では，動的に使用者あるいは対象分野に適応する手法として帰納的学習によるべた書き文のかな漢字変換手法を提案し，実験システムを作成し，学習実験および変換実験を行った．実験の結果，９９．５％の精度で語が学習され，学習が進むと９０％以上の精度で変換が行われることが確認された．これは，本手法がべた書き文のかな漢字変換に有効であることを示していると考えられる．

今後の課題としては，一字語の処理の改善，文脈情報の導入および変換に対する学習結果の反映の高速化が挙げられる．このような課題を解決した後にさらに異なる分野の大量の資料を用いて実験を行い，本手法の学習機能を評価する予定である．

謝　辞

実験を行うにあたり尽力していただいた北海学園大学工学部電子情報工学科，佐藤隆之君，高橋祐治君，富居広樹君に感謝します．

参考文献

１）牧野，木澤：べた書き文の分かち書きと仮名漢字変換，情報処理学会論文誌，Vol.20，No.4，pp.337-345(1979).
２）吉村，日高，吉田：文節数最小法を用いた日本語文の形態素解析，情報処理学会論文誌，Vol.24，No.1，pp.40-46(1983).
３）本間，山階，小橋：連語解析を用いたべた書きかな漢字変換，情報処理学会論文誌，Vol.27，No.11，pp.1062-1067(1986).
４）吉村，日高，吉田：日本語科学技術文における専門用語の自動抽出システム，情報処理学会論文誌，Vo.27，No.1，pp.33-40(1986).
５）荒木，栃内，永田：多段階分割法によるべた書き日本語文のかな漢字変換，情処論文誌，Vol.28，No.4，pp.412-421(1987).
６）荒木，栃内：帰納的学習による形態素解析手法における適応能力の評価，信学技報，Vol.90，No.375，pp.1-8(1990).
７）荒木，栃内：べた書き文のかな漢字変換における帰納的学習による語の獲得，平成３年電気関係学会北海道支部連合大会講演論文集，pp.413(1991).