24 多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳

荒木 健治
(北海学園大学工学部)

栃内 香次
(北海道大学工学部)

1．はじめに

従来の機械翻訳方式の欠点を克服するための方法として実例より帰納的に翻訳ルールを学習し、翻訳を行う手法が提案されている[1,2]。このようなアプローチは、従来は計算量の膨大さから有望なものではなかったが、計算機のハードウェアの急激な進展により現在では非常に有望な手法となっている。本稿で提案する手法も帰納的学習による翻訳の1つである。本手法は、翻訳例より共通パターンと差異部分を多段階に抽出し、翻訳ルールを具象的ルールから抽象的ルールまでに多段階に分けて抽出する。次いで、その抽出されたルールを具象的ルールより順に適用し、翻訳を行うものである。本稿では、本手法の概要と翻訳ルールの抽出方法および翻訳方法と評価実験結果について述べる。

2．概　要

本手法は、まず多くの翻訳例より共通パターンと差異部分を抽出する。この際には原文と訳文を組にして記憶するが、異なる部分が複数存在する場合には対応関係がわからないので、一箇所だけ異なる翻訳例の組しか抽出の対象としない。ここで、一箇所とは英日翻訳の場合には英語ではスペースで区切られた一単位であり、日本語では形態素である。次ぎに抽出された共通パターンよりさらに共通パターンと差異部分を抽出する。これを共通パターンがなくなるまで繰り返す。このような過程の途中で生成された共通パターンと差異部分の組を翻訳ルールと呼ぶ。その結果翻訳ルールはより高次の抽出になるにつれて抽象化される。この結果、具象的ルールから抽象的ルールが多段階に抽出される。次に、このようにして抽出された翻訳ルールを用いて翻訳を行う。翻訳を行う際には最も具象的ルールから順に翻訳ルールを適用し、翻訳ルールが適用された時点で今度はまだ訳語が与えられていない部分に、より具象的ルールを適用する。このような手法を本稿では多段階共通パターン抽出法と呼ぶ。

3．処理過程

3．1　翻訳ルールの抽出

処理過程は以下のようになる。

（1）翻訳例より一箇所のみ異なる翻訳例の組を抽出する。
（2）一箇所のみ異なる翻訳例の組より共通パターンと差異部分を抽出する。
（3）翻訳ルールより一箇所のみ異なる翻訳ルールの組を抽出する。
（4）抽出された共通部分よりさらに共通パターンと差異部分を抽出する。
（5）（3）、（4）を共通パターンがなくなるまで繰り返す。

2段階の翻訳ルール抽出の例を以下に示す。なお、以下の文中で"@"は1段階目、"!"は2段階目の差異部分を表わす。

（1）翻訳例
[1-1](I give her a book. :
私は彼女に本を与える。)
[1-2](We give her a book. :
私達は彼女に本を与える。)
[1-3] (You give her a doll. :
あなたは彼女に人形を与える。)
[1-4] (They give her a doll. :
彼らは彼女に人形を与える)

（2）1段階目の共通パターン、差異部分の抽出
①共通パターン
・[1-1]、[1-2]より
[2-1](@1 give her a book. :
@1は彼女に本を与える。)
・[1-3]、[1-4]より
[2-2](@2 give her a doll. :
@2は彼女に人形を与える。)
②差異部分
・[1-1]、[1-2]より
[2-3](I : 私)、[2-4](We : 私達)
・[1-3]、[1-4]より
[2-5](You : あなた)、[2-6](They : 彼ら)

（3）2段階目の共通パターン、差異部分の抽出
①共通パターン
・[2-1]、[2-2]より
[3-1](!1 give her a @3. :
!1は彼女に@3を与える。)
②差異部分
・[2-1]、[2-2]より
[3-2](book:本)、[3-3](doll:人形)

（4）抽出された翻訳ルール（具象→抽象の順に示す。）
①変数を含まない。
a．例文
[1-1](I give her a book. :
私は彼女に本を与える。)
[1-2](We give her a book.:
私達は彼女に本を与える。)
[1-3](You give her a doll.:
あなたは彼女に人形を与える。)
[1-4](They give her a doll.:
彼らは彼女に人形を与える)
b．単語
[2-3](I : 私)、[2-4](We : 私達)、
[2-5](You : あなた)、[2-6](They : 彼ら)、
[3-2](book:本)、[3-3](doll:人形)
②1つ変数を含む。
[2-1](@1 give her a book.:
@1は彼女に本を与える。)
[2-2](@2 give her a doll.:

@2は彼女に人形を与える。)

③2つ変数を含む。

[3-1](!1 give her a @3. :
!1は彼女に@3を与える。)

3．2 翻訳方法

処理過程を以下に示す。

(1) 最も具象的な翻訳ルールのうちの翻訳例と一致する原文がないかを検索する。
(2) もし、存在すれば終了。存在しない場合は以下の処理を行う。
(3) 変数を含む翻訳ルールのうちの変数の少ないもの(具象度の高いもの)より変数の部分を除き原文と一致する翻訳ルールを検索する。
(4) もし、一致したら変数の部分に相当する原文と最も具象的な翻訳ルールの単語と一致するものがないかを検索する。一致するものがなければ翻訳不能で終了する。
(5) すべての変数に値が代入されると翻訳を終了する。

翻訳の例を以下に示す。

(1) 原文
I know him.
(2) 用いた翻訳ルール
(!1 know @1. : !1は@1を知っている。)
(I : 私) (him : 彼)
(3) 翻訳結果
私は彼を知っている。

4．評価実験

本手法の有効性を評価する実験を行った。今回の実験では英日翻訳に対して本手法を適用した。

4．1 実験方法

実験システムをワークステーション上にC言語を用いて作成し、実験を行った。なお、今回作成した実験システムは学習部すなわち翻訳ルールの抽出を行う部分のみなので翻訳は人手により3．2節に示すアルゴリズムにしたがって行った。260組の翻訳例を翻訳ルールが抽出できるようになるべく一箇所が異なるように任意に作成して用いた。

表1 翻訳ルールの抽出に用いた翻訳例(一部)

1. I study English in the library.
私／は／図書館／で／英語／を／勉強／する。
2. I drive to Otaru.
わたし／は／小樽／に／ドライブ／する。
3. I was born in Sapporo.
私／は／札幌／で／生まれた。
4. I grew up in Sapporo.
私／は／札幌／で／育った。
5. I graduate from high shool.
私／は／高校／を／卒業／する。
6. I eat hamburgers almost everyday.
私／は／ほとんど／毎日／ハンバーガー／を／食べる。
7. This is a pen.
これ／は／ペン／です。
8. I have no plan.
私／は／予定／が／ない。
9. I go to see a movie.
私／は／映画／を／見に／行く。
10. I watch a movie.
私／は／映画／を／見る。

表1に翻訳ルールの抽出に用いた翻訳例の一部を示す。翻訳に用いた例文はこれとは別に任意に作成した260文である。表2に翻訳に用いた文の一部を示す。実験の手順を以下に示す。

(1) 260組の翻訳例より翻訳ルールを抽出する。
(2) 抽出された翻訳ルールを用いて翻訳用に作成された260文の英文を翻訳する。

表2 翻訳に用いた英文(一部)

1. I have no plan.
2. I have been to Kyoto.
3. They came to class.
4. I run.
5. They seem happy.
6. I consider a problem.
7. The noise wakes a baby.
8. Your mother cuts my hair.
9. They know her.
10. We watch television program.

4．2 実験結果

今回の実験では翻訳例が少なかったことと翻訳例に用いた文が短い文であったことから2段階の共通パターンの抽出しか行われなかった。表3に1段階目の翻訳ルールの抽出結果の例を、表4に2段階目の翻訳ルールの抽出結果の例を、表5に翻訳結果を示す。

表3 1段階目の翻訳ルール抽出結果(一部)

(1) 共通パターン
1. I am a @1.
私／は／@1／です。
2. I have no @2.
私／は／@2／が／ない。
3. I have been to @3.
私／は／@3／へ／行ったこと／が／ある。
4. I am from @4.
私／は／@4／出身／です。
5. I grew up in @5.
私／は／@5／で／育った。

(2) 差異部分

1. boy : 少年	girl : 少女	
2. plan : 予定	question : 質問	
3. Kyoto : 京都	England : イギリス	
4. Hokkaido : 北海道	Sapporo : 札幌	
5. Paris : パリ	Otaru : 小樽	

表4 2段階目の翻訳ルール抽出結果(一部)

(1) 共通パターン
1. !1 name is @1.
!1／名前／は／@1／です。
2. I !2 a @2.
私／は／@2／を／!2。
3. !3 have been to @3.
!3／は／@3／へ／行ったこと／が／ある。
4. @4 !4.
@4／は／!4。
5. He @5 !5.
彼／は／!5／を／@5。

(2) 差異部分

1. My : 私の	Your : あなたの	
2. read : 読む	receive : 受け取る	
3. I : 私	We : 私達	
4. run : 走る	cry : 泣く	
5. me : 私	it : それ	