353 帰納的学習による機械翻訳手法の実用化における問題点の改良手法

荒木　健治
（北海学園大学工学部）

栃内　香次
（北海道大学工学部）

1．はじめに

良質な翻訳を行うために実例より帰納的に翻訳ルールを学習し，翻訳を行う手法が提案されている[1,2]．しかし，これらの手法は重文，複文を対象としていなかったり，翻訳ルールを抽出する条件に厳しい制限が存在する．このような問題に対して，我々はすでに実例からの帰納的学習による翻訳方式の一つとして，多段階共通パターン抽出法を提案している[3]が，そこでもこのような問題は解決されていなかった．そこで，本稿では，多段階共通パターン抽出法をより実用化するために行った複数個異なる２組の翻訳例からの翻訳ルールの抽出方法，重文，複文の処理，翻訳ルールの適合度といった改良手法について述べる．

2．多段階共通パターン抽出法の概要

本手法は，多くの翻訳例より共通部分と差異部分を多段階に抽出することにより翻訳ルールを獲得するものである．この際には，一箇所だけ異なる翻訳例の組のみを抽出の対象としている．この様にして取り出された翻訳ルールよりさらに共通部分と差異部分を抽出する．これを繰り返すことにより翻訳ルールは具象的ルールより抽象的ルールまで多段階に構成される．この様にして抽出された翻訳ルールを具象的ルールより順に適用し，翻訳を行う．

3．改良手法

3．1　複数個異なる翻訳例からの翻訳ルールの獲得方法

従来の手法では翻訳ルールを抽出する対象は一箇所のみ異なる翻訳例の組であった．しかし，これでは抽出できる翻訳例の組が限られてしまい，効率よく翻訳ルールを抽出することができない．この問題に対して，我々は異なる部分が複数個存在する場合には，すでに蓄えられている翻訳ルールを利用することによりその対応関係を決定する方法を提案する．この例を図１に示す．

（１）入力文
　① This is a pen.　：　これはペンです．
　② That is a book.　：　あれは本です．
（２）共通部分と曖昧な点
　・ @1 is a @2.　：　@3は@4です．
　・ @1,@2,@3,@4の対応関係がわからない．
（３）既知の翻訳ルール
　① This：これ　② book：本
（４）抽出された翻訳ルール
　① @1 is a @2.　：　@1は@2です．
　② This：これ　③ That：あれ
　④ pen：ペン　⑤ book：本

図１　複数個異なる部分からの翻訳ルール抽出の例

図１に示すように，（１）のような２組の例からは（２）のように異なる部分対応関係がわからない．しかし，（３）のような翻訳ルールがすでに獲得されていれば，（２）の対応関係を決定し，（４）のように翻訳ルールを獲得することができる．

3．2　重文，複文の処理方法

これまでの手法では変数部分には一語しか代入を許していないので，単文より抽出された翻訳ルールを用いると単文を翻訳することしかできなかった．しかし，実用化を考えた場合，しばしば重文，複文が出現するので，これらに対する処理が必要である．そこで，この問題に対して我々は翻訳ルールの変数部分に一語だけではなく，変数を含む翻訳ルールを含めた複数の語を代入できるように拡張した本方式による重文の翻訳例を図２に示す．

（Ⅰ）This is a book which I have chosen.
　　これが私の選んだ本です．
（Ⅱ）翻訳ルール
　① This is a @1.　：　これが@1です．
　② @2 have chosen.　：　@2が選んだ．
　③ @3 is a book which　@4.　：　@3は@4本です．
　④ I　：　私
（Ⅲ）翻訳過程
　(1) ③より：@3 is a book which　@4.：@3は@4本です
　(2) ②，④より
　　@3 is a book which I have chosen.　：
　　@3は私が選んだ本です．
　(3) ①より
　　This is a book which I have chosen.　：
　　これが私の選んだ本です．

図２　　重文の翻訳例

図２の例では（Ⅲ）の(2)で(1)の@4に変数を含む複数の語から構成されている翻訳ルールである（Ⅱ）②を代入している．この様に拡張することにより同様にして複文の翻訳も可能となる．

3．3　適合度による最適な翻訳ルールの組の選択方法

従来の処理では翻訳ルールが複数個適用可能な場合，局所的評価により最適な翻訳ルールを選択していたために誤った翻訳結果が出力されることがあった．この問題点を解決するために適用可能な翻訳ルールの組が複数ある場合には１つの翻訳ルールが最適かどうかではなく，翻訳ルールの組が最適なものを適合度を計算することにより選択する適合度は以下の式により計算される．

適合度＝α・正翻訳度数－β・誤翻訳度数　α，β：係

ここで，正翻訳度数，誤翻訳度数は翻訳結果を使用者が校正した場合にその翻訳は誤っていたとみなし，その際に用いられた翻訳ルールの組み合せの誤翻訳度数を＋１するこの際には２組ごとに記録する．同様に校正が行われなかった場合には正翻訳度数を＋１する．この処理をフィードバック学習と呼ぶ．

4．おわりに

本稿では，実例からの帰納的学習による翻訳手法である多段階共通パターン抽出法を実用化するための改良点として，複数個異なる翻訳例からの翻訳ルールの抽出方法，重文，複文の処理，適合度による最適な翻訳ルールの組の選択方法について述べた．今後はこれらを実験システムに組み込み，大量の翻訳実験を行うことにより本手法の実用性を確認する予定である．

参考文献

１）佐藤：MBT1:実例に基づく訳語選択，人工知能学会誌 Vol.6，No.4，pp.592-600(1991)．
２）赤間：帰納的学習システムLS/1による翻訳の学習，情処研報，Vol.86，No.58，pp.33-40(1986)．
３）荒木，栃内：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳，情報処理北海道シンポジウム'91，pp.47-49(1991)．

表5 翻訳結果（一部）

1．入力文 ：We play baseball.
用いた翻訳ルール：
(@1 play baseball. ：@1は野球をする。)
(We ：私達)
翻訳結果：私達は野球をする。
2．入力文 ：You buy a guitar.
用いた翻訳ルール：
(@2 buy a guitar. ：@2はギターを買う。)
(You ：あなた)
翻訳結果：あなたはギターを買う。
3．入力文 ：They have been to Sapporo.
用いた翻訳ルール：
(!3 have been to @3.:!3は@3へ行ったことがある。)
(They ：彼ら) (Sapporo ：札幌)
翻訳結果：彼らは札幌へ行ったことがある。

4．3 考　察

翻訳ルールの抽出では大部分の翻訳ルールは正しく抽出されたが、以下のような場合誤った翻訳ルールが抽出された。

（1）1段階目の翻訳ルール
(I am a @1. ：私は@1です。)
(I am busy @2. ：私は@2忙しい。)

（2）2段階目の翻訳ルール
(I am !1 @3. ：私は @3 !1 。)
(a ：です。)
(busy ：忙しい)

ここでは、(a ：です。)が誤って抽出されてしまう。これは、（1）の2つ目の文の訳で語尾の「です。」が省略されたためで、訳文の与え方を完全にする必要がある。また、同じ単語に対して表層表現が異なると同一の意味でも異なった部分と見なしてしまう。例えば"go"に対して「行く、行きます」というような訳を与えると訳文の部分は異なった部分となってしまう。しかし、このような場合には翻訳ルールを抽出する対象としないだけで問題とならない。また、日本語文の形態素解析の問題もある。例えば"your"に対して「あなた／の」というように分割した訳文を与えると(your ：あなた)という翻訳ルールが抽出されてしまう。そこで、今回の実験では「あなたの」を一単位にして分割した。これは、日本語文の場合なるべく英文との対応を考えて形態素解析を行えば解決できる。

次に翻訳では翻訳ルールが少なかったため翻訳ルールが存在せず、翻訳不能の文が存在した。これは、翻訳ルールを増加させることにより解決できる。また、以下のような誤訳も存在した。

（1）Jane takes my baby.
(Jane takes my @1. ：
ジェーンは私の@1を持って行く。)
(baby ：赤ちゃん)
ジェーンは私の赤ちゃんを持って行く。

（2）I have a handbag.
(I have a @2. ：私は@2が痛い。)
(handbag ：ハンドバック)
私はハンドバックが痛い。

（3）I am very kind.
(I am !1 @3. ：私は @3 !1。) (very ：大変)
(kind ：親切な)
私は大変親切な。

（4）I have blue birds.
(I have !2 @4. ：私は @4 !2。) (blue ：青い)
(birds ：鳥)
私は鳥が青い。

（1）の場合には"takes"の目的語として物がきた場合の翻訳ルールしか存在しないためにこのような誤訳がおきたと考えられる。また、（2）は" I have a headache. 私は頭が痛い。"、" I have a toothache. 私は歯が痛い。"という2組の翻訳例から作られた(I have a @1. ：私は@1が痛い。)という翻訳ルールを用いたためである。しかし、もし" I have a headache. 私は頭痛を持っている。"、" I have a toothache. 私は歯痛を持っている。"という訳であれば(I have a @1. ：私は@1を持っている。)という翻訳ルールが抽出されて「私はハンドバッグを持っている。」という正しい翻訳ができる。しかし、本研究では良質な翻訳を一つの目的としているので、このような直訳を与えることは本意ではない。そこで、" I have a car. 私は車を持っている。"、" I have a book. 私は本を持っている。"という翻訳例から(I have a @1. ：私は@1を持っている。)翻訳ルールが獲得されるなら、これは不自然な文ではないので本研究の目的とも一致する。また、（3）（4）についても同様にこのような文を訳すのに適した翻訳ルールが存在していないことが原因であった。

以上、これらの誤訳の原因は主に翻訳ルールの不十分さからくるものである。しかし、翻訳ルールがいくら十分であったとしてもどの翻訳ルールを選択するのか判断できなければ問題は解決しない。この問題に対しては、翻訳ルールを適用する際に現在のように局所的にしか英文を参照しない方法では解決できないので、適用した翻訳ルールの適合度を評価する指標が必要であると考えられる。すなわち、"I have a handbag."という文に対して「私はハンドバッグが痛い。」という訳文が誤っていると判断できるのは「ハンドバッグ」という語が出現したときである。したがって、(I have a @1. ：私は@1が痛い。)と(handbag ：ハンドバッグ)の適合度を評価することによりこの翻訳ルールの適用の可否を判断すべきであると考える。

5．おわりに

本稿では、翻訳例からの帰納的学習による翻訳の1つである多段階共通パターン抽出法を提案し、実験システムを作成し小規模な評価実験を行った結果について述べた。実験の結果、本手法は使用者および対象分野に適応し、しかも高速で良質な翻訳手法となる可能性があることが確認された。

今後の課題としては、さらに大規模な翻訳例を用いて実験を行う、翻訳ルールが競合した場合の適合度による翻訳ルールの選択手法の確立および複文に対処するための翻訳ルールの結合等について検討を進める予定である。

参考文献

1）Sato, S. and Nagao, M. ： Toward Memory-based Translation, Proc. of Coling'90, Vol.3, pp.247-252(1990).
2）赤間：帰納的学習システムＬＳ／Ｉによる翻訳の学習、情処研報、Vol.86, No.58, pp.33-40(1986).

連絡先

荒木健治
〒064 札幌市中央区南26条西11丁目1-1
北海学園大学工学部電子情報工学科
TEL (011)-841-1161内860