359　べた書き文のかな漢字変換における帰納的学習による語の獲得

荒木　健治
（北海学園大学工学部）

栃内　香次
（北海道大学工学部）

1．はじめに

計算機に日本語文書を入力する手段としてかな漢字変換が主流となっている．中でも，一切の区切りを入れる必要のない，べた書き文入力方式が最も良く使われている．べた書き文のかな漢字変換手法は，これまで多くの手法が提案されてきている[1,2]が，システムは変換辞書が固定されている方式が大部分であり，変換精度に問題が残されている．

この問題に対して我々は，従来よりシステムが動的に使用者および対象分野に適応する手法を提案している[3]．しかし，これは使用者が単語単位に分割した校正結果を用いるもので，使用者に負担がかかっていた．これを改善する手法として，変換結果と読みの対より帰納的学習により語の表記と読みを獲得する手法を提案する．本手法により辞書を自動的に作成することが可能であり，その辞書を用いて確実性の高いものより変換を行うことによりべた書き文より漢字かな混じり文を生成することができる．本手法を用いたシステムは，辞書を作成する労力が必要なく，しかも使用者あるいは対象分野に速やかに適応することが可能であるので，変換精度が向上すると考えられる．本稿では，本手法の概要と語の獲得方法を中心に述べる．

2．概要

処理の流れを図１に示す．

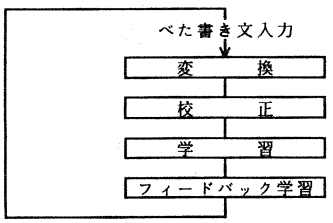


図１　　処理の流れ

図１に示すようにべた書き文はまず，予め学習された状況によって確実性の高いものより順に階層化された辞書を用いて漢字かな混じり文に変換される．次に，校正を行う．これは，人手によって行われる．このようにして得られた正しい漢字かな混じり文と読みを比較することによりシステムは語の表記とその読みを獲得する．最後に，変換結果と校正結果を用いて正しく変換された語の尤度を上昇させ，誤変換された語の尤度を下げることにより以降の変換精度を上昇させる．したがって，辞書が全く空の状態では変換は何も行われないが，学習が進むにつれて次第に辞書に語が登録され，変換精度が向上する．また，本手法は，我々がすでに漢字かな混じり文における形態素解析手法として提案している帰納的学習による形態素解析手法[4]に基づいている．

3．処理過程

3．1　変換

辞書中に存在する語は，その抽出状況によりＣＷ，Ｓ２，Ｓ１，Ｓ３の４階層に分類されている．この分類の方法については３．２節で述べる．各階層はこの順に確実性が高い．したがって，あてはめはこの順に行われる．特に，ＣＷについては，入力べた書き文中に出現する共通パターンを文字数および出現状況により抽出[4]し，抽出された語がＣＷと一致するものをＣＰＣＷ（Common Pattern Correct Word）と呼び，一番最初にあてはめを行う．次に，ＣＷのあてはめ，以下順にＳ２，Ｓ１，Ｓ３とあてはめる．あてはめの基準は，一致した文字数およびあてはめ状況によって定められている[4]．

3．2　学習

漢字かな混じり文に変換された文字列は，誤りが存在した場合には人手により校正される．この結果得られる正しい漢字かな混じり文と入力された読みを用いて語を学習する．この際には，漢字かな混じり文とその読みの共通部分と差異部分を抽出することにより帰納的に語を学習する．この段階で抽出された語をＳ１とする．Ｓ１の抽出例を図２に示す．

１．読み：われわはしゅじゅのほうほうをおこなった．
２．表記：我々は種々の方法を行った．
３．抽出結果
　われわれ→我々，は→は，しゅじゅ→種々，の→の
　ほうほう→方法，を→を，おこな→行，った→った

図２　　語の学習の例

図２のように対応関係が一対一に決まる場合は問題ないが，例えば漢字の読みの中に助詞と同じ文字が含まれる場合は，対応関係が多対多になる．この場合には対応関係を決めることができないのでＳ１を抽出しない．本手法ではこのような場合を検出するために，左と右の両方から解析を行い，両者の解析結果が一致した場合のみＳ１として抽出することにしている．

この様にして抽出された語よりさらに共通部分と差異部分を抽出する．これは，複合語を分解するためのものである．このとき抽出された共通部分をＳ２，差異部分をＳ３とする．共通部分とする条件を以下に示す．

（１）表記，読みともに２文字以上
（２）表記１文字が一致した場合
　①読みが一致する．
　②表記が漢字である．
　③一致した表記と読みが，文字列の先頭あるいは末尾に存在する．

3．3　フィードバック学習

この様にして抽出された語には誤りも含まれるので，変換において誤った語の尤度を下げ，正しかった語の尤度を上げることにより変換精度を次第に上昇させる必要がある．これを行うのがフィードバック学習である．フィードバック学習は校正情報が付加された変換結果を用いて行われる．この場合問題になるのが，どの語が誤った語であるのかを判定する処理である．この問題については，誤りの前後に存在する語の字種によってその処理方法を決定している．

4．おわりに

辞書構築の労力が必要なく，適応的で使用者に負担のかからないべた書き文のかな漢字変換手法として帰納的学習による手法を提案し，特に語の獲得について述べた．今後は，本手法に基づく実験システムを開発し，本手法の有効性を確認するための実験を行う予定である．

＊参考文献

１）牧野，木澤：べた書き文の分かち書きと仮名漢字変換情処論文誌，Vol.20，No.4，pp.337-345(1979)．
２）吉村，日高，吉田：文節数最小法を用いた日本語文の形態素解析，情処論文誌，Vol.24，No.1，pp.40-46(1983)．
３）荒木，栃内，永田：多段階分割法によるべた書き日本語文のかな漢字変換，情処論文誌，Vol.28，No.4，pp.412-421(1987)．
４）荒木，栃内：帰納的学習による形態素解析手法における適応能力の評価，信学技報，Vol.90，No.375，pp.1-8(1990)．