361 部分検索法による文字列の誤りの復元

田中 洋一郎' 荒木 健治'' 宮永 喜一' 栃内 香次'

'北海道大学 ''北海学園大学

1．はじめに

近年、マン・マシンインタフェースの一つとして連続音声認識の実用化が求められており、信号処理技術を応用した様々な認識手法が提案され、実用的、または実験的に実現されている。しかし、連続音声処理においては、音声波形から音素を切り出すセグメンテーションの問題や、前後の音素の発声に関係して発声されない音素が生じる調音結合の問題等により、音素の付加、脱落誤りのない認識結果を得ることは困難である。

我々は、これらの誤りを言語レベルで復元する手法として、多段階分割復元法の適用[1][2]を考えてきた。多段階分割復元法では、認識結果である被復元テキストに対し、それまでの復元処理過程で得られた音素の付加・脱落の傾向情報を利用して、音素列の候補を全て挙げ、それに対して、より正しいと思われる語から当てはめていくことによって復元を行う。しかし、この方法では、処理量が膨大になってしまう。

本稿では、被復元列を適当な大きさに分割し、その断片から単語候補を検索することにより処理量、および復元精度を改善する手法について述べる。

2．部分検索法の概要

比較的誤りの多い文字列を語のあてはめによって復元していく場合には、あらかじめ候補となる文字列を全て挙げ、確からしい語からあてはめていくという方法が考えられる。しかし、この方法では、語のあてはめの際、被復元文字列が長くなると検索をしなければならないパスが爆発的に増加してしまうという欠点がある。また、もともとあったと考えられる文字列の正しい部分も、他の部分と同じように分解され、再編成されるため、復元精度が認識結果の文字列よりも語の確からしさの情報の影響を強く受ける。

これに対し、本手法では、認識結果である被復元文字列には、ある程度正しい部分が残っていると仮定し、被復元文字列を分割した断片に着目する。すなわち、ある断片を含む語の中で最も確からしいと思われる語について、その断片と前後の断片のマッチングをとり、そのマッチングのずれにより語を再評価して決定していく。これにより、着目した断片が誤っていた場合には、その断片を含む語の確からしさ、及び、その断片の前後のつながりの条件により棄却することができる。

なお、本手法は、復元誤りを生じた場合、使用者がこの復元結果を修正することにより、以後、より正しい復元を行なうように学習機能を有している。

3．処理の概要

ここでは、語の決定の際用いる語の評価方法、および本手法の処理過程を例を用いて示す。

3－1．語の評価方法

語は、語の長さ及び語の活性状態から算出される語の評価値により評価される。語の活性状態とは、次の2つの情報により変化する語の状態である。

語出現情報：ある語が決定された場合、その語自身を以後活性化させるための情報であり、短い寿命で管理されるものと、その中で特に使用されたものからなる、長い寿命のものがある。これらは広域的に語を決定する情報になる。

語関連情報：ある語が決定された場合、その語が他の語を活性化させるための情報である。注目している復元単位（通常は1文）内である語が決定されると即辞書中の語に効果を及ぼし、処理が次の復元単位に移ると効果を失う。これは語出現情報によって決定された語の間の語を決定する局所的な情報である。

3－2．部分検索法の処理過程

例：このあんどうちいは　の復元

1．語辞書は、あらかじめ全ての辞書項目について、読みを分割し、分割状態の前後関係とともにテンプレートとして記録する。また、分割された断片と語辞書項目の対応を手掛かり情報としてテーブルに記録する。

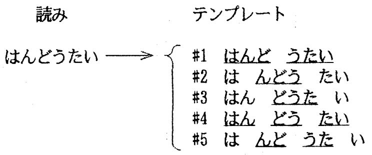

____ 手掛かり情報として記録

2．被復元テキストを分割する。

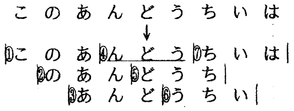

3．被復元テキストを分割した各断片の手掛かり情報から語辞書項目を参照し、その語の活性状態により評価値を算出する。

手掛かり断片	①	③	④	⑤
語	この案	安堵	半導体	同値
評価値	3	4	7	5

4．評価値の最も大きい語について、1.で求めた語辞書のテンプレートにより、前後の部分のマッチングを行なう。このときマッチングによる評価値も考慮し、語の再評価を行なう。

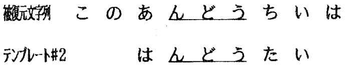
被復元文字列 こ の あ ん ど う ち い は
テンプレート#2 は ん ど う た い

以前の学習で得られた置換情報にもとづき、その使用頻度から再評価のための評価値を得る。この例では（あ→は），（ち→た）の置換情報を使用している。

5．決定された語によって被復元テキストを語の前後の2つの部分に分け、それぞれに対して再帰的に処理を行なう。

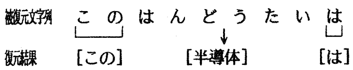
被復元文字列 こ の は ん ど う た い は
復元結果 [この] [半導体] [は]

※実際は手掛かり検索、語のマッチングの各処理過程において、該当するものがなければ、分割単位を一つ減らして再試行する。

4．今後の方針

本稿で提案したシステムを開発し、本手法の有効性を確認する予定である。

参考文献

[1]荒木、宮永、栃内：多段階分割復元法による誤りの多い文字列からの原文の復元，情報処理学会論文誌，Vol.30, No2, pp169-178 (1989).

[2]堤、荒木、宮永、栃内：多段階分割復元法を用いた連続音声認識の誤りの復元，信学会技報，Vol.89, No.341, pp.47-54(1989).