364

単語認識のための コアワードとその共起単語の自動抽出

佐藤智榮† 荒木健治†† 宮永喜一† 栃内香次†
†北海道大学工学部 ††北海学園大学工学部

1．はじめに

音声認識や文字認識など，自然言語を対象とした認識では，得られた信号情報をボトムアップ的に処理する他に，自然言語の特性を生かしたトップダウン的な処理過程が存在する．このトップダウンのアプローチを併用することで認識誤りを復元することが可能である．

さきに発表した多段階分割復元法[1)2)]で，トップダウン的手法による復元処理の有効性が確認されたが，認識候補が多く，処理量が大きいという問題点があった．

本稿では，このような欠点を補うための，復元処理に適した単語辞書の自動作成手法を提案する．

2．概要

人間が行っている認識誤りの復元処理では，比較的少数の手がかりとなる語を見つけ，その語と何らかの意味的関係を持つ語を当てはめて復元していくと考えられる．従って，計算機で同様な復元処理を行うには，この意味的関係を辞書化することが必要となる．

しかしながら，この辞書は作成に膨大な手間がかかり，また，単語の意味が使われ方に依存することから，実際の文書から自動的に抽出することが，本質的に重要となる．

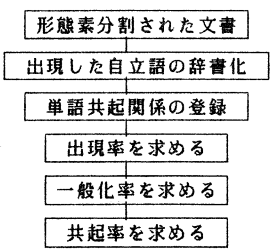
本稿で提案する手法は，意味的な情報に相当するものとして単語共起関係を想定し，実際の文書から単語共起関係を自動的に抽出し，辞書化するものである．

3．処理過程

単語共起関係を利用する上で問題となるのは，一般的単語の取扱いである．ここで，一般的単語とは，どのような文にも出現し，復元過程の最初の段階で手がかりにならない語である．

一般的単語を辞書から取り除く為に，どのような単語とも被共起の関係にある語は一般的単語であると仮定し，辞書の自動作成アルゴリズムを考えた．以下にそのアルゴリズムを示す．

出現率 ＝ 単語の出現回数／全自立語数（重複を含む）
一般化率＝ 被共出回数／文中に出現した自立語の種類数
共起率 ＝ 共出回数／一般化率が低い単語についての共出回数の和



形態素分割された文書を自立語について辞書化し，その自立語各々につき共出単語（同一文中に出現した他の自立語）を登録する．これから被共出回数を調べ一般化率を求め，出現率が高く，一般化率の低いものをとり出す．これをコアワードという．次に一般化率の高い自立語を登録したものの中から削除し，共起率を求める．そして，この共起率の高いものをコアワードに付随する共起単語とする．

4．実験

本手法に基づく実験システムをC言語を用いてワークステーション上で作成し，実際に辞書を作成，その評価を試みた．

評価は誤りの無い文を使用し，文書中に出現する単語がどの程度の割合で辞書に含まれるかを指標とした．

コアワード	共起単語
命令	命令
	マイクロ
	プロセッサ
	実行
	取り出し
	マクロ
	・・・

＜辞書の作成例（一部）＞

	コアワード	共起単語
評価例１	２６．０％	２９．６％
評価例２	２８．０％	２７．８％
評価例３	２６．９％	３１．７％
評価例４	２３．０％	２３．０％
評価例５	３１．３％	３６．５％

＜コアワードと共起単語の当てはめ率（例）＞

5．おわりに

ここまでの実験では出現率，一般化率，共起率のパラメータの最適値は得られなかった．今後の課題として，このパラメータを自動的に決定する仕組みを考察していく予定である．

参考文献

1）荒木，宮永，栃内：多段階分割復元法による誤りの多い文字列からの原文の復元．情報処理学会論文誌 Vol.30, No2,pp169-178(1989)

2）堤，荒木，宮永，栃内：多段階分割復元法を用いた連続音声認識の誤りの復元．信学技報 Vol.89, No.34, pp.47-54(1989)