4P−8　帰納的学習によるべた書き文のかな漢字変換における適応能力の評価

荒木　健治　　栃内　香次

北海学園大学　北海道大学

1．はじめに

我々は，従来より子供が文字列中より語を獲得し，語を使用できるようになる学習能力のモデルを仮定し，そのモデルを実験により検証している[1]．これまで行ってきたのは，漢字かな混じり文中より語を獲得し，その獲得された語を用いて別の漢字かな混じり文中の語を認識するものであった．そこで，これを一歩進めて読みとその変換結果より語の読みとその表記を獲得し，獲得された語を用いて獲得状況に基づく確実性の高い順にべた書き文中の語を認識する手法を提案する[2]．本手法を用いることにより，従来の手法[3,4]に比べて辞書を作成する労力が不要，使用者あるいは対象分野に動的に適応するので変換精度が向上し種々の分野にも高い精度となる，未登録語を自動的に学習できるおよび辞書の容量を小さくできるという利点がある．本稿では，対象分野を変化させた場合の本手法の適応能力の評価実験結果について述べる．

2．概　要

本研究は，子供の言語獲得能力のモデルを計算機上に実現することを目的の一つとしている．そのため，予め与える知識は語を学習するためのものでなくてはならない．したがって，語あるいは文字の字種，品詞，表記，読みといった情報をいっさい与えない状態から我々が仮定している生得的能力である「２つの事物が同一か異なるかを判断する能力」という能力のみで文字列より語を獲得することが可能であるかを実験により確認することを第一に考えている．その結果獲得されたものが既存の文法規則あるいは品詞と一致する必要はない．このような観点から，変換方法も獲得状況に基づく確実性の高いものより変換を行う．処理過程を図１に示す。

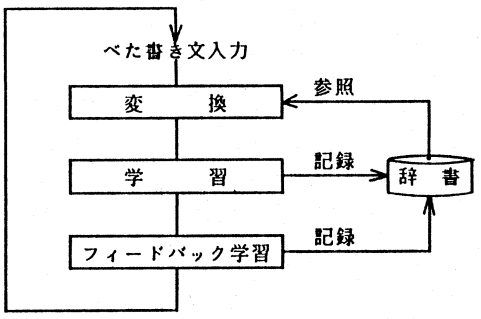


図１　　処理過程

3．処理過程

3．1　変　換

変換は，語の確実性の高いものより行われる．各語の確実性はその語の獲得状況によって決定される．獲得した語を蓄えている辞書中に存在する語はその語の獲得状況に基づく確実性によって４階層に分類されている．語の獲得状況による語の分類については３．２節で述べる．この４分類とは，ＭＳ，ＣＰ，Ｓ１，ＲＳである．これらは，この順に確実性が高いので，この順に変換される．この場合に読みが一致したとみなす条件は，２文字以上一致した場合である．特に一字のみ一致した場合には，２文字以上一致したものに対する処理終了後，再度読みが一字の語についてのみＭＳ，ＣＰ，Ｓ１，ＲＳの順に変換を行う．この場合には，両側が確定済みである場合のみあてはめを行う．上述のような変換中に一致した語候補が重複した場合には尤度評価値によって最適なものを選択する．尤度評価値は以下の式によって与えられる．

ＥＶ＝ＡＦ＋α＊ＣＦ−β＊ＥＦ

ＥＶ：尤度評価値，ＡＦ：出現頻度，ＣＦ：正変換度数

ＥＦ：誤変換度数，α，β：係数

3．2　学　習

入力べた書き文と変換後の漢字かな混じり文の共通部分を手掛りに語候補を抽出する．この際に抽出される語をＳ１と表記し，Segment one と呼ぶ．図２にＳ１抽出の例を示す．

（１）入力べた書き文
　　われわれはしゅじゅのほうほうをおこなった
（２）変換結果
　　我々は種々の方法を行った
（３）語候補の抽出結果
　　（われわれ：我々）　（は：は）
　　（しゅじゅ：種々）　（の：の）
　　（ほうほう：方法）　（を：を）
　　（おこな：行）　　（った：った）

図２　Ｓ１抽出の例

この様にして抽出された語候補Ｓ１よりさらに共通部分と差異部分を抽出し，語を獲得する．これは，Ｓ１が複数の語から構成されている場合にこれを分解するためである．このとき抽出された共通部分をＣＰ（Common Pattern）と呼ぶ．また，差異部分をＲＳ（Remaining Segment）と呼ぶ．なお，Ｓ１がＣＰ，ＲＳに分解されたとき元のＳ１は辞書中より削除される．Ｓ１の共通部分と差異部分の抽出による語の獲得の例を図３に示す．

（１）抽出されたＳ１
　　（れんぞくおんせい：連続音声）
　　（おんせい：音声）
（２）抽出されたＣＰ，ＲＳ
　　ＣＰ：（おんせい：音声）
　　ＲＳ：（れんぞく：連続）

図３　ＣＰ，ＲＳの抽出の例

このＣＰ，ＲＳの抽出の際に共通部分であることの条件は，表意文字とそれ以外の文字で情報量が異なる点を考慮し図４のように定める．

Evaluation of Adaptation Capability for Kana-Kanji Translation of Non-Segmented Japanese Kana Sentences by Inductive Learning

Kenji Araki*1, Koji Tochinai*2

*1Hokkai-Gakuen University, *2Hokkaido University

（１）文字数による制限
　Ｄ＝読みの文字数－表記の文字数
　①Ｄ＝０の時：表意文字でない字種を近似
　　３文字以上表記が一致する．
　②Ｄ≠０の時：表意文字を近似
　　２文字以上表記が一致する．
（２）共通部分の状況による制限
　　一方が他方を完全に含む形で重複する．

図４　ＣＰ，ＲＳ抽出の条件

３．３　フィードバック学習

フィードバック学習では，正しく変換した語の尤度を上げ，誤って変換した語の尤度を下げることによって次回の変換の精度を向上させる．フィードバック学習は正しい変換結果と変換結果を比較することにより行われる．正しい変換結果は変換結果に誤った部分がある場合に人手によって修正することにより得られる．また，各語の変換の精度によって所属クラスの制限を行う．すなわち，ＣＰで９５％以上の精度で使用されたものはＭＳに登録される．また，ＣＰ，Ｓ１，ＲＳの各クラスで５回以上使用され，精度が６０％未満のものは辞書から削除される．

４．適応能力評価実験

情報処理学会論文誌より情報処理工学分野の論文１０編（入力文字数１０３，０００文字）と北海道大学工学部研究報告より機械工学分野の論文２編（入力文字数１６，０２９文字）の計１２編（入力文字数１１９，０２９文字）を用いて実験を行った．初期状態の辞書は全く空から初め，資料のべた書き文を一文ごとに入力し，図１の処理を行った．図５に実験結果を示す．

図５より明らかなように，情報工学分野中でも論文が変化するごとに正変換率は低下しているが，学習により次第に上昇している．特に情報工学分野の後半では論文が変化しても正変換率はさほど低下せず９０％以上を示し，システムが情報工学分野に適応していることがわかる．この状態から機械工学に対象分野を変化させると正変換率は低下する．しかし，学習により次第に正変換率は上昇し，論文２編分（入力文字数１６，０２９文字）を学習した後には，９０％程度まで回復している．以上より本手法の適応能力が分野の変化に追従できることが確認された．

５．おわりに

入力べた書き文とその変換結果より語の読みと表記を帰納的に獲得し，獲得された語を用いて獲得状況に基づく確実性の高いものよりべた書き文中の語を認識する手法について述べ，実験システムを作成し，その適応能力を評価した．実験結果より本手法が，対象分野の変化に追従することが確認された．今後は，さらに文学等の工学以外の資料に対する適応能力の評価を行う予定である．

謝　辞

実験を行うにあたり御協力いただいた北海学園大学工学部電子情報工学科，佐藤隆之氏，高橋祐治氏，富居広樹氏に感謝します．

参考文献

１）荒木，栃内：帰納的学習による形態素解析手法における適応能力の評価，電子情報通信学会技術研究報告，Vol.90，No.375，pp.1-8(1990)．
２）荒木，栃内：帰納的学習によるべた書き文のかな漢字変換，電子情報通信学会技術研究報告，Vol.91，No.396，pp.9-16(1991)．
３）牧野，木澤：べた書き文の分かち書きと仮名漢字換，情報処理学会論文誌，Vol.20，No.4，pp.337-345(1979)．
４）吉村，日高，吉田：文節数最小法を用いた日本語文の形態素解析，情報処理学会論文誌，Vol.24，No.1，pp.40-46(1983)．

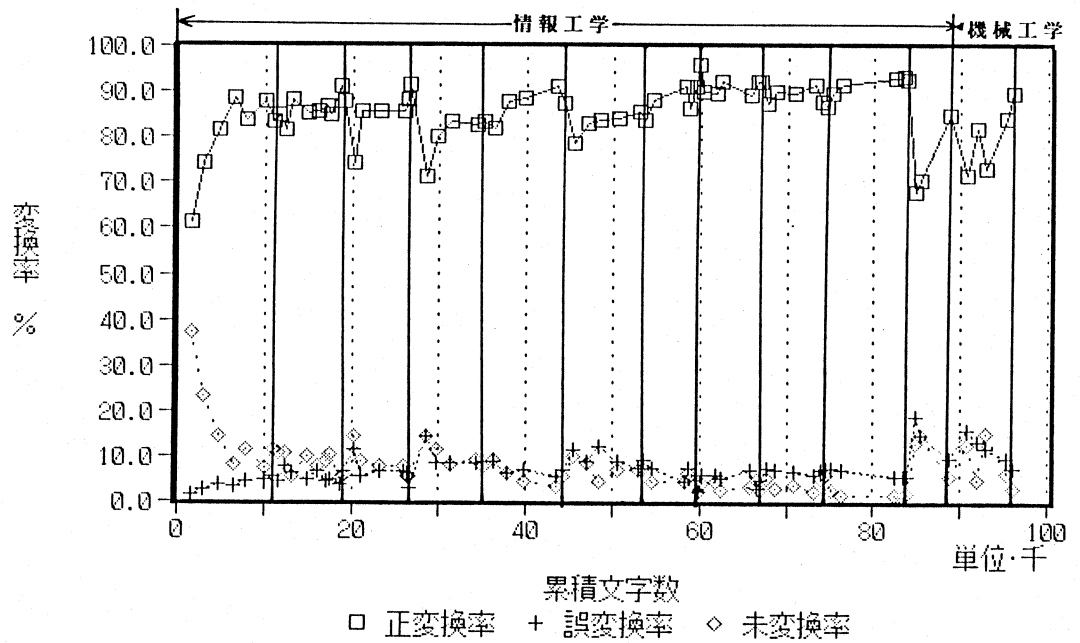


図５　適応能力評価実験結果