論　文

帰納的学習による語の獲得および確実性を用いた語の認識

正員　荒木　健治[†]　　正員　栃内　香次[††]

Acquisition Words by Inductive Learning and Recognition Words Using Certainty

Kenji ARAKI[†] *and* Koji TOCHINAI[††], *Members*

あらまし　日本語文書を計算機で処理する機会が増大しているが，日本語には分かち書きの習慣がないので，計算機で日本語文書を処理する場合，まず分かち書きを行わなければならない．この問題に対して，我々は，文字列中より帰納的学習を用いて語を獲得し，確実性の高いものより語を認識する手法を提案する．確実性はその語の獲得状況に基づいている．本手法は，既に学習された語により入力された文字列中の語を認識する過程，未知文字列中に出現する共通パターンより語を帰納的に学習する過程，確実性の高いものより語を認識する過程および認識結果と校正済みの認識結果より，未登録語や誤りの状況をフィードバック学習する過程よりなる．本手法に基づく実験システムを用いて行った評価実験により，辞書が全く空の状態から始めて正認識率が90％程度まで向上すること，および対象分野が変化しても正認識率はさほど低下しないことが確認され，本手法の有効性が示された．

キーワード　帰納的学習，獲得，認識，確実性，共通パターン

1. まえがき

高度情報化社会の進展により，日本語文書を計算機で利用したいという要求は年々急速に高まっている．日本語文書を計算機で扱う場合，まず，問題となるのが文書中の単語認識の問題である．すなわち，日本語には分かち書きの習慣がないので，計算機で日本語文書を処理する場合には，最初に分かち書きを行って文を単語単位に分割しなければならず，いわゆる形態素解析(1)が必要となる．

計算機による自動分かち書きの処理に対しては，これまで種々の方法が提案されてきた(2)~(5)．これらはすべて既知語（登録語）に対する処理のみに限定しているか，既知語に対する処理の枠組みの中に未知語（未登録語）の処理を付け加えている．しかし，非常に語いが多く，しかも，時代につれて変化するという自然言語が本来もつ性質上，実用システムで未知語が出現しないということは考えられない．また，文節や語の概念も人によって異なっている(6)．従って，未知語の処理は自然言語を扱う上で本質的に重要なことである．

このような立場に立ち，本論文では文字列中に出現する共通パターンを語とみなすことにより帰納的に語を獲得し，確実性の高いものより語を認識する手法を提案する(7),(8)．確実性はその語の獲得状況に基づいている．本手法により文字列中より半自動的に語を獲得することが可能であり，未知語に対する処理を行うことができる．我々は，確実性の高いものより語を認識することにより形態素解析を行う手法として，既に多段階分割法を提案し，べた書き文の仮名漢字変換に対してではあるが，その有効性を確認している(9)．しかし，多段階分割法では未知語を推測することはできなかった．一方，本手法では帰納的学習により語を獲得することにより未知語を推測し，認識することができる．

本手法では，帰納的に語を学習する．すなわち，文字列中に共通に出現する文字パターンを語であると推測することにより未知語に対処する．ここで，本論文で用いている帰納的学習とは，未知文字列中より共通部分を2段階に抽出することにより語を獲得する過程である．次いで，形態素解析された結果を人手で校正

[†] 北海学園大学工学部電子情報工学科，札幌市
Faculty of Engineering, Hokkai-Gakuen University, Sapporo-shi, 064 Japan
[††] 北海道大学工学部電子工学科，札幌市
Faculty of Engineering, Hokkaido University, Sapporo-shi, 060 Japan

することによって得られる正しく分割された文書と認識結果を比較することにより，語および認識傾向を学習する．このように，本手法は学習によって語いを増加させていくので辞書や文法の構築の必要がなく，対象分野あるいは個人に動的に適応することが可能である．従って，本手法を用いることにより文字列中より半自動的に語を獲得することが可能である．このことにより，従来必要であった専門分野ごとの辞書作成や新語登録の手間を軽減することができる．

本論文では，本手法の概要および実験システムを作成して行った評価実験結果(10)について述べる．

2. 概　要

本手法の処理過程は二つの学習過程，二つの認識過程よりなる．処理過程を図1に示す．

本手法では，まず，文が入力されると既知語による認識が行われる．これは，既に獲得され，蓄積された語によって，入力された文字列中の語を認識する過程である．次に帰納的学習による未知語の推測を行う．これは，既知語によって認識されなかった部分より，共通パターンを2段階で抽出することにより未知語を推測する過程である．この手法は，文字列中に繰り返し現れる同一文字列は語である可能性が高いという仮定に基づいている．次に推測された語を用いて未知語の認識を行う．この段階では，確実性の高いものより認識を行っている．次に，必要があればこのようにして得られた認識結果の誤りを人手により校正し，認識結果と校正により得られた正しい認識結果を比較して正認識，誤認識の傾向を学習する．更に未登録語を辞書に登録する．このような操作により，認識の精度を向上させる．この過程をフィードバック学習と言う．

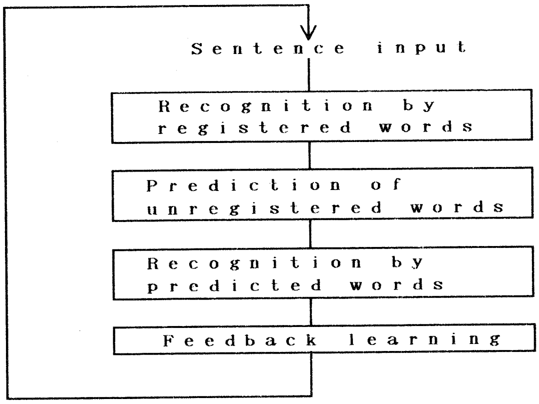
Sentence input
Recognition by registered words
Prediction of unregistered words
Recognition by predicted words
Feedback learning

図1　処理過程
Fig. 1 Process.

従って，本手法では帰納的学習による未知語の推測過程およびフィードバック学習の過程が語の獲得処理，既知語による認識過程と推測された未知語による認識過程が語の認識処理となる．なお，語の認識処理は確実性の高い順に行われるが，確実性が同じときには**3.1**で述べるゆう度評価関数を用いて確実性を評価する．この確実性は語の獲得状況に基づいている．また，文字列中に出現する共通パターンを取り出し，更に共通パターン同士の共通部分と残りの部分を語候補とすることにより語を獲得し，その語候補を用いて文字列中の語を確実性の高いものより認識することにより，70％程度の精度で語の認識が行えることが確認されている(11)．このことは，語そのものを与えず，文字列中に出現する共通パターンを語と推測することにより未知語をある程度予測できることを示している．このような基礎的な考察に基づき本手法は開発された．

3. 処理過程

3.1 既知語による認識

この段階では，これまでに獲得された既知の語を用いて入力文字列中の語を認識する．既知語は語であることが確認されているので，この段階で認識される入力文字列中の部分文字列(語)は，最も確実性が高い．本論文では，このような語をCorrect Wordと呼びCWと表記する．処理は以下のように行われる．

(1)　入力文字列と各CWとを比較する．

(2)　以下の基準に従って入力文字列中のCWを認識する．

(2-1)　CWが2文字以上で構成され，入力文字列中にそのすべてが一致する部分が存在する場合には，その部分はCWである．

(2-2)　CWが1文字で構成され，入力文字列中に一致する部分が存在する場合には，以下の条件のいずれかを満足する場合のみCWである．

①　両側が異なる字種で囲まれている場合

②　両側が認識済みの語で囲まれている場合

(3)　認識された単語候補が重複している場合は以下のゆう度評価関数によって算出されたゆう度評価値の最大のものを選択する．

ゆう度評価関数＝$\alpha*\mathrm{CF}+\mathrm{AF}-\beta*\mathrm{EF}$

CF：正認識度数，AF：出現頻度，
EF：誤認識度数，α，β：係数

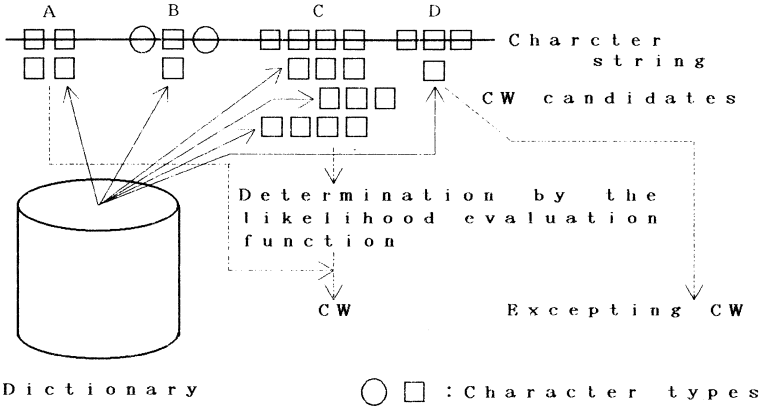

図2　既知語の認識の方法
Fig. 2　Method for the recognition of CW.

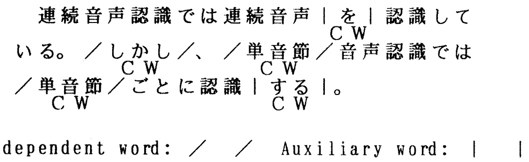
連続音声認識では連続音声｜を｜認識して
いる。／しかし／、／単音節／音声認識では
／単音節／ごとに認識｜する｜。

Independent word: ／　／　Auxiliary word: ｜　｜

図3　既知語の認識の例
Fig. 3　An example of recognition for registered words.

ゆう度評価値が最大のものが複数ある場合には，誤認識度数最小，正認識度数最大，出現頻度最大，文字数最大，分割の位置が最前方の順に評価して最適な単語を決定する．なお，正認識度数，誤認識度数，出現頻度はそれぞれフィードバック学習の段階で更新される．また，α，βについては実験によって求めた最適値，$\alpha=1$，$\beta=10$と決定している(12),(13)．

既知語の認識の方法を図2に示す．図2でAの場合は2文字以上で構成されるCWのすべての文字が一致しているので，この部分をCWと認識する．また，Bは1文字で構成されるCWの場合である．この場合，両側が異なる字種で囲まれているのでCWと認識する．Cは単語候補が重複して出現する場合で，この場合には前述したゆう度評価関数によって最適なCWを決定する．Dは1文字で構成されるCWの場合である．この場合には，両側が同一の字種であるのでCWと認識しない．既知語の認識の具体例を図3に示す．

3.2　帰納的学習による未知語の推測

入力文字列中で，既知語により認識されなかった未認識文字列より未知語を帰納的学習により推測する．帰納的学習による未知語の推測では，まず，CWによって認識されなかった未認識文字列より共通パターンを抽出する．ここで，共通パターンとは文字列中に存在する同一部分列である．この段階で抽出された共通パターンをType I Segmentと呼び，S1と表記する．この共通パターンを抽出する条件を以下に示す．

（1）　文字数による条件
(1-1)　2文字以上の場合
(1-2)　1文字のみの場合
以下の条件のいずれかを満たす場合
①　両側が異なる字種で囲まれている場合
②　両側が認識済みの語で囲まれている場合
（2）　出現状況による条件

少なくとも一つは他の共通パターンに含まれない出現位置が存在する．

次いで抽出された共通パターン(S1)中より共通部分を抽出する．これは，複数の語から構成されるS1を一つの語から構成されるS1で分解するものである．この過程を高次共通パターンの抽出と呼ぶ．高次共通パターンを抽出する条件を以下に示す．

（1）　文字数による条件
(1-1)　2文字以上の場合
(1-2)　1文字のみの場合
以下の条件のいずれかを満たす場合
①　両側が異なる字種で囲まれている場合
②　両側が認識済みの語で囲まれている場合
（2）　出現状況による条件

一方が他方に完全に含まれる形で重複している．

このようにして抽出された共通部分をType II segmentと呼び，S2と表記する．また，共通部分以外

```
(１) Sentences recoginized by CW.
     連続音声認識では連続音声｜を｜認識して
                                CW
   いる。／しかし／、 ／単音節／音声認識では
          ---------
          CW          CW     ----------
   ／単音節／ごとに認識｜する｜。
     CW            CW
Independent word: ／  ／  Auxiliary word: |   |

(２) Result of S1 extraction.
     連続音声、認識、音声認識、では

(３) Process of S2 and S3 extraction.
     (音声認識、認識) →音声: S3 <Independent word>
                       認識: S2 <Independent word>
     (連続音声、音声) →連続: S3 <Independent word>
                       音声: S2 <Independent word>
      では                   S1 <Auxiliary word>

(４) Result of WS extraction.
     S1: では<Auxiliary word>、
     S2: 音声<Independent word>、認識<Independent word>
     S3: 連続<Independent word>
```

図4　未知語の推測の例
Fig. 4　An example of prediction for unregistered words.

```
(1) Affix.
  An affix must satisfy following three conditions.
  1: The WS must be a S3.
  2: The number of character of the WS is 1.
  3: The type of character of the WS is "Kanji".
(1-1) Prefix.
  Extracted S3 is the top character of the S1.
(1-2) Suffix.
  Extracted S3 is the last character of the S1.
(2) Auxiliary word.
  Character type of the WS is "Hiragana".
(3) Inflectional ending.
  An inflectional ending must satisfy following four conditions.
  1: The WS must be a S3.
  2: The number of character of the WS is 1.
  3: The type of character of the WS is  "Hiragana".
  4: The WS is not one of the characters "を、の、は、に、が、と、や、で、
     も、へ、て、ば、か". They are possible to be postpositional words
     functioning as an auxiliary to an independent word.
(4) Independent word.
  Independent words are the WSs except those defined in (1),(2) and (3).
```

図5　品詞推測のヒューリスティックス
Fig. 5　Heuristics for the prediction of the word class.

の残りの部分をType III segmentと呼び，S3と表記する．また，分解されたS1は削除され，共通部分であるS1はS2となる．

以上，S1，S2，S3を総称して，Word segmentと呼び，WSと表記する．図4に帰納的学習による語の推測の例を示す．

また，この高次共通パターンの抽出段階では，品詞の推測を行う．品詞の推測はヒューリスティックスを用いて行われる．この段階では誤りを含む可能性があるが，これらの誤りはフィードバック学習で修正される．すなわち，誤った品詞をもった語はしだいにゆう度が下がり辞書から削除される．品詞推測のヒューリスティックスを図5に，品詞推測の例を図6に示す．

```
(本論文、論文) →  本  : S3 <Prefix>
                  論文: S2 <Independent word>
(簡単化、簡単) →  簡単: S2 <Independent word>
                  化  : S3 <Suffix>
 では          →        S1 <Auxiliary word>
(行う、行)     →  行  : S2 <Independent word>
                  う  : S3 <Inflectional ending>
```

図6　品詞の推測の例
Fig. 6　An example for the prediction of the word class.

なお，以上の処理で単語候補が重複した場合の処理は既知語の認識の場合と同様である．

3.3　推測された未知語による認識

CWによって認識することができなかった未認識文字列について，帰納的学習によって推測された語(WS)を用いて未認識文字列の認識を行う．認識は，確実性

の高いものより行われる．従って，その手順は以下のようになる．

（1） S2による認識

（2） S1による認識

（3） S3による認識

WSの認識の手順を以下に示す．

（1） 入力文字列中の未認識部分とWSとを比較する．

（2） 以下の基準に従って入力文字列中のWSを認識する．

(2-1) WSが2文字以上で構成され，入力文字列中の未認識部分にそのすべてが一致する部分が存在する場合には，その部分は語である．

(2-2) WSが1文字で構成され，入力文字列中の未認識部分に一致する部分が存在する場合には，以下の条件のいずれかを満足する場合のみ語である．

① 両側が異なる字種で囲まれている場合

② 両側が認識済みの語で囲まれている場合

（3） 認識された単語候補が重複している場合の処理は**3.1**の既知語による認識の場合と同様である．

図7に推測された未知語による認識の例を示す．

3.4 フィードバック学習

必要があればシステムが認識した結果を人手により校正する．図7の認識結果を校正したものを図8に示す．図8で＿の部分が未認識を修正したものである．

次いで，認識の精度を向上させるために，認識の状況を学習する．これをフィードバック学習と呼ぶ．フィードバック学習は認識結果と校正結果を比較することにより行われる．フィードバック学習では，未登録語の辞書への登録および正認識を行った語のゆう度を上げ，誤認識を行った語のゆう度を下げるという二つの操作を行う．具体的手順を以下に示す．

```
／連続／／音声／／認識／｜では｜／連続／／音声／
  S3      S2      S2      CW      S3      S2
 ｜を｜／認識／している。／しかし／、／単音節／
  CW    S2                 CW          CW
／音声／／認識／｜では｜／単音節／ごとに／認識／
  S2      S2      S1      CW              S2
｜する｜。
  CW
Independent word: ／  ／    Auxiliary word: ｜  ｜
```

図7 推測された未知語による認識の例
Fig. 7 An example of the recognition by predicted words.

```
／連続／／音声／／認識／｜では｜／連続／／音声／
  S3      S2      S2      CW      S3      S2
｜を｜／認識／｜して｜｜いる｜。／しかし／、
 CW     S2                        CW
／単音節／／音声／／認識／｜では｜
   CW        S2      S2      S1
／単音節／｜ごと｜｜に｜／認識／｜する｜。
   CW                     S2      CW
Independent word: ／  ／    Auxiliary word: ｜  ｜
```

図8 校正結果の例
Fig. 8 An example of proofreading result.

（1） 正認識の場合

(1-1) 認識した語の所属をCWとする．

(1-2) 認識した語のCF（正認識度数）とAF（出現頻度）を1増加する．

（2） 誤認識の処理

(2-1) 正しい語の処理

① 正しい語が辞書に存在しないときはCWにAFを1にして登録する．

② 正しい語が辞書に存在するときはAFを1増加させる．また，その語の所属がCW以外のときはCWに変更する．

(2-2) 誤った語についてはEFを1増加させる．

（3） 未認識の処理

(3-1) 正しい語が辞書に存在しないときはCWにAFを1にして登録する．

(3-2) 正しい語が辞書に存在するときはAFを1増加させる．また，その語の所属がCW以外のときはCWに変更する．

この他フィードバック学習ではゆう度の評価による所属クラスの制限(7)が行われる．

4. 評価実験

実験システムを用いて本手法を評価するための実験を行った．

4.1 実験方法

実験に用いた資料は表1に示す情報処理に関する論文14編（総文字数120,417文字），機械工学に関する論文10編（総文字数58,009文字），応用化学に関する論文10編（総文字数61,591文字）および人文科学に関する論文4編を10に分割したもの（総文字数62,686文字）の合計44編（総文字数302,703文字）である．さらに，この44編の各編をおよそ章ごとに五つにし，合計220に分割した．

実験手順は図1に示す処理を220回行った．なお，初期状態の辞書は全く空である．

4.2 実験結果

認識の位置と品詞が一致したものを正認識とし，認識位置あるいは品詞が一致しないものを誤認識，認識されなかったものを未認識と呼ぶ．正認識率，誤認識率，未認識率はそれぞれ正認識語数，誤認識語数，未

表1 適応能力評価実験に用いた資料

（1）分野：情報処理　出典：情報処理学会論文誌

No	論文名	著者名	巻名	文字数
1	高集積マイクロコンピュータに適したマイクロプログラム制御方式	前島他	Vol.23 No.1	10,920
2	ＣＯＢＯＬマシンとその設計思想－ハードウェア構成について－	山本他	Vol.23 No.1	8,504
3	フーリエ変換を用いたテクスチュアの構造解析	松山他	Vol.23 No.2	7,752
4	日本語文入力用カタカナ語検出規則とオンライン国語辞典の一分析	木村	Vol.23 No.2	8,655
5	インテリジェント・コンソール－ＯＳの機能拡張の一方法－	有田	Vol.23 No.3	9,394
6	ポータブル画像処理ソフトウェア・パッケージＳＰＩＤＥＲの開発	田村他	Vol.23 No.3	9,611
7	グラフィック・ディスプレイ・ターミナルのための端末作画システム	高藤他	Vol.23 No.4	6,582
8	オペレーティング・システムのファームウェア化対象選定法	長岡他	Vol.23 No.4	7,636
9	プログラム階層構造の生成,処理,文書化能力を有するテキスト・エディタ	酒井他	Vol.23 No.4	8,034
10	パステストに本質的な分岐に着目した網ら率尺度の提案	中所他	Vol.23 No.5	10,010
11	計算機システムにおける性能管理の一方式とそれを用いた実験	吉住他	Vol.23 No.6	8,991
12	高速パケット伝送路用前置処理装置の一構成法	寺田他	Vol.23 No.6	8,404
13	ソフトウェア生産過程の評価実験に関する考察	有澤他	Vol.23 No.3	6,550
14	文節数最小法を用いたべた書き日本語文の形態素解析	吉村他	Vol.24 No.1	9,374
	情報工学分野の文字数の合計			120,417

（2）分野：機械工学　出典：北海道大学工学部研究報告

No	論文名	著者名	巻名	文字数
1	格子乱流中における垂直平板の流力特性	有江他	第106号	4,905
2	疲れ強さにおよぼす加工効果および残留応力の影響－低温燃焼の場合－	秦 他	第 97号	8,810
3	暖房用ストーブの燃焼性能に関する研究（第１報）	園田他	第106号	7,212
4	暖房用ストーブの燃焼性能に関する研究（第２報）	園田他	第106号	5,353
5	任意に調節可能な座標線密度をもつ流れ場内格子点網の創成法	飯田他	第107号	6,387
6	円弧切欠きと荷重端の干渉について	岸田他	第108号	2,141
7	境界層剥離の近似的な推定法	知名他	第 98号	4,508
8	換気回数の低い室内における都市ガスの燃焼と一酸化炭素の発生	伊藤他	第105号	7,495
9	チェーンソーの振動におよぼす切削条件の影響	金内他	第104号	7,120
10	任意形状を有する四辺形膜の自由振動	入江他	第 96号	4,078
	機械工学分野の文字数の合計			58,009

（3）分野：応用化学　出典：北海道大学工学部研究報告

No	論文名	著者名	巻名	文字数
1	ニオブ酸カリの凍結に関する研究	小平他	第112号	3,485
2	金属酸化物と動からなる混練触媒のキャラクタリゼーションオン及びメタノールリフォーミング反応	小林他	第102号	5,442
3	混合粒子から成る気固系流動層の粒子混合と分級	千葉他	第102号	7,072
4	有機アルミニウム化合物存在下での環化重合	横田他	第102号	4,783
5	高分子のメカノケミストリー（Ｉ）（綜報）	相馬	第102号	10,502
6	高分子のメカノケミストリー（ＩＩ）（綜報）	相馬	第108号	10,709
7	混合粒子系噴流層の流動特性	上牧他	第 98号	4,236
8	炭酸ガスの有効利用に関する研究	杉岡他	第105号	5,116
9	３－シジクロヘキシルボリルアクリル酸エチルのアルコール中での光化学反応	徳田他	第104号	5,601
10	２－Alkylbenzimidazolの改良合成法	高田他	第 96号	4,645
	応用化学工学分野の文字数の合計			61,591

（4）分野：人文科学　出典：「美と宗教の発見」（梅原　猛著）

No	論文名	頁数	文字数
1	明治百年における日本の自己認識	pp. 65 - 76	9,065
2	明治百年における日本の自己認識	pp. 77 - 83	5,530
3	明治百年における日本の自己認識	pp. 83 - 92	6,286
4	美学におけるナショナリズム	pp. 93 -103	6,232
5	美学におけるナショナリズム	pp.103 -112	6,853
6	浄土教的感情様式について	pp.258 -262	3,787
7	浄土教的感情様式について	pp.263 -275	8,444
8	創価学会の哲学的宗教的批判	pp.276 -282	4,911
9	創価学会の哲学的宗教的批判	pp.282 -286	3,672
10	創価学会の哲学的宗教的批判	pp.287 -296	7,906
	人文科学分野の文字数の合計		62,686
	（1）（2）（3）（4）の文字数の合計		302,703

認識語数の総語数に占める割合である．定義式を以下に示す．

$$\text{正認識率}=\frac{\text{正認識語数}}{\text{総語数}},\quad \text{誤認識率}=\frac{\text{誤認識語数}}{\text{総語数}}$$

$$\text{未認識率}=\frac{\text{未認識語数}}{\text{総語数}}$$

実験結果を図9，図10に示す．図9，図10で破線は論文の切れ目を実線は分野の切れ目を示している．

4.3 考　察

図9に示すように，総合の正認識率は，しだいに上昇しているが，情報処理分野の論文4で極端に下がっている．これは，論文4が日本語処理について書かれた論文であり，“「けしきばむ」が「けしきぱむ」となっていた”といった日本語入力の誤りの例や話言葉などが

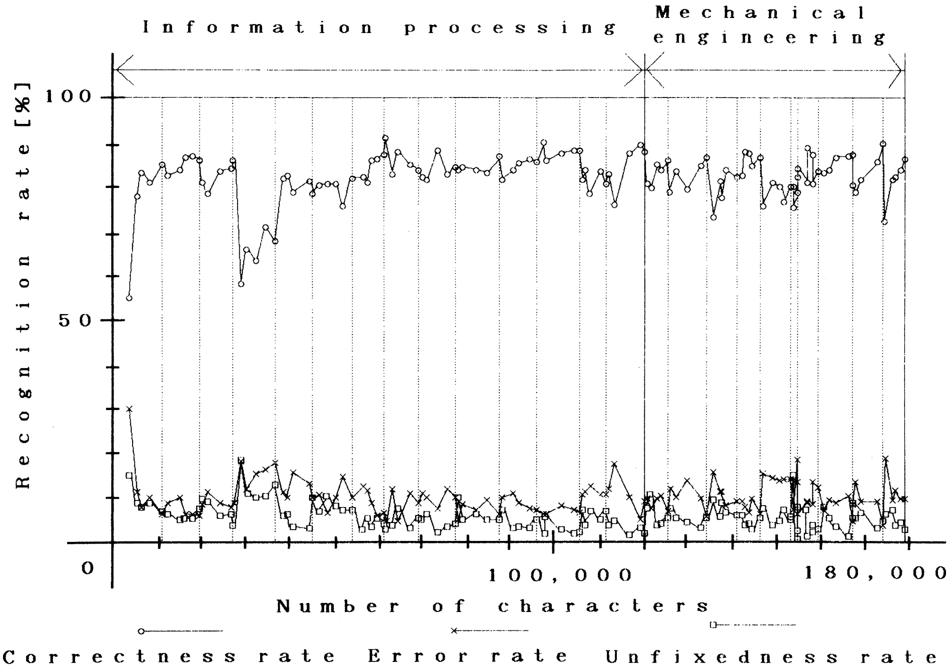

図9　認識率の推移(I)
Fig. 9　Change in the recognition rate (I).

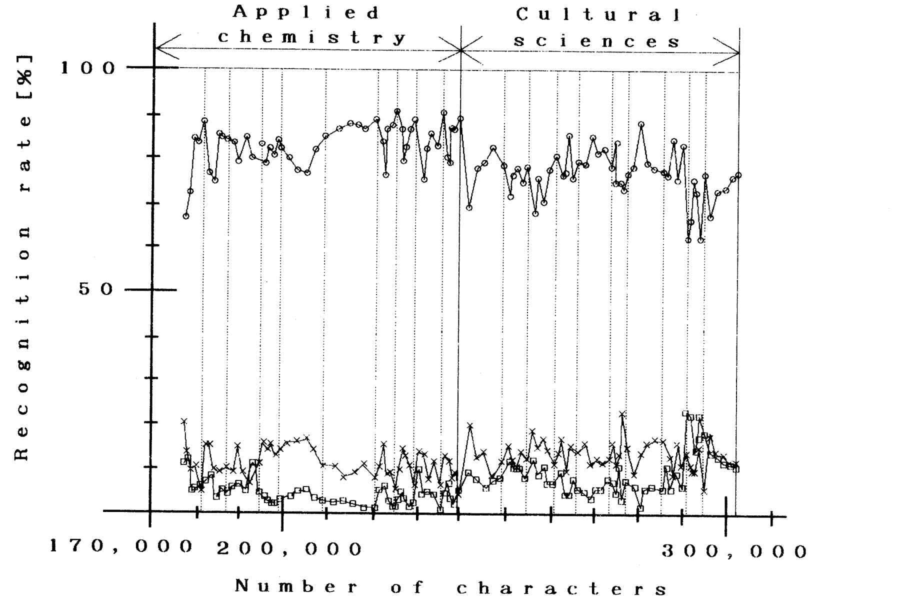

図10　認識率の推移(II)
Fig. 10　Change in the recognition rate (II).

あり，形態素解析を行うことが困難なためと考えられる．しかし，論文 4 でも学習により正認識率はしだいに向上している．

認識率は最高で 90 % 程度にとどまっているが，この原因は，第一には共通部分を抽出する際の CW による未認識文字列が少なかったために，共通部分がさほど出現せず，WS による未知語の推測が行われなかったためである．従って，入力する文書の量を増やす必要があると考えられる．第 2 には，今回は人手による校正処理を二人で行ったために，形態素解析の基準が細かいところで異なったことにより学習が正しく行われなかった部分が存在したと考えられる．校正の方法を統一する必要がある．

分野の変化による適応能力の評価については，図 9，図 10 よりわかるように情報処理，機械工学，応用化学，人文科学と対象分野が変わっても，さほど正認識率は下がっていない．このことは本手法の適応能力の高さを表しているものと考えられる．

また，特に誤認識となった部分では数字，記号，アルファベット，片仮名，平仮名が多い．この原因は，これらの文字が表意文字ではなく漢字とは 1 字のもつ情報量が異なるためであると考えられる．従って，字種ごとにその処理を変えるという方法が考えられる．しかし，同じ字種でも各文字ごとにその情報量は大きく異なっているので，各文字の情報量をシステムが自動的に学習により獲得する方法を検討する必要がある．

処理時間は，辞書が空の状態から 5 回処理を行うのに CPU 時間が 23 分 37.57 秒である(12),(13)．ここで，5 回の処理とは論文 1 編（総文字数 9,223 文字）を処理するということである．処理時間を更に短縮することは今後の課題である．なお，実験は VAX 8550 を用いて行った．

また，もし未知語の推測を行わなければ既知語の認識における正認識以外の部分は，人手により校正を行わなければならない．しかし，本手法では，既知語による未認識部分の語の認識を未知語を推測することにより行っている．従って，本手法による語の獲得の手間の軽減の度合は，既知語による未認識部分のうちの推測された未知語による認識の精度である．この精度は対象とする資料により 0 ～60 % とさまざまである(10)．これは，未知語を推測するのに用いる文書量に依存すると考えられる．この実験結果は，辞書作成の手間の軽減における本手法の有効性を示していると考えられる．

5. むすび

未知語の推測を帰納的学習により行い，その推測状況に基づく確実性の高いものより語の認識を行う手法の概要とその処理方法について述べ，次いで本手法を実験により評価した結果について述べた．実験結果より，辞書が空，すなわち入力文字列中に出現する語がすべて未知の場合でも，学習により語を獲得することにより，正認識率が 90 % 程度得られること，および対象分野が異なっても正認識率はさほど低下しないことが確認された．このことは，本手法が半自動的語の収集および未知文字列中の語の認識に有効であることを示していると考えられる．

今後の課題としては，1 度に学習する文書の量がどれぐらいあれば未知語の推測が良好に行われるのかを実験により考察すること，および学習により自動的に各文字のもつ情報量を獲得し，情報量により処理方法を変化させる方法について研究を進める予定である．

謝辞 北海学園大学在学中実験等に御協力頂いた林研氏（現，ジムラク総合研究所(株)），橋本丈氏（現，松下システムエンジニアリング(株)），宮野正行氏（現，凸版印刷(株)）に感謝します．なお，本研究の一部は文部省科学研究費補助金（奨励研究 A 第 2855098 号）の補助により行われた．

文　献

(1) 中野　洋，野村雅昭："日本語の形態素分析"，情報処理，**20**, 10, pp. 857-864 (1979).

(2) 建石由佳，小野芳彦，山田尚勇："Diction と Style の日本語化について"，第 31 回情処学全大講演論文集，4H-2.

(3) 藤崎博也，亀田弘之："新聞記事データを対象とする自動単位切り処理とそれに基づく語彙調査"，情処学自然言語処理研報，**NL51**-2 (1985-09).

(4) 吉村賢治，武内美津乃，津田健蔵，首藤公昭："未登録語を含む日本語文の形態素解析"，情処学論，**30**, 3, pp. 294-301 (1989).

(5) 大沢幸夫，藤崎博也："未知語を含む文の形態素解析システム"，第 41 回情処学全大講演論文集，1S-5 (1990).

(6) 原田悦子："日本語テキストにおける認知的単位"，情処学文書処理とヒューマンインタフェース研報，**DPHI22**-3 (1989).

(7) 荒木健治，栃内香次："帰納的学習による文字列中の語の認識"，信学技報，**NLC89**-32 (1989-12).

(8) 荒木健治，栃内香次："学習に基づく形態素解析手法"，1990 信学春季全大，D-78.

(9) 荒木健治，栃内香次，永田邦一："多段階分割法によるべた書き日本語文のかな漢字変換"，情処学論，**28**, 4, pp. 412-421 (1987).

(10) 荒木健治，栃内香次："帰納的学習による形態素解析手法

における適応能力の評価”，信学技法，**NLC90**-41 (1990-12).

(11) 荒木健治，栃内香次：“文字列中の共通パターンを用いた語の認識”，平成元北海道連大，274.

(12) 荒木健治，栃内香次：“帰納的学習による形態素解析手法における処理方法の改良”，平2北海道連大，293.

(13) 荒木健治，栃内香次：“帰納的学習による形態素解析手法における処理時間と削減と尤度評価関数について”，北海学園大学工学部研究報告，**18**, pp. 245-256 (1991).

（平成3年7月9日受付，4年1月20日再受付）

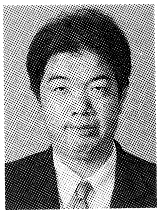

荒木　健治

昭57北大・工・電子卒．昭63同大大学院博士課程了．工博．同年，北海学園大学工学部電子情報工学科助手．平1同講師．平3同助教授．自然言語処理，音声言語情報処理，学習の研究に従事．情報処理学会，日本認知科学会，人工知能学会，IEEE，ACL，AAAI各会員．

栃内　香次

昭37北大・工・電気卒．昭39同大大学院工学研究科電気工学専攻修士課程了．現在，北大・工・電子工学科教授．主として計算機システムおよび自然言語処理の研究に従事．工博．情報処理学会，日本音響学会各会員．