社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC92-33 (1992-10)

# 表層的な単語共起関係を利用した誤りを含む文の復元

佐藤　智栄†　　荒木　健治‡　　宮永　喜一†　　栃内　香次†

†北海道大学工学部
札幌市北区北13条西8丁目

‡北海学園大学工学部
札幌市中央区南26条西11丁目

あらまし
音声認識や文字認識など、自然言語を対象とした認識では、信号情報をボトムアップ的に処理する方法と並んで、自然言語の特徴を生かしたトップダウン的な処理過程が存在する。また、このようなトップダウン処理が認識誤りの復元に有効であることが知られている。本報告では、このトップダウン処理に利用する情報として単語共起関係に着目し、文書の表層情報を用いてキーワードとそれに共起して出現する語を抽出し、利用することによって認識誤りを復元する手法を提案する。また、本手法に基づく実験システムを作成し、その有効性について述べる。
和文キーワード　単語共起関係　キーワード　共起単語　抽出

# Recovery from Errors in Sentences Using Word Co-occurrence Relationship of Character Strings

Norihide SATO†　Kenji ARAKI‡　Yoshikazu MIYANAGA†　Koji TOCHINAI†

†Hokkaido University
N13-W8,Kita-ku,Sapporo 060,Japan

‡Hokkai-Gakuen University
S26-W11,Chuo-ku,Sapporo 064,Japan

Abstract
On speech or character recognition, there exist two approaches for analysis: one is bottom-up analysis of input signal, and the other is top-down analysis based on the characteristics of natural languages. And it is known that top-down analysis is effective to recover from recognition errors. In this paper, a method for recovering from recognition errors using word co-occurrenence relationship in input texts is proposed. In this method, keywords and their co-occurrence words are abstracted by using surface word-relation of input character strings, and then used as information for a top-down process. An experimental system is implemented and effectiveness of the method is shown.
英文 key word　co-occurrent relationship　key word　co-occurrent word　abstruction

# 1 はじめに

音声認識や文字認識などの自然言語を対象とした認識処理では、信号情報をボトムアップ的に処理する処理過程と並んで、自然言語の特徴を生かしたトップダウン的な処理過程が存在する。また、このトップダウン処理が認識誤りの復元に有効であることが知られている。

先に発表した多段階分割復元法[1]は、大規模な文書を対象に、音声入力において発生する誤りを統計的手法を用いて段階的に自動訂正するものであった。この段階的処理においては、上位でいかに多くの正しい復元が行なわれるかが重要であり、上位での復元結果が下位の処理に大きな影響を及ぼしていた。

この問題に対し、我々は上位の段階で精度良く復元するための情報として単語の表層的な共起関係に着目している。

本稿では、この表層的単語共起関係を用い、復元の最初の手がかりとなるキーワードとその共起単語を実際の文書から自動的に抽出する方法について述べ、抽出されたキーワードとその共起単語を用いて、連続音声認識結果に含まれる誤りを復元する手法について述べる。

# 2 概要

音声認識装置の認識結果など、誤りを多く含む文字列を人間が復元する場合、はじめに比較的少数の手がかり語を見つけ、その語と何らかの意味的関係を持つ語を優先的に復元していくと考えられる。従って、計算機で同様の処理を行なうためには、この意味的関係を辞書化しておく必要がある。

しかし、このような辞書は作成に膨大な手間がかかり、また、単語の意味が使われ方に依存して動的に変動するという理由により、文書から自動的に抽出することが必要と考えられる。本手法は、人間が優先的に復元する意味的な関係に相当するものとして、表層的単語共起関係を想定し、手がかり語とその共起単語を自動的に抽出、利用することにより復元処理を行なうものである。

## 2.1 表層的単語共起関係

本稿では以下、前述の手がかり語をキーワードと呼ぶことにする。本手法では、キーワードと同一文中に出現した他の単語は、そのキーワードと何らかの意味的な関係があると考えている。そこで、キーワードと同一文中に出現しているという関係を表層的単語共起関係と呼び、このような関係にある語をそのキーワードに対する共起単語と呼ぶことにする。

## 2.2 キーワード

文書中のある語を仮にキーワードとすると、そのキーワードと表層的単語共起関係にある語を文書全体にわたって調べることが可能である。また、文書中の全ての語を仮にキーワードとした場合、全ての語について共起単語を調べることができる。本手法では、多数の共起単語を持つ語は、文書中では、それらの共起単語と弱い関係があると考え、逆に、少数の共起単語しか持たない語は強い関係があると考えている。つまり、どの様な文脈においても出現する単語は、それだけでは強い意味を持たない語であると考えている。そこで、この共起単語数の大小の関係を利用し、キーワードとその共起単語を自動抽出する。

# 3 キーワードとその共起単語の抽出

次にキーワードとその共起単語の抽出法を述べる。まず、抽出を行なう文書の形態素解析を自立語と付属語の分割を中心として行なう。この中から自立語を全て抽出し、各自立語について出現率を計算する。

出現率＝出現回数/文書中の全単語の延べ数

次に、文書中に出現した全自立語について、各自立語が共起単語をいくつ持つかを調べる。今、ある自立語がその文書中で出現した回数を $n$、その自立語が持つ共起単語の数を $p$ とした場合、

$$a = p/n$$

である $a$ を求める。本手法では、この $a$ を一般化率と呼び、前述の共起関係の強弱に関する指標としている。

文書中の自立語 $W_i$ に対する共起単語 $K_{ij}$ について、$W_i$ に対する共起単語として $K_{ij}$ が出現した回数を $C_{ij}$ とし、

$$D_{ij} = C_{ij} / \sum_{j=1}^{m} C_{ij}$$

である $D_{ij}$ を各共起単語について計算する。本手法ではこの $D_{ij}$ を共起率といい、各語とキーワードの関係の深さを表す指標として用いる。

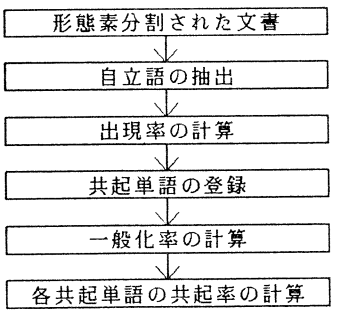



図1 キーワードその共起単語の抽出手順

このように、各自立語について出現率及び一般化率を求め、出現率が高く、一般化率の小さいものをキーワードとして抽出し、それらキーワード個々について共起率の高い共起単語を抽出することにより辞書化を行なう。このようにして得られたキーワードとその共起単語の例を図2に示す。

| キーワード | 共起単語 |
|---|---|
| マクロ (makuro) | 解読 (kaidoku)<br>μ－ROM (maikuroromu)<br>プログラム (puroguramu)<br>デコーダ (dekooda)<br>フィールド (fiirudo)<br>機能 (kinou)<br>形式 (keiSiki)<br>構造 (kouzou)<br>… |
| プログラム (puroguramu) | 制御 (seigyo)<br>方式 (houSiki)<br>構造 (kouzou)<br>マクロ (makuro)<br>… |
| μ－ROM (maikuroromu) | マクロ (makuro)<br>ページ (peezi)<br>解読 (kaidoku)<br>機能 (kinou)<br>構造 (kouzou)<br>アドレス (adoresu)<br>… |
| デコード (dekoodo) | アドレス (adoresu)<br>フィールド (fiirudo)<br>マクロ (makuro)<br>領域 (ryouiki)<br>ビット (biqto)<br>部分 (bubuN)<br>ページ (peezi)<br>… |
| … | … |

図2　キーワードとその共起単語の抽出例（一部）

# 4　復元システムの構成

3章で説明した手法によりキーワードとその共起単語を抽出し、これを連続音声認識結果の復元に利用したシステムを試作した。その構成図を図3に示す。

## 4.1　キーワードとその共起単語の辞書

キーワードとその共起単語辞書は3章で述べた方法により抽出する。出現率、一般化率、共起率の高低は、あらかじめ与える閾値によって判断する。

## 4.2　認識情報辞書

図4に認識情報辞書の例を示す。この辞書は入力された誤りを含む音素列を、どの程度信頼するかを決めるために用いる。図中の確率とは、過去に「入力音素」が「候補音素」であった割合を指す。

| 入力音素 | 復元候補音素 | 頻度 $C$ | 確率 $P$ |
|---|---|---|---|
| z | z | 143 | 1.00 |
| hm | zy | 2 | 1.00 |
| ta | ko | 3 | 1.00 |
| ca | ko | 2 | 1.00 |
| noG | haN | 1 | 1.00 |
| aqs | | 1 | 1.00 |
| … | … | … | … |
| o | o | 2703 | 0.99 |
| a | a | 2589 | 0.98 |
| … | … | … | … |
| n | n | 488 | 0.79 |
| … | … | … | … |
| | u | 42 | 0.45 |
| … | … | … | … |

図4　認識情報辞書の例

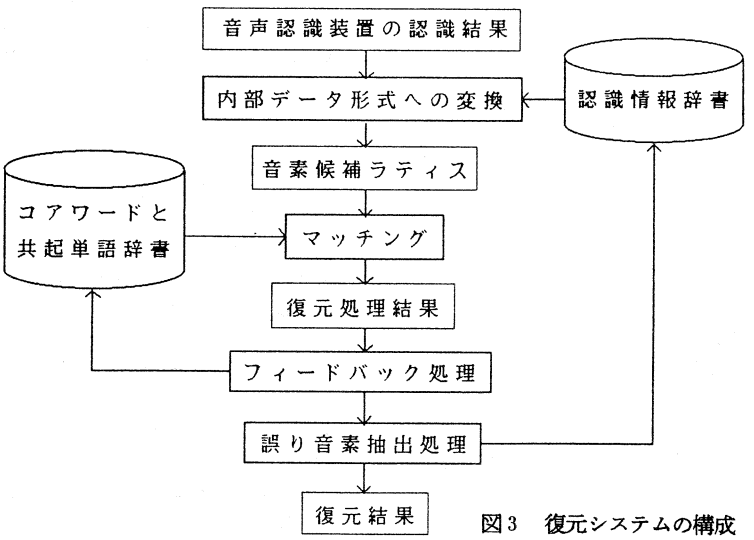



図3　復元システムの構成

本システムでは、この情報は未知であり、入力された誤りを含む音素列と復元結果である正しい音素列から自動的に作成する。また、連続音声認識結果の復元を想定しているので、音素の付加、脱落を考慮する必要がある。一般に、音素の付加、脱落を考慮するとその誤りの対応関係は一意に定まらない。そこで、誤りの部分が最小になるような対応関係を抽出する手法を用いた。なお、復元結果が正しくない場合には人手により正しく修正された結果を用いる。以下に認識情報の抽出方法を示す。

正しいデータ　　ronrinozyuunanseinikaketeiru
誤りを含むデータ　sonrinozyuumanseinikaketeigi

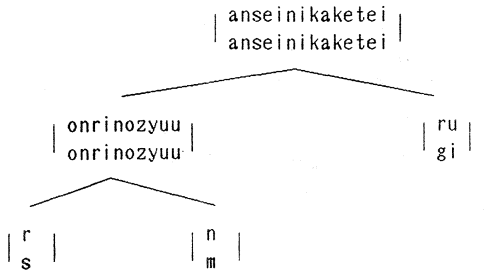



図5　誤りの対応関係抽出

まず、誤りを含む音素列と復元された正しい音素列で連続して一致する共通部分を見つける。見つかった共通部分を、その部分の長さと位置関係から評価し、評価値の高い共通部分によって分割し木を構成する。分割された残りの部分について再帰的に処理を行なうことにより、共通部分が最大となる木を生成することにより誤りの対応関係がわかる。図5の例の場合は次の図6に示す対応関係が得られる。

| 正しいデータ | 誤りを含むデータ |
|---|---|
| r | s |
| onrinozyuu | onrinozyuu |
| n | m |
| anseinikaketei | anseinikaketei |
| ru | gi |

図6　抽出された対応関係

## 4.3　音素候補ラティス

入力された音声認識結果は、前節で説明した認識情報辞書を参照することで、単語のマッチングに向いた音素候補ラティスに変換される。

音素候補ラティスとは入力音素に対し、候補となる音素を確からしさに従って並べたものである。図7に音素候補ラティスの例を示す。

| m | a | s | u | r | o | m | e | i | n | e | i | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| no | a | s | u | r | o | m | aq | i | ra | aq | i | − | y |
| m | ot | k | o | n | a | n | e | u | n | e | u | − | z |
| y | oh | ro | e | g | u | y | u | e | r | u | e | − | n |
| r | o | to | i | m | q | r | a | q | h | a | q | − | yu |
| s | q | − | | y | | q | q | | g | q | | − | do |
| q | | zo | | d | | b | | | d | | | − | iz |
| b | | ta | | w | | s | | | − | | | ... | ... |
| s | | i | | q | | g | | | | | | | |
| g | | r | | h | | z | | | | | | | |
| z | | t | | z | | | | | | | | | |
| | | h | | | | | | | | | | | |
| | | z | | | | | | | | | | | |
| | | g | | | | | | | | | | | |

図7　音素候補ラティスの例

確からしさとは図4中の頻度$C$と確率$P$によって決定されるもので、頻度により重み付けされた確率である。重み付けの方法は種々考えらるが、本手法では、頻度が極端に小さい場合の重みは極端に小さくすべきであるとの考えから、次の式を採用した。

$$R = P \times (1.0 - \exp(\alpha \times C))$$

ただし、$R$は確からしさ、$P$は確率、$C$は頻度、$\alpha$は、$-1 < \alpha < 0$である任意の定数。

この図の右の方に書かれた音素列は、過去に脱落したことのある音素を表し、音素ラティスから、語を検索する際に考慮しなければならないものである。

## 4.4　マッチングアルゴリズム

本手法では先に述べたように、少数のキーワードとその共起単語を復元の上位の段階で利用することを考えている。したがって、音素候補ラティスに変換された誤りを含む音素列に対し、はじめにキーワードの当てはめを行なう。

まず、音素候補ラティス中から単語候補音素列と一致するパスを全て検索し、一致度の一番高いパスを見つける。一致度$S$とは、パス$P_i$の個々の候補の確からしさ$R_i$を候補単語の音素列長で重み付けした値で、つぎの式により求める。

$$S = \sum_{i=1}^{N} R_i / (1.0 + \exp(\beta \times N))$$

ただし、$N$は候補単語の音素列長、$\beta$は、$-1 < \beta < 0$である任意の定数。

これを全てのキーワードについて行ない、もっとも一致度の高いキーワードが閾値を越えていれば、そのパスの部分を確定し、分割する。

分割されなかった、残りの部分についても、閾値を越える一致度を持つキーワードがある限り、同じ操作を繰り返すことによって、当てはめを行なう。当てはめることの出来るキーワードが全て当てはめられた後、そのキーワードについての共起単語を、再び、キーワードと共起単語辞書を参照することによって獲得し、まだ当てはめの行なわれていない部分について、共起単語を当てはめる。

## 5 実験

一般化率が復元結果にどの様な影響を与えるかについて実験を行なった。

### 5.1 実験資料

実験には、次の資料を用いた。

| | |
|---|---|
| 出典 | 情報処理学会論文誌 vol.24 No.1 |
| 題名 | 高集積マイクロコンピュータに適したマイクロプログラム制御方式 |
| 著者 | 前島他 |
| 総音素数 | 26346 |

図8 実験資料

### 5.2 実験手順

前節で示した実験資料をシミュレーションによって誤らせ、これにキーワードとその共起単語を適用した。

キーワードとその共起単語は、出現率0.006以上、共起率0.008以上、に固定し、一般化率は0.3未満、0.4未満、0.5未満の3種類を用意した。

音素の誤らせ方は、ほぼ図9に示した割合になるように、ランダムに誤りを発生させ、誤り率21％の資料を作成した。

また、確からしさを求めるための定数$\alpha$と一致度を求めるための定数$\beta$は経験的に、次の値を選んだ。

| | |
|---|---|
| $\alpha$ | -0.0305 |
| $\beta$ | -0.2682 |

図10 実験に使用した式の定数

### 5.3 実験結果

一般化率0.3, 0.4, 0.5未満のキーワードの数及び、キーワードとその共起単語の数を図11に示す。

| 一般化率 | キーワードの数 | キーワードと共起単語の数 |
|---|---|---|
| 0.3 | 17 | 162 |
| 0.4 | 19 | 160 |
| 0.5 | 20 | 160 |

図11 キーワードと共起単語の数

| | | | | | | | | | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| pu | 89.89 | p | 8.99 | t | 1.12 | | | | | | | | | | | | | | |
| tsu | 88.89 | ts | 11.11 | | | | | | | | | | | | | | | | |
| ku | 90.91 | k | 9.09 | | | | | | | | | | | | | | | | |
| hu | 93.02 | h | 3.49 | f | 3.49 | | | | | | | | | | | | | | |
| su | 84.51 | S | 12.68 | s | 2.82 | | | | | | | | | | | | | | |
| Si | 86.42 | S | 11.11 | s | 2.47 | | | | | | | | | | | | | | |
| Q | 96.15 | Qt | 1.28 | Qk | 0.85 | Qp | 1.39 | pS | 0.32 | | | | | | | | | | |
| a | 93.99 | u | 1.30 | e | 2.40 | o | 1.40 | N | 0.60 | G | 0.30 | | | | | | | | |
| i | 90.03 | u | 2.89 | e | 0.70 | N | 4.09 | G | 2.29 | | | | | | | | | | |
| u | 73.19 | a | 0.70 | i | 5.22 | e | 2.31 | N | 8.23 | G | 10.34 | | | | | | | | |
| e | 90.43 | i | 4.68 | u | 4.89 | | | | | | | | | | | | | | |
| o | 90.23 | a | 2.64 | u | 7.12 | | | | | | | | | | | | | | |
| y | 76.77 | w | 6.35 | m | 7.27 | n | 3.89 | g | 3.28 | r | 2.46 | | | | | | | | |
| w | 81.44 | n | 1.88 | g | 9.50 | r | 4.64 | h | 2.54 | | | | | | | | | | |
| N | 39.80 | G | 39.53 | u | 8.09 | m | 5.39 | n | 7.19 | | | | | | | | | | |
| G | 40.90 | N | 40.63 | g | 7.39 | u | 3.69 | m | 1.85 | n | 5.54 | | | | | | | | |
| m | 58.00 | y | 20.61 | w | 3.73 | g | 1.47 | r | 2.55 | h | 11.78 | s | 1.86 | | | | | | |
| n | 28.19 | m | 20.27 | y | 21.60 | b | 1.13 | g | 12.76 | r | 8.13 | h | 6.07 | s | 1.85 | | | | |
| b | 74.48 | g | 5.97 | d | 4.09 | m | 3.31 | p | 2.21 | h | 4.42 | s | 5.52 | | | | | | |
| g | 19.55 | b | 19.07 | w | 4.53 | m | 3.58 | n | 11.08 | r | 12.63 | h | 14.54 | s | 15.02 | | | | |
| d | 72.57 | g | 10.29 | r | 4.57 | s | 7.43 | h | 4.00 | n | 1.14 | | | | | | | | |
| z | 3.26 | s | 31.27 | b | 25.90 | h | 11.07 | t | 2.12 | g | 8.31 | n | 2.61 | m | 3.26 | S | 3.91 | c | 8.31 |
| r | 54.49 | g | 14.17 | s | 5.98 | h | 2.21 | g | 14.17 | b | 2.99 | n | 2.99 | w | 2.99 | | | | |
| p | 35.50 | t | 26.40 | k | 23.93 | s | 12.74 | h | 1.43 | | | | | | | | | | |
| t | 30.22 | p | 24.57 | k | 21.45 | s | 15.46 | h | 0.46 | b | 0.35 | d | 0.12 | y | 7.38 | | | | |
| k | 24.95 | s | 20.08 | t | 19.98 | p | 10.25 | c | 22.73 | h | 2.01 | | | | | | | | |
| h | 57.48 | s | 21.26 | g | 5.66 | n | 10.31 | m | 1.38 | w | 3.90 | | | | | | | | |
| s | 77.54 | f | 13.16 | p | 4.61 | b | 2.35 | g | 0.75 | h | 0.75 | d | 0.28 | t | 0.28 | k | 0.28 | | |
| S | 59.84 | s | 14.63 | f | 7.37 | h | 4.34 | c | 6.46 | z | 0.91 | c | 6.46 | | | | | | |
| f | 56.42 | t | 0.25 | s | 20.86 | n | 10.12 | m | 1.36 | g | 5.56 | z | 1.11 | r | 0.49 | w | 3.83 | | |
| c | 88.20 | p | 3.76 | y | 4.61 | s | 1.82 | h | 1.61 | | | | | | | | | | |

図9 誤り発生の割合

一般化率 0.3, 0.4, 0.5 とした時の精度を図Xに網羅率を図Xに示す。図中の閾値とは、マッチングアルゴリズムの節で述べたもので、閾値を越える一致度を持つパスが確定、分割の操作の対象となる。

### 5.4 考察

本手法では、比較的少ないキーワードとその共起単語を復元の上位の段階で当てはめることを想定している。従って上位の段階での誤復元は、下位の段階での処理に大きく影響すると考えられる。今回の実験では、閾値をある程度大きくしなければ、誤復元が避けられないこと、さらに、そのような閾値を選んだ場合、網羅率が小さく、下位の段階での復元処理の負担が大きくなることがわかった。誤復元を少なくするためには、精度良い認識情報の抽出が必要であるが、今回用いた認識情報の抽出手法は、精度の面で満足できるものではなく、この部分の改良によって、誤復元率の改善が見込まれる。

一般化率が復元に与える影響は、キーワードの数が多くなった場合に顕著になると考えられるが、今回行なった実験では大きな特徴の差は見られなかった。

## 6 まとめ

本稿では、キーワードとその共起単語を文書の表層レベルから抽出する手法を述べ、そのキーワードと共起単語を誤りを含む音素列に適用したシステムの作成をおこなった。今後の課題としては、大量の実験により、キーワードとその共起単語の有効性を確認すること、精度の良い認識情報の抽出法、また、下位の処理過程をも含めた総合的な復元システムの構築が上げられる。

## 参考文献


[1] 荒木、宮永、栃内：多段階分割復元法による誤りの多い文字列からの原文の復元。情報処理学会論文誌 Vol.30,No2,pp169-178(1989).

[2] 今井、古市：連続音声の音素的単位へのセグメンテーション。電子情報通信学会論文誌 D-II, No1, pp11-21(1989).

[3] 潤潟、荒木、宮永、栃内：表層より得られる単語共起関係とその評価。情処研報 Vol.90, No.93 自然言語処理 80-2.(1990).

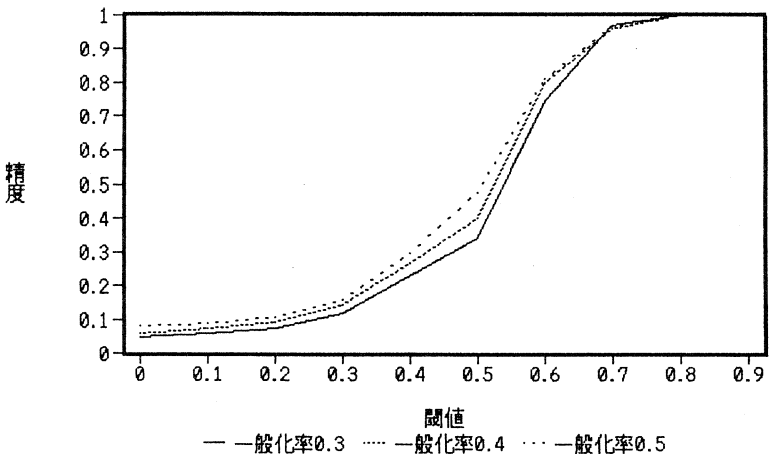




図 12 一般化率と精度

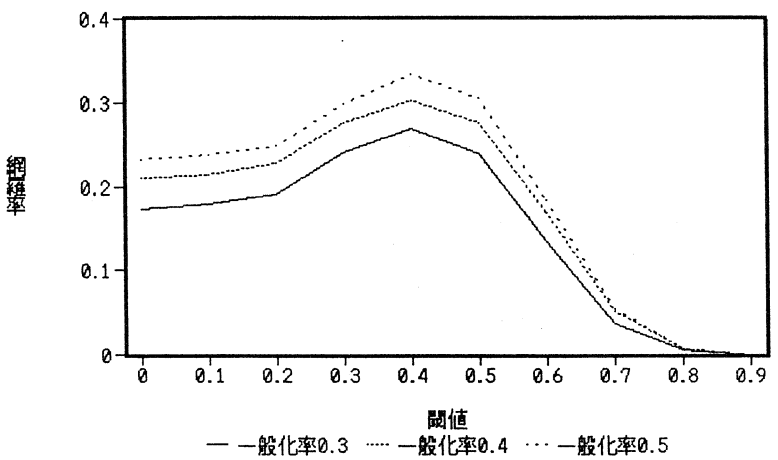



図 13 一般化率と網羅率