357自然言語処理における実験用文書データの取得および保存について

堤 正勝[†]　荒木 健治[††]　宮永 喜一[†]　栃内 香次[†]
[†] 北海道大学　[††] 北海学園大学

1　まえがき

現在われわれの研究室では、誤りを含む文字列、特に連続音声認識によって得られたものを対象とし、その誤りを計算機により自動修正を行い、正しい文章を復元する手法を研究している。　この研究では提案した手法に対して実験によって有効性の裏付けを取る必要がある。特に現在行っている手法は統計的手法であるため、大量の文書データを用いることが要求され、データ取得に際して多大な労力を要する。　本稿では、このようなデータ取得の作業を如何に効率よく行うかに関して述べる。

2　対象となる実験の方法

まず、対象としている作業の方法を示す。

実験は音声認識により得られる誤りを含む音素列を、辞書などを用いて復元処理を行い、結果として、かな漢字混じり文を得るものである。この文を正しいテキストと比較し、復元率を求め、有効性の指標とする。ここで用いるデータは大きくわけて二つである。

一つは、辞書や統計データを作成するための文書データであり形態素解析がなされていることが望ましい。また、漢字かな混じり文を結果として出力するための辞書であるからローマ字と単語が対になっている必要がある。

もう一つは連続音声認識の結果の誤りを含む文字列からなるテキストである。こちらは実際の音声認識の結果を用いて実験を行うことが望まれるが、現在のところ、そのようなデータを大量に取得することは困難である。そこではじめのデータから、ローマ字表記の部分だけ取り出して、べた書きローマ字テキストとし、これを音素列と見なし、ある一定の傾向に従って誤らせたシミュレーション用データを作成する。

現段階では音声認識の結果としてどのような形式のものが得られるかは未定であるが、どのような形式にせよ、誤りを含む音素列、或いはラチスの形式で得られれば本質的には問題はない。

そこで問題は如何にして上述の文書データを取得するかに絞られる。

3　文書データの取得

近年のマイクロエレクトロニクス革命により、情報の取得、特にテキストデータの取得は容易になってきている。しかしながら自分のニーズに適うデータを見出すのは現在でも非常に困難である。

本研究で必要としている文書データは文書そのものとその読みがペアで取得されねばならない。このため読みの一定していない記号などが含まれるテキストは、本質的でない処理を多数記述しなければならず、好ましくない。また、得られる文書データには読みや形態素分割などといった処理は施されていないのが普通である。

このために、通常はこれらのデータを再編集する必要が生じる。これを自動的に行おうとすると、自分の形態素の定義に基づいた逆引き辞書が必要となるうえに、変換精度１００％を得るのは困難であるので最終的には目視によりチェックする必要がある。

辞書がない場合にはエディタを用いて編集しなければならない。ところが人手による入力には形態素の定義のゆれなどが生じるためこれも必ずしも好ましいとは言い難い。このため所定の形式の文書を作成するための専用エディタが必要になる。このエディタについては現在作成中であり、上記の二つの目的（再編集、新規入力の機能）への対応を特徴としている。

4　保存用文書

上記のようにして得られた文書データは日本語処理に関する他の研究、例えば日英翻訳などにも使用することが容易であるという利点があり、一定の形式を定めて、実験用保存文書形式として定義している。各形態素の表現形式を以下に示す。

形態素のフォーマット：
（読み／漢字／属性／その他）

このフォーマットを繰り返すことによりテキストを構成する。各実験においてはこの文書から必要な部分を取り出してそれぞれの目的にあったデータを作成する。辞書もこのデータを集めてソーティングすることにより作成する。

5　形態素の定義

最後に形態素の定義について述る。計算機で処理することを考えると、学校文法で用いられている品詞をそのまま扱うのは必ずしも効率的とはいい難い。そこで文献 [1],[2] を考慮し、さらに助述表現に関しても、子音で区切ることにする。

例：そのようなことが考えられる。
(sono)(you)(na)(koto)(ga)
(kangaw)(er)(ar)(er)(u)(.)
————：助述表現

この形態素定義がどのくらい有用であるかを確認する作業を現在行っている。

6　あとがき

今後の予定および課題としては、専用エディタの完成と上記形態素分割の有用性、さらに各種文書処理ツールの作成を予定している。また、このような形態素定義に基づき、多段階分割復元法 [3] に、動詞拡張処理を追加することによりさらなる有用性の確認をしたいと考えている。

参考文献

[1] 久光 徹、新田 義彦: " 漢字かな混じり文形態素解析における非サ変動詞の分割単位設定に関して", 情報処理,Vol.33,No.2,pp.159-167(1991).

[2] 小松 英雄: " 日本語の世界 7 『日本語の音韻』", 中央公論社 (1981).

[3] 荒木 健治、宮永 喜一、栃内 香次: " 多段階分割復元法による誤りの多い文字列からの原文の復元", 情報処理,Vol.30,No.2,pp.169-178(1989).