358 帰納的学習によるべた書き文のかな漢字変換における尤度の評価について

高橋祐治 荒木健治 桃内佳雄
北海学園大学工学部

1．はじめに

日本語を計算機に入力する手段として現在、べた書き文のかな漢字変換方式が主流となっている[1]。この方式は利用者の負担を軽減させるが、一方では辞書作成の労力、未登録語の処理、変換精度、専門用語への対応などに依然として問題が残されている。

そこで、我々は、これまでこれらの問題を解決する1つの手法としてべた書き文とその正しい変換結果である漢字かな混じり文から帰納的に語を学習し確実性の高い順に変換を行う手法を提案してきた[2]。本手法は、人間が未知の読みとその表記から語を獲得し、その獲得した語を用いてかな漢字変換を行う過程に基づいている。これまでの実験により、本手法の有効性が確認されている[2]。しかし、単語候補の尤度を決定する評価関数の係数、削除条件及び評価開始値については、十分な検討が行われていなかった。そこで、本稿では、これらの値について実験を行い、各値を決定した結果について述べる。

2．システム概要

処理の流れを図1に示す。

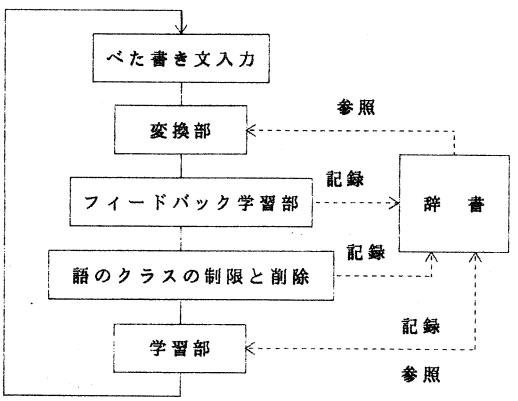


図1　処理の流れ

辞書中に存在する語は、その抽出状況や変換率により、MS，CP，S1，RSの4つのクラスに分類されている。辞書のクラスの分類を図2に示す。

MS：(Most cirtain Segment)
　CPであり、かつ95％以上の正変換率の語
CP：(Common Pattern)
　辞書の各クラスの語について共通部分抽出により取り出される語であり、95％未満の正変換率の語
S1：(Segment One)
　漢字かな混じり文とその読みから獲得した語
RS：(Remain Segment)
　CPの抽出の際に差異部分になった語

図2　辞書のクラスの分類

最初に、べた書き文とその正しい変換結果より学習部で文字の変化部分と不変化部分を比較することにより語を獲得する。この段階で抽出された語をS1と呼ぶ。語の獲得の例を図2に示す。

1．読み：われわれはしゅじゅのほうほうをおこなった
2．表記：我々は種々の方法を行った
3．抽出結果（S1）
　われわれ→我々，は→は，しゅじゅ→種々
　の→の，ほうほう→方法，を→を，おこな→行った→った

図2　語の獲得の例

獲得された語は、複数個の語を含む場合があるので、表記が2文字以上場合に、さらに共通部分と差異部分に分ける処理を施す。その例を図3に示す。

れんぞくおんせい：連続音声
おんせい　　：音声
↓
れんぞく：連続（RS）
おんせい：音声（CP）

図3　共通部分と差異部分による語の獲得

このように獲得された語を辞書として用いて、べた書き文を変換部へと渡す。変換部では、学習部での語の獲得の状況やフィードバック学習による語の精度によって確実性の高い語からMS，CP，S1，RSの順に当てはめを行う。次に、変換結果であるかな漢字混じり文の正誤の判断を行う。従来までの正誤の判定は人手で行っていたが、高速化と確実性向上のため、正しい漢字かな混じり文の1つ1つの表記に対して、それに対応するべた書き表記の文字数をテーブルとして保持し、表記に対する読みの文字数を計算することにより文字列を比較するという方法により、正誤判定を自動的に行う。なお、誤りがある場合には修正を行う。そして、変換結果と正しい変換結果の比較を行い、語の正誤認識度数を更新する。語のクラスの制限及び削除条件値未満の語の削除を行う。

4．　尤度評価方法

4．1　正変換率による語の削除の定義

辞書の各語には、出現度数AF（Appearance Frequency)、正認識度数CF（Correctness Frequency)、誤認識度数EF（Error Frequency）が付加されており、各々、学習部やフィードバック学習部で更新される。本手法では、語の正変換率を算出し、その値が一定条件値より落ちると辞書の語の削除を行う。ここで、この一定条件値を削除条件と呼ぶ。その評価は、CF＋EFの値が一定の値以上の時に開始することになっている。この値を評価開始値という。以下に正変換率

ＣＲ（Correct Rate）の定義を示す。

$$CR = \frac{CF}{CF+EF} \times 100$$

４．２　尤度評価関数ＥＶ

変換部において、単語候補が重複する場合には、先にこの尤度評価関数の値が最大の語を選択し語を決定している。αは、正認識度数ＣＦに対する重み係数、βは、誤認識度数ＥＦに対する重み係数である。このα、βの値によって語候補の重複の際に決定される語群が変化するので係数値の決定は重要な問題である。以下に尤度評価関数を示す。

$$EV = AF + \alpha * CF - \beta * EF$$

（ただし、α，βは係数）

５．　実　　験

５．１　実験方法と結果

本手法に基づく実験システムをＶＡＸ８５５０上で作成し評価実験を行った。この実験は、尤度評価関数α、βおよび辞書の語の削除条件、評価開始値の各々の値を決定するものである。ここで、βはαに対する重みとして作用することからα＝２で固定した。実験方法は、評価開始値及び削除条件という２つのパラメータを固定し、βの値を変化させて極大値を決定する。また、評価開始値は、ＣＦ＋ＥＦ＝３、５、１０の場合について行った。辞書の初期状態は、空である。評価実験には、情報処理学会論文誌より５編（漢字かな混じり文表記で４４，２０６文字）を用いた。その資料を表１に示す。また、実験結果を表２に示す。

表１　実験資料

出典：情報処理学会論文誌，Vol.23，No.1～4

著者名	論文題目と総文字数
前島ほか	高集積マイクロコンピュータに適したマイクロプログラム制御方式（１０９４６）
山本ほか	COBOLマシンとその設計思想-ハードウェア構成について　（８１８４）
松山ほか	フーリエ変換を用いたテクスチュアの構造解析　（７５１７）
木　村	日本語入力用カタナカ語検出規則とオンライン国語辞典の一分析　（８４８５）
有　田	インテリジェント・コンソール-ＯＳの機能拡張の一方法　（９０７４）

５．２　考　　察

実験結果から評価開始値と削除条件を固定した場合、変換率の推移を見ると、極大値が存在していることがわかる。評価開始値５の場合は、実験結果に示すように、β＝２１、辞書の語の削除条件５０％の時に変換率が最大となった。また、評価開始値１０の場合は、遅い段階で評価が開始されるので、削除条件が６０％という高い条件でないと、辞書の活性化が図れないことがよくわかる。これは、評価開始値を１０よりも大きい値にしても高い変換率は得られないと考えられる。最後に評価開始値３の場合は、１０の場合とは反対に早い段階で、評価が始まることから、４０％という比較的低い削除条件の時に、変換率が最大となった。また、実験は、評価開始値を離散的な値を用いて行ったが、結果として、大半が８４％台と大きな変化はなかったので、実験は、変換率が高くなる決定することが目的であり、これ以上の実験は行わないものとした。

上述した結果から、係数は、評価開始値３、削除条件４０％、α＝２、β＝２８と決定された。この結果は、評価の開始値が３なので、正しい辞書中の語をも誤って削除してしまう恐れがある。正しい辞書の語を削除した場合の対処方法としては、現在ある４つの辞書の階層に、削除された語を格納するもう一つの階層を増設し、その語を最後の段階で使用し、正しく使用された語を上位の階層へ復帰させる方法が考えられる。また、辞書の語数も、３，５７４語であった。これは、学習の状態が進んでいる事を示しており、語の重複が頻繁に生じやすい状態で実験を行っているので、この実験結果が定常状態での最適値に近い値を示していると考えられる。

表２　実験結果

評価開始値	削除条件	β	変換率
3	４０％	１３	８４．５９％
		１５	８４．６７％
		１８	８４．７８％
		２０	８４．８０％
		２２	８４．８０％
		２５	８４．８１％
		２６	８４．７９％
		２７	８４．８１％
		２８	８４．８３％
		２９	８４．８２％
		３０	８４．８０％
	５０％	１３	８４．５８％
	６０％	１３	８４．４３％
5	４０％	１２	８４．３０％
		１３	８４．３４％
	５０％	１２	８４．３３％
		１３	８４．３６％
		１４	８４．４２％
		１５	８４．４７％
		１６	８４．５２％
		１８	８４．５９％
		２０	８４．６２％
		２１	８４．６３％
		２２	８４．６１％
		２４	８４．４７％
		２５	８４．５３％
		３０	８４．５４％
	６０％	１０	８３．９９％
		１１	８４．１１％
		１２	８４．１６％
		１３	８４．１８％
	７０％	８	８３．９０％
10	４０％	１５	８４．１５％
		１７	８４．２１％
	５０％	１３	８４．０８％
		１４	８４．１８％
		１５	８３．２４％
		１６	８３．７４％
	６０％	１３	８４．１０％
		１４	８４．１３％
		１５	８４．１６％
		１６	８４．２１％
		１８	８４．２５％
		１９	８４．３０％
		２０	８４．３２％
		２１	８４．３３％
		２２	８４．３１％
		２３	８４．２９％

６．おわりに

実験結果から、各係数の値が決定した。今後は、この実験結果を基に、本手法の改良を行い、大量データによる性能評価実験を行う予定である。

謝　　辞

実験の遂行にあたり、本学國在学中種々の討論及び協力をしていただいた現㈱ＮＥＣ　佐藤隆之氏、現㈱デービーソフト　富居広樹氏に感謝いたします。

＊参考文献

１）長尾：日本語情報処理，電子情報通信学会(1984).
２）荒木，栃内：機能的学習によるべた書き文のかな漢字変換，電子情報学会技術研究報告，pp.9-16 (1991).