370　帰納的学習による翻訳手法の実用性評価

内山　智正[†]　荒木　健治[††]　北海道大学[†]
宮永　喜一[†]　栃内　香次[†]　北海学園大学[††]

1．はじめに

これまでに提案された機械翻訳システムの翻訳手法[1,2]の多くが、文法解析による翻訳、つまり解析主導型機械翻訳を採用している。この種の翻訳手法では、多数の言語学的知見により、構文解析処理、意味解析処理を行ない、これらに適した翻訳辞書を必要とする。しかし、このような解析主導型機械翻訳の問題点として、個々の言語現象の性質の多様性、規則の多さ、例外の多さ等、規則による言語現象の記述の難しさが挙げられる。そしてそのため、システム処理が複雑なものとなり、使用している知識表現の拡張が困難であること、既存モジュールへの副作用があること等、首尾一貫した処理の枠組みを確立することが困難であった。

上記の問題点を解決するため、実例に基づいた翻訳[3]、用例に基づいた翻訳[4]、変換主導型機械翻訳[5]など従来の翻訳方法とは異なる新しい翻訳方法が研究されている。これらの翻訳手法は、実例や用例などの変換知識を利用した高品質の翻訳を目的とし、変換プロセスに重点が置かれているが、精度と処理速度という点では問題が多く存在する。

本稿は後者の立場に立ち、帰納的学習に基づく多段階共通パターン抽出法[6]に基づく実験システムを作成し、実用性の評価実験を行なった結果について述べる。

2．処理過程

本手法は、翻訳例から帰納的学習により翻訳知識を獲得し、良質な翻訳結果を得ようというものである。翻訳例をもとに、その差異部分・共通部分を見出し、翻訳に利用する。本手法に基づく翻訳システムは、翻訳例をもとにしているため慣用句表現に強く、一度翻訳された翻訳結果により学習を行なうため、次々と翻訳知識が追加されていくという利点がある。そのため、対象分野の変化に適応可能である。また、翻訳結果により、フィードバック学習を行ない、次回の翻訳の精度を向上させている。図1に、処理の流れを示す。

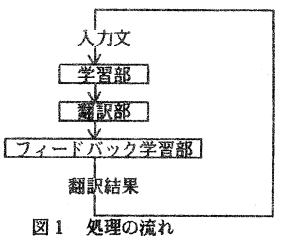


図1　処理の流れ

2．1　学習部

学習時にルール辞書を作成する規則を、以下の例文で説明する。

This is a pen.　　これ／は／ペン／です。
This is a book.　　これ／は／本／です。

この2文を比較し、英文と日本文の差異部分を抜き出してルールとする。また、残りの部分つまり共通部分には差異部分であったところに変数部分を表す'@'をつけてルールとする。この結果、以下のような辞書データが得られる。

pen　　ペン
book　　本
This is a @.　　これ／は／@／です。

学習部は、翻訳を行なうための辞書を作成する部分であり、その翻訳辞書を以後ルール辞書と呼ぶことにする。すなわち、学習は英文と日本文の対訳とルールを比較し、差異部分を抜き出す処理を基本としている。学習部で作成された差異部分の対、またその差異部分を変数とした共通部分の対の一つ一つをルールと呼ぶ。

新規に入力された学習文をルール辞書のルールすべてと比較して、共通部分・差異部分をルールとして登録する。また、差異部分を抜き出す前の学習文も、そのままルールとして登録する。次に、抽出されたルールをルール辞書と比較し、共通部分・差異部分が抽出されなくなるまで繰り返す。また、比較処理を行う前に、学習文とルールの単語数が一致していない場合に単語数を一致させるため、ルールの変数部に他のルールの代入を行なう。このとき、ルールの組み合わせの深さ（回数）により、一致する割合に制限を設けている。この制限値Xの決定は以下の式によっている。

$$X_n = (X_{n-1} + 100) / 2 \qquad (X_0 = 0)$$

そして、学習文とルールを組み合わせたルールの単語が一致している割合が、その制限値X以上になる場合に学習を行なう。

2．2　翻訳部

翻訳部では、学習部で作成されたルール辞書を用いて翻訳文を作成する。ここで訳文は、ルール辞書の組み合わせにより作成される。作成された組み合わせの順番に、ルールの対を変数部分に代入させると目的の翻訳文となる。翻訳文は一つの入力文に対して、複数作成されることがあるので、フィードバックデータをもとに一意に決定する。

未登録単語処理は、基本となるルール（翻訳文全体にまたがるルール）が存在し、その文内の単語がルール辞書内に存在しない場合に、入力文内の未登録単語をそのまま翻訳文に使用するものである。但し、未登録単語の語数が余りに多いと翻訳文としての意味をなさないため、未登録語単語数は最大2とする。

フィードバックデータは、翻訳結果に対して利用者が正誤の判断を行なった結果により作成・更新される。フィードバックデータは、使用ルール番号と正翻訳度数と誤翻訳度数をひとまとめとした要素と、その要素の個数、使用回数からなっていて、フィードバックデータはルールとルールの間の関係を示している。次に、翻訳の処理手順を以下に示す。

（1）初期値設定
検索の対象とするルールの階層を0階層（原文）に設定し、入力文を受け取る。

（2）適用可能ルールの選出
検索対照としている階層上の全てのルールを検索し終わるまで検索を繰り返す。検索したルールが、入力文に対して適用可能なルールならば保持する。先に述べた学習部で、ルール辞書の変数の数ごとに階層を作成してある。

ルール辞書全てを検索し終わっても、翻訳結果が得られない場合は、未登録単語処理へ行く。

（3）適用可能ルールの組み合わせ作成
ルールの組み合わせで変数部が消去できる場合は、（4）へ行く。まだ変数部が残る場合は、適用可能なルールを保持したまま、次の階層に設定し、（2）へ行く。

（4）翻訳順位の決定
以下の方法で翻訳文を並べ換える。
①未登録単語数が最小
②適合度Sが最大
③正翻訳度数が最大
④誤翻訳度数が最小
⑤上から順番
ここで、適合度Sは、次式でに定義されている。

$$S = \alpha \cdot (\text{正翻訳度数}) - \beta \cdot (\text{誤翻訳度数}) + (\text{使用回数}) \qquad (\alpha, \beta \text{は任意定数})$$

（5）翻訳終了

3．性能評価実験

3．1　実験方法

中学１年用教科書ガイド・ワンワールド[7]に掲載されている全例文を、各章ごとに順次学習させる。この学習結果を初期辞書として翻訳実験を行なった。

次に中学１年用教科書ガイド・ニューホライズン[8]に載っている全英文を、各章ごとに翻訳させた。そのとき、翻訳結果に誤りがあれば、全てニューホライズンに掲載されている日本文になるように修正した。また、未登録単語処理で得た単語は、意味的に通じる限り訳を与えた。そして、その翻訳した章の対訳、未登録単語で得た対訳を学習して次の章の翻訳実験を行なった。そのとき、翻訳、学習に要したＣＰＵ時間を記録した。使用した計算機はＶＡＸ８５５０である。

３．２　実験結果と考察

３．２．１　翻訳率

全入力文は８４１文で、表１のような結果が得られた。この中で実際に使用可能な訳文は、正翻訳、意味的、未登録であり、全体の５３．４%となっている。ここで、正しい翻訳結果を正翻訳、誤った翻訳結果を誤翻訳、文の意味が通じるが表層文が異なるものを意味的、未登録語を含むものを未登録、翻訳できなかったものを不翻訳と呼ぶ。

表１　翻訳率

使用可能な翻訳	正翻訳	２７６文　（３２．８%）
	意味的	２３文　（２．８%）
	未登録	１５０文　（１７．８%）
使用不可能な翻訳	未登録	７１文　（８．５%）
	誤翻訳	２８文　（３．３%）
	不翻訳	２９３文　（３４．８%）
	合計	８４１文

各章ごとの翻訳結果の推移を見ると、最初は未登録語が多かったが、章を重ねるにつれ減少した。未登録語の出現率を図２に示す。未知語は、従来の翻訳システムの大きな問題であったが、本手法では一度未知語が現れても、学習を行なうことにより、未知語を減少させることができた。また、不翻訳となる場合には以下の２つの場合があった。一つは入力文に対してその入力文すべてを含むルールが存在しない場合である。本手法では、全体の位置関係を示すルールが存在しなくては翻訳できない。次は入力文すべてを含むルールは存在するが、未登録単語処理のところで、未登録単語の単語数が３以上となり不翻訳となる場合である。これらの不翻訳を回避するためには、より多数の文を学習させる必要がある。

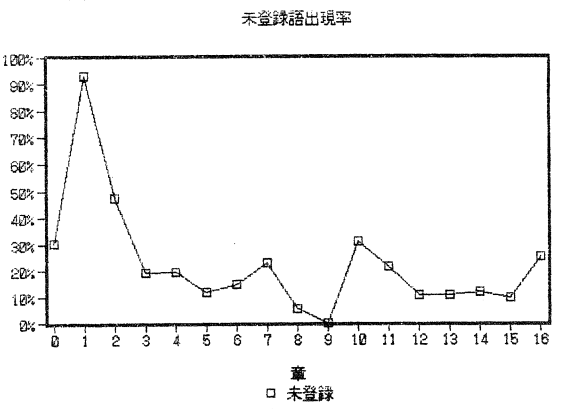


図２　未登録語の出現率の推移

３．２．２　処理時間

全１７章を翻訳・学習した際にかかったＣＰＵ時間を表２に示す。翻訳時にかかるＣＰＵ時間は、１文平均約１８秒であった。また、学習時にかかるＣＰＵ時間は、１文平均約２分であった。

今後、実験を続ける際に、ルール辞書の大容量化は避けられない。従って、翻訳・学習時における辞書検索に時間がかかり、翻訳時間・学習時間が増大していく。この問題を解決するため、辞書検索の高速化、ルール辞書の索引化、特に学習条件の細分化などが必要である。

５．おわりに

本手法は良質な翻訳結果が得られ、利用者の負担の減少が可能で、拡張性に富む手法として提案された。しかし、翻訳率の精度はまだ高いと言えず、学習方法・翻訳方法の改良が必要である。本稿では中学１年生の教科書を用いて実験を行なったが、今後は高校３年生までの教科書による実験を行なう予定である。

表２　処理時間

章	文の数	正翻訳	意味的	未登録	誤翻訳	不翻訳	翻訳時間	学習時間	平均翻訳時間	平均学習時間
０章	２３文	２	１	９		１１	:03:49.80	0:43:46.77	９．９９秒	１１４．２秒
１章	１４文	１		１３			:03:16.97	0:48:17.54	１４．０７秒	２０６．９秒
２章	１９文	９		９		１	:02:53.21	0:50:07.79	９．１２秒	１５８．３秒
３章	３１文	１２		１１		８	:05:49.19	0:51:37.95	１１．２６秒	９９．９秒
４章	４１文	２２	２	１２	２	３	:09:03.78	0:54:40.61	１３．２６秒	８０．０秒
５章	７７文	４２	２	１３	９	１１	:18:38.98	0:57:20.11	１４．５３秒	４４．６秒
６章	４７文	１９		１６		１２	:11:09.88	0:58:48.85	１４．２５秒	７５．０秒
７章	３５文	８	２	１２		１３	:10:30.99	1:00:13.07	１８．０３秒	１０３．２秒
８章	９２文	２０	８	１２	５	４７	:33:40.14	0:53:05.91	２１．９６秒	３４．６秒
９章	３２文	７	２	１	２	２０	:13:23.51	1:17:10.38	２５．１１秒	１４４．７秒
１０章	１０３文	３９	４	４５	２	１３	:24:14.64	2:18:12.88	１４．１２秒	８０．５秒
１１章	５６文	１５	２	１５	２	２２	:15:20.54	1:36:01.30	１６．４４秒	１０２．８秒
１２章	９２文	２９		１４	２	４７	:23:21.54	2:08:10.63	１５．２３秒	８３．５秒
１３章	４６文	８		１０	１	２７	:20:06.92	1:45:22.99	２６．２４秒	１３７．４秒
１４章	５９文	１７		１５		２７	:27:35.98	1:53:50.66	２８．０７秒	１１５．７秒
１５章	４２文	１０		６	２	２４	:27:31.25	1:59:04.27	３９．３２秒	１７０．１秒
１６章	３２文	１６		８	１	７	:06:17.79	2:01:34.75	１１．８１秒	２２７．９秒
	８４１文	２７６	２３	２２１	２８	２９３	------	------	１８．３１秒	１６６．４秒

参考文献
（１）辻井純一：機械翻訳システム、スペクトラム，Vol.11，pp.48-57(1988).
（２）上田良寛：タイプ付き素性構造主導型生成、情報処理学会論文誌，Vol.33，No.1，pp.28-35(1992).
（３）佐藤理史：ＭＢＴ２：実例に基づく翻訳における複数翻訳例の組合せ利用、人工知能学会誌，Vol.6，pp.861-871(1991).
（４）隅田英一郎、飯田仁、幸山秀雄：用例に基づいた翻訳、情報処理学会第４０回全国大会講演論文集，pp.411-412(1990).
（５）古瀬蔵、隅田英一郎、飯田仁：変換主導型機械翻訳の実現手法、情報処理学会研究報告，Vol.90，No.93，pp.1-8(1990).
（６）荒木健治、栃内香次：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳、情報処理北海道シンポジウム講演論文集，pp.412(1991).
（７）教科書ガイド教育出版版ワンワールド１、日本教材、東京(1991).
（８）教科書ガイド東京書籍版ニューホライズン１、あすとろ出版、東京(1991).