373　文章からの自動話題抽出手法の検討

亘理　克好[†]　荒木　健治[††]　宮永　喜一[†]　栃内　香次[†]
[†] 北海道大学　[††] 北海学園大学

1　はじめに

要約(抄録、あらすじ)自動生成の手法は、これまでにいくつか提案されている。これらの手法には、表層的なものから深層的なものまでさまざまなものがある[1][2][3]。また、話題抽出については、談話を話題という側面からとらえたものがある[4]。しかし、直接に文章の話題を抽出するものについては、これまで十分に研究されているとは言えない。そこで、我々は文章から話題を自動的に抽出するシステムの構築を考えている。今回は、基本方針と、人間の話題抽出機構の調査結果について報告する。

2　基本方針

本研究では、話題を求める範囲として、段落(形式段落、意味段落)ごとを想定している。また、対象とする文章は、比較的やさしい説明文(論説文)を考えている。

本稿では、自動話題抽出のアルゴリズムを構築するために、まず人間が話題をどの様にして決定しているのかを実験により考察した。

3　話題抽出実験

3.1　実験方法

実験に用いた文章は、小学校四年生の国語の教科書の一部(説明文)(1640 文字、54 文、15 段落)[5] である。実験の被験者は四人の工学部の大学院生(24 歳男 1 人、23 歳男 2 人、22 歳男 1 人)である。形式段落と意味段落のそれぞれを単位として話題を抽出した。ここで意味段落の範囲は、市販の教科書ガイド[6]によった。被験者には、話題と思われるもの、およびその理由をなるべく自由に記述させ、その結果を比較した。さらに、上記教科書ガイドに記載されている該当部分の話題とも比較した。なお、話題抽出の際の制約は、「なるべく、名詞句で。」というもののみである。

3.2　実験結果と考察

抽出した結果を見ると、全被験者が似たような話題を抽出するところと、異なるところがある。また、話題の抽出理由をまとめると、次のようになる。

(1) 単語の頻度などの情報の利用
　多くの文に見られる単語。(単語の頻度)
　特定の接続詞(「今度は」「ですから」等)がある文中の単語。
(2) 文間の情報の利用
　核となる文がある。
　文章の構造、流れを考える。
(3) 段落間の情報の利用
　前の段落からの受け、前の段落との関係を考える。

これらの三つを見ると、抜けているものがある。それは語間の情報であり、理由としてあげられていない。しかし、人間は無意識のうちにこの情報も使っていると考えられる。そこで、以下に示すもう一つの理由を仮定する。

(4) 語間の情報の利用
　修飾関係の情報。

4　アルゴリズム

上記の四つの理由を参考にし、表層レベルで行なえる話題抽出手法を提案する。この手法を以下に示す。

(1) 出現頻度の高い単語は話題である可能性が高い。
(2) 始めの文か終りの文が核の文である可能性が高く、話題が含まれている可能性が高い。
(3) 特定の単語(「今度は」「ですから」等)がある場合は、その文が重要であると考え、その文から話題が得られる可能性が高い。以下に例を示す。
　例:「今度は、においのしない花—プラスチックの造花を用意してみました。色は、花だんのときと同じ赤、黄、むらさき、青の四種類です。」
　話題: においのしない花、プラスチックの造花で実験、もう一つの実験、準備
(4) ある文に含まれる単語が、次の文に含まれるとき、一方は他方の上下関係にあると考えられ、後の文が前の文の補足説明をしている可能性が高い。つまり、前の文から話題が得られる可能性が高い。以下に例を示す。
　例:「実験は、花だんのまわりで始まりました。花だんには、赤、黄、むらさき、青と、四種類の色の花がさいています。少しはなれた所で、生まれてから花を見たことのないもんしろちょうを、いっせいに放すのです。すると、どういうことが起こるでしょう。」
　話題: 花だんを使った実験、花だん、四種類の色、実験の場所、実験手法
(5) 述語の流れを考え、文の流れをつかむ(特定のフレーズ)。そこから話題を導く。以下に例を示す。
　例:「実験には、たくさんのもんしろちょうが必要です。一度に百ぴき、二百ぴきというもんしろちょうを、いろいろな場所で放してやり、花をさがす様子をえい画のカメラで記録して、くわしく観察するためです。キャベツをえさに青虫を育て、一万ぴきものもんしろちょうを用意しました。」
　話題: 実験準備、方法、もんしろちょうの準備、観察

これらのアルゴリズムに基づき、システムを構築する予定である。

5　おわりに

文章から話題を自動的に抽出する手法の構築を考えている。その前段階として、人間の話題抽出実験を行ない、そのアルゴリズムについて考察した。

今後は、上述したアルゴリズムを実現し、アルゴリズムの評価を行なう予定である。またさらに、より深層的な部分のアルゴリズムの検討を行なう予定である。

参考文献

[1] 喜多壮太郎:説明文を要約するシステム, 情報処理学会研究報告 63-NL-6,pp.41-48(1987).
[2] 安原宏, 小松英二, 日比孝, 加藤安彦:要約支援システム COGITO, 情報処理,Vol.30,No.10,pp.1258-1267(1989).
[3] 中澤俊哉, 重永実:エピソードネットワークを用いた物語のあらすじ生成, 情報処理学会論文誌,Vol.32,No.10,pp.1215-1224(1991).
[4] 竹下　敦:表層的処理による話題抽出, 情報処理学会研究報告 83-NL-4,pp.23-30(1991).
[5] 吉原順平:花を見つける手がかり, 新版国語 4 上 (pp.50-57), 教育出版 (東京)(1992).
[6] 教科書ガイド小学国語 4 年上教育出版版, 新興出版社 (東京)(1992).