D-66

帰納的学習による機械翻訳手法の評価 II

An Evaluation of Machine Translation by Inductive Learning II

内山 智正+ 荒木 健治++ 宮永 喜一+ 栃内 香次+
Norimasa Uchiyama+, Kenji Araki++, Yoshikazu Miyanaga+ and Koji Tochinai+
+北海道大学工学部電子工学科
++北海学園大学工学部電子情報工学科
+Department of Electronic Engineering, Hokkaido University
++Department of Electronics and Information Engineering, Hokkai-Gakuen University

1．はじめに

我々は帰納的学習による機械翻訳手法を提案し、実験システムの構築を行なっている[1)]。そして、これまで本手法の利点と問題点を明らかにすることを目的とした性能評価実験[2) 3)]を行なってきた。本稿では、上記実験結果に基づきシステムの改良を行ない、評価実験を行なった結果について述べる。

2．処理過程

我々が先に提案した帰納的学習に基づく機械翻訳手法[1)]は、学習部により翻訳例から差異部分と共通部分を多段階に抽出し、次いで具象的ルールから抽象的ルールへと翻訳ルールを抽出し、翻訳辞書を構築していくものである。翻訳部では、具象的ルールより順に翻訳ルールを適用し翻訳を行なう。その後、翻訳された結果の正誤を利用者が判断し、フィードバック学習を行ない、次回の翻訳の精度を向上させる。我々は、このような手法を多段階共通パターン抽出法[1)]と呼んでいる。図1に、処理の流れを示す。

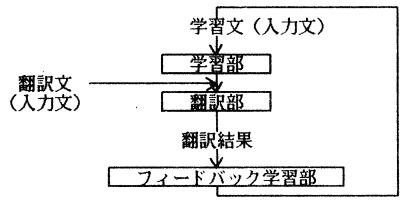


図1 処理の流れ

3．学習例

学習処理で翻訳ルールを獲得する具体的な例を、以下の例文で説明する。

This is a pen. これ／は／ペン／です。
This is a book. これ／は／本／です。

この2つの対訳を比較し、英文と日本文の差異部分を抜き出して翻訳ルールとする。また、共通部分には差異部分であったところに変数部分を表す'@'をつけて翻訳ルールとする。このとき、過剰な抽象化は誤った学習を引き起こしたり、翻訳処理における翻訳ルールの適用が膨大になる。そこで、抽象化するときの閾値を設けて翻訳ルールにおける変数部分の割合を決定し、学習に制限をつける。この学習の結果、以下のような翻訳ルールが得られる。

pen ペン
book 本
This is a @. これ／は／@／です。

4．改良点

これまで行なった実験の結果明らかになった問題点を解決するために、以下の改良を行なった。

まず、フィードバック処理によって翻訳結果が誤翻訳となった場合には、その翻訳に使用した翻訳ルールすべてにおける誤翻訳度数を1上げる。そしてある一定回数連続して誤翻訳となった翻訳ルールは以後翻訳処理・学習処理に使用しないようにした。これにより、誤った学習によって得られた誤りを含む翻訳ルールが消去され、あるいは増加しないといった効果が期待される。

次に、疑問文における句点"？"を字面情報として利用し、疑問文とその他の文における学習処理を行なわないようにした。過去の実験により、疑問文と他の文を混在させて学習を行ない得られた翻訳ルールはすべて誤りを含んでいるという経験則に基づいている。

また、実験方法の改良として、従来は処理時間を考慮して100文単位に翻訳・学習を行なっていたものを、学習結果のフィードバックを早くするために、1文ごとに翻訳・学習を行なうようにした。

5．実験方法

実験の初期条件として、翻訳ルールを持たない状態から始めた。中学1年用教科書ガイド・ワンワールド[4)]に掲載されている例文から、英文の翻訳処理を行ない、次にその英文・日本文の対訳を学習させる。この作業を順次1文づつ、1000文繰り返した。学習処理において作成される翻訳ルールの変数部分の割合を、50%以上と50%未満の両方の値で実験を行なった。また、フィードバック学習による翻訳ルールの削除機能の閾値は3とした。

6．実験結果

実験結果を表1に示す。変数部分の割合を50%未満としたときの使用可能な訳文は全体の29．3%、50%以上としたときの使用可能な訳文は全体の40．9%となっている。ここで、正しい翻訳結果を正翻訳、誤った翻訳結果を誤翻訳、未登録語を含むものを未登録、翻訳できなかったものを不翻訳と呼ぶ。未登録は使用可能な未登録と使用不可能な未登録とに分けられる。ここで、使用可能な未登録とは未登録語に訳を与えることにより簡単に正翻訳を導き出せる場合や、未登録語が名詞か、形容詞の場合である。

表1 翻訳率

変数部分の割合		50%未満	50%以上
使用可能な翻訳	正翻訳	18．5%	24．3%
	未登録	10．8%	16．6%
使用不可能な翻訳	未登録	0．6%	1．5%
	誤翻訳	9．2%	16．3%
	不翻訳	60．9%	41．3%

7．考察

実験結果から、変数部分の割合によって翻訳率が大きく変化していることがわかる。それゆえ、今回使用した50%という値が適当であるということはこの実験結果からはいえない。これを明らかにするためには、変数部分の割合50%以上の部分でより詳細な実験が必要である。また、フィードバック学習による翻訳ルールの削除機能については、多数回正翻訳として使用された翻訳ルールでも、たまたま一定回数連続で誤翻訳となれば削除されてしまい、正翻訳として使用されたことがなく、一定回数連続で誤翻訳となった翻訳ルールとの重み付けが同じになってしまう。これは今後、正翻訳度数、誤翻訳度数、使用回数による評価関数を定義し、ある一定の閾値により重み付けをすることにより解決されるものと考えられる。

8．おわりに

翻訳率を見るとまだ実用的なレベルとは言えず、さらに学習手法・翻訳手法の改良が必要である。また、より複雑な文章を用いた実験を行ない、本手法の利点と問題点を明らかにしたい。その上で、本手法の限界を明らかにし、実用的なシステムの開発を進める予定である。

参考文献

（1）荒木健治、栃内香次：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳、情報処理北海道シンポジウム講演論文集，pp.412(1991)．
（2）内山智正、荒木健治、宮永喜一、栃内香次：帰納的学習による翻訳手法の実用性評価、電気関係学会北海道支部連合大会講演論文集,pp.424-425(1992)．
（3）内山智正、荒木健治、宮永喜一、栃内香次：帰納的学習による機械翻訳手法の評価実験、情報処理学会研究報告，Vol.93,No.1,pp.23-30(1993)．
（4）教科書ガイド教育出版版ワンワールド1、日本教材、東京(1991)．