# D-134　帰納的学習による階層的かな漢字変換辞書の構成

## Hierarchical dictionary for Kana-Kanji transformation by inductive learning

高橋 祐治　荒木 健治　桃内 佳雄
Yuuji Takahashi　Kenji Araki　Yoshio Momouchi
北海学園大学
Hokkai-Gakuen University

### 1．はじめに

日本語を計算機に入力する方法として、利用者側に負担が少ないべた書き文入力方式が、現在主流となっている[1]。この方式の核心は、優れたかな漢字変換手法にあり、様々な手法が提案されている。我々もかな漢字変換の1つの手法として、べた書き文とその正しい変換結果である漢字かな混じり文から語の読みと表記の対を帰納的に学習し、確実性の高い語から順に変換を行う手法を提案している[2]。この手法では、確実性の高さに対応した変換処理を効率的に実現するために、4つの階層からなる辞書を構成している。我々は、これまでの実験により、この手法の有効性を確認してきた[3][4]。本稿では、更に変換処理の効率を上げるための一工夫として正変換率の低い語を格納する階層を辞書構成に付加し、利用することの可能性について検討する。

### 2．システム概要

処理過程を図1に示す。

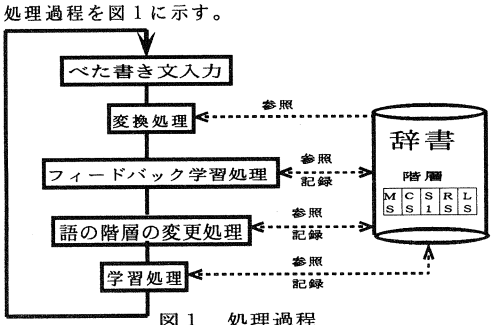



図1　処理過程

まず、入力されたべた書き文は、変換処理に行き、学習処理で語が獲得されたときの状況とフィードバック学習による語の正変換率に応じて、確実性の高い語から変換が行われる。次に、変換された語の正誤を判定する。フィードバック学習処理では、正誤判定の結果から語の正変換率を更新し、語が属する階層の変更を行う。最後に、学習処理で語を獲得し、結果を辞書に登録する。学習処理では、まず入力べた書き文とあらかじめ与えられる正しい変換結果から表記文字の変化部分と不変化部分を探すことにより語を獲得しS1とする。次に、獲得された語は複数の語に分割できる場合があるので、条件に従いさらに共通部分と差異部分に分け、それぞれCS，RSとする。以上の処理過程の中で、辞書中に存在する語は、学習処理で語を獲得したときの状況とフィードバック学習で更新される語の正変換率により、MS，CS，S1，RS，LSの5つの階層に分類・格納され、この順に確実性が高いものとする。辞書階層の分類を表1に示す。

表1　辞書階層の分類

| | |
|---|---|
| MS： | （Most certain Segment）<br>CSであり、かつ95%以上の正変換率の語 |
| CS： | （Common Segment）<br>S1の語について共通部分抽出により取り出される語 |
| S1： | （Segment 1）<br>漢字かな混じり文とその読みから獲得した語 |
| RS： | （Remained Segment）<br>CSの抽出の際の残留部分の語 |
| LS： | （Less certain Segment）<br>各々の階層で正変換率が40%未満の語 |

### 3．改良点

従来までの4階層システムでは、正変換率が40%未満の語は削除されていた。しかし、削除された語の中に正しい語が含まれる可能性が大であり、それを回復させるための手法として、新たな階層（LS）を増設した。このLS階層には正変換率40%未満の語が格納されるが、変換処理において使用され正変換率が上昇したLSの語は元の階層へ復帰させるものとする。

### 4．実　験

本手法に基づく実験システムをVAX8550上で作成し、実験を行った。辞書の初期状態は空にし、実験データとしては、情報分野，機械分野より各10編の論文（漢字かな混じり表記で139，427文字）を用いた。

### 5．結果と考察

最終的に辞書の全階層に含まれる総語数は、8668語であり、そのうちLS階層の登録語数は約500語で、正変換率が上昇したことによるLSから各階層への復帰も確認でき、変換精度の向上に貢献していることがわかった。又、各階層毎の登録語数をLS階層無しのものと比較しても、S1の登録語数が4000語台にまで増えている事からも、このLSの階層を増設することの有効性が確認できた。

### 6．おわりに

今後の課題としては、この実験結果を基に新しいS1抽出アルゴリズムを検討していく予定である。

**＊参考文献**

1）長尾：日本語情報処理，電子情報通信学会(1984).
2）荒木，栃内：帰納的学習によるべた書き文のかな漢字変換，電子情報通信学会技術研究報告，Vol.91, No.397, pp.9-16(1991).
3）高橋，荒木，桃内：帰納的学習によるべた書き文のかな漢字変換における尤度の評価について，電気関係学会北海道支部連合大会論文集，pp.409-410(1992).
4）高橋，荒木，桃内：帰納的学習によるべた書き文のかな漢字変換の有効性，情報処理学会研究報告,Vol.93, No.1,pp.31-38(1993).