337 自然言語処理支援エディタの作成

堤 正勝† 荒木 健治†† 宮永 喜一† 栃内 香次†
†北海道大学工学部 ††北海学園大学工学部

1 はじめに

自然言語処理に関する研究では、前処理として形態素解析が必要となる。著者らはこれまで、形態素を入力の段階でわかち書き（ＫＫＨ表記）[1] を行なったり、文書データの計算機による形態素解析の結果を編集して未知語や解析誤りに対処してきた。辞書の語彙が少ない場合には、同一の新出語が複数箇所に出現し、作業効率を低下させる。本エディタの第一の目的は、形態素解析と同時に未知語の登録を行なって作業効率を向上させることである。第二の目的は、解析結果を効率よく使用することにある。形態素解析の結果は主記憶上の辞書項目へのポインタの列として保持されるので、その後の形態素に関する実験手続きをエディタに組み込むことにより容易に実験ができる。本エディタは、以上二点について自然言語処理の環境を提供する。

2 エディタの構成

エディタの基本構成を図１に示す。

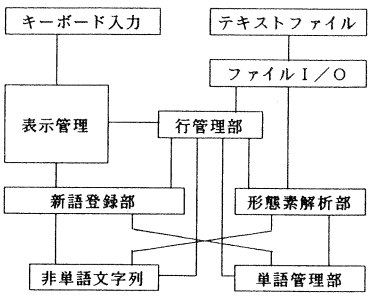


図 1: エディタの構成

本エディタはフルスクリーンエディタの形態をとり、入力は二系統ある。一つはキーボードから入力するものである。行管理部を通じて入力と同時に形態素解析が行なわれる。形態素解析アルゴリズムの不都合と未知語対応のために半分ち書き入力を行う。もう一つは、既に編集された文書データを入力するもので、文書の読み込みと同時に形態素解析を行なう。入力文書の中に未知語が存在すると、逐次切り出し範囲と読みを要求する。解析結果が複数存在し、一意に決定できない場合は、その部分をレジスタに格納して最初の候補に設定しておき、会話モードにおいてそれらの部分を最少の操作で次々と検索、編集できるようにした。

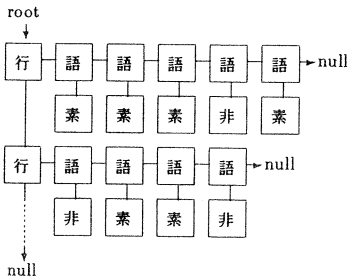
形態素に分割された文書は行管理部において図２に示す形で管理される。文書要素は、単語と非単語（未解析部分）に分けられる。表示管理はキーボード入力と各種管理部を結び付け、それぞれの機能の呼び出す。ファイルのセーブには形態素分割の情報を残すため、形態素を保存する形式 [2] を用意している。非単語は品詞属性に未処理のフラグを与えている。文書の保存形式は以下のとおり。

(＜読み＞/＜表示文字＞/＜品詞属性＞ [/＜その他の情報＞])…

「…」は有限の繰り返しを意味する。文書は形態素列として表される。

3 単語管理と行管理

辞書は単語管理において起動時に主記憶にロードし終了時にセーブする。単語文字列は単語管理の下に文字列管理を設け、同じ文字列が重複して登録されないように、検索してから登録している。



行：行のノード
語：語のノード
素：形態素としての単語
非：非単語文字列

図 2: 行と単語の管理

これにより、同音語、同表記語は、同じ文字列を指すポインタとして管理されるため、おなじ文字列であるかどうかはポインタを比較するだけでよいという利点をもつ。

入力したテキストは、行に分割され、形態素解析によりさらに単語に分割する。単語の定義は資料 [2] に従った内部表現で管理する。大部分の用言は子音で終るので叙述表現 [2]（一般の助動詞に相当）の並びとともに表示部で仮名に変換している。非単語文字列は、テキストバッファ内の文字列へのポインタと長さの情報で未処理の部分として管理される。なお、記号や、罫線文字、スペース、句読点、改行等の文要素も語として登録してる。これにより音声による文書入力および編集にも対応している。

行は、単語へのポインタのリストで構成される。また、ファイル通常のエディタと同様には、行のリストとして管理される。

4 おわりに

以上、本稿では、現在作成中の形態素の処理に適した自然言語処理支援エディタについて報告した。本エディタはＣ言語で書かれたプログラムを本体にリンクすることで機能の追加が容易に実現できる。具体的には、校正処理、翻訳処理、また、単語にファイルをリンクすることによりハイパーテキストエディタなどが考えられる。著者はこのエディタを、連続音声認識によって得られる誤りを含む文字列の復元処理に関する研究 [3] の道具、及び環境として考えており、また、このエディタに復元処理そのものを追加することを考えている。今後はこのエディタを完成した上で、復元に関する実験をしてゆく予定である。

参考文献

[1] 栃内、伊藤、荒木、鈴木、永田：研究者向き日本語ワードプロセッサＫＫＨ：北海道大学工学部研究報告，No.109,pp.119-126(1984).

[2] 堤 正勝、荒木健治、宮永喜一、栃内香次：自然言語処理における実験用文書データの取得及び保存について：平成４年度電気関係学会北海道支部連合大会，北見 (1992).

[3] 堤 正勝、荒木健治、宮永喜一、栃内香次：多段階分割復元法を用いた連続音声認識の誤りの復元：電子情報通信学会、音声研究会資料、SP89-92 (1989).