339 帰納的学習による機械翻訳手法の改良

内山 智正+ 荒木 健治++ 宮永 喜一+ 栃内 香次+
+北海道大学工学部電子工学科 ++北海学園大学工学部電子情報工学科

１．はじめに

我々は帰納的学習による機械翻訳手法を提案し、実験システムの構築を行なっている[1]。そして、これまで本手法の利点と問題点を明らかにすることを目的とした性能評価実験[2)3)]を行なってきた。本稿では、上記実験結果に基づき、本実験システムの学習手法の改良点について提案する。

２．処理過程

我々が先に提案した帰納的学習に基づく機械翻訳手法[1]は、学習部により翻訳例の字面情報から差異部分と共通部分を多段階に抽出し、次いで具象的翻訳ルールから抽象的翻訳ルールを抽出し、これらを翻訳辞書として構築していくものである。翻訳部では、具象的ルールより順に翻訳ルールを適用し翻訳を行なう。その後、翻訳された結果の正誤を利用者が判断してフィードバック学習を行ない、次回の翻訳の精度を向上させる。我々は、このような手法を多段階共通パターン抽出法[1]と呼んでいる。図１に、処理の流れを示す。

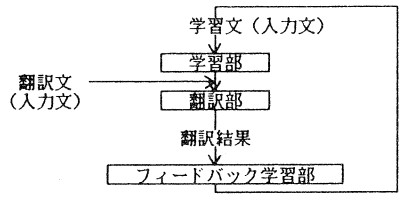


図１ 処理の流れ

３．学習例

学習処理で翻訳ルールを獲得する具体的な例を、以下の例文で説明する。

```
[1-1] ( I play tennis.    私 は テニス を する。    )
[1-2] ( You play tennis.  あなた は テニス を する。 )
```

この２つの対訳を比較すると、英文と日本語訳文それぞれの差異部分が１対１で対応付けられるので、差異部分をを抜き出して翻訳ルールとする。また、共通部分には差異部分であったところに変数部分を表す’@’をつけて翻訳ルールとする。このような形式のものを抽象的翻訳ルールという。このとき、過剰な抽象化は誤った学習を引き起こしたり、翻訳処理における翻訳ルールの適用が膨大になる。そこで、抽象化するときの閾値を設けて翻訳ルールにおける変数部分の割合を決定し、学習に制限をつける。この学習の結果、以下のような翻訳ルールが得られる。

```
[2-1] ( I              私                )
[2-2] ( You            あなた            )
[2-3] ( @0 play tennis.  @0 は テニス を する。  )
```

４．翻訳例

翻訳処理では、学習処理により抽出された翻訳ルールを用いて翻訳文を作成する。翻訳処理の具体的な例を以下に示す。

He is my friend.

といった入力文を翻訳させる場合に、適用可能な翻訳ルールを選出する。但し、既に以下の翻訳ルールは学習処理によって抽出されているものとする。

```
[3-1] ( friend         友人              )
[3-2] ( my @0          私の @0           )
[3-3] ( He is @0.      彼 は @0 です。    )
```

翻訳ルールの変数部分に、[3-1]、[3-2]、[3-3] といった順番に翻訳ルールの代入を行なうと、翻訳結果は次のようになる。

彼は私の友人です。

５．翻訳結果及び問題点

我々の翻訳システムでは、中学一年生程度の英文を翻訳させる場合、約４０％について有効な翻訳結果を得ることが可能である。なおこの中には、未登録語が存在するがそれに訳語を与えることにより、比較的容易に有効な翻訳結果が得られる場合を含めている。このような未登録語は名詞か、固有名詞か、形容詞に限られている。

翻訳結果の残り６０％は誤った翻訳と翻訳不能との２つに分けることができる。誤った翻訳は、翻訳ルールの組み合わせの誤りに起因する。翻訳不能は、学習処理によって既に入力文の基本的な構造を含む翻訳ルールが抽出されていない場合に起こる。これまでの実験では上記のうちの約７０％が翻訳不能で、３０％が誤翻訳である。

我々が提案した手法では、少なくとも２つの似通った翻訳例が存在しなければならない。先の実験に利用した中学１年生の教科書でも、日本語における「～です。」・「～だ。」また「私」・「僕」等の表現の違い、英語における「play」・「plays」等の動詞の変化等により、類似しているが差異部分を１対１に対応付けられずに学習ができない場合が多く存在した。

６．改良点

２つの翻訳例の英語訳または日本語訳のどちらかが同じで、それに対する訳文同士の差異部分が１対１に対応付けられる場合に学習処理を行なう。

実際に上で述べた学習処理の具体例を以下に示す。

（例１）

次のような例文があるとする。

```
[1-1] ( I play tennis.    私 は テニス を する。    )
[4-1] ( I play tennis.    僕 は テニス を する。    )
                  ↓
              私 = 僕
```

（例２）

次のような例文があるとする。

```
[4-2] ( He plays tennis.  彼 は テニス を する。    )
[4-3] ( She plays tennis. 彼女 は テニス を する。  )
```

学習処理を行なうと次の結果が得られる。

```
[5-1] ( He                彼                )
[5-2] ( She               彼女              )
[5-3] ( @0 plays tennis.  @0 は テニス を する。  )
```

ここで、先に学習処理で得た翻訳ルールの[2-3]と[5-3]を比較する。

```
[2-3] ( @0 play tennis.   @0 は テニス を する。  )
[5-3] ( @0 plays tennis.  @0 は テニス を する。  )
                  ↓
            play = plays
```

このような翻訳例を比較することにより、”私，僕”の言い回しの違い、”play,plays”の動詞の変化を導き出すことができる。

これらの知識を学習処理に利用することで、差異部分を１対１に対応付けできる場合が増し、より有効に翻訳ルールが抽出されると思われる。

７．おわりに

本稿では多段階共通パターン抽出法[1]の改良点について提案した。上で述べた問題点を解決することによって、より効率的な学習処理を行なうことができると考える。しかし、ここで提案した学習処理は同じ訳文の組が存在しなければならず、より実用的な翻訳例を学習させる場合にはこのような翻訳例は減少すると思われる。

ここで提案した学習処理手法を実際のシステムとして作成し、今後大量の資料による実験を行なう予定である。

参考文献

（１）荒木健治、栃内香次：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳、情報処理北海道シンポジウム講演論文集，pp.412(1991).
（２）内山智正、荒木健治、宮永喜一、栃内香次：帰納的学習による翻訳手法の実用性評価、電気関係学会北海道支部連合大会講演論文集,pp.424-425(1992).
（３）内山智正、荒木健治、宮永喜一、栃内香次：帰納的学習による機械翻訳手法の評価実験、情報処理学会研究報告，NL93-4,pp.23-30(1993).
（４）教科書ガイド教育出版版ワンワールド１、日本教材、東京(1991).