342　文章からの自動話題抽出手法の実験

亘理 克好† 荒木 健治†† 宮永 喜一† 栃内 香次†
†北海道大学工学部 ††北海学園大学工学部

1 はじめに

これまでに要約(抄録、あらすじ)自動生成の手法については、表層的なものから深層的なものまでいくつか提案されている[1][2]。しかし、話題抽出については談話を話題という側面からとらえたものがある程度で[3]、直接に文章の話題を抽出するものについては、十分に研究されているとは言えない。

文章理解の立場から考えても、文章の部分部分における話題を抽出することは重要であると考えられる。そこで、我々は文章から話題を自動的に抽出するシステムの構築を考えている。我々はこれまでに人間の話題抽出機構の調査結果について報告した[7]。その中で人間はさまざまな情報を用いていることが明らかになったが、今回はそのうちの表層で処理できる、単語の頻度の利用について取り上げる。

一般に文章中では同じことについてさまざまな言い方がされるので、それを考慮して字面のみの頻度に加えて、シソーラスを用いて重み付けをした。本報告ではそれらの結果と人間の抽出した話題との関係について調査した結果について報告する。

2 基本方針

本研究では、話題を求める範囲として、段落(形式段落、意味段落)ごとを想定しているが、本報告では対象を形式段落のみに絞っている。また、対象とする文章は、将来論文に拡張することを前提に、現段階では比較的やさしい説明文(論説文)を考えている。形態素解析は二文節最長一致法を用いている。

3 実験

3.1 単語の頻度調査

段落毎に単語の頻度を調査し、人間が抽出した話題と比較した。

実験に用いた文章は、小学校四年生の国語の教科書の一部(説明文)(1640文字、54文、15段落)[4]である。人間が抽出した話題は工学部大学院学生4人が実際に抽出したものと教科書ガイド[5]によるものである。頻度の調査は自立語を対象とした。

最も高頻度の単語(最高出現語)が、人間の抽出した話題に含まれているかどうかを段落毎に調べた結果、5人のうちの誰かが抽出した話題に最高出現語が含まれていた段落は10段落あった。また、全ての自立語の頻度が1で比較ができなかった段落が、3段落あった。約6割の段落で単語の抽出ができた。

3.2 シソーラスを用いた重み付け

人は文章を書くにあたり、同じことについて述べるのに、さまざまな言い方をする。また人間は頻度情報を利用するとき、字面のみの頻度を利用しているわけではなく似たような意味の単語の頻度を利用していると考えられる。そのため単語の字面のみで頻度を計算すると、頻度に差が出てこない可能性があり、頻度が全て1であるような段落が生じると考えられる。そこで、単語の抽出率を上げるためにシソーラスを用いて頻度に重みを加えることを考えている。

シソーラス辞書については、分類語彙表などいくつか市販されているが、本研究では角川書店の類語国語辞典[6]を用いている。類語国語辞典では、すべての収録語彙は十進分類方式による語彙分類体系表に基づき、大分類(一桁目=10項目)・中分類(二桁目=100項目)・小分類(三桁目=1000項目)の3桁の数字によって分類され、さらに必要に応じて a・b・c・・・により細分化されている。この内、本研究では上位概念の比較のために、3桁の数字のみを使用し、必要に応じて付けられている a・b・c・・・は用いない。

上位概念を考慮した重み付けの方法を以下に示す。

1. 分類番号の上位3桁が等しい単語の頻度に C_3 を加える。
2. 分類番号の上位2桁が等しい単語の頻度に C_2 を加える。
3. 分類番号の上位1桁が等しい単語の頻度に C_1 を加える。

ただし、$1 \geq C_3 \geq C_2 \geq C_1 \geq 0$ とする。

この、$C_1 \sim C_3$は重みである。また、一つの単語が必ずしも一つの分類番号を持っているわけではなく、それぞれの単語は何種類かの分類番号を持っている。文章内での単語の使用法を考慮して、その中から適切な分類番号を選択する方法もあるが、処理の簡潔さからそれを行なわず、$C_1 \sim C_3$それぞれに $\frac{C_0}{\text{分類番号の数}}$ を乗じて均一化をはかる。

前述の小学校四年生の教科書の説明文について上述の方法を適用すると結果は表1のようになる。ただし、表1において「4人と同じ」というのは、4人が抽出した話題全てに最高出現語が含まれていたということである。また、「頻度なし」というのは全ての自立語の頻度が1であったということである。

表1: シソーラスを用いた重み付け

	段落数			
	$C_0 = 1$		C_0 = 分類番号の数	
	$C = A$	$C = B$	$C = A$	$C = B$
4人と同じ	3	3	0	0
3人と同じ	0	0	1	1
2人と同じ	5	6	0	0
1人と同じ	2	1	2	2
0人と同じ	5	5	12	12
頻度なし	0	0	0	0
合計	15	15	15	15

ただし、

$$A = \begin{cases} C_1 = 0.25 \\ C_2 = 0.5 \\ C_3 = 0.75 \end{cases} \quad B = \begin{cases} C_1 = 1.0 \\ C_2 = 1.0 \\ C_3 = 1.0 \end{cases}$$

表1によると、1人以上と同じという段落数が10であり、字面のみの頻度の時と同じであるが、「頻度なし」という段落はなくなっている。さらに抽出率を上げるにはパラメータ $C_0 \sim C_3$の模索や、大量データによる実験が必要であると考えられる。

4 おわりに

文章から話題を自動的に抽出する手法の構築を考えている。そこでまず、話題に含まれる単語を見つけることを考えている。その一つの方法として頻度を取り上げ調査した。またその上位概念の頻度情報も考慮した。字面の頻度のみを使うことにより、人間が抽出した話題に含まれる単語が、約6割の段落で抽出できた。

今後は、パラメータ $C_0 \sim C_3$の模索や、大量データによる実験を行なう予定である。また、結果の評価方法についての検討、単語抽出についての他の情報の利用についての検討、調査も行ないたい。

参考文献

[1] 安原宏,小松英二,日比孝,加藤安彦:要約支援システム COGITO, 情報処理,Vol.30,No.10,pp.1258-1267(1989).
[2] 中澤俊哉,重永実:エピソードネットワークを用いた物語のあらすじ生成,情報処理学会論文誌,Vol.32,No.10,pp.1215-1224(1991).
[3] 竹下 敦:表層的処理による話題抽出,情報処理学会研究報告 83-NL-4,pp.23-30(1991).
[4] 吉原順平:花を見つける手がかり,新版国語 4 上 (pp.50-57),教育出版 (東京)(1992).
[5] 教科書ガイド小学国語 4 年上教育出版版,新興出版社 (東京)(1992).
[6] 大野晋,浜西正人:類語国語辞典第 6 版,角川書店 (東京)(1992).
[7] 亘理克好,荒木健治,宮永喜一,栃内香次:文章からの自動話題抽出手法の検討,平成 4 年電気関係学会北海道支部連合大会講演論文集, pp.428(1992).