346　語の接続関係を利用した文の誤りの復元

神野 大輔† 荒木 健治†† 宮永 喜一† 栃内 香次†
† 北海道大学工学部 †† 北海学園大学工学部

1 はじめに

計算機に日本語文書を入力する際に、人間にとって簡単な入力方法として音声によるものが考えられる。しかし、音声による入力においては、音響的な情報のみで１００％の認識結果を得ることは非常に困難である。そこで、誤りを含む音響処理部の出力に対して、語彙情報や構文情報、意味情報などの言語情報を利用して、原文を復元する必要がある [1]。

我々は既に、入力者が単音節単位で発声した音声を単音節音声認識装置により認識を行い、その出力結果である誤りを含む音素列から原文を復元する手法として多段階分割復元法を提案し、その有効性を確認した [2]。さらに、より実用的でかつ自然な方法として、連続音声認識対応にする研究を行っている [3]。

そこで本稿では単語どうしの接続関係に着目し、連続音声認識に対応した多段階分割復元法に適用することにより復元精度の向上をはかる手法とそれに基づく実験結果について述べる。

2 復元手法の概要

今回提案する手法の処理手順を図 1に示す。本来の多段階分割復元法による復元の処理手順は図 1で接続辞書を除いたものである。

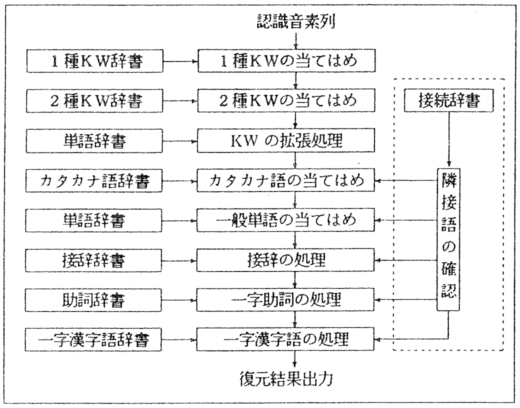

図 1: 多段階分割復元法の処理手順と接続辞書の使用

出典	情報処理学会論文誌 Vol.24 No.1
題名	高集積マイクロコンピュータに適した マイクロプログラム制御方式
著者	前島他
総単語数	5932
単語の種類	805

表 1: 実験資料

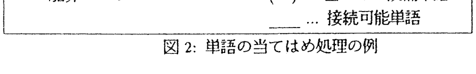

sono(suNpou)waneNnibyuN/paaseNto/(hodo)nosokudode
その ○寸法　は　　　　　　　%　　○ほど の
bisai(kasa)ge/tsutsu/arumaru　　/ / … 当てはめ済み単語
×加算　　つつ　　　　　　　　( ) … 当てはめ候補単語
　　　　　　　　　　　　　　＿＿ … 接続可能単語

図 2: 単語の当てはめ処理の例

各処理段階毎に単語辞書を用いて単語を順次当てはめていく。この中で、一般単語の当てはめと一字漢字語の当てはめに際しては、連接情報 [2] を用いて当てはめの際の整合性を高めている。この連接情報とは単語の前後にある文字の組である。しかし、単音節単位の認識と異なり連続音声認識の場合音素の付加、脱落が生ずるために 1 文字だけでは当てはめに整合性を持たせることができなくなると考えられる。そこで、この連接情報を前後 1 文字から前後 1 単語に拡張することにより文全体として整合性のある当てはめを行うことができると考えられる。

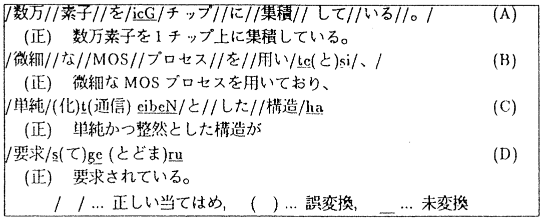

/数万//素子//を/icG/チップ//に//集積// して//いる//。/　　(A)
(正)　数万素子を 1 チップ上に集積している。
/微細//な//MOS//プロセス//を//用い/tc(と)si/、/　　(B)
(正)　微細な MOS プロセスを用いており、
/単純/(化)t(通信) eibeN/と//した//構造/ha　　(C)
(正)　単純かつ整然とした構造が
/要求/s(て)ge (とどま)ru　　(D)
(正)　要求されている。
/ / … 正しい当てはめ,　( ) … 誤変換,　＿ … 未変換

図 3: 当てはめ結果の一例

3 実験

まず、前後 1 単語の接続情報を調査した。用いた資料は表 1 である。ここでいう単語とは、形態素のことを示し、単語の種類には、自立語、付属語、接辞、活用語尾、記号が含まれている。全ての単語に関して、前後に隣接する語が何であるかを調べそれを接続辞書に記録してある。

次に、実際に誤りを含む音素列に対して単語の当てはめを行った。用いた資料は、単語の接続関係を調べたものと同様である。また、誤りはシミュレーションにより作成したものであり、文章全体で音素の誤り率は 11.87%である。単語の当てはめ手順を図 1 に、その例を図 2 に示す。例えば、' 寸法 ' が当てはめ候補単語である時、その前後の音素列に接続可能な' その ' と' は ' が存在するので、' 寸法' の当てはめを決定する。また、' 加算' が当てはめ候補である時、前後に接続可能単語が存在しないため、' 加算' の当てはめは行わない。以上のような処理を加えて、単語の当てはめを多段階に行った。

その結果を表 2 に示す。ここで、当てはめ精度は式 (1)、正当てはめ率は式 (2) により表される。

$$(\text{当てはめ精度}) = (\text{正当てはめ数}) \div (\text{当てはめ数}) \qquad (1)$$

$$(\text{正当てはめ率}) = (\text{正当てはめ数}) \div (\text{総単語数}) \qquad (2)$$

当てはめ数	5555	当てはめ精度	0.9174
正当てはめ数	5096	正当てはめ率	0.8591

表 2: 実験結果

4 考察

単語の当てはめ誤りとして、未変換と誤変換が存在した。(図 3)

未変換としては、特に接辞、助詞など 1 ～ 3 音素程度の短い語が多く見られた (図 3 (A))。これは、当てはめ候補としてとり上げる際に単語の長さに関して重み付けをして、閾値を越えたもののみ扱っているためにそれらの短い語が当てはめ候補として取り上げられなかったためと考えられる。

誤変換としては、5 音素前後の一般単語が多く見られた (図 3 (C),(D))。これは、これらの単語が当てはめ候補として取り上げられやすく、また前後に短い単語（助詞など）が接続するので前後に自立語が接続する語に比べて当てはめが決定されやすい。他に、長めの未変換の部分がある場合その中に短い付属語が誤変換される場合も存在した (図 3 (B),(D))。これも、同様の理由と考えられる。

本手法では、語の接続関係として自立語、付属語を同様に扱っているが、隣接する単語として付属語をとった場合と自立語をとった場合とでは異なると考えられる。つまり、自立語に付属語が隣接する場合は文法的に決定されるものが多いのに対し、自立語に自立語が隣接する場合は意味的に近いあるいは、関連のある場合が多いと考えられるからである。よって、質的に異なる自立語- 付属語と自立語-自立語の接続関係を同様のものとして扱うのには問題がある。より正しい単語の当てはめを行うために、自立語どうしでの接続関係と、自立語と付属語を含む接続関係の両方についてさらに調査する必要がある。

5 おわりに

本稿では、多段階分割復元法において語の接続関係を用いて単語の当てはめの精度を上げるための実験と考察を行った。

今後は、考察で述べた問題点についての検討と大量文書による実験を行い、より実用的な接続関係の利用について検討していく予定である。

参考文献

[1] 古井:ディジタル音声処理, 東海大学出版会,(1985)
[2] 荒木, 宮永, 栃内:多段階分割復元法による誤りの多い文字列からの原文の復元, 情報処理学会論文誌,Vol30,No2,pp.169-178(1989).
[3] 堤, 荒木, 宮永, 栃内:多段階分割復元法を用いた連続音声認識の誤りの復元, 信学技報,NLC-89-33,pp.47-54(1989).