3Q－8

帰納的学習によるべた書き文のかな漢字変換における語の獲得

高橋祐治* 荒木健治* 桃内佳雄* 栃内香次**
*北海学園大学　**北海道大学

１．はじめに

日本語を計算機に入力する方法として、利用者側に負担が少ないべた書き文入力方式が、現在主流となっている[1]。この方式には、様々な手法が提案されている[2]。我々はその１つとして、べた書き文とその漢字かな混じり文から語の読みと表記の対を帰納的に学習して辞書を構築し、その辞書を参照しながら、確実性の高い語から順に変換を行う手法を提案している[3,4,5,6]。本手法の学習処理部で従来は、文字列の比較のみで語の読みと表記の抽出を行っていた。このため、入力文によっては語と表記の対応が曖昧になり、すべてを完全に抽出できないという問題点があった。本稿では、この問題点を解決し、更に学習効率を上げるため、べた書き文とその漢字かな混じり文の比較を行う際、字種情報を用いた経験則を導入する手法を提案する。このことによって、辞書の登録語数の増大及び辞書の活性化が図られる。さらに、経験則の提案とその有効性を確認するために行った学習実験について述べる。

２．システム概要

処理過程を図１に示す。

まず、入力されたべた書き文は、変換処理部でＭＳ，ＣＳ，Ｓ１，ＲＳ，ＬＳの５つの階層に分類して構築されている辞書を参照して、確実性の高い語から変換が行われる。この確実性は、学習処理で語が獲得されたときの状況とフィードバック学習による語の正変換率に応じて、各語に与えられたものである。次に、変換結果は、人手によって校正される。フィードバック学習処理部では、校正の結果から語の正変換率を更新し、語が属する階層の変更を行う。最後に、学習処理部で語を獲得し、結果を辞書に登録する。学習処理部では、まず入力べた書き文と変換結果を人手で修正することによって得られた正しい漢字かな混じり文から表記文字の変化部分と不変化部分を探すことにより、語を獲得しＳ１階層に格納する。次に、獲得された語は複合語を含むので、条件に従いさらに共通部分と差異部分に分け、それぞれＣＳ，ＲＳとする。処理過程の中で、辞書中に存在する語は、学習処理で語を獲得したときの状況と、フィードバック学習で更新される語の正変換率により分類・格納される。本手法は、上記の処理の繰り返しからなる。なお、本報告では、学習処理部のＳ１抽出処理について考察する。

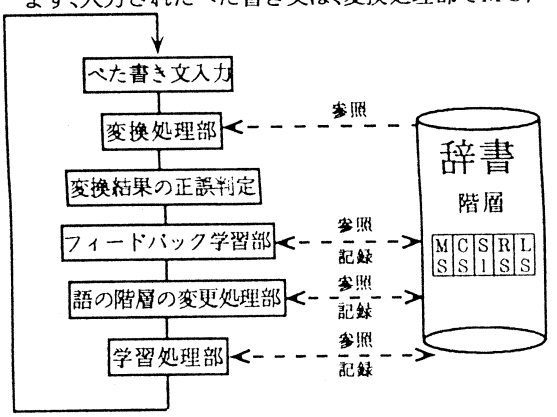


図１　処理過程

Word acquisition method for Kana-Kanji translation of Non-segmented Japanese Kana sentence by inductive learning
*Yuji TAKAHASHI　*Kenji ARAKI　*Yoshio MOMOUCHI
**Koji TOCHINAI
*Hokkai-Gakuen University　**Hokkaido University
*South 26 West 11, Chuo-ku, Sapporo, 064, Japan

３．従来の学習処理

学習処理部のＳ１抽出処理では、図２に示すように、入力べた書き文とそれに対応するかな漢字混じり文から文字の変化部分と不変化部分を探すことで、Ｓ１階層に格納される語の読みと表記を獲得する。

図２において、左から右の解析によって、文字列を比較すると、「は」が不変化部分となる。このことから変化部分である「我々」の読みが「われわれ」であることがわかる。次に不変化部分となる文字は「の」であるから、「種々」の読みを「しゅじゅ」と抽出する。以後、同様に不変化部分を検索することによって、語の読みと表記の獲得を行う。図２のように読みと表記の正しい対応関係が一意に決定できる場合は問題はない。しかし、例えば漢字の読みの中に不変化部分の文字が含まれる場合には、誤った対応関係が抽出されてしまう。図３にこの例を示す。

図３では、不変化部分となる語は「な」であるが、「柔軟」の読みである「じゅうなん」のなかに「な」が、存在しているため、活用語尾の「な」を「じゅうなん」の「な」と誤って対応づけてしまう。結果として、「柔軟」の読みを「じゅう」と誤抽出する。そこで本手法では、抽出される語の正当性確保のため、左

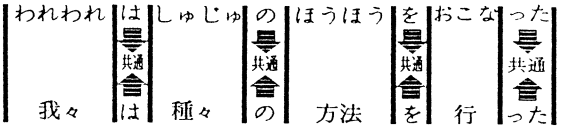


図２　学習処理の例

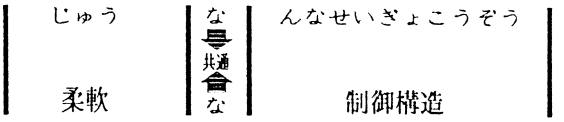


図３　抽出が失敗する例

から右と、右から左の双方向解析を行い、その結果、同じ語がある場合のみ辞書に登録するという方式を採用している。よって、図３の例では、辞書に登録される語は「な」のみとなる。

４．学習処理部の改良点

本手法のＳ１抽出処理では、双方向の解析が一致しないものは辞書への登録を行わないことにしていた。これは、登録されなかった語は、それ以降の文章において一対一に対応づけられるような表現が出現すれば、登録される可能性があるので問題はないからである。しかし、語の獲得効率の低下を防ぐことはできなかった。そこで、字種情報を用いた経験則を導入することにより語の獲得効率を上昇させることを試みた。改良後の学習処理の手順は、双方向解析において不変化部分を見つける度に字種情報を利用した経験則を用いることによって行う。この経験則の条件に合わない場合は、その語の獲得結果は誤抽出と認識し、次の区切り候補を再検索する。

５．経験則

導入した経験則は、ひらがな、漢字及びカタカナ表記の語に対して用いる。以下に、改良したＳ１抽出処理に用いる経験則の一覧を示す。

A　表記の文字列が全てひらがなである場合、読みは、表記と同じ文字列である
B　表記の文字列が全て漢字である場合、読み文字数は表記の文字数よりも多いか、同じである
C　表記の先頭文字が漢字である場合、読みの先頭は、文法的に「ん」、「ゅ」等ではなく、かつ記号でもない
D　表記中にカタカナが存在する場合、それを平仮名にしたものが、必ず読みに存在する

６．学習実験

本手法の学習処理部の実験を行い、従来の学習処理と改良後の学習処理の比較を行った。資料として、情報処理分野と機械工学分野の論文各１０編合計２０

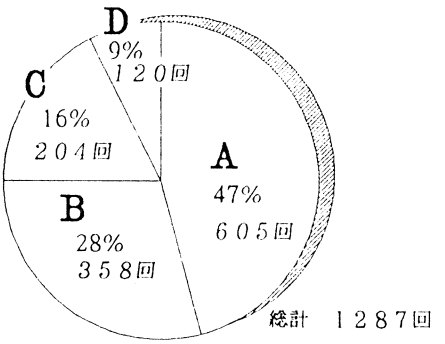


図４　経験則別の使用頻度

編、漢字かな混じり表記で139,427文字を用いた。

７．結果及び考察

図４に適用された経験則の使用頻度を示す。

従来のＳ１抽出処理と抽出語数を比較すると、論文５編の学習終了時で100語前後の違いがあった。このことから初期の状態においても、経験則の導入が有効であると考えられる。また、その後学習が進めば進むほど従来の手法との抽出語数の違いは、より顕著になっている。さらに、従来の手法で誤抽出をしていた語を80.7%回復できることがわかった。このことは、本手法への経験則の導入の有効性を示していると考えられる。

８．おわりに

本論文では、学習部における語の読みと表記の獲得手法を改良して、経験則を用いてＳ１抽出する手法の有効性を確認する評価実験を行った。その結果より、本手法へ経験則を導入した手法の有効性を確認することができた。今後は、変換処理部の変換精度の向上を確認する実験を行う予定である。

参考文献

１）長尾：日本語情報処理，電子情報通信学会(1984).
２）牧野，木澤：べた書き文の分かち書きと仮名漢字変換，情報処理学会論文誌，Vol.20,No.4(1979).
３）荒木，栃内：帰納的学習によるべた書き文のかな漢字変換，電子情報通信学会技術研究報告，Vol91,No.397,pp.9-16(1991).
４）高橋，荒木，桃内：帰納的学習によるべた書き文のかな漢字変換における尤度の評価について，電気関係学会北海道支部連合大会論文集，pp.409-410(1992).
５）高橋，荒木，桃内：帰納的学習によるべた書き文のかな漢字変換の有効性，情報処理学会研究報告,Vol93,No.1,pp.31-38(1993).
６）高橋，荒木，桃内：帰納的学習によるべた書き文のかな漢字変換辞書の構成，電子情報通信学会秋季大会論文集，Vol.D-134，No.6,pp.136(1993).