キーワードとの単語接続情報を用いた誤りを含む文字列からの原文の復元

Recovery of Errors in Character Strings Using Word Connections with Key-words

D-113

神野 大輔[I] 荒木 健治[II] 宮永 喜一[I] 栃内 香次[I]
Daisuke Jinno[I] Kenji Araki[II] Yoshikazu Miyanaga[I] Koji Tochinai[I]
[I] 北海道大学工学部 [II] 北海学園大学工学部
[I] Faculty of engineering, Hokkaido University [II] Faculty of engineering, Hokkai-Gakuen University

1 はじめに

計算機に日本語文書を入力する際に，人間にとって親しみやすいインターフェースとして音声の利用が考えられる．しかし，音声による入力においては，音響的な情報のみで１００％の認識結果を得ることは非常に困難である．そこで誤りを含む音響処理部の出力に対して，語彙情報や構文情報，意味情報などの言語情報を利用して，原文を復元する必要がある[1]．

我々は既に入力者が単音節単位で発声した音声を単音節音声認識装置により認識を行い，その出力結果である誤りを含む音素列から原文を復元する手法として多段階分割復元法を提案し，その有効性を確認した[2]．多段階分割復元法においては語彙情報を主体にして復元処理を行っているために，復元された文章が日本語として意味を持たない場合や文章としての整合性を持たない場合が存在する．そこでより上位レベルの情報として単語とキーワードとの接続関係を導入して復元の信頼性を向上させる手法を提案した[3]．本稿では，本手法を評価するために行った実験の結果について報告する．

2 接続情報の利用

現在，我々が対象としている学術論文においては，過去に入力された一定量の資料中でその語を誤りの復元に用いた場合，誤る確率が極めて低い語が存在することが思い出されている．このような語をキーワードとしてまず最初に決定することにより処理量の増加を押え，語の当てはめを正確に行うことができる[3]．また，キーワードはそれと何らかの関係のある語を伴って現れることが多い．これらの語はキーワードほどの確実性はないが，キーワードとの関連で考えた場合確実性が高いと考えられる．そこで，キーワードとその前後に隣接する語の組を接続情報として利用することにする．

多段階分割復元法においては，確実性の高い単語としてキーワードの当てはめを行っている．例えば以下の文字列において，

しょりすることによりまくろめいれいけいしきにせいやくされない
処理 すること より いる 命令 意識 制約 される ない
章 シングル おり マクロ れる 形式 指定 搭載
しよう マイクロ 例
とりわけ ROM array

命令がキーワードとして当てはめられれば，当てはめ候補単語は２４語から１９語へ減少する．しかしながら，その場合でも残りの候補単語中から正しい語を選ぶのは容易ではない．そこで，キーワードの当てはめが終った時点でキーワードの接続情報を用いる．この時，命令との接続情報を持つ語としてマクロと形式が辞書中に蓄えられていれば正しい語が選択できることになる．

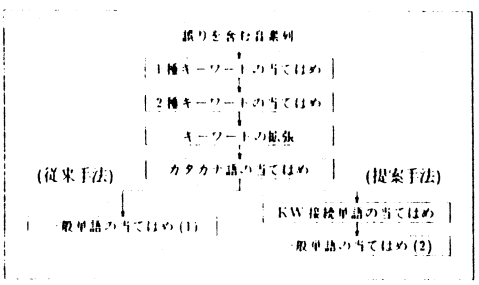


図 1: 実験システムの処理手順

3 実験

前章で述べた手法をもとに単語の接続情報を利用した語の当てはめ実験を行った．実験に使用した資料は，情報処理関係の論文１編（総単語数5928，総文字数15199，総音素数25892）である．キーワードの当てはめを行った後，キーワードに隣接する語（以後，キーワード接続単語と呼ぶ）の当てはめを行い，その後残りの一般単語の当てはめを行った．なお，多段階分割復元法においてはキーワードをその確実性の高さにより１種，２種キーワードに分けているがそれらを共に接続情報の使用対象とする．また，比較実験として従来の多段階分割復元法の一部を使用した（図１）．ただし，キーワードの拡張及びカタカナ語の当てはめについては今回の実験において適用箇所が存在しなかった．それぞれの処理段階の当てはめ結果を表1に示す．ここで当てはめ精度と正当てはめ率は次の式により定義される．

$$(\text{当てはめ精度}) = \frac{(\text{正当てはめ単語数}) \times 100}{\text{当てはめ単語数}} \quad (\%)$$

$$(\text{正当てはめ率}) = \frac{(\text{正当てはめ単語数}) \times 100}{\text{総単語数}} \quad (\%)$$

処理段階	当てはめ数	正当てはめ数	当てはめ精度	正当てはめ率
１種 KW	338	338	100	5.70
２種 KW	675	641	95.0	10.8
一般単語 (1)	2866	2525	88.1	42.6
KW 接続単語	554	542	97.8	9.14
一般単語 (2)	2305	2008	87.1	33.9

表 1: 実験結果

4 考察

接続情報を用いることにより，一般単語当てはめの直前で97.1％の精度で26.4％の正しい当てはめを行うことができた．従来手法では一般単語当てはめの直前は精度96.6％，正当てはめ率16.5％であるので，従来手法においてキーワードより確実性の低い一般単語として当てはめられていた語の一部がキーワードと同様に高い確実性を持つキーワード接続単語として当てはめることができたということができる．言い換えると，高い確実性を持った語による当てはめが従来よりも広範囲に行うことができたといえる．しかしながら，今回の実験ではキーワードの拡張及びカタカナ語の当てはめの適用箇所が存在しなかったために，これらの処理が適用された場合の影響を調査するためさらに大量の資料による実験を行う必要がある．また，従来一般単語の当てはめ時に誤った当てはめが行われていた375語のうち25語がキーワード接続単語として正しく当てはめられており，6.7％の当てはめ改善効果があったと考えられる．

接続情報を用いることにより従来正しかった部分に誤って当てはめられた語は３語存在した．これらは，キーワードの当てはめが誤っているために誤った接続情報が使用された場合と比較的短くて頻度の高い語が接続情報により当てはめられた場合である．キーワードとして当てはめる語にはなお一層の正確さを求める必要がある．また，今回の接続情報の利用のみでは決定できないと思われる語に対し新たな情報の利用を考える必要がある．

5 おわりに

本稿では，単語の接続情報を当てはめの確実性の高い語であるキーワードに適用する手法を提案し，その手法を評価するための実験を行った．その結果，キーワードと同様に高い精度で単語の当てはめを行うことができた．

今後は，キーワードとの接続情報のみでは当てはめの困難な比較的短い語に関して有効な接続情報の利用法，あるいは新たな情報についての検討を行うとともに，さらに大量の資料を用いた実験を行う予定である．

参考文献

[1] 古井：ディジタル音声処理，東海大学出版会，(1985).
[2] 荒木，宮永，栃内：多段階分割復元法による誤りの多い文字列からの原文の復元，情報処理学会論文誌，Vol30,No2,pp.169-178(1989).
[3] 神野，荒木，宮永，栃内：語の接続関係を利用した文の誤りの復元，平成５年度電気関係学会北海道支部連合大会講演論文集，pp.404(1993).