社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC94-3 (1994-05)

帰納的学習によるべた書き文のかな漢字変換手法の適応能力の評価

荒木 健治 †　　高橋 祐治†　　桃内 佳雄 †　　栃内香次 ††
† 北海学園大学工学部
† 〒064 札幌市中央区南２６条西１１丁目
†† 北海道大学工学部
†† 〒060 札幌市北区北１３条西８丁目

あらまし　我々は、人間の言語および知識獲得能力の解明とその実現を目的として研究を行なっている。従来よりこの能力を工学的に実現する一つの試みとして、入力べた書き文とその漢字かな混じり文より帰納的に語の読みと表記を獲得し、その獲得状況及び変換精度に基づく確実性の高い語より順に変換するという帰納的学習によるべた書き文のかな漢字変換手法を提案している。本稿では、分野の異なる論文４０編を用いて行なった本手法の適応能力評価実験結果及びその考察結果について述べる。

和文キーワード　帰納的学習、かな漢字変換、適応、確実性、べた書き文、言語獲得

Evaluation for Adaptability of Non-Segmented Kana-Kanji Translation Method Using Inductive Learning

Kenji ARAKI †　Yuji TAKAHASHI †　Yoshio MOMOUCHI †　Koji TOCHINAI ††
† Hokkai-Gakuen University
† S26-W11,Chuo-ku,Sapporo 064,Japan
†† Hokkaido University
††N13-W8,Kita-ku,Sapporo 060,Japan

Abstract　The goal of our research is the analysis and the realization of acquisition capability of language and knowledge of human being. We have already proposed a new *Kana-Kanji* translation method based on an inductive learning. Our proposed method automatically acquires phonogramic and ideographic characters for a word from a *Kanji-Kana* mixed sentence and its non-segmented *Kana* sentence. This method translates a non-segmented *Kana* sentence into the *Kanji-Kana* mixed sentence using the words classified in order of the higher value of the certainty degree. This paper outlines this method, and the results and considerations of experiments of the adaptability for four fields.

英文 key words　Inductive Learning, *Kana-Kanji* Translation, Adaptability, Certainty, Language Acquisition

1 はじめに

我々は従来より人間が言語を獲得し、知識を学習していくメカニズムに興味を持ち、このメカニズムを解明し、それを工学的に実現することにより環境より情報を学習し、次第に成長するシステムの開発を最終目的とし、研究を進めている。このようなシステムを開発することにより、現在の高度情報化社会が抱えている複雑で使いにくい機械やプログラム作成の重労働といった種々の問題を解決し、人にやさしい柔軟なシステムを開発できると考えている。人間の赤ちゃんは、言語も知識も持たない状態から周囲の様々な環境より学習を行ない、言葉を話し、種々の知識を持つ大人に成長する。したがって、このような生得的な能力は確かに存在する。このような観点からの研究は、いくつか存在するが [赤間 87, 赤間 88, 錦見 91]、工学的に有効なシステムを完成するまでには至っていない。また、心理学の立場からの研究も多くある [小林 92, Clark 77]。しかし、これらの研究は、どのようして子供が言語を獲得するのかを解明すると言う点では大きな意義があるが、そのような機構をどのようにして工学的に実現するかという問題は、当然ながら対象としていない。

我々は、このような生得的能力を解明する基礎的な第一歩として、すでに日本語の漢字かな混じり文を対象として未知の文字列中より語を獲得するメカニズムついての考察を行ない、形態素解析手法としての応用を行なっている。このような手法を我々は帰納的学習による形態素解析手法と呼んでいる。この帰納的学習による形態素解析手法では、漢字かな混じり文より共通部分と差異部分を多段階に抽出することにより語を帰納的に獲得する。本手法を用いることにより、辞書が空の状態からでも論文２編程度の学習により約９０％の語を認識できることが、実験により確認されている。また、異なる４分野の４０編の論文を用いた実験でも各分野へ迅速に適応し、その学習機能の有効性が確認されている [荒木 92]。

本稿では、言語獲得、知識獲得能力実現のための基礎的な研究の第２段階として、べた書き文とその漢字かな混じり文から帰納的学習によりかな漢字変換に必要な語、すなわち表記と読みを獲得し、次いで獲得状況および変換精度に基づく確実性の高い順に多段階に変換を行なう手法 [荒木 91, 高橋 93] について述べる。さらに、本手法の学習能力の有効性を確認するために異なる４分野の４０編の論文を用いて行なった適応能力評価実験結果および考察結果について述べる。実験の結果、すべての分野で約９５％の変換率が得られその有効性が確認された。また、本研究の第１段階として行なった帰納的学習による形態素解析手法 [荒木 92] が漢字かな混じり文という一種類のデータからの学習を行なうのに対して、本手法では、べた書き文とその漢字かな混じり文という二種類のデータからその対応関係を予測する過程が必要となる。本稿では、この予測メカニズムに関する考察も行なう。また、形態素解析、かな漢字変換における未登録語の問題に対する研究もいくつかある [吉村 86, 吉村 89] が、これらの研究は与えられた語が辞書にある程度存在することを前提とした上での少数の未登録語に対する処理であるため、大半の語が辞書に存在し、その語の情報を利用して未登録語を予測している。したがって、初期辞書作成の労力は避けられない。これに対して、本手法は、辞書が空の状態からでも学習により語を獲得することができるので、辞書を個人毎に自動的に作成することが可能、未登録語の自動登録、初期辞書作成の労力を回避できるという利点がある。

2 基本的考え方

本手法の前段階となる帰納的学習による形態素解析手法においては、生得的な能力を「二つの事物が同じか異なるかを判断する能力」と仮定して手法を開発し、実験を行なった。その結果からこの仮定の正当性を確認できた。したがって、本稿で述べる、対応関係を有する二種類の未知文字列からの帰納的学習においても、この能力から語の表記と読みを獲得できなくては研究の目的に合致しない。ところで、人間は対応関係を有する二種類の記号列に対してどのような方法を用いてその対応関係を決定しているのであろうか。表 1に未知文字列からの対応関係抽出の例を示す。

表 1: 未知文字列からの対応関係抽出の例（１）

入力１	$\alpha\ \theta\ \sigma\ \psi\ \delta\ \lambda\ \vartheta$	
入力２	$\Xi\ \Sigma\ \psi\ \delta\ \Upsilon\ \Phi\ \Theta$	
結果１	$\alpha\ \theta\ \sigma$	$\Xi\ \Sigma$
結果２	$\psi\ \delta$	$\psi\ \delta$
結果３	$\lambda\ \vartheta$	$\Upsilon\ \Phi\ \Theta$

表 1のような対応関係を有する二つの未知文字列を見た場合に人間は、まず二つの文字列に共通な部分を検出する。表 1の例では、($\psi\ \delta$) に注目すると考えられる。そして、その両側の差異部分をその出現順に対応付ける。すなわち、表 1の結果１、２、３のような対応関係を考える。このような抽出過程は、我々が生得的な能力として仮定している「二つの事物が同じか異なるかを判断する能力」を基本として考えることができる。しかし、二つの文字列に共通な部分は別として異なる部分は、表 1以外に、表 2のような結果を考えることもできる。

表 2では、対応関係が出現順ではなく出現順と逆順に

表 2: 未知文字列からの対応関係抽出の例（２）

入力１	$\alpha\ \theta\ \sigma\ \psi\ \delta\ \lambda\ \vartheta$	
入力２	$\Xi\ \Sigma\ \psi\ \delta\ \Upsilon\ \Phi\ \Theta$	
結果１	$\alpha\ \theta\ \sigma$	$\Upsilon\ \Phi\ \Theta$
結果２	$\psi\ \delta$	$\psi\ \delta$
結果３	$\lambda\ \vartheta$	$\Xi\ \Sigma$

なっている。このような対応関係は、実際に起こり得るのでここで出現順の対応関係を取るか出現順と逆順の対応関係を取るかは、対象とする問題に依存したヒューリスティクスであると考えられる。このようなヒューリスティクスがどのようにして獲得されるのかは、非常に重要な問題である。しかし、同時に非常に大きなテーマでもあるので、別のテーマとして研究を進め、ここではこのようなヒューリスティクスは与えられたものとする。このようなヒューリスティクスを獲得するメカニズムについては、さらに研究を進め別の機会に報告したい。

さらに、このようにして抽出されたセグメントから共通部分を抽出することにより、プリミティブな単位に分解することができる。表3にこの抽出されたセグメントからの共通部分の抽出によるプリミティブ抽出の例を示す。

表 3: セグメントからのプリミティブ抽出の例

セグメント１	$\alpha\ \theta\ \sigma$	$\Upsilon\ \Phi\ \Theta$
セグメント２	$\theta\ \sigma\ \gamma\ \mu$	$\Phi\ \Theta\ \Sigma$
プリミティブ１	α	Υ
プリミティブ２	$\theta\ \sigma$	$\Phi\ \Theta$
プリミティブ３	$\gamma\ \mu$	Σ

表 3に示したように、共通部分と差異部分を分離することにより三つのプリミティブを得ることができる。この三つのプリミティブを合成することにより元の二つのセグメントを得ることができるので、この三つのプリミティブがあれば、二つのセグメントは不要となる。このような抽出方法は、基本的には我々の仮定している「二つの事物が同じか異なるかを判断する能力」によって得られるものではあるが、その他にやはり上述したような出現順に対応関係があるというヒューリスティクスが使われている。我々は、このように実例より共通部分と差異部分を多段階に抽出することにより知識を獲得する手法は帰納的学習の一つである。

3 帰納的学習によるべた書き文のかな漢字変換手法

２章で述べたような立場に基づき、人間の言語獲得能力の、べた書き文のかな漢字変換における語の獲得への応用を行なった。本章では、その応用方法について述べる。

3.1 概 要

図 1に本手法の処理の流れを示す。図 1に示すように本手法は、変換処理、学習処理、フィードバック学習処理の三つの処理からなる。べた書き文が入力されるとそれまでの学習によって獲得された語によって語の当てはめが行なわれる。この際には、確実性の高い語より順に変換が行なわれる。確実性は、学習処理におけるその語の獲得状況および変換に使用された際の精度によって決定される。次に、学習処理を行なうが、この際に変換結果に誤りが存在する場合には、人手によって校正が行なわれる。このようにして得られた正しい漢字かな混じり文と入力されたべた書き文を用いて学習処理が行なわれる。学習処理は、二つの段階からなる。まず、第一段階では、入力べた書き文と校正済みの変換結果より共通部分を手掛りに語候補を得る。次に、第二段階ではこの語候補同士の共通部分と差異部分を抽出することにより語を獲得する。最後にフィードバック学習処理では、変換結果と校正された変換結果を比較することにより正変換に使用された語と誤変換に使用された語を決定し、正変換に使用された語の尤度を上げ、誤変換に使用された語の尤度を下げる。このことにより、次回からの変換精度の向上を計ることができる。

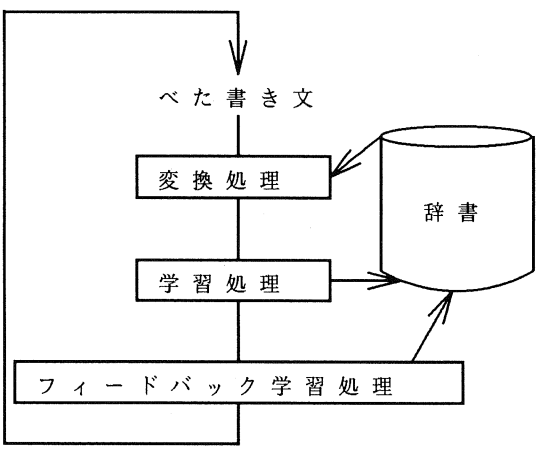


図 1: 処理の流れ

実際に行なわれる処理の流れは、図 1に示されるように変換処理、学習処理、フィードバック学習処理の順に行な

われるが、変換処理は確実性の高い語より多段階に順に変換が行なわれる。この確実性は、学習処理での語の獲得状況およびフィードバック学習処理での尤度の更新によって決定される。そこでまず、学習処理およびフィードバック学習処理について述べる。

3.2 学習処理

3.2.1 語候補の獲得

入力べた書き文と校正済みの変換結果を用いて語候補を獲得する。この方法は、2章で述べた人間の二つの未知文字列からの対応関係の獲得過程に対する考察に基づいている。この処理で抽出される語候補をS 1と表記し、Segment One と呼ぶ。語候補を獲得する手順は以下の通りである。

1. 入力べた書き文と校正済みの変換結果の共通部分を決定する。
2. 共通部分の間の差異部分を抽出する。
3. 出現順に従って差異部分の対応関係を決定する。
4. 共通部分と差異部分をS 1として抽出する。

表4に S1 抽出の例を示す。表4で入力べた書き文と校正済みの変換結果の共通部分は下線を引いた部分である。この部分の対応関係がまず決定される。すなわち、表4の3の右側の部分である。次に共通部分の間の差異部分を抽出する。その対応関係は出現順なので、表4の3の左側の部分のようなS 1を得る。このようにして、語候補S 1の表記と読みが獲得される。

表 4: 語候補の抽出例

1．入力べた書き文

われわれはしゅじゅのほうほうをおこなった。

2．校正済みの変換結果

我々は種々の方法を行なった。

3．語候補の獲得結果

差異部分	共通部分
(われわれ:我々)	(は:は)
(しゅじゅ:種々)	(の:の)
(ほうほう:方法)	(を:を)
(おこな:行な)	(った:った)

表4のように対応関係が一意に決定できる場合は問題ないが、漢字の読みの中に助詞と同じ読みが存在する場合には、対応関係が多対多になり、誤った対応関係が抽出されてしまう場合がある。この例を表5に示す。

表 5: 対応関係を誤る例

1．入力べた書き文

そのすんぽうはびさいかされつつある。

2．校正済みの変換結果

その寸法は微細化されつつある。

3．語候補の獲得結果

差異部分	共通部分
(すんぽう:寸法)	(その:その)
*(び:微細化)	(は:は)
*(いかさ:)	*(さ:さ)
	(れつつある:れつつある)

＊は誤りを示す。

表5は左から右方向へ解析を行なった結果である。このような誤ったS 1から3.2.2で述べる方法で生成される語は、変換の際に誤りを引き起こすので、4章で述べるフィードバック学習によってその尤度が下がり、次第に語としての確実性が下がるので、語の階層の下位へ下がり誤りは低下する。このような試行錯誤の過程は、人間の行なう処理に近いと考えられる。しかし、誤った語の尤度が下がるのは、徐々にであり、最初から誤った語が辞書中に存在しない方がシステムの変換精度が定常的に高くなるのは確かである。そこで、システムの効率を考え、ここでは双方向解析を導入する。これは、さらに右から左方向の解析を行ない、2つの方向の解析結果が一致しなければ語候補としないというものである。双方向解析はヒューリスティクスの一つで、このようなヒューリスティクスも当然何らかの方法で獲得されたものであるが、ここでは、2章で述べたように与えられるものとする。

表5を右から左方向に解析した例を表6に示す。実際には、表6の3の語候補の獲得結果には誤りは含まれてはいない。しかし、システムはこの段階では、左から右の解析結果と右から左の解析結果のどちらが正しいかを判断することはできないので、両者の解析結果の共通部分のみをS 1として決定する。したがって、両者で異なるS 1は、ここでは獲得されないが、曖昧さの生じない別の文脈で獲得されると考えられる。

3.2.2 語候補からの語の獲得

次に、語候補として抽出されたS1より、さらに共通部分と差異部分を抽出し、語を獲得する。これは、S 1が複数の語から構成される可能性があるため、S 1を単一の語

表 6: 右から左方向の解析結果の例

1．入力べた書き文
そのすんぽうはびさいかされつつある。
2．校正済みの変換結果
その寸法は微細化されつつある。

3．語候補の獲得結果	
差異部分	共通部分
(すんぽう:寸法) (びさいか:微細化)	(その:その) (は:は) (されつつある:されつつある)
4．採用される S1	
差異部分	共通部分
(すんぽう:寸法)	(その:その) (は:は)

に分解するために行なう処理である。この処理は、2章で述べたセグメントからのプリミティブの抽出に基づくものである。この時に抽出された共通部分を CS と表記し、Common Segment と呼ぶ。また、差異部分を RS と表記し、Remained Segment と呼ぶ。また、S 1 が CS、RS に分解された時、分解された S 1 は辞書中から削除する。表7に、語候補からの語の獲得の例を示す。

表 7: 語候補からの語の獲得の例

1．S1	(れんぞくおんせい：連続音声) (おんせい：音声)
2．CS	(おんせい：音声)
3．RS	(れんぞく：連続)

読みと表記が一致する条件を以下に示す。

1. 文字数による制限
   D = 読みの文字数 − 表記の文字数
   (a) $D = 0$ の場合 ： 表音文字を近似
   3 文字以上表記が一致する。
   (b) $D \neq 0$ の場合 ： 表意文字を近似
   2 文字以上の表記が一致する。
2. 重複の状況
   一方が他方を含む。

2 の条件は本処理が複数の語から構成される S 1 を一つの語から構成される S 1 に分解することを目的としているためである。

3.2.3 一字一音語の処理

上述したような処理を行なって語を抽出すると漢字とかなが一字づつ交互に出現する「取り引き」のような語は、(と:取)、(り:り)、(引:ひ)、(き:き) のように抽出される。このような一字一音語の連続する場合には、変換処理でも常に変換されない。これは、3.3 節で述べるように変換処理では、読みが一字の語は両側が確定済みの場合にしか当てはめないという条件のためである。このためこのように漢字とかなが一字づつ交互に出現する語は永遠に獲得されず、また当てはめられることもない。そこで、このように一字一音の語が連続する場合には一語にまとめるというヒューリスティクスを与える。

3.3 フィードバック学習処理

3.3.1 手 順

フィードバック学習では、変換結果および校正済みの変換結果より正しい変換に使われた語の尤度を上げ、誤変換に使用された語の尤度を下げる。以下にフィードバック学習処理の手順を示す。

1. 変換結果および校正済みの変換結果の共通部分と差異部分を決定する。
2. 共通部分を正変換とし、差異部分を誤変換とする。
3. 正変換に用いられた語の正変換度数を 1 増加させる。
4. 誤変換に用いられた語の誤変換度数を 1 増加させる。

3.3.2 尤度評価関数と頻度の更新方法

3.4.2 項で述べるように変換処理で複数の候補が重複した場合には、尤度評価関数 (PEF : Promising Evaluation Function) を用いて最適な候補を決定する。この尤度評価関数は、以下の式によって与えられる。

$$PEF = AF + \alpha \times CF - \beta \times EF \qquad (1)$$

ここで、AF は出現頻度 (Appearance Frequency), CF は正変換度数 (Frequency of Correct Translation), EF は誤変換度数 (Frequency of Erroneous Translation), α, β は係数である。

式 (1) で AF は、変換処理で語が使用された場合および学習処理で S 1 として抽出された時に増加する。S 1 が CS および RS に分解された時は CS の AF は CS を生成するために使用された S 1 の AF の和とし、RS の AF は RS を含んでいる S 1 の AF とする。また、正認識度数

CFについては、フィードバック学習処理で正変換と決定された変換に用いられた語のCFを1増加させる。また、誤認識度数EFについては、誤変換と決定された変換に用いられた語のEFを1増加する。

3.3.3 語の階層

3.2節で述べたように語はその獲得状況によって、S1、CS、RSの3つに階層化されている。さらに、本手法で用いる語は各語の正変換率によって2つの階層を追加し、計5階層に分類される。この内容は、正変換率が95%以上のものを最も確実性の高い語として辞書に登録する。このような語をMSと表記し、Most Certain Segmentと呼ぶ。また、各階層で正変換率が40%以下の語を最も確実性の低い語として辞書に登録する。このような語をLSと表記し、Less Certain Segmentと呼ぶ。LSは、使用の結果再度正変換率が40%を越えた場合には、元の階層に復帰する。正変換率(CR : Rate of Correct Translation)の定義式を以下に示す。

$$CR = \frac{CF}{CF + EF} \tag{2}$$

表8に各階層の獲得状況および正変換率による条件を示す。

表8: 語の階層の条件

Rank	条件	
	獲得状況	正変換率
MS	CSより	CR $\geq$ 95%
CS	S1の共通部分	40% $\leq$ CR $<$ 95%
S1	入力べた書き文と校正済み変換結果より	CR $\geq$ 40%
RS	S1の差異部分	CR $\geq$ 40%
LS	LS以外の各階層より	CR $<$ 40%

3.4 変換処理

3.4.1 手順

上述のようにして得られた語を用いて変換を行なう。変換処理は確実性の高いものより行なわれる。したがって、MS、CS、S1、RS、LSの順に変換が行なわれる。この際には、まず読みが2文字以上の語のみを対象として変換を行ない、確実性の低い、読みが一字の語については、2文字以上の語の処理終了後変換を行なう。この際には、両側が確定済みである場合についてのみ変換を行なう。

3.4.2 複数の変換候補からの最適な候補の決定方法

変換の際に同一箇所に複数の変換候補が出現する場合には、その中から最適な候補を決定しなければならない。最適な候補を決定する場合には、3.3.2項の式(1)に示す尤度評価関数PEFを用いる。この尤度評価関数が最大のものを選択するが、尤度評価関数の値が同一の場合には、以下の順に評価する。

1. 尤度評価関数の最大のもの。
2. 誤変換度数の最小のもの。
3. 正変換度数の最大のもの。
4. 出現頻度の最大のもの。
5. 一致した文字数の最大のもの。
6. 一致した位置が最も左のもの。
7. 辞書に登録されたのが最新のもの。

4 適応能力評価実験

4.1 実験手順

本手法に基づく実験システムを作成し、本手法の適応能力を評価するための実験を行なった。用いた資料は、情報工学、機械工学、応用化学工学、人文科学分野の論文各10編、計40編、259,187文字を用いて行なった。辞書は空の状態から始め、一文ごとに図2に示す処理を行なった。なお、本実験では式(1)の係数α,βはそれぞれ2、8に、式(2)における語の所属階層の更新を行なう時期をCFとEFの和が3以上として行なった。これらの値は、先に行なった実験の結果最適とされた値である[高橋 92]。

4.2 実験結果と考察

変換率の定義を以下に示す。

$$\text{正変換率} = \frac{\text{正変換文字数}}{\text{総文字数}} \tag{3}$$

$$\text{誤変換率} = \frac{\text{誤変換文字数}}{\text{総文字数}} \tag{4}$$

$$\text{未変換率} = \frac{\text{未変換文字数}}{\text{総文字数}} \tag{5}$$

ここで、正変換文字数とは正変換に使用された文字数と未変換で結果として正しかった文字数を含んでいる。ま

た、誤変換文字数とは誤って変換された文字数である。また、未変換文字数とは変換対象とならなかった部分で結果として誤った文字数である。

図２に各変換率の推移を示す。図２に示すように正変換率は辞書が空の状態から始めても 10,000 文字程度の学習で約９０％まで上昇している。また、図２の実線で示した各分野の変化点では一時的に正変換率は落ちるが、すぐに回復し、各分野の終りには約９５％程度の正変換率を示している。このことは、本手法の学習機能の有効性を示していると考えられる。また、情報工学、機械工学、応用化学工学と工学分野の論文を学習した後に人文科学という全く異なる分野の資料に対してもすぐに適応している。この場合には、逆に分野の変化による一時的な落ち込みが見られない。これは、辞書が十分に大きくなり分野の変化に対して適応が早くなったことと人文科学の最初の論文が比較的長い論文であったために、一文ごとの学習で最初の論文の終りまでにシステムがすでに適応してしまったためと考えられる。

図２のグラフで最初の情報工学分野の４番目の論文で正変換率の低下が見られるのは、この論文が日本語の表記をテーマとした論文であり、日本語の誤りが例として含まれているためである。しかし、論文４の中を章ごとに見ると次第に正変換率は上昇しているので、通常の解析型の静的な手法では変換が困難な資料もさらに同様の資料を学習することにより他の論文の正変換率と同程度にまで上昇するものと考えられる。

表 9に変換結果の例を示す。表 9の例は情報処理分野の１０編目の論文の一部なので、精度が約９５％と高く、誤りは３箇所のみである。これらの誤りの原因は、複数の変換候補が重複して出現した場合の最適な候補の決定を誤った結果である。本手法では、3.4 節で述べたように５つの階層に語を分類し、これらの階層の確実性の高いものより語を変換し、同一の階層中では式（１）に示す尤度評価関数により最適な候補を決定する。このような誤りは、本手法のように確実性を用いている限り避けられないものである。一方、人間の場合には、確率的情報を用いるのと同時に前後の意味的な文脈情報より正しい語を決定していると考えられる。したがって、今後はこの意味的な文脈情報を学習するメカニズムについての考察を進め、より一層の精度の向上を図る必要がある。このような文脈情報の導入は、変換精度の向上に寄与するばかりでなく、誤り方が人間の誤り方に近くなるので、誤りに対するユーザの不快感の軽減にもつながるものであり、この点での改善は非常に重要であると考えられる。

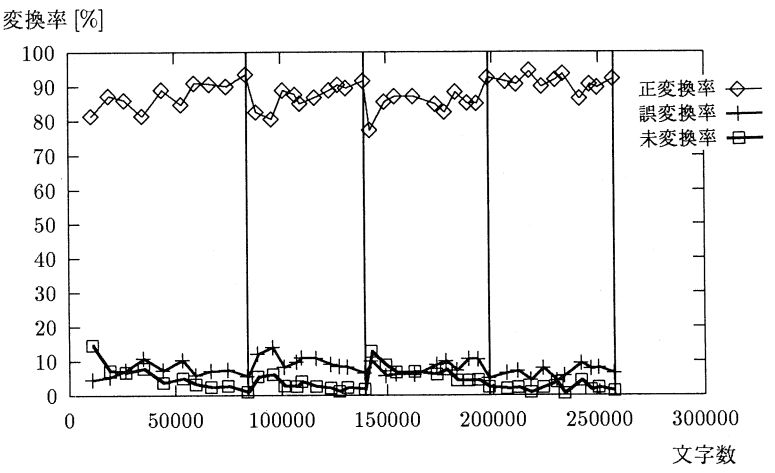


図 2: 変換率の推移

表 9: 変換結果の例

1．正しいテキスト ソフトウェアのテストを効率的かつ効果的に行うために、プログラム内の全分岐方向のテスト実行をめざす分岐テストに従来から用いられていた網ら率尺度は、品質が過大に評価されたり、冗長なテストケースが選択されやすいという欠点があった。
2．変換結果 [ソフトウェア]<の>[テスト]<を>[効率]+的+<かつ>(効果)+的+<に><行>[うため]<に>、[プログラム]<内><の>+全+[分岐](方向)<の>[テスト][実行]をめざす[分岐][テスト]<に><従来>(からも)+値+[いられ](ていた)<網><ら><率>[尺度]<は>、[品質]が か(第二)(評価)[されたり]、<冗長><な>[テスト]<ケース><が>[選択]<され>やすい[という]+け+<って>んが[あった]。

[ ] : MS, ( ) : CS, < > : S1, + + : RS, | | : LS

注) 変換結果で下線部は誤変換を示す。

5 おわりに

人間の言語および知識獲得過程を考察し、それに基づく語の獲得手法および確実性を用いたべた書き文のかな漢字変換手法を提案し、その学習機能による適応性能を評価するための実験を行なった。実験の結果、異なる４つの分野において９０%以上の精度が得られ、本手法のべた書き文かな漢字変換における適応性能の有効性が確認された。

今後は、さらに科学的立場から人間のヒューリスティクスの獲得メカニズム、文脈情報などの意味を獲得するメカニズムについての考察を進め、かな漢字変換はもとより機械翻訳システム、質問応答システムなどへの工学的な応用を計りたい。

また、学習によって言語および知識を獲得するのとは別に、人間の場合でも言語あるいは知識をメタ的に与えられることは日常的に起こっている。したがって、実例からの帰納的学習とメタ的な知識の教示との関わり合いについても考察を進める必要がある。

参考文献

[赤間 87] 赤間清：“未知言語環境における帰納的学習のモデル”, 情処学論、**28**, 5, pp.446-454(1987).

[赤間 88] 赤間清：“知識はいかに獲得されうるか”, 認知科学の発展、**Vol.1**, pp.161-188, 講談社、東京 (1988).

[錦見 91] 錦見美貴子、中島秀之、松原仁：“一般学習機構を用いた言語獲得の計算機モデル”, 認知科学の発展、**Vol.5**, pp.143-185, 講談社、東京 (1991).

[小林 92] 小林春美：“アフォーダンスが支える語彙獲得”, 月刊 言語、**Vol.21**, No.4, pp.37-45, 大修館書店、東京 (1992).

[Clark 77] Herbert H. Clark and Eve V. Clark : “Psychology and Language”, Harcourt Brace Jovanovich, Inc.(1977).

[荒木 92] 荒木健治、栃内香次：“帰納的学習による語の獲得および確実性を用いた語の認識”、信学論 $(D-II)$, **J75-D-II**,7,pp.1213-1221(1992-07).

[荒木 91] 荒木健治、栃内香次：“帰納的学習によるべた書き文のかな漢字変換”, 信学技法, **NLC91**-38, pp.9-16(1991).

[高橋 93] 高橋祐治、荒木健治、桃内佳雄：“帰納的学習によるべた書き文のかな漢字変換の有効性”, 情処研報, **NL93**-5, pp.31-38(1993).

[吉村 86] 吉村賢治、日高達、吉田将：“日本語科学技術文における専門用語の自動抽出システム”、情処学論、**27**, 1, pp.33-40(1986).

[吉村 89] 吉村賢治、武内美津乃、津田健蔵、首藤公昭：“未登録語を含む日本語文の形態素解析”, **30**, 3, pp.294-301(1989).

[高橋 92] 高橋祐治、荒木健治、桃内佳雄：“帰納的学習によるべた書き文のかな漢字変換における尤度の評価について”, 平成４北海道連大, pp.409-410(1992).